

Association Rule Mining berbasis Algoritma Apriori untuk Meningkatkan Penjualan Pengecer Skala Kecil

Arin Rosana D. (5002221010), Lintang Syawalani H.N. (5002221058), Novita Indah S. (5002221122)

Dosen Pengampu: Dr. Imam Mukhlas, S.Si, M.T.

Ringkasan—Industri ritel hadiah skala kecil menghadapi penurunan penjualan akibat pergeseran konsumen ke belanja daring, tekanan ekonomi, dan persaingan yang ketat, sehingga diperlukan pemanfaatan data transaksi untuk mendukung pengambilan keputusan berbasis data. Penelitian ini menerapkan *association rule mining* menggunakan algoritma Apriori pada data transaksi toko hadiah daring di Inggris. Setelah melalui tahapan pra-pemrosesan (filter negara, penghapusan nilai hilang, transaksi dibatalkan, item non-produk, dan transaksi produk tunggal), diperoleh 159.940 transaksi valid. Hasil *Exploratory Data Analysis* menunjukkan distribusi jumlah item per transaksi yang *right-skewed* dengan dominasi 1–12 item, serta lonjakan penjualan signifikan pada kuartal keempat menjelang Natal. Algoritma Apriori dengan *minimum support* 3% digunakan untuk mengekstraksi *frequent itemsets* dan membentuk aturan asosiasi berdasarkan *support*, *confidence*, dan *lift*. Ditemukan bahwa kategori *candlelight holder*, *bag*, dan *tableware* merupakan produk dengan frekuensi tinggi, sementara aturan dengan *lift* terbesar muncul pada pasangan “ROSES REGENCY TEACUP AND SAUCER” dan “GREEN REGENCY TEACUP AND SAUCER”, serta beberapa kombinasi *lunch bag*. Temuan ini memberikan dasar praktis bagi peritel hadiah skala kecil untuk menyusun strategi *bundling*, *cross-selling*, dan *up-selling*, mengoptimalkan tata letak produk, serta mengembangkan rekomendasi produk berbasis data tanpa membutuhkan sistem yang kompleks.

Kata Kunci—Market Basket Analysis, Association Rule Mining, Algoritma Apriori, Ritel Hadiah Skala Kecil, Sistem Rekomendasi.

I. LATAR BELAKANG

Industri ritel hadiah (gift retail) dalam beberapa tahun terakhir mengalami penurunan penjualan yang cukup signifikan, terutama pada skala usaha kecil. Perubahan perilaku konsumen yang semakin beralih ke belanja daring, kondisi ekonomi global, serta meningkatnya persaingan pasar membuat metode tradisional dalam pengelolaan produk dan strategi penjualan menjadi kurang efektif. Dalam situasi ini, pelaku usaha ritel dituntut untuk mampu beradaptasi dengan memanfaatkan pendekatan berbasis data guna mempertahankan daya saing dan meningkatkan peluang penjualan.

Seiring berkembangnya *e-commerce*, aktivitas konsumen dalam menjelajah, memilih, dan membeli produk meninggalkan jejak data digital yang sangat besar. Data transaksi tersebut sebenarnya menyimpan pola perilaku konsumen yang berharga, khususnya terkait hubungan antar produk yang sering dibeli secara bersamaan. Penjualan suatu produk sering kali memengaruhi penjualan produk lain yang berkait-

tan, sehingga kemampuan untuk mengidentifikasi keterkaitan tersebut menjadi faktor penting dalam optimalisasi strategi penjualan dan pengelolaan inventori. Namun, bagi peritel skala kecil, proses identifikasi asosiasi antarproduk secara manual merupakan pekerjaan yang sulit dan tidak efisien.

Untuk mengatasi permasalahan tersebut, sistem rekomendasi berbasis *data mining* mulai banyak diterapkan dalam domain penjualan daring. Sistem ini membantu konsumen dalam mengambil keputusan pembelian dengan memberikan rekomendasi produk yang relevan berdasarkan riwayat pembelian atau perilaku belanja sebelumnya. Berbeda dengan pendekatan konvensional seperti promosi dari mulut ke mulut atau ulasan pelanggan, sistem rekomendasi modern memanfaatkan analisis data transaksi untuk mengekstraksi pola tersembunyi yang mencerminkan preferensi pelanggan secara lebih akurat.

Salah satu teknik *data mining* yang banyak digunakan untuk menganalisis pola pembelian konsumen adalah *association rule mining*, khususnya dengan algoritma Apriori. Algoritma ini mampu mengidentifikasi frequent itemsets serta membentuk aturan asosiasi berdasarkan nilai *support*, *confidence*, dan *lift*. Dengan demikian, peritel dapat mengetahui kombinasi produk yang sering dibeli bersama dan memanfaatkannya untuk strategi *cross-selling* dan *up-selling*. Penelitian ini menunjukkan bahwa algoritma Apriori efektif diterapkan pada dataset transaksi ritel untuk menghasilkan rekomendasi produk yang relevan dan bernilai bisnis tinggi.

Berdasarkan permasalahan tersebut, penelitian ini bertujuan untuk memberikan wawasan dan solusi praktis bagi peritel hadiah daring skala kecil yang belum mengadopsi sistem rekomendasi. Dengan menerapkan algoritma Apriori pada data transaksi penjualan, diharapkan dapat diperoleh pola pembelian pelanggan yang berguna dalam meningkatkan efektivitas pengelolaan inventori, personalisasi rekomendasi produk, serta peningkatan penjualan dan kepuasan pelanggan secara keseluruhan.

II. TINJAUAN PUSTAKA

A. Small-Scale Retailer Sales

Ritel skala kecil memiliki peran penting dalam perekonomian, namun umumnya menghadapi keterbatasan dalam pemanfaatan teknologi dan analisis data untuk mendukung pengambilan keputusan bisnis. Banyak peritel skala kecil

masih mengandalkan intuisi dan pengalaman dalam menentukan strategi penjualan dan pengelolaan produk. Padahal, pendekatan tersebut kurang efektif dalam menghadapi persaingan pasar yang semakin dinamis dan berbasis data, khususnya di era digital saat ini

Industri ritel hadiah (gift retail) termasuk sektor yang sangat dipengaruhi oleh perubahan perilaku konsumen dan kondisi ekonomi. Produk hadiah bersifat musiman dan sangat bergantung pada tren serta momen tertentu, sehingga kesalahan dalam pengelolaan stok dapat berdampak langsung pada kerugian bisnis. Johnson dan Wilson (2017) menyatakan bahwa tanpa pemahaman yang baik terhadap pola pembelian konsumen, peritel hadiah akan kesulitan mempertahankan profitabilitas dan daya saing, terutama ketika menghadapi tekanan dari pasar global [1].

Pemanfaatan data transaksi penjualan melalui teknik data mining menjadi salah satu solusi yang efektif untuk memahami perilaku konsumen. Market Basket Analysis memungkinkan peritel mengidentifikasi keterkaitan antarproduk yang sering dibeli secara bersamaan, sehingga dapat digunakan sebagai dasar dalam menyusun strategi promosi dan penataan produk. Penelitian oleh Ünvan (2021) menunjukkan bahwa analisis aturan asosiasi mampu memberikan wawasan yang signifikan dalam mengoptimalkan strategi penjualan ritel [2].

Salah satu metode yang paling banyak digunakan dalam Market Basket Analysis adalah algoritma Apriori. Algoritma ini mampu mengekstraksi frequent itemsets dan aturan asosiasi berdasarkan nilai support dan confidence. Studi yang dilakukan oleh Qisman et al. (2021) pada ritel komputer menunjukkan bahwa algoritma Apriori efektif dalam mengidentifikasi pola pembelian pelanggan dan dapat digunakan sebagai dasar dalam pengembangan sistem rekomendasi produk untuk meningkatkan penjualan [3].

B. Data Mining dalam Bidang Ritel

Data mining merupakan proses penggalian informasi dan pola tersembunyi dari kumpulan data berukuran besar dengan menggunakan teknik statistik, matematika, dan kecerdasan buatan. Dalam konteks bisnis ritel, data mining digunakan untuk mengekstraksi pengetahuan dari data transaksi penjualan yang tersimpan dalam basis data perusahaan. Menurut Han, Kamber, dan Pei (2012), data mining memungkinkan organisasi untuk menemukan pola yang bermakna dan sebelumnya tidak diketahui, sehingga dapat dijadikan dasar dalam pengambilan keputusan strategis [4].

Dalam bidang ritel, data mining berperan penting sebagai alat pendukung pengambilan keputusan bisnis, khususnya dalam memahami perilaku dan preferensi konsumen. Dengan menganalisis data historis penjualan, peritel dapat mengidentifikasi produk yang paling diminati, pola pembelian pelanggan, serta hubungan antarproduk. Pendekatan ini membantu peritel dalam menyusun strategi pemasaran, perencanaan promosi, dan pengelolaan inventori secara lebih efektif dan berbasis data [5].

Salah satu bentuk pemanfaatan data mining yang paling umum dalam ritel adalah analisis data transaksi penjualan

melalui teknik Market Basket Analysis. Teknik ini bertujuan untuk mengetahui kombinasi produk yang sering dibeli secara bersamaan oleh konsumen. Hasil analisis tersebut dapat digunakan untuk meningkatkan strategi cross-selling dan up-selling, serta sebagai dasar pengembangan sistem rekomendasi produk. Penelitian oleh Ünvan (2021) menunjukkan bahwa penerapan data mining pada data transaksi ritel mampu memberikan wawasan yang signifikan dalam meningkatkan efisiensi penjualan dan pengambilan keputusan manajerial.

C. Market Based Analysis

Market Basket Analysis (MBA) merupakan salah satu teknik dalam data mining yang digunakan untuk menganalisis pola pembelian konsumen berdasarkan data transaksi penjualan. Teknik ini bertujuan untuk mengidentifikasi hubungan atau asosiasi antarproduk yang sering dibeli secara bersamaan dalam satu transaksi. Dengan mengetahui kombinasi produk tersebut, peritel dapat memahami perilaku belanja konsumen secara lebih mendalam dan memanfaatkan informasi tersebut untuk meningkatkan strategi pemasaran dan penjualan. Menurut Han, Kamber, dan Pei (2012), Market Basket Analysis menjadi metode yang efektif dalam mengekstraksi pola tersembunyi dari data transaksi berskala besar [4].

Dalam konteks bisnis ritel, Market Basket Analysis banyak digunakan untuk mendukung pengambilan keputusan, seperti penataan produk di rak, penyusunan paket promosi, serta strategi cross-selling dan up-selling. Analisis ini membantu peritel menentukan produk apa saja yang memiliki keterkaitan kuat sehingga dapat dipromosikan secara bersamaan. Ünvan (2021) menyatakan bahwa penerapan Market Basket Analysis mampu memberikan wawasan yang signifikan bagi peritel dalam mengoptimalkan strategi penjualan dan meningkatkan efisiensi operasional [2].

Selain itu, Market Basket Analysis sering diterapkan dengan pendekatan association rule mining, yang menghasilkan aturan berbentuk implikasi antaritem, seperti $X \rightarrow Y$. Aturan ini menunjukkan bahwa pembelian suatu produk memiliki kecenderungan diikuti oleh pembelian produk lain. Penelitian oleh Prawira et al. (2020) membuktikan bahwa penggunaan Market Basket Analysis berbasis aturan asosiasi dapat membantu peritel dalam mengelola stok dan menyusun pola penempatan produk yang lebih efektif, sehingga berpotensi meningkatkan penjualan dan kepuasan pelanggan [6].

D. Association Rule Mining

Association rule mining adalah teknik analisis data yang digunakan untuk menemukan pola hubungan atau asosiasi yang menarik antara item-item dalam kumpulan data transaksi yang besar. *Association rule* sering dinotasikan dalam bentuk ekspresi $X \rightarrow Y$ di mana X dan Y mewakili dua set produk yang berbeda. Terdapat beberapa metrik evaluasi yang terlibat dalam *association rule mining*, yaitu:

- **Support** – Merupakan ukuran persentase seberapa sering kombinasi item muncul dalam transaksi. Nilai ini me-

nunjukkan popularitas suatu *itemset* dan dapat diperoleh menggunakan formula berikut:

$$Support(X) = \frac{\text{Jumlah transaksi yang memuat } X}{\text{Total transaksi}} \quad (1)$$

- **Confidence** – Merupakan ukuran persentase kekuatan hubungan antara kombinasi item. Nilai ini menunjukkan seberapa sering aturan tersebut benar dan dapat diperoleh menggunakan formula berikut:

$$Confidence(X \rightarrow Y) = \frac{Support(X \cup Y)}{Support(X)} \quad (2)$$

- **Lift** – Merupakan ukuran yang membandingkan probabilitas kemunculan anteseden dan konsekuen bersamaan dengan probabilitas kemunculannya secara independen. Nilai *lift* lebih dari 1 menunjukkan adanya korelasi positif antara item, nilai sama dengan 1 menunjukkan independensi, dan nilai kurang dari 1 menunjukkan korelasi negatif. Formula *lift* adalah:

$$Lift(X \rightarrow Y) = \frac{Support(X \cup Y)}{Support(X) \times Support(Y)} \quad (3)$$

- **Conviction** – Merupakan ukuran yang menunjukkan seberapa kuat implikasi suatu aturan dengan mengukur seberapa sering konsekuen tidak muncul ketika anteseden muncul. Nilai *conviction* yang tinggi mengindikasikan bahwa aturan tersebut lebih dapat diandalkan. Formula *conviction* adalah:

$$Conviction(X \rightarrow Y) = \frac{1 - Support(Y)}{1 - Confidence(X \rightarrow Y)} \quad (4)$$

Sebagai contoh *association rule*:

Phone $\Rightarrow$ *Casing* [support = 2%, confidence = 70%, lift = 2.5, conviction = 2.33]

Aturan ini menunjukkan bahwa 2% dari seluruh transaksi mengandung *Phone* dan *Casing*, dan 70% pelanggan yang membeli *Phone* juga membeli *Casing*. Nilai *lift* sebesar 2.5 mengindikasikan bahwa kemungkinan membeli *Casing* meningkat 2.5 kali lipat ketika pelanggan membeli *Phone*, yang menunjukkan korelasi positif yang kuat antara kedua produk. Nilai *conviction* sebesar 2.33 menunjukkan bahwa aturan ini cukup dapat diandalkan, artinya jika aturan dilanggar (membeli *Phone* tanpa *Casing*), maka akan terjadi pelanggaran sebesar 2.33 kali lebih sering dari yang diharapkan secara acak. Pendekatan berbasis *association rule mining* ini menekankan transparansi dan kemampuan interpretasi dalam mengidentifikasi hubungan pembelian, yang sangat berguna untuk pengambilan keputusan bisnis [7].

E. Algoritma Apriori

Algoritma Apriori merupakan algoritma klasik dalam *association rule mining* yang digunakan untuk menemukan kombinasi item yang sering muncul bersama (*frequent itemsets*) dari data transaksi penjualan. Dalam konteks *Market Basket Analysis*, Apriori menghasilkan aturan berbentuk $X \rightarrow Y$ yang menunjukkan bahwa pembelian suatu produk memiliki

kecenderungan diikuti oleh pembelian produk lain. Kekuatan aturan diukur dengan *support* (proporsi kemunculan kombinasi item di seluruh transaksi), *confidence* (kemungkinan *Y* muncul ketika *X* dibeli), dan *lift* (tingkat peningkatan peluang *Y* ketika *X* hadir dibandingkan jika independen) [2] [3].

Secara garis besar, Apriori bekerja secara iteratif: algoritma terlebih dahulu mencari *frequent 1-itemset*, kemudian membentuk kandidat *2-itemset*, *3-itemset*, dan seterusnya hanya dari *itemset* yang memenuhi *minimum support*. Efisiensi dicapai melalui *Apriori property*, yaitu jika suatu *itemset frequent* maka seluruh subset-nya juga harus *frequent*, sehingga kandidat yang memiliki subset tidak *frequent* dapat dipangkas sejak awal (*pruning*). Berbagai penelitian menunjukkan bahwa Apriori efektif dan masih kompetitif dibanding algoritma lain seperti *FP-Growth*, *Eclat*, dan *PrefixSpan* untuk dataset kecil hingga menengah, serta banyak dimanfaatkan dalam studi ritel untuk analisis pola pembelian, penataan rak, dan strategi *bundling* produk [6] [8] [9].

Dalam penelitian ini, algoritma Apriori digunakan untuk menganalisis data transaksi ritel skala kecil dan menghasilkan aturan asosiasi yang dapat dimanfaatkan sebagai dasar penyusunan rekomendasi produk dan strategi peningkatan penjualan.

III. ARSITEKTUR SISTEM DAN METODE

A. Dataset

Dataset yang digunakan dalam penelitian ini merupakan data transaksi penjualan ritel daring yang merepresentasikan aktivitas pembelian pelanggan dalam suatu periode tertentu. Dataset ini berisi catatan transaksi yang mencakup informasi terkait produk, pelanggan, waktu transaksi, serta nilai penjualan. Data transaksi tersebut digunakan sebagai dasar untuk melakukan analisis pola pembelian konsumen menggunakan teknik *association rule mining*.

TABEL I
FITUR DATASET

Atribut	Deskripsi
InvoiceNo	ID transaksi unik 6 digit. Transaksi dianggap dibatalkan jika diawali dengan huruf "C".
StockCode	Kode unik 5 digit yang diberikan pada setiap produk.
Description	Deskripsi dari produk.
Quantity	Jumlah produk yang terjual dalam setiap transaksi.
InvoiceDate	Tanggal dan waktu penerbitan faktur.
UnitPrice	Harga satuan dari produk.
CustomerID	ID pelanggan unik 5 digit yang diberikan kepada setiap pelanggan.
Country	Negara tempat tinggal pelanggan.

Setiap baris data merepresentasikan satu transaksi pembelian yang diidentifikasi secara unik melalui atribut *InvoiceNo*. Atribut ini merupakan kode transaksi enam digit, di mana transaksi yang diawali dengan huruf "C" menunjukkan transaksi yang dibatalkan oleh pelanggan. Informasi ini penting dalam proses data preprocessing untuk memastikan bahwa hanya transaksi valid yang digunakan dalam analisis.

Atribut *StockCode* dan *Description* digunakan untuk mengidentifikasi produk yang terlibat dalam setiap transaksi. *Stock-*

Code merupakan kode unik lima digit yang diberikan pada setiap produk, sedangkan Description berisi deskripsi atau nama produk. Kedua atribut ini berperan penting dalam proses pembentukan itemsets pada analisis Market Basket Analysis.

Jumlah produk yang dibeli dalam setiap transaksi dicatat pada atribut Quantity, sementara waktu terjadinya transaksi direkam melalui atribut InvoiceDate yang berisi informasi tanggal dan jam penerbitan faktur. Informasi waktu ini memungkinkan analisis lebih lanjut terkait pola pembelian berdasarkan periode tertentu, seperti bulanan atau musiman.

Nilai harga satuan produk direpresentasikan oleh atribut UnitPrice, yang menunjukkan harga per unit barang pada saat transaksi dilakukan. Selain itu, atribut CustomerID digunakan untuk mengidentifikasi pelanggan secara unik, sehingga memungkinkan analisis perilaku pembelian pelanggan berdasarkan riwayat transaksi. Atribut Country menunjukkan negara tempat tinggal pelanggan, yang dapat digunakan untuk analisis segmentasi geografis.

Secara keseluruhan, dataset ini memiliki struktur yang komprehensif dan relevan untuk analisis pola pembelian konsumen. Kombinasi atribut produk, pelanggan, dan transaksi menjadikan dataset ini sesuai untuk diterapkan pada algoritma Apriori dalam menemukan frequent itemsets dan aturan asosiasi guna mendukung pengambilan keputusan bisnis di sektor ritel.

B. Pra-Pemrosesan Data

Sebelum dilakukan analisis lebih lanjut, tahapan pra-pemrosesan data dilakukan untuk memastikan kualitas dan konsistensi data. Beberapa permasalahan ditemukan pada dataset, antara lain: adanya nilai hilang (*null values*), data duplikat, transaksi yang dibatalkan, item non-produk, serta transaksi yang hanya memuat satu produk. Mengingat fokus penelitian ini adalah untuk menganalisis produk-produk yang dibeli secara bersamaan, maka tahapan pembersihan data menjadi sangat penting. Proses pra-pemrosesan dilakukan secara bertahap sebagai berikut:

- 1) **Filtering berdasarkan negara:** Hanya transaksi dari *United Kingdom* yang dipertahankan untuk menjaga konsistensi analisis, menghasilkan pengurangan sekitar 46.000 transaksi.
- 2) **Penanganan nilai hilang:** Transaksi dengan nilai *null* pada atribut *Description* dan *CustomerID* dihapus dari dataset. Terdapat 1.454 transaksi dengan nilai *null* pada atribut *Description* dan 133.600 nilai *null* pada atribut *CustomerID*.
- 3) **Penghapusan transaksi yang dibatalkan:** Transaksi dengan *InvoiceNo* yang diawali huruf 'C' merupakan indikasi pembatalan pesanan, sehingga dihapus dari dataset (sekitar 9.000 transaksi).
- 4) **Filtering nilai harga dan kuantitas:** Transaksi dengan nilai *UnitPrice* dan *Quantity* yang bernilai nol atau negatif dihapus karena tidak mencerminkan transaksi penjualan yang valid (sekitar 5.000 transaksi).

- 5) **Pembuatan variabel Sales:** Variabel baru bernama 'Sales' dibuat dengan mengalikan *UnitPrice* dan *Quantity* untuk setiap produk dalam transaksi.
- 6) **Penghapusan item non-produk:** Item-item seperti POSTAGE, FEE, DISCOUNT, dan sejenisnya yang bukan merupakan produk fisik dihapus dari dataset (sekitar 180.000 entri).
- 7) **Penghapusan transaksi produk tunggal:** Mengingat tujuan penelitian adalah menganalisis produk yang dibeli secara bersamaan, transaksi yang hanya memuat satu produk dihapus dari dataset (sekitar 5.000 transaksi).

Setelah melalui seluruh tahapan pra-pemrosesan, dataset akhir yang digunakan untuk analisis terdiri dari 159.940 transaksi.

C. Exploratory Data Analysis (EDA)


Analisis terhadap distribusi jumlah item per transaksi menunjukkan pola *right-skewed distribution* dengan rentang terbanyaknya adalah 1-12 item per transaksi, seperti yang ditunjukkan pada Gambar 1. Distribusi ini mengindikasikan bahwa sebagian besar pelanggan cenderung membeli beberapa produk dalam satu transaksi, yang memungkinkan identifikasi kombinasi produk yang sering dibeli bersamaan. Pola distribusi ini sangat relevan dengan tujuan penelitian, yaitu menemukan asosiasi antar produk melalui algoritma Apriori.



Gambar 1. Distribusi jumlah item per transaksi

Analisis temporal terhadap data penjualan mengungkapkan pola musiman yang signifikan. Seperti yang ditunjukkan pada Gambar 2, tren penjualan menunjukkan lonjakan tajam pada kuartal keempat (Q4), khususnya mulai dari bulan November. Peningkatan penjualan ini kemungkinan disebabkan oleh faktor musiman, terutama mendekati periode Natal yang merupakan momen pemberian hadiah. Lonjakan penjualan pada periode Q4 mencapai sekitar 98% dibandingkan dengan periode sebelumnya.

Temuan ini memiliki implikasi strategis penting bagi pengelola ritel, khususnya dalam perencanaan inventori dan strategi pemasaran. Pola musiman ini dapat dimanfaatkan untuk mengoptimalkan strategi *bundling* produk dan rekomendasi produk yang lebih efektif pada periode penjualan puncak. Hasil EDA ini memberikan pemahaman mendasar tentang perilaku pembelian pelanggan dan menjadi landasan untuk tahapan analisis selanjutnya menggunakan algoritma Apriori dalam mengidentifikasi *association rules* antar produk.



Gambar 2. Tren penjualan bulanan

D. Algoritma Apriori


Algoritma Apriori digunakan dalam penelitian ini untuk melakukan *association rule mining*, yaitu menggali pola keterkaitan antar produk yang sering dibeli secara bersamaan. Algoritma ini bekerja dengan terlebih dahulu mencari himpunan item yang sering muncul bersama dalam transaksi (*frequent itemset*), kemudian membentuk aturan asosiasi dalam bentuk implikasi $X \rightarrow Y$, di mana X dan Y merupakan himpunan produk. Aturan tersebut dapat diinterpretasikan sebagai: jika pelanggan membeli X , maka terdapat kecenderungan pelanggan juga membeli Y .

Dalam konteks ini, kualitas aturan asosiasi diukur menggunakan tiga metrik utama, yaitu *support*, *confidence*, dan *lift*. *Support* menyatakan proporsi transaksi yang mengandung kombinasi item tertentu terhadap seluruh transaksi. *Confidence* mengukur kekuatan hubungan aturan $X \rightarrow Y$, yakni persentase transaksi yang mengandung Y di antara transaksi yang mengandung X . Sementara itu, *lift* membandingkan *confidence* aturan dengan kemungkinan kemunculan Y secara umum; nilai *lift* lebih besar dari 1 menunjukkan bahwa kehadiran X meningkatkan peluang kemunculan Y , sehingga keduanya memiliki asosiasi positif. Dalam penelitian ini, hanya aturan dengan nilai *lift* > 1 yang dipertahankan untuk memastikan bahwa hubungan antar produk yang dihasilkan benar-benar bersifat saling menguatkan.

Secara prinsip, Algoritma Apriori bekerja secara iteratif berdasarkan ukuran panjang *itemset*. Pada iterasi pertama, algoritma membentuk kandidat *1-itemset* dari seluruh produk yang ada di dalam dataset, kemudian menghitung nilai *support* masing-masing item dan menyaring item yang *support*-nya memenuhi ambang *minimum support* yang ditetapkan. Himpunan ini disebut *frequent 1-itemset*. Pada iterasi berikutnya, *frequent (k-1)-itemset* digabungkan untuk membentuk kandidat *k-itemset*, kemudian kembali dilakukan perhitungan *support* dan penyaringan berdasarkan *minimum support*. Proses ini diulang dengan menaikkan nilai k hingga tidak ada lagi *frequent k-itemset* yang ditemukan.

Efisiensi algoritma dijaga melalui pemanfaatan *Apriori property*, yaitu: jika suatu *itemset* bersifat *frequent*, maka seluruh subset-nya juga harus *frequent*. Berdasarkan prinsip ini, kandidat *k-itemset* yang memiliki subset tidak *frequent* dapat dieliminasi sejak awal melalui proses *pruning*, sehingga jumlah kandidat yang perlu diuji ke seluruh transaksi menjadi

jauh lebih sedikit. Alur yang menunjukkan tahapan mulai dari pembentukan kandidat *k-itemset*, pemeriksaan keberadaan *frequent itemset*, proses *pruning*, hingga diperolehnya himpunan item *frequent* yang benar-benar ditunjukkan pada Gambar 5.



Gambar 3. Tahapan Algoritma Apriori

Pada penelitian ini, setelah tahapan pra-pemrosesan selesai, data transaksi yang sudah bersih terlebih dahulu diubah menjadi *transaction basket matrix*, dengan mengelompokkan data berdasarkan *InvoiceNo* dan *Description*. Untuk setiap kombinasi *invoice*–produk dihitung total kuantitas yang dibeli, kemudian dikonversi menjadi bentuk biner (1 jika produk muncul dalam transaksi, 0 jika tidak). Matriks biner ini menjadi masukan utama bagi fungsi Apriori dalam pustaka Python yang digunakan.


Nilai *minimum support* ditetapkan sebesar 0,03 (3%), sesuai dengan konfigurasi pada jurnal, sehingga hanya kombinasi produk yang muncul pada sedikitnya 3% dari seluruh transaksi yang dipertahankan sebagai *frequent itemset*. Dari *frequent itemset* tersebut, aturan asosiasi $X \rightarrow Y$ kemudian dibentuk dan dievaluasi berdasarkan *support*, *confidence*, dan *lift*. Aturan-aturan dengan nilai *lift* tertinggi dipandang sebagai pola pembelian yang paling kuat, misalnya hubungan antara produk *teacup and saucer* dan berbagai jenis *lunch bag* yang dilaporkan sangat sering dibeli secara bersamaan dalam jurnal.

Dengan demikian, Algoritma Apriori pada penelitian ini berperan sebagai inti dari tahapan analisis, yang menghubungkan hasil EDA dengan tujuan utama penelitian, yaitu mengidentifikasi kombinasi produk yang sering dibeli bersama dan menyusunnya menjadi aturan asosiasi yang dapat dimanfaatkan untuk strategi *bundling*, rekomendasi produk, dan optimasi manajemen inventori pada ritel daring skala kecil.

IV. HASIL

Pada tahap awal analisis, dilakukan identifikasi *frequent itemsets* untuk mengetahui produk-produk yang paling sering muncul dalam transaksi penjualan. Analisis ini bertujuan untuk memberikan gambaran umum mengenai pola pembelian konsumen berdasarkan tingkat kemunculan produk dalam keseluruhan data transaksi. Nilai *support* digunakan sebagai parameter utama untuk menentukan tingkat frekuensi kemunculan suatu produk, sehingga produk dengan nilai *support* tinggi dapat diidentifikasi sebagai produk yang memiliki kontribusi signifikan terhadap aktivitas penjualan. Hasil analisis *frequent*

itemsets ini selanjutnya disajikan dalam bentuk grafik Top 10 Frequent Items untuk memudahkan interpretasi.



Gambar 4. Top 10 Frequent Items

Gambar 4 menampilkan hasil Top 10 Frequent Items berdasarkan nilai support yang diperoleh dari data transaksi penjualan. Produk WHITE HANGING HEART T-LIGHT HOLDER memiliki nilai support tertinggi sebesar 0,121492, yang menunjukkan bahwa produk tersebut muncul pada sekitar 12,15 persen dari seluruh transaksi dan merupakan produk yang paling sering dibeli oleh konsumen. Produk lain seperti JUMBO BAG RED RETROSPOT dan REGENCY CAKE-STAND 3 TIER juga memiliki nilai support yang relatif tinggi, masing-masing sebesar 0,093235 dan 0,090566, sehingga dapat dikategorikan sebagai produk populer dengan tingkat permintaan yang signifikan. Selain itu, beberapa produk seperti LUNCH BAG RED RETROSPOT dan LUNCH BAG BLACK SKULL turut muncul dalam daftar ini, yang mengindikasikan bahwa kategori tas makan siang merupakan salah satu kelompok produk yang cukup diminati. Hasil frequent itemsets ini memberikan gambaran awal mengenai produk-produk unggulan yang berpotensi menjadi fokus strategi penjualan dan pengelolaan inventori. Selanjutnya, berdasarkan frequent itemsets yang telah diperoleh, algoritma Apriori menghasilkan sejumlah aturan asosiasi yang ditunjukkan pada Gambar 5.

Antecedents	Consequents	Support	Confidence	Lift	Conviction
ROSES REGENCY TEACUP AND SAUCER	GREEN REGENCY TEACUP AND SAUCER	0,030992	0,705185	17,69761	3,256803
GREEN REGENCY TEACUP AND SAUCER	ROSES REGENCY TEACUP AND SAUCER	0,030992	0,777778	17,69761	4,302233
LUNCH BAG PINK POLKADOT	LUNCH BAG RED RETROSPOT	0,030666	0,55608	7,625747	2,088392
LUNCH BAG RED RETROSPOT	LUNCH BAG PINK POLKADOT	0,030666	0,420536	7,625747	1,630563
JUMBO BAG PINK POLKADOT	JUMBO BAG RED RETROSPOT	0,032945	0,624691	6,700164	2,416051
JUMBO BAG RED RETROSPOT	JUMBO BAG PINK POLKADOT	0,032945	0,353352	6,700164	1,464881
LUNCH BAG BLACK SKULL	LUNCH BAG RED RETROSPOT	0,031512	0,486922	6,677346	1,806894

Gambar 5. Hasil Algoritma Apriori

Berdasarkan hasil yang diperoleh, aturan asosiasi dengan nilai lift tertinggi ditemukan pada kombinasi produk ROSES

REGENCY TEACUP AND SAUCER dan GREEN REGENCY TEACUP AND SAUCER, dengan nilai lift sebesar 17,69761. Nilai tersebut menunjukkan bahwa kedua produk memiliki hubungan yang sangat kuat dan cenderung dibeli secara bersamaan oleh konsumen. Hal ini juga didukung oleh nilai confidence yang tinggi, yaitu 0,705185 dan 0,777778, yang mengindikasikan bahwa peluang terjadinya pembelian bersama kedua produk tersebut cukup besar. Selain itu, kombinasi produk LUNCH BAG PINK POLKADOT dan LUNCH BAG RED RETROSPOT juga menunjukkan hubungan yang kuat dengan nilai lift sebesar 7,625747, yang menandakan adanya kecenderungan konsumen untuk membeli produk dengan jenis yang sama namun memiliki variasi warna atau motif yang berbeda.

V. DISKUSI DAN KESIMPULAN

Penelitian ini berhasil mengidentifikasi 10 produk yang paling sering dibeli secara bersamaan menggunakan algoritma Apriori dengan minimum support 3%. Produk dengan nilai support tertinggi adalah *candlelight holder* (12,49%), diikuti oleh kategori *bag* dan *tableware*. Temuan ini menunjukkan bahwa pelanggan toko ritel hadiah cenderung membeli produk dekoratif dan peralatan rumah tangga dalam satu transaksi yang sama. Adapun *association rules* dengan lift tertinggi ditemukan pada pasangan “ROSES REGENCY TEACUP AND SAUCER” dan “GREEN REGENCY TEACUP AND SAUCER” (*lift* = 17,69; *confidence* = 70–77%). Nilai lift yang tinggi ini mengindikasikan bahwa pembelian salah satu produk sangat berpengaruh terhadap pembelian produk pasangannya. Sehingga dapat dimanfaatkan untuk mengatur tata letak produk di toko maupun dalam katalog, sehingga memudahkan pelanggan menemukan produk terkait dan meningkatkan potensi pembelian tambahan.

Distribusi jumlah item per transaksi menunjukkan pola *right-skewed* dengan rentang ter-banyaknya adalah 1-12 item per transaksi, yang mengindikasikan bahwa pelanggan cenderung membeli beberapa item sekaligus dalam satu pembelian dengan jumlah yang tidak terlalu banyak. Pola ini memperkuat relevansi penggunaan algoritma Apriori untuk menemukan kombinasi produk yang sering dibeli bersamaan. Analisis temporal memperlihatkan adanya lonjakan penjualan hingga 98% pada kuartal keempat, terutama bulan November menjelang Natal. Pola musiman seperti ini membuka peluang bagi pengelola ritel untuk menerapkan strategi *bundling* dan promosi produk yang lebih tepat sasaran pada periode tersebut.

Hasil penelitian ini memberikan panduan praktis bagi ritel hadiah skala kecil yang belum memiliki sistem rekomendasi otomatis. Dengan memanfaatkan *association rules*, pengelola dapat menyusun paket bundel produk, memberikan rekomendasi yang relevan, dan mengoptimalkan stok barang berdasarkan keterkaitan antar produk. Strategi *cross-selling* dan *up-selling* menjadi lebih terarah ketika ada data konkret tentang produk mana yang biasa dibeli bersama, seperti pasangan *teacup* yang memiliki korelasi sangat kuat.

Secara keseluruhan, algoritma Apriori terbukti mampu mengungkap pola pembelian tersembunyi dari data transaksi ritel.

Temuan-temuan ini tidak hanya berguna untuk meningkatkan penjualan, tetapi juga untuk memperbaiki pengalaman berbelanja pelanggan melalui rekomendasi yang lebih personal dan relevan. Penerapan teknik *data mining* semacam ini menjadi solusi yang efisien bagi pelaku usaha yang ingin bersaing di pasar retail tanpa harus berinvestasi besar dalam sistem teknologi yang kompleks.

VI. WAKTU KOMPUTASI

Didapatkan waktu komputasi untuk menyelesaikan permasalahan peningkatan penjualan dengan menggunakan algoritma Apriori selama 21.507 detik.

DAFTAR PUSTAKA

- [1] R. Johnson and J. Wilson, "The impact of economic recession on gift retailing: A comparative study of the uk and us markets," *International Journal of Retail and Distribution Management*, vol. 45, no. 8, pp. 807–823, 2017.
- [2] Y. A. Ünvan, "Market basket analysis with association rules," *Communications in Statistics - Theory and Methods*, vol. 50, no. 7, pp. 1615–1628, 2021.
- [3] M. Qisman, R. Rosadi, and A. S. Abdullah, "Market basket analysis using apriori algorithm to find consumer patterns in buying goods through transaction data," in *Journal of Physics: Conference Series*, vol. 1722, no. 1. IOP Publishing, 2021, p. 012020.
- [4] J. Han, M. Kamber, and J. Pei, *Data Mining: Concepts and Techniques*, 3rd ed. Morgan Kaufmann, 2012.
- [5] M. J. A. Berry and G. S. Linoff, *Data Mining Techniques: For Marketing, Sales, and Customer Relationship Management*, 2nd ed. Wiley, 2011.
- [6] T. Y. Prawira, S. Sunardi, and A. Fadlil, "Market basket analysis to identify stock handling patterns using apriori algorithm," *Khazanah Informatika: Jurnal Ilmu Komputer dan Informatika*, vol. 6, no. 1, pp. 33–41, 2020.
- [7] W. Prasetyo and A. Rahman, "Interpretable product recommendation using apriori-based association rule mining," *International Journal of Informatics and Information Systems*, vol. 8, no. 2, pp. 67–74, March 2025.
- [8] K. Venkatachari and I. D. Chandrasekaran, "Market basket analysis using fp growth and apriori algorithm: a case study of mumbai retail store," *BVIMSR's Journal of Management Research*, vol. 8, no. 1, p. 56, 2016.
- [9] H. Zhao, L. Xie, and X. Dong, "A comparison of frequent itemset mining algorithms on different datasets," *Applied Sciences*, vol. 10, no. 10, p. 3616, 2020.