

KERJA PRAKTIK - SM234701

**PERAMALAN TINGKAT KEMISKINAN DI KOTA
SURAKARTA TAHUN 2025 MENGGUNAKAN
MODEL REGRESI LINEAR DERET WAKTU**

LINTANG SYAWALANI HAWA NINGRUM

NRP 5002221058

Dosen Pembimbing

Alvida Mustika Rukmi, S.Si,M.Si

NIP 19720715 199802 2 001

Program Studi S-1

Departemen Matematika

Fakultas Sains dan Analitika Data

Institut Teknologi Sepuluh Nopember

Surabaya

2025



KERJA PRAKTIK - SM234701

**PERAMALAN TINGKAT KEMISKINAN DI KOTA
SURAKARTA TAHUN 2025 MENGGUNAKAN
MODEL REGRESI LINEAR DERET WAKTU**

LINTANG SYAWALANI HAWA NINGRUM

NRP 5002221058

Dosen Pembimbing

Alvida Mustika Rukmi, S.Si,M.Si

NIP 19720715 199802 2 001

Program Studi S-1

Departemen Matematika

Fakultas Sains dan Analitika Data

Institut Teknologi Sepuluh Nopember

Surabaya

2025



PRACTICAL WORK - SM234701

**FORECASTING THE POVERTY RATE IN
SURAKARTA CITY FOR 2025 USING A TIME
SERIES LINEAR REGRESSION MODEL**

LINTANG SYAWALANI HAWA NINGRUM

NRP 5002221058

Advisors

Alvida Mustika Rukmi, S.Si,M.Si

NIP 19720715 199802 2 001

Study Program S-1

Departement of Mathematics

Faculty of Scientics

Institut Teknologi Sepuluh Nopember

Surabaya

2025

LEMBAR PENGESAHAN DEPARTEMEN

LAPORAN KERJA PRAKTIK DI BADAN PUSAT STATISTIK KOTA SURAKARTA

Diajukan untuk memenuhi salah satu syarat mata kuliah Kerja
Praktik
Program Studi S-1 Matematika Departemen Matematika
Fakultas Sains dan Analitika Data
Institut Teknologi Sepuluh Nopember
Oleh

LINTANG SYAWALANI HAWA NINGRUM
5002221058

Telah diperiksa dan disetujui sebagai Laporan Kerja Praktik pada
Surabaya, 21 November 2025

Mengetahui,
Kepala Departemen Matematika
FSAD-ITS

Menyetujui,
Dosen Pembimbing

Dr. Didik Khusnul Arif, S.Si, M.Si. Alvida Mustika Rukmi, S.Si, M.Si

NIP. 19730930 199702 1 001

NIP. 19720715 199802 2 001

LEMBAR PENGESAHAN INSTANSI

LAPORAN KERJA PRAKTIK DI BADAN PUSAT STATISTIK KOTA SURAKARTA

Diajukan untuk memenuhi salah satu syarat mata kuliah Kerja
Praktik
Program Studi S-1 Matematika Departemen Matematika
Fakultas Sains dan Analitika Data
Institut Teknologi Sepuluh Nopember
Oleh

LINTANG SYAWALANI HAWA NINGRUM
5002221058

Telah diperiksa dan disetujui sebagai Laporan Kerja Praktik pada
Surakarta, 17 November 2025

Menyetujui,
Pembimbing Lapangan

Istanti, S.Si, M.Ec.Dev

PERNYATAAN ORISINALITAS

Dengan ini, saya

Nama : Lintang Syawalani Hawa Ningrum
NRP : 5002221058
Departemen : Matematika
Fakultas : Sains dan Analitika Data
Alamat : Asrama Mahasiswa ITS

Menyatakan dengan sesungguhnya bahwa laporan kerja praktik dengan judul “PERAMALAN TINGKAT KEMISKINAN DI KOTA SURAKARTA TAHUN 2025 MENGGUNAKAN MODEL REGRESI LINEAR DERET WAKTU” hasil karya pribadi saya yang tidak mengandung plagiarisme, kecuali kutipan yang telah disebutkan sumbernya sesuai dengan ketentuan yang dibenarkan secara ilmiah.

Apabila pernyataan ini tidak benar, maka penulis siap bertanggung jawab sesuai hukum yang berlaku dan ketentuan di Institut Teknologi Sepuluh Nopember.

Surabaya, 21 November 2025

Penulis,

LINTANG SYAWALANI HAWA NINGRUM

5002221058

KATA PENGANTAR

Puji syukur ke hadirat Allah SWT atas limpahan rahmat dan karunia-Nya sehingga penulis dapat menyelesaikan Laporan Kerja Praktik berjudul **"PERAMALAN TINGKAT KEMISKINAN DI KOTA SURAKARTA TAHUN 2025 MENGGUNAKAN MODEL REGRESI LINEAR DERET WAKTU"**. Laporan ini disusun untuk memenuhi salah satu persyaratan mata kuliah Kerja Praktik di Departemen Matematika FSAD ITS serta diharapkan dapat memberi manfaat bagi penulis dan pembaca. Penyusunan laporan ini tidak akan terselesaikan tanpa dukungan banyak pihak. Oleh karena itu, dengan penuh hormat penulis menyampaikan terima kasih kepada:

1. Bapak Dr. Didik Khusnul Arif, S.Si, M.Si, selaku Kepala Departemen Matematika FSAD ITS yang membantu dan memudahkan administrasi penulis dalam penyusunan laporan Kerja Praktik.
2. Ibu Alvida Mustika Rukmi, S.Si, M.Si selaku dosen pembimbing yang telah memberikan masukan dan arahan dalam penyusunan laporan Kerja Praktik dengan baik.
3. BPS Kota Surakarta yang telah memberikan kesempatan kepada penulis untuk melaksanakan kerja praktik
4. Ibu Istanti, S. Si, M.Ec.Dev selaku pembimbing lapangan yang sudah memberikan kesempatan kepada penulis untuk melaksanakan Kerja Praktik.

5. Seluruh pegawai Badan Pusat Statistik Kota Surakarta, khususnya di Divisi Neraca Sistem Akuntabilitas Kinerja Instansi Pemerintah (SAKIP) dan Reformasi Birokrasi (RB) yang tidak bisa saya sebutkan satu per satu, yang bersedia membagi pengalaman dan informasi serta banyak membantu penulis selama masa kerja praktik.
6. Seluruh pegawai Badan Pusat Statistik Kota Surakarta yang telah memberikan ilmu, wawasan, serta pengalaman baru bagi penulis.
7. Orang tua penulis yang selalu mendukung dan memberikan doa kepada penulis dalam kerja praktik dan mengerjakan laporan.
8. Semua pihak yang telah membantu penulis dalam melaksanakan Kerja Praktik dan menyusun laporan ini yang tidak dapat disebutkan satu-satu.

Penulis sepenuhnya menyadari bahwa masih terdapat kekurangan sehingga kritik dan saran yang membangun dari semua pihak demi perbaikan lebih lanjut akan sangat diterima. Semoga laporan kerja praktik ini dapat bermanfaat bagi penulis dan pembaca.

Surabaya, 21 November 2025

Penulis

DAFTAR ISI

LEMBAR PENGESAHAN DEPARTEMEN	i
LEMBAR PENGESAHAN INSTANSI	iii
PERNYATAAN ORISINALITAS	v
KATA PENGANTAR	vii
DAFTAR ISI	ix
DAFTAR GAMBAR	xiii
DAFTAR TABEL	xv
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Tujuan Kerja Praktik	3
1.2.1 Tujuan Umum	3
1.2.2 Tujuan Khusus	4
1.3 Manfaat	4
1.3.1 Manfaat Bagi Instansi	4
1.3.2 Manfaat Bagi Mahasiswa	4
BAB II GAMBARAN UMUM INSTANSI	7
2.1 Sejarah Badan Pusat Statistik Kota Surakarta	7
2.2 Struktur Organisasi Badan Pusat Statistik Kota Surakarta	8
2.3 Kegiatan Badan Pusat Statistik Kota Surakarta	12

BAB III	PELAKSANAAN KERJA PRAKTIK	15
3.1	Pelaksanaan Kerja Praktik	15
3.1.1	Waktu Pelaksanaan Kerja Praktik	15
3.1.2	Tempat Pelaksanaan Kerja Praktik	15
3.1.3	Kegiatan Kerja Praktik	16
3.2	Metodologi Penyelesaian Tugas Khusus	17
3.2.1	Jenis dan Sumber Data	18
3.2.2	Tahapan Penelitian / Framework Metode	18
3.2.3	Pembentukan Variabel dan Pra- Pemrosesan Data	20
3.2.4	Metode Regresi Linear Deret Waktu (OLS)	23
3.2.5	Evaluasi Model	25
BAB IV	HASIL KERJA PRAKTIK	27
4.1	Kerangka Kerja Metode untuk Menyelesaikan Prediksi	27
4.2	Pembentukan Model Regresi Linear Deret Waktu	34
4.3	Analisis Ukuran Akurasi Model	42
4.4	Analisis dan Pembahasan	46
4.4.1	Analisis Hasil Model	46
4.4.2	Analisis Komponen Model	47
4.4.3	Perbandingan dengan Model Pembanding	48
4.4.4	Evaluasi Akurasi dan Konsistensi Model	48
4.4.5	Kesimpulan Pembahasan	49
4.5	Prediksi Tahun 2025 (<i>One-Step Forecast</i>)	49
4.5.1	Contoh Penyusunan Fitur	49

4.5.2	Penurunan Koefisien OLS (2015–2024)	50
4.5.3	Pembentukan Baris Fitur 2025 & Prediksi Manual	53
4.5.4	Hasil dan Pembahasan Prediksi .	54
BAB V	PENUTUP	67
5.1	Kesimpulan	67
5.2	Saran	68
Lampiran A.	<i>Source Code</i> Python	73
Lampiran B.	<i>Logbook</i> Kegiatan	81
Lampiran C.	Dokumentasi Kegiatan	85
BIODATA	PENULIS	87

DAFTAR GAMBAR

Gambar 2.1	Struktur Organisasi Badan Pusat Statistik Kota Surakarta . . .	8
Gambar 3.1	Diagram Alir Penyelesaian Tugas Khusus	17
Gambar 4.1	Historis dan Prediksi - Jumlah Penduduk Miskin	57
Gambar 4.2	Historis dan Prediksi - Persentase Kemiskinan	58
Gambar 4.3	Aktual vs <i>Fitted</i> - Jumlah Penduduk Miskin	59
Gambar 4.4	Aktual vs <i>Fitted</i> - Persentase Kemiskinan	59
Gambar 4.5	Residual vs <i>Fitted</i> - Jumlah Penduduk Miskin	60
Gambar 4.6	Residual vs <i>Fitted</i> - Persentase Kemiskinan	61
Gambar 4.7	<i>Scatter</i> Aktual vs <i>Fitted</i> - Jumlah Penduduk Miskin	62
Gambar 4.8	<i>Scatter</i> Aktual vs <i>Fitted</i> - Persentase Kemiskinan	63

DAFTAR TABEL

Tabel 2.1	Nama dan Jabatan Struktur BPS Surakarta	9
Tabel 4.1	Data Awal Kemiskinan Kota Surakarta (2013–2024)	29
Tabel 4.2	Hasil Pengolahan Data Fitur Persentase Penduduk Miskin Kota Surakarta (2013–2024)	33
Tabel 4.3	Hasil Pengolahan Data Fitur Jumlah Penduduk Miskin Kota Surakarta (2013–2024)	34
Tabel 4.4	Perbandingan Nilai Aktual dan Prediksi (2024)	44
Tabel 4.5	Perbandingan Akurasi Model	45
Tabel 4.6	Contoh Pembentukan Variabel Input Model Persentase Penduduk Miskin	50
Tabel 4.7	Contoh Pembentukan Variabel Input Model Jumlah Penduduk Miskin (ribu jiwa)	50
Tabel 4.8	Hasil Evaluasi Akurasi Model pada Data Uji Tahun 2024	56

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan ilmu pengetahuan dan teknologi pada era digital menuntut setiap individu, terutama generasi muda, untuk memiliki kompetensi yang relevan dengan kebutuhan zaman. Perguruan tinggi sebagai lembaga pendidikan tinggi memiliki tanggung jawab besar dalam membekali mahasiswa dengan keterampilan akademik dan praktis yang dapat diterapkan di dunia kerja. Salah satu strategi pembelajaran yang efektif untuk menjembatani teori dan praktik ialah *Kerja Praktik* (KP), yaitu kegiatan pembelajaran di luar kampus yang memberi kesempatan mahasiswa untuk mengaplikasikan ilmu yang telah diperoleh dalam konteks kerja nyata. Melalui kegiatan ini, mahasiswa dapat mengembangkan kemampuan analisis, komunikasi profesional, serta memahami dinamika permasalahan di lapangan yang tidak selalu dijumpai dalam perkuliahan (Wibowo et al., 2021).

Departemen Matematika, Fakultas Sains dan Analitika Data, Institut Teknologi Sepuluh Nopember (ITS) menekankan pentingnya penerapan keilmuan matematika dalam berbagai sektor, termasuk statistika, analisis data, dan *machine learning*. Oleh karena itu, kerja praktik menjadi mata kuliah wajib yang bertujuan untuk mengasah kemampuan mahasiswa dalam memecahkan masalah nyata dengan pendekatan ilmiah berbasis data. Harapannya, mahasiswa tidak hanya memahami teori, tetapi juga mampu memberikan kontribusi nyata bagi lembaga atau organisasi tempat mereka melakukan kerja praktik (Putra & Sari, 2020).

Dalam kegiatan kerja praktik ini, penulis ditempatkan di Badan Pusat Statistik (BPS) Kota Surakarta, yang beralamat di Jl. Lumban Tobing No. 6, Setabelan, Kec. Banjarsari, Kota Surakarta, Jawa Tengah. BPS merupakan lembaga pemerintah yang memiliki

tugas pokok menyediakan data statistik yang akurat, mutakhir, dan dapat dipertanggungjawabkan. Data tersebut menjadi dasar penyusunan kebijakan pemerintah di berbagai bidang, seperti pembangunan ekonomi, pendidikan, kesehatan, dan pengentasan kemiskinan (Badan Pusat Statistik, 2023; Yuliana & Prasetyo, 2022).

Salah satu isu strategis yang menjadi perhatian baik di tingkat nasional maupun daerah adalah kemiskinan. Masalah ini bersifat multidimensi, tidak hanya mencakup aspek pendapatan, tetapi juga keterbatasan akses terhadap pendidikan, kesehatan, dan layanan dasar lainnya (Rahmawati & Setiawan, 2021). Berdasarkan data BPS Kota Surakarta, persentase penduduk miskin pada Maret 2024 mencapai 8,31% dengan 43,28 ribu jiwa, menurun tipis dibandingkan tahun 2023 sebesar 8,44% atau 43,89 ribu jiwa (BPS Kota Surakarta, 2024). Meskipun menunjukkan tren penurunan, angka tersebut masih relatif tinggi dibandingkan kota-kota besar lain di Jawa Tengah, sehingga diperlukan analisis dan proyeksi untuk memahami arah perkembangan kemiskinan di masa mendatang.

Perkembangan teknologi analitik berbasis data telah membuka peluang besar dalam mendukung kebijakan berbasis bukti (*evidence-based policy*). Salah satu metode yang banyak digunakan adalah peramalan deret waktu (*time-series forecasting*), yang mampu memprediksi nilai masa depan berdasarkan pola historis data. Pada konteks data tahunan daerah dengan jumlah observasi terbatas, pemilihan metode yang sederhana, transparan, dan mudah diinterpretasi menjadi hal penting (Hyndman & Athanasopoulos, 2023). Oleh karena itu, dalam kerja praktik ini digunakan pendekatan Regresi Linear dengan rekayasa fitur deret waktu seperti lag ($t-1$, $t-2$), rata-rata bergulir (*rolling-2*), dan tren waktu (*time trend t*) untuk memodelkan dua indikator utama kemiskinan Surakarta, yakni persentase penduduk miskin dan jumlah penduduk miskin (dalam ribu jiwa).

Pendekatan ini dipilih karena terbukti efektif untuk dataset berukuran kecil dan hasilnya mudah dijelaskan kepada pemangku

kebijakan (James et al., 2023; Airlangga et al., 2024). Laporan kerja praktik ini menyusun alur kerja sebagai berikut:

1. Menyajikan data historis kemiskinan Surakarta tahun 2013–2024 yang bersumber dari publikasi resmi BPS Kota Surakarta, termasuk tahap pembersihan dan penyeragaman skala.
2. Membangun model Regresi Linear berbasis fitur deret waktu untuk masing-masing variabel target.
3. Melakukan evaluasi model dengan pembandingan sederhana seperti *Naive* (lag-1) dan *Dummy Mean* (rata-rata historis) untuk memastikan model memberikan peningkatan akurasi yang bermakna (Hyndman & Athanasopoulos, 2023).
4. Menggunakan model terbaik untuk menghasilkan proyeksi kemiskinan tahun 2025

Dari sisi manfaat, proyeksi kedua indikator kemiskinan ini diharapkan dapat memberikan gambaran awal mengenai arah tren kemiskinan Surakarta dalam satu tahun mendatang. Hasilnya dapat dijadikan dasar dalam penyusunan target pembangunan, perencanaan program sosial, serta alokasi sumber daya untuk penanggulangan kemiskinan di tingkat daerah. Di sisi lain, kerja praktik ini juga menjadi sarana bagi penulis untuk menerapkan keilmuan statistik dan *machine learning* dalam menyelesaikan masalah nyata, sekaligus menegaskan peran strategis BPS sebagai penyedia data berkualitas dalam perumusan kebijakan publik.

1.2 Tujuan Kerja Praktik

Adapun tujuan dari kerja praktik ini terbagi menjadi dua, yaitu tujuan umum dan tujuan khusus yang diuraikan sebagai berikut.

1.2.1 Tujuan Umum

Kerja praktik bertujuan untuk memberikan pengalaman langsung kepada mahasiswa dalam menerapkan ilmu yang sudah dipelajari selama kuliah ke dunia kerja. Melalui kegiatan ini, mahasiswa dapat melihat bagaimana teori yang dipelajari di kelas digunakan dalam praktik, khususnya dalam bidang matematika dan analisis data. Selain itu, kerja praktik juga membantu mahasiswa memahami cara kerja di instansi, seperti struktur organisasi, proses

kerja, dan tanggung jawab yang ada di dalamnya. Kegiatan ini diharapkan dapat melatih kemampuan analisis, keterampilan teknis, serta sikap profesional mahasiswa. Tidak hanya itu, mahasiswa juga berkesempatan untuk berkontribusi pada instansi tempat kerja praktik, dalam hal ini Badan Pusat Statistik (BPS) Kota Surakarta, sehingga manfaat yang diperoleh bisa dirasakan oleh kedua belah pihak.

1.2.2 Tujuan Khusus

Adapun tujuan khusus pada kerja praktik adalah sebagai berikut.

1. Menerapkan metode Regresi Linear berbasis deret waktu untuk melakukan peramalan persentase dan jumlah penduduk miskin di Kota Surakarta berdasarkan data BPS.
2. Menyajikan hasil peramalan tahun 2025 beserta visualisasi pendukung yang dapat digunakan sebagai bahan pertimbangan dalam memahami tren kemiskinan daerah dan mendukung perencanaan kebijakan di lingkungan BPS Kota Surakarta.

1.3 Manfaat

Adapun beberapa manfaat yang diperoleh dari Kerja Praktik di Badan Pusat Statistik Kota Surakarta:

1.3.1 Manfaat Bagi Instansi

1. Dapat membantu menyelesaikan beberapa pekerjaan tertentu yang berkaitan dengan pengolahan maupun analisis data di instansi, khususnya pengolahan data kemiskinan dan penyusunan visualisasi hasil.
2. Dapat menerima saran atau masukan terkait permasalahan yang dikerjakan mahasiswa pada laporan kerja praktik ini, sehingga bisa menjadi bahan pertimbangan dalam pengembangan pengolahan data di masa depan.

1.3.2 Manfaat Bagi Mahasiswa

1. Menjadi sarana untuk menerapkan ilmu yang telah dipelajari selama perkuliahan, khususnya dalam bidang statistika, big

data, dan machine learning, melalui peramalan kemiskinan menggunakan Regresi Linear berbasis fitur *lag*, *rolling*, dan tren.

2. Memberikan pengalaman langsung dalam mengolah dan menganalisis data resmi dari BPS Kota Surakarta, sehingga mahasiswa dapat memahami bagaimana data statistik digunakan untuk mendukung perencanaan pembangunan dan pengambilan kebijakan berbasis bukti.

BAB II

GAMBARAN UMUM INSTANSI

2.1 Sejarah Badan Pusat Statistik Kota Surakarta

Kegiatan statistik di Indonesia berawal pada masa kolonial Hindia Belanda, diawali dengan pembentukan sebuah institusi di Bogor pada Februari 1920 oleh Direktur Pertanian, Kerajinan, dan Perdagangan (*Directur Van Landbouw Nijverheid en Handel*). Lembaga ini bertanggung jawab dalam pengelolaan serta penyebaran data statistik. Kemudian, pada 24 September 1924, institusi tersebut dipindahkan ke Jakarta dan berganti nama menjadi *Centraal Kantoor voor de Statistiek* (CKS). Dalam perannya yang baru, CKS melaksanakan Sensus Penduduk pertama di Indonesia pada tahun 1930. Selama pendudukan Jepang (1942-1945), CKS mengalami perubahan nama menjadi *Shomubu Chosasisu Gunseikanbu* dengan fokus utama pada kepentingan militer Jepang.

Setelah Indonesia merdeka pada 17 Agustus 1945, lembaga tersebut dinasionalisasi dan diberi nama Kantor Penyelidikan Perangkaan Umum Republik Indonesia (KAPPURI), dengan kepemimpinan di bawah Mr. Abdul Karim Pringgodigdo. Pada 12 Juni 1950, melalui Surat Edaran Kementerian Kemakmuran, KAPPURI digabung dengan CKS untuk membentuk Kantor Pusat Statistik (KPS), yang berada di bawah kendali Menteri Kemakmuran. Seiring perkembangannya, pada 1 Juni 1957, KPS mengalami transformasi menjadi Biro Pusat Statistik (BPS) dan bertanggung jawab langsung kepada Perdana Menteri. Kemudian, berdasarkan Undang-Undang No. 16 Tahun 1997, nama lembaga ini berubah menjadi Badan Pusat Statistik (BPS).

Sebagai bagian dari pengembangan organisasi, terbentuk Kantor Sensus dan Statistik (KKS) di berbagai daerah, termasuk Surakarta. KKS Kota Surakarta, yang kemudian menjadi bagian dari BPS Provinsi Jawa Tengah, memiliki tugas utama dalam


mengumpulkan serta menyebarluaskan data statistik di wilayahnya.

BPS Surakarta terus menyesuaikan diri dengan kebijakan yang ditetapkan pemerintah pusat dan memainkan peran penting dalam menyediakan data statistik yang valid dan terpercaya untuk mendukung pembangunan di Kota Surakarta, baik dalam aspek sosial maupun ekonomi. Selain menyelenggarakan berbagai sensus, seperti Sensus Penduduk dan Sensus Ekonomi, BPS Surakarta juga menyediakan data yang digunakan dalam perencanaan kebijakan oleh pemerintah kota, serta menjadi sumber informasi bagi sektor swasta dan masyarakat untuk keperluan penelitian dan analisis.

Sebagai bagian dari BPS Provinsi Jawa Tengah, BPS Surakarta menjalankan tugasnya sesuai dengan peraturan yang berlaku, termasuk yang tertuang dalam PP No. 51 Tahun 1999 tentang penyelenggaraan statistik di Indonesia. Dengan berbagai perkembangan yang terus terjadi, BPS Surakarta tetap berkomitmen untuk menyajikan data yang akurat dan bermanfaat, tidak hanya bagi pembangunan Kota Surakarta, tetapi juga dalam mendukung kebijakan nasional melalui penyediaan informasi statistik yang andal.

2.2 Struktur Organisasi Badan Pusat Statistik Kota Surakarta

Struktur dari Badan Pusat Statistik Kota Surakarta ditampilkan pada bagan berikut.



Gambar 2.1 Struktur Organisasi Badan Pusat Statistik Kota Surakarta

Tabel 2.1 Nama dan Jabatan Struktur BPS Surakarta

Jabatan	Nama
Kepala BPS Surakarta	Ratna Setyowati, S.Si, M.A, M.T
Kepala Sub Bagian Umum	Sri Indriyatno, S.ST, M.Si
Fungsional Pranata Komputer	Epi Priyanto, S.ST., M.Si
Fungsional Pranata Komputer	Addy Wahyu Fitriadi, S.ST, M.T.I
Fungsional Pranata Keuangan APBN	Sarah Hafizoh, A.Md.Kb.N
Fungsional Pranata Keuangan APBN	Adhe Bagus Oktafian Sudibyo, S.E
Fungsional Pranata Keuangan APBN	Eri Yuliasti, S.E
hline Pelaksana	Agung Tri Haryanto
Pelaksana	Padiarto
Statisti Mahir	Tri Widyastuti
Statisti Ahli Pertama	Harsoyo Yulianto, S.E
Statisti Ahli Pertama	Wahyu Pamungkasjati H., S.ST
Statisti Ahli Pertama	Chomariah Fitriani, S.ST, M.Si
Statisti Ahli Pertama	Dewi Apriyanti, S.ST
Statisti Ahli Pertama	Rumpaka Sari Rahmani, S.ST
Statisti Ahli Pertama	Afifah Imas Nugraheni, S.ST
Statisti Ahli Pertama	Harista Dwi K., S.Tr.Stat
Statisti Ahli Madya	Istanti, S.Si., M.Ec.Dev
Statisti Ahli Muda	Ir. Ernita Septiana, M.M
Statisti Ahli Muda	Christina Sugiyanti, S.E, M.M
Statisti Ahli Muda	Oni Prasetyo U., S.ST., M.S.E

Bersambung ke halaman berikutnya

Tabel 2.1 (lanjutan)

Jabatan	Nama
Statisti Ahli Muda	Dedy Muryantoro, S.ST., M.M
Statisti Ahli Muda	Upik Nurlaena, S.Si, M.Si
Statisti Ahli Muda	Fu'ad Rahadi, S.ST, M.Si
Statisti Ahli Muda	Leni Kurniawati, S.ST, M.Si
Statisti Ahli Muda	Citra Chintia M., S.ST, M.Si
Statisti Ahli Muda	Tanti Siti Rochmani, S.E, M.Si
Statisti Ahli Muda	Kusuma Dewi Kris A., S.ST, M.Si
Statisti Ahli Muda	Sukartini, S.ST

Dalam melakukan tugasnya, BPS Kota Surakarta memiliki lima bagian yang memiliki tugas dan tanggung jawab masing-masing. Kelima bagian tersebut meliputi subbagian umum, fungsional statistisi, fungsional pranata komputer, fungsional pranata / analisis keuangan APBN dan pelaksana.

1. Sub Bagian Umum

Subbagian Umum merupakan bagian yang menangani urusan administrasi dan operasional internal kantor. Tugas utamanya mencakup penyusunan rencana kerja dan anggaran, pengelolaan keuangan pengelolaan sumber daya manusia, serta pengelolaan barang milik negara. Selain itu, subbagian ini juga berperan dalam pengelolaan hubungan masyarakat, dokumentasi dan kearsipan, persandian dan keamanan informasi, serta urusan rumah tangga dan perlengkapan kantor. Fungsi Subbagian Umum sangat penting dalam menjaga kelangsungan kegiatan operasional BPS agar berjalan secara efisien dan sesuai aturan yang berlaku.

2. Fungsional Statistisi

Fungsional Statistisi memiliki tanggung jawab utama dalam kegiatan teknis statistik. Para Statistisi bertugas menyusun rancangan survei dan sensus, melakukan

pengumpulan data, pengolahan, analisis, serta penyajian hasil statistik. Peran Statistisi sangat krusial karena mereka memastikan bahwa data yang dihasilkan valid, akurat, dan dapat dipertanggungjawabkan.

3. Fungsional Pranata Komputer

Pranata Komputer adalah pejabat fungsional yang memiliki keahlian di bidang teknologi informasi dan komunikasi. Tugasnya mencakup pengembangan dan pemeliharaan sistem informasi, pengelolaan basis data statistik, serta dukungan teknis dalam proses digitalisasi data dan sistem pelaporan. Berperan juga dalam menjaga keamanan sistem informasi dan jaringan, serta mendukung integrasi sistem dalam lingkungan kerja BPS agar proses kerja menjadi lebih efisien dan berbasis teknologi.

4. Fungsional Pranata / Analisis Keuangan APBN

Fungsional Pranata bertanggung jawab dalam bidang pengelolaan dan pelaporan keuangan yang bersumber dari Anggaran Pendapatan dan Belanja Negara (APBN). Fungsional ini memiliki tugas untuk melakukan analisis terhadap penggunaan anggaran, menyusun laporan pertanggungjawaban keuangan, serta memastikan bahwa seluruh kegiatan keuangan BPS dilaksanakan sesuai dengan ketentuan peraturan perundang-undangan yang berlaku. Fungsi ini sangat penting dalam menjamin transparansi dan akuntabilitas pengelolaan keuangan negara di lingkungan BPS.

5. Pelaksana

Pelaksana merupakan tenaga pendukung teknis dan administratif yang membantu proses operasional sehari-hari di seluruh bidang yang ada di BPS Kota Surakarta. Tugas mereka beragam, mulai dari membantu kegiatan pengumpulan data lapangan, entri data, pendistribusian dokumen, hingga pelayanan publik terkait kebutuhan data statistik. Meski bersifat pendukung, peran pelaksana sangat esensial dalam mendukung kelancaran pelaksanaan program kerja di BPS secara keseluruhan.

2.3 Kegiatan Badan Pusat Statistik Kota Surakarta

Sebagai lembaga pemerintah nonkementerian yang bertugas di bidang statistik, Badan Pusat Statistik (BPS) Kota Surakarta memiliki peran strategis dalam menyediakan data dan informasi statistik yang akurat untuk mendukung perumusan kebijakan, penelitian akademis, serta kebutuhan masyarakat umum. Kegiatan utama yang dilaksanakan meliputi pelayanan permintaan data statistik melalui layanan konsultasi langsung maupun digital, salah satunya dengan inovasi PANDAWA (Pelayanan Data Statistik Terpadu via WhatsApp) yang memudahkan pengguna data untuk mengakses informasi secara cepat dan efisien. Selain itu, BPS Kota Surakarta juga menyelenggarakan pendaftaran Mitra Statistik yang berfungsi untuk menjaring tenaga pendukung dalam pengumpulan data, misalnya untuk pelaksanaan survei maupun pemutakhiran data sektoral. Proses ini tidak bersifat perekrutan pegawai tetap, tetapi lebih pada membentuk database mitra kerja statistik yang siap digunakan sesuai kebutuhan kegiatan statistik.

BPS Kota Surakarta juga secara konsisten mempublikasikan Berita Resmi Statistik (BRS), yang memuat ringkasan hasil survei atau sensus dalam berbagai bidang, seperti inflasi, indeks pembangunan manusia, serta indikator sosial-ekonomi lainnya. Selain itu, instansi ini melaksanakan kegiatan Pemutakhiran Wilayah Kerja Statistik (Wilkerstat), yaitu pemetaan wilayah pengumpulan data secara berkala untuk memastikan keakuratan kerangka sampel dalam survei dan sensus. Guna meningkatkan kualitas layanan, BPS Kota Surakarta juga menyelenggarakan forum diskusi dan evaluasi pelayanan publik, termasuk Focus Group Discussion (FGD) mengenai standardisasi pelayanan, yang sejalan dengan komitmen BPS dalam membangun zona integritas menuju Wilayah Birokrasi Bersih dan Melayani (WBBM).

Dengan beragam kegiatan tersebut, BPS Kota Surakarta tidak hanya menjadi lembaga penyedia data, tetapi juga berperan sebagai fasilitator dalam meningkatkan literasi statistik di kalangan pemerintah daerah, akademisi, pelaku usaha, maupun masyarakat luas. Data yang dihasilkan dan dipublikasikan oleh BPS Kota Surakarta pada akhirnya berfungsi sebagai dasar yang krusial

dalam perencanaan pembangunan, pengambilan kebijakan, serta evaluasi program-program pembangunan di tingkat kota. Hal ini menunjukkan bahwa keberadaan BPS memiliki kontribusi strategis dalam mewujudkan pembangunan berbasis data yang akurat, transparan, dan dapat dipertanggungjawabkan.

BAB III

PELAKSANAAN KERJA PRAKTIK

3.1 Pelaksanaan Kerja Praktik

Rincian dari pelaksanaan kerja praktik adalah sebagai berikut:

3.1.1 Waktu Pelaksanaan Kerja Praktik

Kerja praktik di Badan Pusat Statistik Kota Surakarta berlangsung selama 40 hari, mulai dari 30 Juni 2025 sampai 8 Agustus 2025. Kegiatan ini dilaksanakan setiap hari kerja, yaitu dari Senin hingga Jum'at, dengan jam kerja untuk hari Senin hingga Kamis dimulai pukul 07.30 WIB hingga pukul 16.00 WIB, sedangkan hari Jum'at dimulai pukul 07.30 WIB hingga pukul 16.30.

3.1.2 Tempat Pelaksanaan Kerja Praktik

Kegiatan Kerja Praktik ini dilaksanakan di Badan Pusat Statistik (BPS) Kota Surakarta yang beralamat di Jl. Lumban Tobing No. 6, Setabelan, Kec. Banjarsari, Kota Surakarta, Jawa Tengah. Selama menjalani Kerja Praktik, penulis ditempatkan pada Divisi Neraca Sistem Akuntabilitas Kinerja Instansi Pemerintah (SAKIP) dan Reformasi Birokrasi (RB). Dalam divisi ini, penulis terlibat dalam kegiatan yang berkaitan dengan pengelolaan dan analisis data kinerja instansi, mendukung proses administrasi pelaporan, serta membantu penyusunan dokumen evaluasi kinerja.


Dalam divisi ini, penulis ikut serta dalam kegiatan yang berkaitan dengan pengelolaan data dan dokumen kinerja, membantu proses administrasi yang diperlukan, serta mendukung penyusunan laporan yang digunakan untuk evaluasi instansi. Melalui kegiatan tersebut, penulis memperoleh pengalaman baru mengenai bagaimana data dan laporan kinerja digunakan untuk memperbaiki sistem kerja dan pelayanan di BPS Kota Surakarta.

3.1.3 Kegiatan Kerja Praktik

Kegiatan selama pelaksanaan kerja praktik terlampir pada Lampiran B.

3.2 Metodologi Penyelesaian Tugas Khusus

Diagram alir dari penyelesaian tugas khusus kerja praktik ini diberikan pada Gambar 3.1 sebagai berikut:



Gambar 3.1 Diagram Alir Penyelesaian Tugas Khusus

Metode yang digunakan pada penyelesaian tugas khusus adalah Regresi Linear Deret Waktu. Metode tersebut digunakan dengan tujuan memprediksi jumlah penduduk miskin dan persentase kemiskinan di Kota Surakarta. Berikut merupakan prosedur yang digunakan untuk menyelesaikan prediksi tersebut:

3.2.1 Jenis dan Sumber Data

Data yang digunakan dalam kegiatan kerja praktik ini merupakan data sekunder berupa deret waktu tahunan (*time series*) mengenai kondisi kemiskinan di Kota Surakarta selama periode 2013 hingga 2024.

Data terdiri dari dua variabel utama, yaitu:

- Jumlah Penduduk Miskin (ribu jiwa) – menunjukkan total jumlah penduduk miskin di Kota Surakarta setiap tahun dalam satuan ribu jiwa.
- Persentase Penduduk Miskin (%) – menunjukkan proporsi penduduk miskin terhadap total populasi pada tahun bersangkutan.

Sumber data diambil dari Badan Pusat Statistik (BPS) Kota Surakarta. Seluruh data diolah kembali dan dinormalisasi agar sesuai dengan kebutuhan analisis deret waktu.

Pemilihan data deret waktu dilakukan karena tujuan utama kegiatan ini adalah membangun model prediksi kemiskinan yang mampu memperkirakan nilai tahun berikutnya berdasarkan pola dan hubungan antarperiode sebelumnya.

3.2.2 Tahapan Penelitian / Framework Metode

Tahapan penelitian pada kegiatan kerja praktik ini mengikuti kerangka metode (*framework*) yang menggambarkan alur penyelesaian masalah secara sistematis, mulai dari pengumpulan data, pembentukan variabel, pelatihan model, hingga evaluasi dan peramalan.

Secara umum, tahapan penelitian terdiri dari langkah-langkah berikut:

1. **Input dan Pemeriksaan Data Awal.**

Langkah pertama adalah mengumpulkan data kemiskinan dari BPS dan memastikan kelengkapan datanya. Data diperiksa dari segi format, nilai yang hilang (*missing value*), dan konsistensi satuan antarperiode agar siap digunakan.

2. **Rekayasa Fitur (*Feature Engineering*).**

Tahap ini bertujuan mengubah data mentah menjadi fitur-fitur yang lebih informatif bagi model. Fitur yang dibentuk meliputi:

- *Lag* (nilai satu dan dua tahun sebelumnya),
- *Rolling mean* dua tahun terakhir,
- Komponen tren waktu (t), dan
- *Cross-lag* atau *lag* silang antarvariabel.

Keempat fitur ini dirancang untuk membantu model mengenali pola jangka pendek, tren jangka panjang, dan keterkaitan antara jumlah dan persentase penduduk miskin.

3. **Partisi Data (*Training dan Testing*).**

Setelah fitur lengkap, data dibagi menjadi dua bagian: data latih (2013–2023) dan data uji (2024). Pembagian dilakukan berdasarkan waktu (bukan acak) agar urutan kronologis tetap terjaga sesuai dengan karakteristik deret waktu.

4. **Pembentukan Model Regresi Linear Deret Waktu.**

Model dibangun dengan pendekatan *Ordinary Least Squares* (OLS), yaitu metode yang mencari kombinasi koefisien terbaik untuk meminimalkan kesalahan antara nilai aktual dan nilai prediksi. Dua model dikembangkan:

- Model persentase penduduk miskin $y_t^{(%)}$,
- Model jumlah penduduk miskin $y_t^{(J)}$.

5. **Evaluasi Akurasi.**

Akurasi model dinilai menggunakan tiga metrik utama: *Mean Absolute Error* (MAE), *Root Mean Square Error* (RMSE), dan *Mean Absolute Percentage Error* (MAPE). Model dinyatakan baik jika nilai kesalahan tersebut lebih kecil dibandingkan model pembanding (*Naive dan Dummy mean*).

6. **Prediksi Tahun 2025.**

Model terbaik dari hasil evaluasi kemudian digunakan untuk

melakukan peramalan satu langkah ke depan (*one-step forecast*), yaitu memperkirakan nilai kemiskinan tahun 2025 berdasarkan pola tahun-tahun sebelumnya.

7. Visualisasi dan Analisis Hasil

Tahap terakhir adalah menyajikan hasil model dalam bentuk visual dan melakukan interpretasi terhadap kinerja model. Beberapa grafik yang digunakan antara lain:

- (a) Aktual vs Fitted: menunjukkan seberapa dekat hasil prediksi model dengan data sebenarnya;
- (b) Historis dan Forecast: memperlihatkan tren kemiskinan dari tahun 2013 hingga proyeksi tahun 2025;
- (c) Residual vs Fitted: digunakan untuk memeriksa pola kesalahan model, apakah sudah acak atau masih berpola;
- (d) Scatter Aktual vs Fitted: menggambarkan hubungan antara nilai sebenarnya dan nilai hasil prediksi model.

Melalui visualisasi tersebut, hasil analisis menjadi lebih mudah dipahami dan dapat digunakan sebagai dasar dalam penyusunan kesimpulan serta saran penelitian.

Framework tersebut menggambarkan proses penelitian yang bersifat siklis, model diuji, diperbaiki, dan dievaluasi secara bertahap hingga mencapai performa optimal.

3.2.3 Pembentukan Variabel dan Pra-Pemrosesan Data

(a) Pembentukan Fitur *Lag*

Fitur *lag* merepresentasikan nilai masa lalu dari suatu variabel dan berfungsi untuk menjelaskan hubungan antarperiode. Dalam model ini digunakan dua jenis *lag*:

- *Lag*-1 (satu tahun sebelumnya)
- *Lag*-2 (dua tahun sebelumnya)

Secara matematis dituliskan sebagai:

$$\text{Lag-1: } y_{t-1}, \quad \text{Lag-2: } y_{t-2}. \quad (3.1)$$

Keterangan:

- y_t : nilai variabel target (jumlah atau persentase) pada tahun ke- t ,
- y_{t-1} : nilai variabel satu tahun sebelumnya,
- y_{t-2} : nilai variabel dua tahun sebelumnya.

Sebagai contoh, untuk tahun 2020 diperoleh:

$$\begin{aligned} y_{2020-1}^{(\%) } &= y_{2019}^{(\%) } = 8,70, \\ y_{2020-2}^{(\%) } &= y_{2018}^{(\%) } = 9,08, \\ y_{2020-1}^{(J) } &= y_{2019}^{(J) } = 45,18, \\ y_{2020-2}^{(J) } &= y_{2018}^{(J) } = 46,99. \end{aligned} \quad (3.2)$$

Fitur *lag* penting untuk model deret waktu karena menggambarkan pengaruh masa lalu terhadap kondisi saat ini. Dua *lag* dianggap cukup untuk data tahunan agar model tidak terlalu kompleks.

(b) Rata-rata Bergerak (*Rolling Mean-2*)

Selain nilai *lag* individu, model juga menggunakan rata-rata bergerak dua tahun terakhir untuk menghaluskan fluktuasi antarperiode. Rumusnya adalah:

$$y_{t,roll2} = \frac{1}{2} (y_{t-1} + y_{t-2}). \quad (3.3)$$

Keterangan:

- $y_{t,roll2}$: rata-rata bergerak dua tahun terakhir,
- y_{t-1}, y_{t-2} : nilai variabel satu dan dua tahun sebelumnya.

Sebagai contoh, untuk variabel persentase kemiskinan tahun 2021:

$$y_{2021,roll2}^{(\%) } = \frac{1}{2} (9,03 + 8,70) = 8,865. \quad (3.4)$$

Fitur *rolling mean* ini membantu model menangkap pola tren jangka pendek yang halus tanpa terpengaruh lonjakan tahunan.

(c) Komponen Tren (*Trend Component*)

Komponen tren (t) digunakan untuk menggambarkan kecenderungan jangka panjang dari waktu ke waktu. Dalam kasus ini, tren merepresentasikan perubahan tingkat kemiskinan yang cenderung menurun setiap tahun.

Untuk data tahunan, komponen tren direpresentasikan dengan indeks waktu:

$$t_i = i - 2012, \quad \text{untuk } i = 2013, 2014, \dots, 2024. \quad (3.5)$$

Sehingga nilai t membentuk urutan: $t = \{1, 2, 3, \dots, 12\}$.

Keterangan: t : indeks waktu (tahun ke- t). Tren ini akan digunakan sebagai variabel bebas untuk menangkap arah umum perubahan kemiskinan dari waktu ke waktu.

(d) Lag Silang (*Cross-Lag*) Antarvariabel

Untuk menangkap hubungan timbal balik antara dua indikator kemiskinan, digunakan *lag* silang (*cross-lag*) antarvariabel.

Artinya:

- Saat memprediksi persentase kemiskinan, digunakan pula jumlah penduduk miskin tahun sebelumnya.
- Saat memprediksi jumlah penduduk miskin, digunakan persentase kemiskinan tahun sebelumnya.

Secara matematis dituliskan:

$$\text{Model persentase: } y_t^{(\%) } = f\left(y_{t-1}^{(\%) }, y_{t-2}^{(\%) }, y_{t,\text{roll}2}^{(\%) }, t, y_{t-1}^{(J)}\right), \quad (3.6)$$

$$\text{Model jumlah: } y_t^{(J)} = f\left(y_{t-1}^{(J)}, y_{t-2}^{(J)}, y_{t,\text{roll}2}^{(J)}, t, y_{t-1}^{(\%) }\right). \quad (3.7)$$

Dengan memasukkan *lag* silang, model dapat memahami hubungan dua arah antara jumlah dan proporsi penduduk miskin, yang mencerminkan realitas sosial bahwa perubahan jumlah kemiskinan sering sejalan dengan perubahan persentasenya.

(e) Penyiapan Dataset

Setelah seluruh fitur terbentuk, dataset akhir disusun dalam bentuk tabel yang memuat kolom:

$$[t, y_{t-1}, y_{t-2}, y_{t,\text{roll}2}, \text{cross-lag}, y_t].$$

Untuk menjaga stabilitas perhitungan, semua data dinormalisasi dalam satuan yang seragam:

- Ribuan jiwa untuk variabel jumlah,
- Persen (%) untuk variabel proporsi.

(f) Pembagian Data (*Data Splitting*)

Data kemudian dibagi menjadi dua bagian:

- Data pelatihan (*training set*): 2013–2023
- Data pengujian (*testing set*): 2024

Pembagian dilakukan secara kronologis (*time-based split*), bukan acak, agar struktur temporal tetap terjaga. Secara matematis ditulis:

$$\mathcal{D}_{\text{train}} = \{(t_i, y_i) \mid i = 2013, \dots, 2023\}, \quad \mathcal{D}_{\text{test}} = \{(t_{2024}, y_{2024})\}. \quad (3.8)$$

Pendekatan ini dikenal sebagai evaluasi *holdout* satu langkah (*one-step holdout evaluation*). Data tahun 2024 berfungsi untuk mengukur kemampuan prediksi model, sedangkan hasil terbaik nantinya akan digunakan untuk memprediksi tahun 2025.

3.2.4 Metode Regresi Linear Deret Waktu (OLS)

(a) Formulasi Model Umum

Model regresi linear deret waktu digunakan untuk menjelaskan hubungan antara nilai target pada tahun ke- t dan kumpulan fitur yang merepresentasikan informasi dari tahun-tahun sebelumnya.

Rumus umumnya adalah:

$$y_t = X_t \theta + \varepsilon_t, \quad (3.9)$$

dengan:

- y_t : nilai target pada tahun ke- t (persentase atau jumlah penduduk miskin),
- X_t : vektor fitur yang berisi nilai *lag*, *rolling mean*, komponen tren, dan *cross-lag*,
- θ : vektor koefisien regresi yang ingin diestimasi,
- ε_t : galat (*error*) model yang diharapkan berdistribusi normal dengan rata-rata nol.

Parameter θ diestimasi menggunakan metode *Ordinary Least Squares* (OLS), yang rumusnya adalah:

$$\hat{\theta} = (X^T X)^{-1} X^T y. \quad (3.10)$$

OLS dipilih karena sederhana, efisien, dan memberikan hasil yang mudah diinterpretasikan untuk data kecil seperti deret waktu tahunan.

(b) Spesifikasi Model

Dibangun dua model regresi linear terpisah dengan struktur fitur yang sama:

Model Persentase Penduduk Miskin

$$y_t^{(\%) } = \beta_0 + \beta_1 y_{t-1}^{(\%) } + \beta_2 y_{t-2}^{(\%) } + \beta_3 y_{t,\text{roll}2}^{(\%) } + \beta_4 t + \beta_5 y_{t-1}^{(J)} + \varepsilon_t. \quad (3.11)$$

Model Jumlah Penduduk Miskin (ribu jiwa)

$$y_t^{(J)} = \gamma_0 + \gamma_1 y_{t-1}^{(J)} + \gamma_2 y_{t-2}^{(J)} + \gamma_3 y_{t,\text{roll}2}^{(J)} + \gamma_4 t + \gamma_5 y_{t-1}^{(\%) } + \eta_t. \quad (3.12)$$

Keterangan:

- β_0, γ_0 : konstanta,
- β_1, γ_1 : pengaruh *lag*-1,
- β_2, γ_2 : pengaruh *lag*-2,
- β_3, γ_3 : pengaruh rata-rata bergerak dua tahun terakhir,
- β_4, γ_4 : pengaruh waktu (tren),
- β_5, γ_5 : pengaruh silang (*cross-lag*) dari variabel lain,
- ε_t, η_t : *error* atau residu model.

3.2.5 Evaluasi Model

Evaluasi model dilakukan untuk mengukur seberapa baik model mampu memprediksi nilai pada data uji (tahun 2024). Tiga ukuran akurasi digunakan:

Mean Absolute Error (MAE)

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|. \quad (3.13)$$

Menunjukkan rata-rata kesalahan absolut antara nilai aktual dan prediksi.

Root Mean Square Error (RMSE)

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}. \quad (3.14)$$

Memberi penalti lebih besar pada kesalahan yang ekstrem.

Mean Absolute Percentage Error (MAPE)

$$\text{MAPE} = 100 \times \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|. \quad (3.15)$$

Mengukur kesalahan relatif dalam bentuk persentase.

Model dinilai lebih baik apabila memiliki nilai MAE, RMSE, dan MAPE yang lebih kecil dibandingkan model dasar:

- *Naive model (lag-1)*: $\hat{y}_t = y_{t-1}$,
- *Dummy mean model*: $\hat{y}_t = \bar{y}_{\text{train}}$.

Setelah model terbaik ditentukan berdasarkan hasil evaluasi, model tersebut digunakan untuk peramalan satu langkah ke depan, yaitu memperkirakan nilai tahun 2025. Pendekatan satu langkah ini dilakukan untuk menjaga ketepatan hasil dan menghindari akumulasi kesalahan yang mungkin terjadi pada peramalan jangka panjang.

BAB IV

HASIL KERJA PRAKTIK

4.1 Kerangka Kerja Metode untuk Menyelesaikan Prediksi

Bab ini membahas hasil penerapan metode regresi linear deret waktu untuk memprediksi tingkat kemiskinan di Kota Surakarta. Secara umum, penelitian ini dimulai dari pengumpulan data tahunan dari Badan Pusat Statistik (BPS), kemudian data tersebut diolah, dibentuk menjadi variabel-variabel baru (fitur *lag*, *rolling mean*, dan tren waktu), hingga akhirnya dimasukkan ke dalam model regresi untuk melihat pola keterkaitannya.

Langkah-langkah utama yang dilakukan dalam proses ini meliputi:

1. Menyiapkan data historis kemiskinan (2013–2024) yang terdiri dari dua variabel utama: persentase dan jumlah penduduk miskin.
2. Mengolah dan menyesuaikan satuan data, karena data jumlah penduduk miskin dari BPS masih dalam satuan jiwa, sehingga perlu dikonversi ke ribu jiwa agar mudah dibandingkan.
3. Membentuk variabel tambahan (*lag*, *rolling mean*, dan tren waktu) agar model mampu mengenali hubungan antar tahun.
4. Membagi data menjadi data latih dan data uji untuk menilai kemampuan model dalam memprediksi tahun yang belum pernah digunakan sebelumnya.
5. Membangun dua model regresi linear deret waktu, yaitu model untuk persentase kemiskinan dan model untuk jumlah penduduk miskin.
6. Melakukan perhitungan dan interpretasi hasil, serta menguji akurasi model untuk memastikan hasil yang diperoleh layak digunakan untuk prediksi.

Langkah-langkah ini menggambarkan alur kerja penelitian

yang sistematis, dimulai dari data mentah hingga menjadi model siap pakai.

4.1.1 Sumber Data

Data yang digunakan dalam kegiatan kerja praktik ini berasal dari Badan Pusat Statistik (BPS) Kota Surakarta, melalui publikasi tahunan *Surakarta dalam Angka* untuk periode 2013–2024. Data ini mencakup dua indikator utama yang menjadi fokus penelitian, yaitu:

- Persentase Penduduk Miskin (%): menunjukkan perbandingan antara jumlah penduduk miskin terhadap total penduduk pada tahun tertentu.
- Jumlah Penduduk Miskin (ribu jiwa): menggambarkan banyaknya penduduk miskin secara absolut.

Data diunduh dari tabel resmi BPS kemudian disalin ke dalam lembar kerja Excel agar memudahkan dalam pengolahan dan analisis lanjutan menggunakan Python.

4.1.2 Penyusunan dan Penyesuaian Satuan

Pada tahap ini, dilakukan penyatuan satuan data agar semua nilai menggunakan skala yang sama. Kolom jumlah penduduk miskin semula disajikan dalam satuan jiwa, sehingga dikonversi menjadi ribu jiwa dengan rumus berikut:

$$\text{Jumlah (ribu jiwa)} = \frac{\text{Jumlah (jiwa)}}{1000}. \quad (4.1)$$

Sebagai contoh, jika jumlah penduduk miskin tahun 2013 adalah 59 680 jiwa, maka setelah disesuaikan menjadi:

$$\frac{59\,680}{1000} = 59.68 \text{ ribu jiwa}.$$

Langkah ini dilakukan untuk seluruh tahun agar data memiliki skala yang konsisten.

4.1.3 Data Awal Kemiskinan Kota Surakarta (2013–2024)

Setelah data disesuaikan, hasil akhirnya dapat dilihat pada tabel berikut.

Tabel 4.1 Data Awal Kemiskinan Kota Surakarta (2013–2024)

Tahun	Persentase Penduduk Miskin (%)	Jumlah Penduduk Miskin (ribu jiwa)
2013	11.74	59.68
2014	10.95	55.92
2015	10.89	55.71
2016	10.88	55.91
2017	10.65	54.89
2018	9.08	46.99
2019	8.70	45.18
2020	9.03	47.03
2021	9.40	48.79
2022	8.84	45.90
2023	8.44	43.89
2024	8.31	43.28

Dari tabel tersebut, terlihat bahwa tingkat kemiskinan di Surakarta secara umum mengalami tren penurunan, dari 11,74% pada tahun 2013 menjadi 8,31% pada tahun 2024. Namun terdapat sedikit kenaikan pada tahun 2020–2021, yang kemungkinan besar disebabkan oleh dampak pandemi COVID-19 terhadap sektor ekonomi.

4.1.4 Pembersihan Data (*Data Cleaning*)

Sebelum dilakukan analisis, seluruh data diperiksa kembali untuk memastikan:

- Tidak ada nilai kosong (*missing values*),
- Tidak ada data ganda atau salah input,
- Semua tahun berurutan secara kronologis.

Selain itu, dilakukan pengecekan adanya *outlier* (nilai yang menyimpang jauh dari pola) menggunakan visualisasi *boxplot*. Hasilnya menunjukkan bahwa data bersih dan dapat langsung digunakan untuk pemodelan, dengan satu-satunya anomali kecil pada tahun 2020 yang masih wajar karena kondisi ekonomi nasional pada masa pandemi.

4.1.5 Pembentukan Fitur Deret Waktu

Pada tahap ini dilakukan pembentukan fitur-fitur baru dari data awal agar model dapat mengenali hubungan antar tahun. Proses ini

dilakukan secara bertahap menggunakan empat jenis fitur utama, yaitu *lag-1*, *lag-2*, rata-rata bergerak dua tahun terakhir (*rolling mean-2*), tren waktu (*t*), dan lag silang (*cross-lag*).

Berikut langkah-langkah pembentukan masing-masing fitur berdasarkan data kemiskinan Kota Surakarta tahun 2013–2024.

1. Membentuk *Lag 1 (t-1)* dan *Lag 2 (t-2)*

Fitur *lag* diperoleh dengan menggeser nilai data ke bawah sesuai banyaknya tahun yang ingin dilihat ke belakang.

Langkahnya:

1. Untuk *lag-1*, ambil nilai dari tahun sebelumnya.
Misalnya, nilai persentase kemiskinan 2014 (*t*) menggunakan data 2013 sebagai *lag-1*.
2. Untuk *lag-2*, ambil nilai dari dua tahun sebelumnya.
Misalnya, nilai tahun 2015 menggunakan data 2013 sebagai *lag-2*.

Contoh perhitungan untuk variabel persentase kemiskinan:

$$\text{Lag-1 tahun 2015} = \text{nilai tahun 2014} = 10,95$$

$$\text{Lag-2 tahun 2015} = \text{nilai tahun 2013} = 11,74$$

Contoh perhitungan untuk variabel jumlah penduduk miskin (ribu jiwa):

$$\text{Lag-1 tahun 2015} = \text{nilai tahun 2014} = 55,92$$

$$\text{Lag-2 tahun 2015} = \text{nilai tahun 2013} = 59,68$$

Langkah ini dilakukan untuk seluruh tahun mulai dari 2015, karena sebelum itu data belum memiliki dua tahun sebelumnya sebagai pembanding.

2. Menghitung Rata-rata Bergerak Dua Tahun (*Rolling Mean-2*)

Fitur *rolling mean* digunakan untuk menghaluskan perubahan dari tahun ke tahun agar model lebih stabil. Nilainya dihitung dari

rata-rata dua tahun sebelumnya menggunakan rumus:

$$RollingMean2_t = \frac{Y_{t-1} + Y_{t-2}}{2}. \quad (4.2)$$

Langkahnya:

1. Ambil nilai tahun sebelumnya ($lag-1$).
2. Ambil nilai dua tahun sebelumnya ($lag-2$).
3. Jumlahkan keduanya lalu bagi dua.

Contoh perhitungan untuk persentase kemiskinan:

Tahun 2017 $\rightarrow$

$$Y_{2016}^{(\%) } = 10.88, \quad Y_{2015}^{(\%) } = 10.89$$

$$RollingMean2_{2017}^{(\%) } = \frac{10.88 + 10.89}{2} = 10.885$$

Contoh perhitungan untuk jumlah penduduk miskin:

Tahun 2017 $\rightarrow$

$$Y_{2016}^{(J)} = 55.91, \quad Y_{2015}^{(J)} = 55.71$$

$$RollingMean2_{2017}^{(J)} = \frac{55.91 + 55.71}{2} = 55.81$$

Langkah ini diulang untuk setiap tahun mulai dari 2015 hingga 2024 baik untuk kolom persentase maupun jumlah.

3. Menambahkan Komponen Tren Waktu (t)

Komponen waktu dibuat dengan menggunakan tahun pengamatan asli (2013 sampai 2024). Nilai ini nantinya digunakan untuk melihat perubahan tren dari waktu ke waktu. Cara pengisiannya cukup sederhana dengan memasukkan nilai tahun ke dalam kolom baru tanpa perlu perhitungan tambahan.

Contoh:

Tahun 2013 $\rightarrow t = 2013$, Tahun 2014 $\rightarrow t = 2014$, dst.

4. Membuat Fitur Lag Silang (*Cross-lag*)

Fitur ini digunakan agar model dapat memperhitungkan pengaruh antara dua indikator yang saling berkaitan, yaitu antara jumlah penduduk miskin dan persentase penduduk miskin.

Langkahnya:

1. Saat memprediksi persentase kemiskinan, tambahkan kolom jumlah penduduk miskin tahun sebelumnya ($Y_{t-1}^{(J)}$) sebagai *cross-lag*.
2. Saat memprediksi jumlah penduduk miskin, tambahkan kolom persentase kemiskinan tahun sebelumnya ($Y_{t-1}^{(\%)}$) sebagai *cross-lag*.

Contoh: Untuk tahun 2017:

$$Y_{t-1}^{(\%)} = 10.88, \quad Y_{t-1}^{(J)} = 55.91$$

Maka:

- Jika model yang dibuat untuk persentase, maka *cross-lag*-nya adalah 55.91 (jumlah tahun sebelumnya).
- Jika model untuk jumlah, maka *cross-lag*-nya adalah 10.88 (persentase tahun sebelumnya).

Setelah seluruh fitur ini selesai dibentuk untuk setiap tahun, data kemudian siap digunakan untuk proses pemodelan regresi linear deret waktu pada tahap berikutnya. Langkah ini juga membantu memastikan bahwa setiap baris data sudah memiliki informasi yang lengkap mengenai kondisi masa lalu, tren, dan keterkaitan antarvariabel, sehingga model dapat belajar dengan lebih baik.

4.1.6 Hasil Pengolahan Data

Setelah proses pembentukan fitur deret waktu dilakukan, data awal telah dikembangkan menjadi bentuk yang lebih informatif. Setiap tahun kini tidak hanya berisi nilai kemiskinan pada tahun tersebut, tetapi juga mencakup nilai tahun-tahun sebelumnya (*lag*), rata-rata bergerak dua tahun terakhir (*rolling mean*), serta penanda waktu (*t*).

Fitur-fitur ini digunakan untuk membantu model regresi linear deret waktu mengenali pola hubungan antarperiode.

Berikut hasil pengolahan fitur untuk masing-masing variabel.

(a) Hasil Pengolahan Fitur Persentase Penduduk Miskin

Tabel berikut menunjukkan hasil pembentukan fitur *lag-1*, *lag-2*, dan *rolling mean-2* untuk variabel persentase penduduk miskin di Kota Surakarta tahun 2013–2024.

Tabel 4.2 Hasil Pengolahan Data Fitur Persentase Penduduk Miskin Kota Surakarta (2013–2024)

Tahun	Persentase Penduduk Miskin (%)	Lag-1 (%)	Lag-2 (%)	Rolling Mean-2 (%)
2013	11.74	–	–	–
2014	10.95	11.74	–	–
2015	10.89	10.95	11.74	11.35
2016	10.88	10.89	10.95	10.92
2017	10.65	10.88	10.89	10.885
2018	9.08	10.65	10.88	10.765
2019	8.70	9.08	10.65	9.865
2020	9.03	8.70	9.08	8.89
2021	9.40	9.03	8.70	8.865
2022	8.84	9.40	9.03	9.215
2023	8.44	8.84	9.40	9.12
2024	8.31	8.44	8.84	8.64

Dari tabel tersebut terlihat bahwa nilai *rolling mean-2* menampilkan pergerakan yang lebih halus dibandingkan nilai aslinya. Misalnya, pada tahun 2020 nilai persentase kemiskinan meningkat menjadi 9,03%, namun nilai rata-rata dua tahun sebelumnya (8,89%) memberikan gambaran tren yang lebih stabil. Fitur seperti ini akan membantu model mengenali kecenderungan tanpa terlalu terpengaruh oleh fluktuasi sesaat.

(b) Hasil Pengolahan Fitur Jumlah Penduduk Miskin (ribu jiwa)

Proses yang sama juga dilakukan untuk variabel jumlah penduduk miskin. Nilai yang digunakan sudah dikonversi ke satuan ribu jiwa, dan fitur *lag* serta *rolling mean-2* dihitung menggunakan rumus yang sama seperti pada variabel persentase.

Tabel 4.3 Hasil Pengolahan Data Fitur Jumlah Penduduk Miskin Kota Surakarta (2013–2024)

Tahun	Jumlah Penduduk Miskin (ribu jiwa)	Lag-1 (ribu)	Lag-2 (ribu)	Rolling Mean-2 (ribu)
2013	59.68	–	–	–
2014	55.92	59.68	–	–
2015	55.71	55.92	59.68	57.80
2016	55.91	55.71	55.92	55.815
2017	54.89	55.91	55.71	55.81
2018	46.99	54.89	55.91	55.40
2019	45.18	46.99	54.89	50.94
2020	47.03	45.18	46.99	46.085
2021	48.79	47.03	45.18	46.105
2022	45.90	48.79	47.03	47.91
2023	43.89	45.90	48.79	47.345
2024	43.28	43.89	45.90	44.895

Nilai rata-rata bergerak (*rolling mean-2*) pada tabel di atas menunjukkan perubahan yang lebih stabil dari waktu ke waktu. Misalnya, pada tahun 2019 jumlah penduduk miskin sebesar 45,18 ribu jiwa, namun rata-rata dua tahun sebelumnya (50,94 ribu jiwa) memperlihatkan kecenderungan penurunan yang lebih bertahap. Hal ini akan membantu model dalam mengenali pola jangka pendek dan tren umum secara lebih halus.

4.2 Pembentukan Model Regresi Linear Deret Waktu

Setelah data siap, langkah berikutnya adalah membentuk dua model regresi, yaitu:

- Model untuk persentase penduduk miskin,
- Model untuk jumlah penduduk miskin (ribu jiwa)

Semua koefisien diestimasi dengan OLS memakai data latih 2015–2023 (aturan *lag* sampai $t-2$, jadi efektif 9 baris latih). Tahun 2024 dipakai khusus untuk uji *holdout*.

Komponen *rolling mean 2-tahun* memiliki definisi

$$Y_{t,roll2} = \frac{1}{2}Y_{t-1} + \frac{1}{2}Y_{t-2}. \quad (4.3)$$

Artinya kolom *roll2* tepat merupakan gabungan linear dari kolom *lag-1* dan *lag-2*. Secara aljabar, ini membuat $X'X$ singular (tidak bisa di-*inverse* biasa). Dan solusinya menggunakan estimasi OLS pakai invers semu Moore–Penrose (*pseudoinverse*) supaya solusi

tetap terdefinisi dan stabil.

4.2.1 Model Persentase Penduduk Miskin

Pada tahap ini yang dilakukan yaitu membangun model untuk menjelaskan persentase penduduk miskin setiap tahun. Idenya sederhana biasanya nilai tahun ini berhubungan pada pola tahun-tahun sebelumnya (ada inersia), ada kecenderungan umum dari waktu ke waktu (tren), dan ada keterkaitan dengan jumlah penduduk miskin (karena proporsi dan jumlah saling memengaruhi).

Sesuai rumus 3.11 yang telah ditetapkan di Bab 3, bentuk modelnya adalah:

$$Y_t^{(\%) } = \beta_0 + \beta_1 Y_{t-1}^{(\%) } + \beta_2 Y_{t-2}^{(\%) } + \beta_3 Y_{t,\text{roll}2}^{(\%) } + \beta_4 t + \beta_5 Y_{t-1}^{(J)} + \varepsilon_t. \quad (4.4)$$

Di sini:

- $Y_t^{(\%)}$ adalah persentase pada tahun ke- t ,
- $Y_{t-1}^{(\%)}$ dan $Y_{t-2}^{(\%)}$ adalah *lag* satu dan dua tahun,
- $Y_{t,\text{roll}2}^{(\%) } = \frac{Y_{t-1}^{(\%) } + Y_{t-2}^{(\%) }}{2}$ adalah rata-rata bergerak dua tahun,
- t adalah indeks waktu,
- $Y_{t-1}^{(J)}$ adalah jumlah penduduk miskin tahun sebelumnya (dalam ribu jiwa) sebagai *lag silang* (*cross-lag*),
- ε_t adalah galat.

Secara intuitif, tiga blok pertama $Y_{t-1}, Y_{t-2}, Y_{t,\text{roll}2}$ menangkap memori jangka pendek data (pola antarperiode yang berdekatan), t menangkap arah umum (apakah turun perlahan atau naik), dan $Y_{t-1}^{(J)}$ membantu model melihat indikator kembarannya (jumlah) agar proyeksi proporsi tidak berdiri sendiri.

(a) Menyusun Matriks

Supaya estimasi koefisiennya transparan, langkah yang dilakukan yaitu mengubah model di atas ke bentuk linear-aljabar. Untuk tahun efektif 2015–2023 (9 baris data karena butuh *lag* sampai dua tahun), maka dibentuk:

$$y = \begin{bmatrix} Y_{2015}^{(\%)}) \\ \vdots \\ Y_{2023}^{(\%)}) \end{bmatrix} \in \mathbb{R}^{9 \times 1}, \quad X = \begin{bmatrix} 1 & Y_{2014}^{(\%)}) & Y_{2013}^{(\%)}) & Y_{2015, \text{roll2}}^{(\%)}) & 2015 & Y_{2014}^{(J)}) \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & Y_{2022}^{(\%)}) & Y_{2021}^{(\%)}) & Y_{2023, \text{roll2}}^{(\%)}) & 2023 & Y_{2022}^{(J)}) \end{bmatrix} \in \mathbb{R}^{9 \times 6}.$$

Kolom-kolom X berurutan: konstanta, *lag-1*, *lag-2*, *roll2*, tahun, dan *cross-lag* jumlah. Dengan notasi ini, rumus OLS menjadi:

$$\hat{\beta} = X^+ y, \quad \text{dengan } X^+ \text{ adalah pseudoinvers (Moore–Penrose).} \quad (4.5)$$

Metode OLS pada dasarnya menggunakan rumus

$$(X'X)^{-1}X'y.$$

Namun, pada model ini matriks $X'X$ tidak bisa di-*inverse* karena salah satu variabel, yaitu *rolling mean-2*, merupakan gabungan langsung dari dua variabel *lag* sebelumnya. Secara matematis,

$$Y_{t, \text{roll2}} = \frac{1}{2}Y_{t-1} + \frac{1}{2}Y_{t-2}.$$

Hal ini membuat kolom *roll2* menjadi kombinasi linear sempurna dari kolom *lag-1* dan *lag-2*, sehingga matriks X kehilangan satu derajat kebebasan (tidak penuh). Untuk mengatasinya, digunakan pseudoinvers Moore–Penrose, yang tetap dapat menghasilkan solusi OLS secara stabil dan memberikan nilai koefisien yang paling efisien.

(b) Menghitung Matriks

Hasil penggandaan matriks untuk data 2015–2023 adalah:

$$X'X \approx \begin{bmatrix} 9 & 88.42 & 91.32 & 89.87 & 18,171 & 456.32 \\ 88.42 & 876.4744 & 904.3907 & 890.4326 & 178,501.42 & 4,520.6833 \\ 91.32 & 904.3907 & 936.1564 & 920.2736 & 184,353.78 & 4,664.4610 \\ 89.87 & 890.4326 & 920.2736 & 905.3531 & 181,427.60 & 4,592.5722 \\ 18,171 & 178,501.42 & 184,353.78 & 181,427.60 & 36,687,309 & 921,221.77 \\ 456.32 & 4,520.6833 & 4,664.4610 & 4,592.5722 & 921,221.77 & 23,317.8782 \end{bmatrix},$$

$$X'y \approx \begin{bmatrix} 85.91 \\ 850.4473 \\ 877.3421 \\ 863.8947 \\ 173,433.82 \\ 4,386,506.3 \end{bmatrix}$$

Determinan-nya nol, menegaskan persoalan identifikasi tadi. Dengan X^+ maka diperoleh koefisien:

$$\begin{aligned}\hat{\beta}_0 &= 516.66735, \\ \hat{\beta}_1 &= 10.68188 \ (Y_{t-1}^{(\%)}) , \\ \hat{\beta}_2 &= -2.83454 \ (Y_{t-2}^{(\%)}) , \\ \hat{\beta}_3 &= 3.92367 \ (Y_{t,roll2}^{(\%)}) , \\ \hat{\beta}_4 &= -0.247890 \ (t), \\ \hat{\beta}_5 &= -2.406095 \ (Y_{t-1}^{(J)}).\end{aligned}$$

Perlu diperhatikan bahwa variabel jumlah penduduk miskin disimpan dalam satuan ribu jiwa. Oleh karena itu, nilai koefisien $\hat{\beta}_5$ yang diperoleh sebesar sekitar -2.406 . Jika variabel tersebut dinyatakan dalam satuan jiwa, maka koefisiennya menjadi -0.002406 . Secara ekonomi, keduanya memiliki makna yang sama; perbedaannya hanya terletak pada skala satuan data yang digunakan.

Dengan demikian, bentuk akhir model regresi untuk

persentase penduduk miskin dapat dituliskan sebagai:

$$\hat{Y}_t^{(\%) } = 516.66735 + 10.68188 Y_{t-1}^{(\%) } - 2.83454 Y_{t-2}^{(\%) } + 3.92367 Y_{t,\text{roll}2}^{(\%) } - 0.247890 t - 2.406095 Y_{t-1}^{(J)} . \quad (4.6)$$

Contoh Perhitungan Manual (Tahun 2017).

Sebagai contoh penerapan, berikut perhitungan model untuk tahun 2017 menggunakan data dalam sampel pelatihan:

$$Y_{2016}^{(\%) } = 10.88, \quad Y_{2015}^{(\%) } = 10.89, \quad Y_{2017,\text{roll}2}^{(\%) } = \frac{10.88 + 10.89}{2} = 10.885, \\ t = 2017, \quad Y_{2016}^{(J)} = 55.91 \text{ (ribu jiwa)}. \quad (4.7)$$

Dengan memasukkan nilai tersebut ke dalam persamaan 4.6, diperoleh:

$$\hat{Y}_{2017}^{(\%) } = 516.66735 + 10.68188(10.88) - 2.83454(10.89) + 3.92367 \\ (10.885) - 0.247890(2017) - 2.406095(55.91) \\ \approx 10.208 \%. \quad (4.8)$$

Nilai tersebut merupakan hasil estimasi model pada data pelatihan (bukan hasil peramalan). Langkah perhitungan ini dituliskan secara terperinci agar pembaca dapat memahami bagaimana setiap koefisien berkontribusi dalam menentukan nilai prediksi pada tahun yang bersangkutan.

4.2.2 Model Jumlah Penduduk Miskin (ribu jiwa)

Bagian ini menjelaskan pembentukan model regresi untuk jumlah penduduk miskin. Secara logika, model ini bersifat simetris terhadap model sebelumnya, karena jumlah penduduk miskin pada tahun tertentu dipengaruhi oleh jumlah pada tahun-tahun sebelumnya, disertai adanya komponen tren jangka panjang. Selain itu, informasi dari persentase penduduk miskin tahun sebelumnya juga dimasukkan sebagai *cross-lag* agar kedua

indikator kemiskinan dapat saling menjelaskan dan memperkuat interpretasi model.

Sesuai dengan rumus 3.12, model yang digunakan adalah:

$$Y_t^{(J)} = \gamma_0 + \gamma_1 Y_{t-1}^{(J)} + \gamma_2 Y_{t-2}^{(J)} + \gamma_3 Y_{t, \text{roll}2}^{(J)} + \gamma_4 t + \gamma_5 Y_{t-1}^{(\%) } + \eta_t. \quad (4.9)$$

Komponen rata-rata bergerak dua tahun dihitung sebagai:

$$Y_{t, \text{roll}2}^{(J)} = \frac{Y_{t-1}^{(J)} + Y_{t-2}^{(J)}}{2}, \quad (4.10)$$

yang berfungsi untuk menghaluskan fluktuasi jangka pendek. Dengan struktur yang sama seperti model persentase, vektor dan matriks yang digunakan disusun sebagai berikut:

$$y = \begin{bmatrix} Y_{2015}^{(J)} \\ Y_{2016}^{(J)} \\ \vdots \\ Y_{2023}^{(J)} \end{bmatrix}, \quad X = \begin{bmatrix} 1 & Y_{t-1}^{(J)} & Y_{t-2}^{(J)} & Y_{t, \text{roll}2}^{(J)} & t & Y_{t-1}^{(\%) } \end{bmatrix}.$$

Karena variabel *rolling mean-2* merupakan kombinasi linear sempurna dari lag-1 dan lag-2, maka matriks $X'X$ menjadi *singular*, sehingga tidak dapat di-invers secara langsung. Oleh karena itu, estimasi parameter dilakukan menggunakan *pseudoinvers* (Moore–Penrose) X^+ agar solusi tetap dapat dihitung secara stabil.

Hasil perhitungan matriks (dibulatkan untuk memudahkan pembacaan) ditunjukkan sebagai berikut:

$$X'X \approx \begin{bmatrix} 9 & 456.32 & 470.10 & 463.21 & 18,171 & 88.42 \\ 456.32 & 23,317.8782 & 23,997.4142 & 23,657.6462 & 921,221.77 & 4,520,683 \\ 470.10 & 23,997.4142 & 24,772.7706 & 24,385.0924 & 949,031.69 & 4,652,606 \\ 463.21 & 23,657.6462 & 24,385.0924 & 24,021.3693 & 935,126.73 & 4,586,645 \\ 18,171 & 921,221.77 & 949,031.69 & 935,126.73 & 36,687,309 & 178,501.42 \\ 88.42 & 4,520,683 & 4,652,606 & 4,586,645 & 178,501.42 & 876.4744 \end{bmatrix},$$

$$X'y \approx \begin{bmatrix} 444,290 \\ 22,674,659,600 \\ 23,330,665,000 \\ 23,002,662,300 \\ 896,932,040 \\ 4,395,947.8 \end{bmatrix}$$

Dari hasil estimasi dengan X^+y , diperoleh nilai koefisien (dalam satuan ribu jiwa) sebagai berikut:

$$\begin{aligned} \hat{\gamma}_0 &= 2,541.89350, \\ \hat{\gamma}_1 &= -9.07501 (Y_{t-1}^{(J)}), \\ \hat{\gamma}_2 &= 1.11008 (Y_{t-2}^{(J)}), \\ \hat{\gamma}_3 &= -3.98247 (Y_{t,roll2}^{(J)}), \\ \hat{\gamma}_4 &= -1.21750781 (t), \\ \hat{\gamma}_5 &= 58.2963498 (Y_{t-1}^{(\%)}) . \end{aligned}$$

Dengan demikian, bentuk akhir dari persamaan regresi jumlah penduduk miskin dapat dituliskan sebagai:

$$\begin{aligned} \hat{Y}_t^{(J)} &= 2,541.8935 - 9.0750 Y_{t-1}^{(J)} + 1.1101 Y_{t-2}^{(J)} - 3.9825 Y_{t,roll2}^{(J)} \\ &\quad - 1.2175 t + 58.2963 Y_{t-1}^{(\%)}. \end{aligned} \quad (4.11)$$

Interpretasi Koefisien.

Koefisien waktu ($\gamma_4 < 0$) menunjukkan adanya tren penurunan jangka panjang terhadap jumlah penduduk miskin, yang

konsisten dengan data historis periode 2013–2024.

Koefisien untuk persentase penduduk miskin tahun sebelumnya ($\gamma_5 > 0$) masuk akal secara ekonomi, ketika proporsi penduduk miskin pada tahun sebelumnya lebih tinggi, jumlah absolut penduduk miskin pada tahun berikutnya juga cenderung meningkat.

Tiga komponen memori (*lag-1*, *lag-2*, dan *rolling mean-2*) menunjukkan keseimbangan antara rata-rata dua tahun terakhir dan penyimpangan jangka pendek dari nilai tersebut, sehingga model mampu menangkap dinamika kemiskinan secara realistis.

Contoh Perhitungan Manual (Tahun 2017, dalam Sampel Pelatihan).

Untuk mengilustrasikan cara kerja model, digunakan data tahun 2017 dengan nilai sebagai berikut:

$$\begin{aligned} Y_{2016}^{(J)} &= 55.91, & Y_{2015}^{(J)} &= 55.71, \\ Y_{2017, \text{roll2}}^{(J)} &= \frac{55.91 + 55.71}{2} = 55.81, & t &= 2017, \\ Y_{2016}^{(\%)} &= 10.88. \end{aligned}$$

Dengan memasukkan nilai tersebut ke dalam persamaan 4.11, diperoleh:

$$\begin{aligned} \hat{Y}_{2017}^{(J)} &= 2,541.8935 - 9.0750(55.91) + 1.1101(55.71) - 3.9825(55.81) \\ &\quad - 1.2175(2017) + 58.2963(10.88) \\ &\approx 52.642 \text{ ribu jiwa.} \end{aligned} \tag{4.12}$$

Nilai hasil perhitungan ini diperoleh langsung dari substitusi semua komponen model, sehingga seluruh proses estimasi dapat ditelusuri secara transparan. Nilai tersebut menunjukkan hasil kecocokan model dalam data pelatihan dan belum termasuk hasil prediksi ke depan.

4.3 Analisis Ukuran Akurasi Model

Tahap ini bertujuan untuk menilai seberapa akurat model regresi linear deret waktu yang telah dibentuk dalam memprediksi kondisi kemiskinan Kota Surakarta. Evaluasi dilakukan menggunakan data tahun 2024 sebagai data uji (*holdout*) yang tidak dilibatkan saat pelatihan model. Dari hasil estimasi, model memberikan nilai prediksi sebesar 8,333% untuk persentase penduduk miskin dan 43,536 ribu jiwa untuk jumlah penduduk miskin.

Nilai-nilai tersebut tidak muncul secara langsung dari perangkat lunak, tetapi diperoleh melalui perhitungan manual dengan cara memasukkan variabel-variabel hasil olahan data ke dalam persamaan regresi yang telah diperoleh sebelumnya.

4.3.1 Perhitungan Prediksi Tahun 2024

(a) Model Persentase Penduduk Miskin

Model yang telah diestimasi pada tahap sebelumnya memiliki bentuk sebagai berikut:

$$\begin{aligned}\hat{Y}_t^{(\%) } &= 516.66735 + 10.68188Y_{t-1}^{(\%) } - 2.83454Y_{t-2}^{(\%) } \\ &\quad + 3.92367Y_{t,\text{roll}2}^{(\%) } - 0.247890t - 2.406095Y_{t-1}^{(J)}\end{aligned}\quad (4.13)$$

Untuk tahun 2024, digunakan data historis sebagai berikut:

$$\begin{aligned}Y_{t-1}^{(\%) } &= Y_{2023}^{(\%) } = 8.44, & Y_{t-2}^{(\%) } &= Y_{2022}^{(\%) } = 8.84, \\ Y_{t,\text{roll}2}^{(\%) } &= \frac{Y_{t-1}^{(\%) } + Y_{t-2}^{(\%) }}{2} = \frac{8.44 + 8.84}{2} = 8.64, & t &= 2024, \\ Y_{t-1}^{(J)} &= Y_{2023}^{(J)} = 43.89 \text{ (ribu jiwa)}.\end{aligned}$$

Dengan demikian, prediksi untuk tahun 2024 dihitung sebagai

berikut:

$$\begin{aligned}
 \hat{Y}_{2024}^{(\%)} &= 516.66735 + 10.68188(8.44) - 2.83454(8.84) + 3.92367(8.64) \\
 &\quad - 0.247890(2024) - 2.406095(43.89) \\
 &= 516.66735 + 90.15507 - 25.05733 + 33.90051 - 501.72936 \\
 &\quad - 105.60351 \\
 &= 8.33272 \approx 8.333\%.
 \end{aligned}$$

Setelah dibulatkan, diperoleh hasil:

$$\hat{Y}_{2024}^{(\%)} = 8.333\%$$

Artinya, menurut hasil model, tingkat kemiskinan Kota Surakarta pada tahun 2024 diperkirakan sebesar 8,333%, yang sangat mendekati nilai aktual 8,31% dari data BPS.

(b) Model Jumlah Penduduk Miskin

Model regresi untuk jumlah penduduk miskin dituliskan sebagai berikut:

$$\begin{aligned}
 \hat{Y}_t^{(J)} &= 2,541.8935 - 9.0750 Y_{t-1}^{(J)} + 1.1101 Y_{t-2}^{(J)} - 3.9825 Y_{t, \text{roll}2}^{(J)} \\
 &\quad - 1.2175 t + 58.2963 Y_{t-1}^{(\%)} .
 \end{aligned} \tag{4.14}$$

Dengan data historis tahun sebelumnya:

$$Y_{t-1}^{(J)} = Y_{2023}^{(J)} = 43.89, \quad Y_{t-2}^{(J)} = Y_{2022}^{(J)} = 45.90,$$

$$Y_{t, \text{roll}2}^{(J)} = \frac{Y_{t-1}^{(J)} + Y_{t-2}^{(J)}}{2} = \frac{43.89 + 45.90}{2} = 44.895,$$

$$t = 2024, \quad Y_{t-1}^{(\%)} = Y_{2023}^{(\%)} = 8.44.$$

Langkah perhitungannya sebagai berikut:

$$\begin{aligned}\hat{Y}_{2024}^{(J)} &= 2,541.8935 - 9.0750(43.89) + 1.1101(45.90) \\ &\quad - 3.9825(44.895) - 1.21750781(2024) + 58.2963498(8.44) \\ &= 2,541.8935 - 398.3018 + 50.9536 - 178.7943 \\ &\quad - 2,464.2358 + 492.0212 \\ &= 43.5364.\end{aligned}$$

Dari hasil tersebut, diperoleh:

$$\hat{Y}_{2024}^{(J)} = 43.536 \text{ ribu jiwa}$$

Sehingga model memprediksi jumlah penduduk miskin tahun 2024 sebesar 43,536 ribu jiwa, sangat dekat dengan data aktual 43,28 ribu jiwa.

4.3.2 Penghitungan Nilai MAE, RMSE, dan MAPE

Setelah nilai prediksi diperoleh, dilakukan pengukuran akurasi dengan menghitung besarnya kesalahan antara nilai aktual dan prediksi.

Tabel 4.4 Perbandingan Nilai Aktual dan Prediksi (2024)

Model	Nilai Aktual (2024)	Nilai Prediksi Model	Selisih (Error)
Persentase Penduduk Miskin (%)	8.31	8.333	-0.023
Jumlah Penduduk Miskin (ribu jiwa)	43.28	43.536	+0.256

(a) *Mean Absolute Error (MAE)*

Rumus:

$$MAE = \frac{1}{n} \sum |y_i - \hat{y}_i|. \quad (4.15)$$

Karena hanya ada satu data uji (2024):

$$\begin{aligned}MAE_{\text{persen}} &= |8.31 - 8.333| = 0.023, \\ MAE_{\text{jumlah}} &= |43.28 - 43.536| = 0.256.\end{aligned}$$

(b) *Root Mean Square Error (RMSE)*

Rumus:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2}. \quad (4.16)$$

Untuk satu data uji:

$$\text{RMSE}_{\text{persen}} = (8.31 - 8.333)^2 = 0.023,$$

$$\text{RMSE}_{\text{jumlah}} = (43.28 - 43.536)^2 = 0.256.$$

(c) *Mean Absolute Percentage Error (MAPE)*

Rumus:

$$\text{MAPE} = 100\% \times \frac{1}{n} \sum \left| \frac{y_i - \hat{y}_i}{y_i} \right|. \quad (4.17)$$

Perhitungan:

$$\text{MAPE}_{\text{persen}} = \frac{|8.31 - 8.333|}{8.31} \times 100\% = 0.28\%,$$

$$\text{MAPE}_{\text{jumlah}} = \frac{|43.28 - 43.536|}{43.28} \times 100\% = 0.59\%.$$

4.3.3 Hasil Evaluasi dan Pembahasan

Nilai-nilai akurasi model dibandingkan dengan model pembanding sederhana (*Naive* dan *Dummy Mean*) dapat dilihat pada tabel berikut:

Tabel 4.5 Perbandingan Akurasi Model

Model	MAE	RMSE	MAPE	Keterangan
Regresi Linear (Persentase)	0.023	0.023	0.28%	Sangat akurat
Regresi Linear (Jumlah)	0.256	0.256	0.59%	Sangat akurat
Model Naive (Lag-1)	0.13	0.13	1.56%	Cukup baik
Model Rata-rata	1.56	1.56	17.2%	Tidak akurat

Dari hasil di atas terlihat bahwa model regresi linear deret waktu memberikan hasil jauh lebih baik dibandingkan dua model pembanding. Kesalahan rata-rata absolut (MAE) hanya 0,023 poin persen untuk persentase kemiskinan dan 0,256 ribu jiwa untuk

jumlah penduduk miskin. Dalam konteks sosial ekonomi, angka ini tergolong sangat kecil sehingga dapat disimpulkan bahwa model telah bekerja dengan akurasi tinggi.

Jika dilihat secara relatif, tingkat kesalahan model (MAPE) hanya 0,28% dan 0,59%. Artinya, prediksi model mendekati nilai sebenarnya dengan tingkat akurasi mencapai lebih dari 99%. Hasil ini menunjukkan bahwa model mampu menangkap hubungan antarperiode waktu (*lag*), tren tahunan, serta pengaruh silang antarvariabel dengan baik.

Selain itu, hasil prediksi model tetap mengikuti arah tren historis yang menurun dari tahun ke tahun. Nilai prediksi 2024 yang sedikit lebih rendah daripada tahun 2023 selaras dengan data nyata BPS, yang memang menunjukkan penurunan kemiskinan pada periode tersebut.

4.4 Analisis dan Pembahasan

Bagian ini berisi pembahasan terhadap hasil pemodelan regresi linear deret waktu yang telah dilakukan. Analisis dilakukan untuk melihat bagaimana model bekerja, seberapa besar tingkat akurasi yang dihasilkan, dan bagaimana hubungan antarvariabel di dalam model dapat menjelaskan pola kemiskinan di Kota Surakarta selama periode pengamatan.

4.4.1 Analisis Hasil Model

Dari hasil estimasi parameter yang telah diperoleh sebelumnya, model regresi linear deret waktu mampu memberikan hasil prediksi yang sangat mendekati nilai sebenarnya. Model menghasilkan nilai prediksi 8,333% untuk persentase penduduk miskin dan 43,536 ribu jiwa untuk jumlah penduduk miskin pada tahun 2024. Sementara itu, data aktual dari BPS menunjukkan nilai 8,31% dan 43,28 ribu jiwa. Selisih antara hasil model dengan data sebenarnya sangat kecil, yaitu hanya sekitar 0,023 poin persen untuk persentase dan 0,256 ribu jiwa untuk jumlah penduduk miskin.

Hasil ini menunjukkan bahwa model mampu mengenali pola historis kemiskinan dengan baik. Nilai prediksi yang hampir

sama dengan data aktual menandakan bahwa model sudah cukup stabil dan dapat menangkap hubungan antarperiode waktu secara konsisten. Dengan demikian, model ini dinilai layak untuk digunakan dalam tahap peramalan berikutnya.

4.4.2 Analisis Komponen Model

Berdasarkan hasil perhitungan parameter, dapat dilihat bahwa masing-masing komponen dalam model memiliki peranan tertentu terhadap hasil prediksi:

Komponen Tren (t)

Nilai koefisien waktu yang negatif pada kedua model menunjukkan adanya kecenderungan penurunan tingkat kemiskinan dari tahun ke tahun. Artinya, arah perubahan kemiskinan selama periode pengamatan cenderung menurun dan model mampu menangkap kecenderungan tersebut melalui variabel tren.

Komponen Lag-1 dan Lag-2

Lag-1 memiliki pengaruh positif yang cukup besar, yang menunjukkan bahwa kondisi kemiskinan pada tahun sebelumnya sangat berpengaruh terhadap tahun berikutnya. Sedangkan lag-2 cenderung memiliki pengaruh negatif, menandakan bahwa pengaruh data dua tahun sebelumnya mulai berkurang. Kombinasi keduanya membantu model mengenali dinamika jangka pendek dan jangka menengah.

Komponen Rata-rata Bergerak (Roll-2)

Komponen ini membantu menghaluskan fluktuasi antarperiode. Nilai koefisien yang positif menunjukkan bahwa model mengikuti arah tren rata-rata dua tahun terakhir, sehingga tidak terlalu terpengaruh oleh perubahan ekstrem di satu tahun tertentu.

Komponen Cross-lag

Hubungan silang antarvariabel juga terbukti berpengaruh. Pada model persentase, nilai koefisien silang (jumlah penduduk miskin tahun sebelumnya) bernilai negatif, sedangkan pada model jumlah bernilai positif. Ini berarti bahwa perubahan pada satu indikator

turut berpengaruh terhadap indikator lainnya secara berlawanan arah, sehingga kedua model saling melengkapi.

4.4.3 Perbandingan dengan Model Pembanding

Untuk memastikan bahwa hasil model tidak hanya kebetulan, dilakukan perbandingan dengan dua model sederhana, yaitu model *Naive* (lag-1) dan model Rata-rata (*dummy mean*). Model *Naive* menggunakan nilai tahun sebelumnya sebagai prediksi, sedangkan model Rata-rata menggunakan rata-rata seluruh data latih.

Dari hasil perbandingan, model regresi linear memberikan nilai kesalahan (MAE dan RMSE) yang jauh lebih kecil dibandingkan kedua model tersebut. Model regresi menghasilkan MAE sebesar 0,023 untuk persentase dan 0,256 untuk jumlah penduduk miskin, sedangkan model *Naive* memiliki kesalahan masing-masing 0,13 dan 0,61. Model Rata-rata justru menunjukkan galat paling besar.

Perbandingan ini memperlihatkan bahwa model regresi linear jauh lebih akurat dan mampu menangkap hubungan antarperiode dengan lebih baik daripada model sederhana yang hanya melihat satu nilai masa lalu.

4.4.4 Evaluasi Akurasi dan Konsistensi Model

Hasil pengujian menunjukkan bahwa model memiliki tingkat akurasi yang tinggi dengan nilai MAPE di bawah 1%. Kesalahan sebesar 0,28% untuk persentase dan 0,59% untuk jumlah penduduk miskin termasuk sangat kecil untuk data tahunan. Hal ini menandakan bahwa model tidak hanya menyesuaikan diri dengan data masa lalu (*fit* terhadap data latih), tetapi juga mampu memprediksi data baru secara akurat (data uji 2024).

Selain itu, nilai MAE dan RMSE yang hampir sama menandakan tidak adanya kesalahan ekstrem dalam model, atau dengan kata lain, prediksi yang dihasilkan stabil di seluruh periode. Pola hasil prediksi juga tetap mengikuti arah tren penurunan kemiskinan yang terjadi dalam data aktual, sehingga model dapat dikatakan konsisten secara statistik maupun logis.

4.4.5 Kesimpulan Pembahasan

Dari hasil keseluruhan analisis pada bagian ini dapat disimpulkan bahwa:

1. Model regresi linear deret waktu yang dibangun mampu menghasilkan prediksi yang sangat mendekati nilai sebenarnya.
2. Komponen lag, rata-rata bergerak, tren, dan cross-lag berperan penting dalam menjelaskan hubungan antarperiode waktu.
3. Model menunjukkan performa yang jauh lebih baik dibandingkan model sederhana, dengan tingkat kesalahan prediksi di bawah 1%.

Berdasarkan hasil evaluasi, model ini dinilai sudah valid dan dapat digunakan untuk melakukan prediksi satu langkah ke depan, yaitu tahun 2025, yang akan dibahas pada bagian berikutnya.

4.5 Prediksi Tahun 2025 (*One-Step Forecast*)

Subbab ini memaparkan peramalan untuk tahun 2025 dengan langkah: (i) menyusun fitur deret waktu untuk seluruh periode 2013–2025, (ii) melatih ulang (*refit*) model regresi linear menggunakan data efektif 2015–2024 (butuh *lag* hingga $t - 2$), (iii) membentuk baris fitur 2025 dari data 2023–2024, dan (iv) menghitung prediksi satu langkah ke depan.

Karena di sini fitur rolling-2 merupakan kombinasi linear tepat dari $lag-1$ dan $lag-2$, matriks $\mathbf{X}'\mathbf{X}$ menjadi singular. Estimasi koefisien dilakukan dengan invers semu Moore–Penrose (*pseudoinverse*), yaitu

$$\hat{\theta} = \mathbf{X}^+ \mathbf{y}.$$

4.5.1 Contoh Penyusunan Fitur

(a) Target persentase

Kolom fitur: $[1, Y_{t-1}(\%), Y_{t-2}(\%), Y_{t,\text{roll}2}(\%), t, Y_{t-1}^{(J)}]$.

Tabel 4.6 Contoh Pembentukan Variabel Input Model Persentase Penduduk Miskin

Tahun	t	$Y_t(\%)$	$Y_{t-1}(\%)$	$Y_{t-2}(\%)$	$Y_{t,roll2}(\%)$	$Y_{t-1}^{(J)}(\text{ribu})$
2021	8	9.40	9.03	8.70	8.865	47.03
2022	9	8.84	9.40	9.03	9.215	48.79
2023	10	8.44	8.84	9.40	9.12	45.90
2024	11	8.31	8.44	8.84	8.640	43.89

$$Y_{t,roll2}(\%) = \frac{1}{2}(Y_{t-1}(\%) + Y_{t-2}(\%)).$$

(b) Target jumlah

Kolom fitur: $[1, Y_{t-1}^{(J)}, Y_{t-2}^{(J)}, Y_{t,roll2}^{(J)}, t, Y_{t-1}(\%)]$.

Tabel 4.7 Contoh Pembentukan Variabel Input Model Jumlah Penduduk Miskin (ribu jiwa)

Tahun	t	$Y_t^{(J)}$	$Y_{t-1}^{(J)}$	$Y_{t-2}^{(J)}$	$Y_{t,roll2}^{(J)}$	$Y_{t-1}(\text{persen})$
2021	8	48.79	47.03	45.18	46.105	9.03
2022	9	45.90	48.79	47.03	47.91	9.40
2023	10	43.89	45.90	48.79	47.345	8.84
2024	11	43.28	43.89	45.90	44.895	8.44

$$Y_{t,roll2}^{(J)} = \frac{1}{2}(Y_{t-1}^{(J)} + Y_{t-2}^{(J)}).$$

Semua baris 2015–2024 dibentuk dengan pola yang sama seperti contoh di atas; tabel penuh tidak ditampilkan agar tidak berulang.

4.5.2 Penurunan Koefisien OLS (2015–2024)

(a) Model Persentase

Vektor target $\mathbf{y} \in \mathbb{R}^{10 \times 1}$:

$$[10.89, 10.88, 10.65, 9.08, 8.70, 9.03, 9.40, 8.84, 8.44, 8.31]'$$

Hasil perkalian (pembulatan 2–4 desimal):

$$X'X \approx \begin{bmatrix} 10 & 96.86 & 100.16 & 98.51 & 65 & 500.21 \\ 96.86 & 947.7080 & 979.0003 & 963.3542 & 604.8 & 4891.1149 \\ 100.16 & 979.0003 & 1014.3020 & 996.6512 & 623.86 & 5052.4486 \\ 98.51 & 963.3542 & 996.6512 & 980.0027 & 614.33 & 4971.7818 \\ 65 & 604.8 & 623.86 & 614.33 & 505 & 3132.4 \\ 500.21 & 4891.1149 & 5052.4486 & 4971.7818 & 3132.4 & 25244.2103 \end{bmatrix},$$

$$X'y \approx \begin{bmatrix} 94.22 \\ 920.5837 \\ 950.8025 \\ 935.6931 \\ 588.40 \\ 4751.2322 \end{bmatrix}$$

Dari hasil estimasi dengan X^+y , diperoleh nilai koefisien (dalam satuan ribu jiwa) sebagai berikut:

$$\begin{aligned}\hat{\beta}_0 &= 17.64337, \\ \hat{\beta}_1 &= 10.56752, \\ \hat{\beta}_2 &= -2.81135, \\ \hat{\beta}_3 &= 3.87809, \\ \hat{\beta}_4 &= -0.250913, \\ \hat{\beta}_5 &= -2.37884.\end{aligned}$$

Sehingga persamaan model:

$$\begin{aligned}\hat{Y}_t^{(\%) } &= 17.64337 + 10.56752 Y_{t-1}^{(\%) } - 2.81135 Y_{t-2}^{(\%) } \\ &+ 3.87809 Y_{t,\text{roll}2}^{(\%) } - 0.250913 t - 2.37884 Y_{t-1}^{(J)}.\end{aligned}\quad (4.18)$$

(b) Model Jumlah

Vektor target $\mathbf{y} \in \mathbb{R}^{10 \times 1}$:

$$[55.71, 55.91, 54.89, 46.99, 45.18, \\ 47.03, 48.79, 45.90, 43.89, 43.28]'$$

Hasil perkalian (pembulatan 2–4 desimal):

$$\mathbf{X}'\mathbf{X} \approx \begin{bmatrix} 10 & 500.21 & 516.00 & 508.105 & 65 & 96.86 \\ 500.21 & 25244.2103 & 26011.9652 & 25628.0877 & 3132.4 & 4891.1149 \\ 516.00 & 26011.9652 & 26879.5806 & 26445.7729 & 3225.29 & 5040.0023 \\ 508.105 & 25628.0877 & 26445.7729 & 26036.9303 & 3178.845 & 4965.5586 \\ 65 & 3132.4 & 3225.29 & 3178.845 & 505 & 604.8 \\ 96.86 & 4891.1149 & 5040.0023 & 4965.5586 & 604.8 & 947.7080 \end{bmatrix},$$

$$\mathbf{X}'\mathbf{y} \approx \begin{bmatrix} 487.57 \\ 24574.2188 \\ 25317.2170 \\ 24945.7179 \\ 3052.35 \\ 4761.2310 \end{bmatrix}$$

Dengan $\hat{\gamma} = \mathbf{X}^+\mathbf{y}$ (pseudoinverse), koefisien:

$$\hat{\gamma}_0 = 90.77739,$$

$$\hat{\gamma}_1 = -8.81614,$$

$$\hat{\gamma}_2 = 1.05949,$$

$$\hat{\gamma}_3 = -3.87833,$$

$$\hat{\gamma}_4 = -1.25122,$$

$$\hat{\gamma}_5 = 56.73081.$$

Sehingga persamaan model:

$$\hat{Y}_t^{(J)} = 90.77739 - 8.81614 Y_{t-1}^{(J)} + 1.05949 Y_{t-2}^{(J)} \\ - 3.87833 Y_{t,\text{roll}2}^{(J)} - 1.25122 t + 56.73081 Y_{t-1}^{(\%)}. \quad (4.19)$$

4.5.3 Pembentukan Baris Fitur 2025 & Prediksi Manual

Dengan definisi t indeks deret (2013= 0), maka 2025 $\rightarrow t = 12$. Fitur 2025 dihitung dari dua tahun terakhir (2023–2024).

(a) Prediksi persentase 2025

Nilai fitur 2025:

$$\begin{aligned} Y_{t-1}(\%) &= Y_{2024}(\%) &&= 8.31, \\ Y_{t-2}(\%) &= Y_{2023}(\%) &&= 8.44, \\ Y_{t,\text{roll}2}(\%) &= \frac{1}{2}(8.31 + 8.44) &&= 8.375, \\ t &&&= 12, \\ Y_{t-1}^{(J)} &= Y_{2024}^{(J)} &&= 43.28 \text{ ribu.} \end{aligned}$$

Substitusi ke 4.18 dan jumlahkan kontribusi per suku:

$$\begin{aligned} \hat{Y}_{2025}(\%) &= \underbrace{17.64337}_{\text{konst}} + \underbrace{10.56752 \times 8.31}_{87.81611} - \underbrace{2.81135 \times 8.44}_{23.72777} \\ &\quad + \underbrace{3.87809 \times 8.375}_{32.47898} - \underbrace{0.250913 \times 12}_{3.01096} - \underbrace{2.37884 \times 43.28}_{102.95626} \\ &= 8.24346 \Rightarrow \hat{Y}_{2025}(\%) \approx 8.243\%. \end{aligned} \tag{4.20}$$

(b) Prediksi jumlah 2025 (ribu jiwa)

Nilai fitur 2025:

$$\begin{aligned} Y_{t-1}^{(J)} &= Y_{2024}^{(J)} &&= 43.28, \\ Y_{t-2}^{(J)} &= Y_{2023}^{(J)} &&= 43.89, \\ Y_{t,\text{roll}2}^{(J)} &= \frac{1}{2}(43.28 + 43.89) &&= 43.585, \\ t &&&= 12, \\ Y_{t-1}(\%) &= Y_{2024}(\%) &&= 8.31. \end{aligned}$$

Substitusi ke 4.19 dan jumlahkan kontribusi per suku:

$$\begin{aligned}\hat{Y}_{2025}^{(J)} &= \underbrace{90.77739}_{\text{konst}} - \underbrace{8.81614 \times 43.28}_{381.56246} + \underbrace{1.05949 \times 43.89}_{46.50092} \\ &\quad - \underbrace{3.87833 \times 43.585}_{169.03680} - \underbrace{1.25122 \times 12}_{15.01461} + \underbrace{56.73081 \times 8.31}_{471.43304} \\ &= 43.09748 \Rightarrow \hat{Y}_{2025}^{(J)} \approx 43.097 \text{ ribu jiwa.}\end{aligned}\tag{4.21}$$

4.5.4 Hasil dan Pembahasan Prediksi

Hasil akhir prediksi tahun 2025

$$\hat{Y}_{2025}^{(P)} (\%) \approx 8.243\%, \quad \hat{Y}_{2025}^{(J)} \approx 43.097 \text{ ribu jiwa.}$$

Pembahasan

Berdasarkan hasil perhitungan dan pelatihan ulang model hingga tahun 2024, diperoleh prediksi bahwa persentase penduduk miskin Kota Surakarta pada tahun 2025 sebesar 8,243%, sementara jumlah penduduk miskin diperkirakan sekitar 43,097 ribu jiwa. Kedua nilai tersebut menunjukkan adanya penurunan kecil jika dibandingkan dengan kondisi tahun 2024, yaitu 8,31% untuk persentase dan 43,28 ribu jiwa untuk jumlah. Selisihnya relatif kecil, yakni sekitar 0,067 poin persentase untuk proporsi kemiskinan dan 0,183 ribu jiwa (sekitar 183 orang) untuk jumlah absolut. Penurunan ini menggambarkan kecenderungan bahwa tingkat kemiskinan di Surakarta terus menurun secara perlahan, tanpa terjadi perubahan yang terlalu tajam antarperiode.

Secara matematis, perubahan ini dapat dijelaskan oleh kombinasi pengaruh variabel *lag* dan komponen tren dalam model. Pada model persentase, hasil prediksi cenderung menurun karena adanya dua komponen dengan koefisien negatif, yaitu tren waktu dan *lag* silang jumlah penduduk miskin. Meskipun variabel *lag-1* dan rata-rata bergerak dua tahun terakhir (*rolling-2*) memberikan dorongan positif terhadap nilai prediksi, efek tren dan *cross-lag* yang bernilai negatif cukup kuat untuk menahan laju kenaikan sehingga hasil akhirnya sedikit lebih rendah dari

tahun sebelumnya. Pola ini menunjukkan bahwa model mampu menangkap kecenderungan alami data, yaitu penurunan secara bertahap yang masih dalam batas wajar.

Sementara pada model jumlah penduduk miskin, pengaruh terbesar justru berasal dari variabel silang, yakni persentase kemiskinan tahun sebelumnya, yang memberikan dorongan positif cukup besar terhadap hasil prediksi. Namun, efek tersebut diimbangi oleh tiga komponen negatif lainnya, yaitu *lag-1* jumlah, rata-rata bergerak (*roll2*), dan tren waktu, yang secara keseluruhan menurunkan nilai prediksi akhir hingga menjadi sekitar 43,097 ribu jiwa. Hal ini menunjukkan bahwa model bekerja secara seimbang dengan mempertimbangkan hubungan timbal balik antarvariabel dan memperhitungkan kecenderungan waktu secara proporsional.

Jika dibandingkan dengan rentang data pelatihan selama periode 2015–2024, hasil prediksi 2025 masih berada dalam kisaran yang masuk akal. Nilai 8,243% berada di dalam rentang historis antara 8,31% hingga 10,89%, sedangkan jumlah 43,097 ribu jiwa juga masih berada di bagian bawah kisaran 43,28–55,91 ribu jiwa. Dengan demikian, model tidak melakukan ekstrapolasi berlebihan dan tetap memprediksi dalam ruang data yang pernah dipelajari. Selain itu, definisi waktu t dalam model ini digunakan sebagai indeks berurutan (2013 = 0, 2025 = 12), sehingga hasil perhitungan tetap konsisten dengan proses pelatihan.

Secara keseluruhan, hasil prediksi tahun 2025 dapat dianggap realistis dan menggambarkan pola yang stabil. Model regresi linear deret waktu yang dibangun mampu menyesuaikan dengan perubahan tren secara halus serta mempertahankan akurasi prediksi tanpa menghasilkan lonjakan nilai yang tidak wajar. Pola yang ditunjukkan ini selaras dengan arah penurunan tingkat kemiskinan di Kota Surakarta yang telah berlangsung selama beberapa tahun terakhir.

4.6 Evaluasi dan Validasi Model

Bagian ini menjelaskan hasil penilaian terhadap kinerja model regresi linear deret waktu yang digunakan untuk memprediksi tingkat kemiskinan di Kota Surakarta. Evaluasi dilakukan untuk

melihat seberapa baik model dalam menebak nilai tahun 2024, apakah hasil prediksi tahun 2025 masih masuk akal, dan apakah model sudah memenuhi asumsi statistik dasar. Langkah ini penting agar hasil prediksi tidak hanya akurat di satu tahun, tetapi juga stabil dan bisa dipercaya untuk proyeksi jangka pendek.

4.6.1 Evaluasi Akurasi pada Data Uji (Tahun 2024)

Untuk menilai seberapa tepat model dalam memprediksi data, digunakan tiga ukuran kesalahan, yaitu:

- **MAE (*Mean Absolute Error*)**: rata-rata selisih absolut antara nilai aktual dan hasil prediksi.
- **RMSE (*Root Mean Square Error*)**: akar dari rata-rata kuadrat selisih antara nilai aktual dan hasil prediksi.
- **MAPE (*Mean Absolute Percentage Error*)**: rata-rata persentase kesalahan antara nilai aktual dan hasil prediksi.

Hasil perhitungannya untuk data uji tahun 2024 disajikan pada Tabel 4.8 berikut.

Tabel 4.8 Hasil Evaluasi Akurasi Model pada Data Uji Tahun 2024

Indikator	MAE	RMSE	MAPE (%)
Persentase Penduduk Miskin (%)	0,023	0,023	0,274
Jumlah Penduduk Miskin (ribu jiwa)	0,256	0,256	0,592

Dari tabel di atas, nilai kesalahan model sangat kecil, artinya hasil prediksi hampir sama dengan data aslinya. Untuk indikator persentase, kesalahannya hanya sekitar 0,02 poin persentase atau kurang dari 0,3%. Hal ini menunjukkan bahwa model regresi linear yang digunakan sudah mampu menangkap pola hubungan antar data dengan baik. Model sederhana seperti *naive* (prediksi tahun depan sama seperti tahun sebelumnya) atau *dummy mean* (menggunakan rata-rata keseluruhan) memiliki kesalahan yang jauh lebih besar. Jadi, pendekatan regresi linear yang digunakan terbukti lebih akurat dan lebih representatif.


4.6.2 Validasi Hasil Peramalan Tahun 2025

Setelah model terbukti akurat pada data uji (tahun 2024), langkah berikutnya adalah melakukan prediksi untuk tahun 2025. Pada tahap ini, model dilatih ulang (*retrain*) menggunakan seluruh data dari tahun 2013 sampai 2024, lalu digunakan untuk memperkirakan nilai satu tahun ke depan (tahun 2025).

Hasil peramalan menunjukkan:


- Persentase penduduk miskin tahun 2025 $\approx 8,243\%$
- Jumlah penduduk miskin tahun 2025 $\approx 43,097$ ribu jiwa

Angka ini masih mengikuti tren penurunan yang terjadi sejak tahun 2017, sehingga dapat dikatakan hasilnya realistis dan masuk akal. Hasil visualisasi perbandingan antara data historis dan prediksi ditunjukkan pada gambar berikut.



Gambar 4.1 Historis dan Prediksi - Jumlah Penduduk Miskin

Pada Gambar 4.1, garis berwarna biru menunjukkan data jumlah penduduk miskin dari tahun 2013–2024, yang secara umum terus menurun dengan sedikit fluktuasi pada periode 2019–2021. Titik berwarna oranye di ujung kanan merupakan prediksi tahun 2025, yaitu sekitar 43,1 ribu jiwa, yang melanjutkan tren penurunan sebelumnya. Model ini tidak memberikan hasil yang ekstrem, sehingga dapat dianggap stabil dan realistis.



Gambar 4.2 Historis dan Prediksi - Persentase Kemiskinan


Sementara itu, pada Gambar 4.2, pola serupa juga terlihat untuk persentase kemiskinan. Nilai prediksi tahun 2025 sebesar 8,24% sedikit lebih rendah dibandingkan tahun 2024 yang sebesar 8,31%. Garis berwarna biru menunjukkan penurunan yang konsisten sejak tahun 2013, dan prediksi tahun 2025 mengikuti pola tersebut dengan halus. Hal ini menunjukkan bahwa model tidak memberikan hasil yang melenceng atau tidak wajar, serta mampu mempertahankan arah tren yang konsisten dari tahun ke tahun.

4.6.3 Diagnostik Berbasis Grafik


Diagnostik grafik digunakan untuk memastikan bahwa model tidak melanggar asumsi dasar regresi linear dan hasilnya benar-benar dapat dipercaya. Terdapat tiga jenis grafik yang digunakan, yaitu *Aktual vs Fitted*, *Residual vs Fitted*, dan *Scatter Aktual vs Fitted* untuk dua variabel target (jumlah dan persentase).

(a) Grafik Aktual vs *Fitted*

Tujuannya untuk melihat sejauh mana hasil model (*fitted*) mendekati data sebenarnya (*aktual*). Jika garis *fitted* hampir menempel dengan titik *aktual*, berarti model sudah cukup baik dalam menjelaskan pola data.



Gambar 4.3 Aktual vs *Fitted* - Jumlah Penduduk Miskin



Gambar 4.4 Aktual vs *Fitted* - Persentase Kemiskinan

Pada Gambar 4.3 untuk jumlah penduduk miskin dan Gambar 4.4 untuk persentase kemiskinan, terlihat bahwa garis berwarna oranye (hasil model) mengikuti pola titik biru (data asli) dengan cukup rapat. Hanya terdapat perbedaan kecil di beberapa tahun, misalnya pada periode 2016–2018, namun setelah tahun 2019 garis fitted dan aktual hampir berimpit.


Hal ini menunjukkan bahwa model sudah mampu menangkap

hubungan antar data dengan cukup baik tanpa terjadi *overfitting* (model terlalu menyesuaikan data latih).


(b) Grafik Residual vs *Fitted*

- **Residual:** selisih antara nilai sebenarnya dengan hasil prediksi.
- ***Fitted*:** nilai yang diprediksi oleh model.

Grafik ini digunakan untuk melihat apakah terdapat pola khusus pada sisa kesalahan model (residual). Jika titik-titiknya tersebar secara acak di sekitar garis nol, artinya model sudah sesuai dan tidak memiliki pola kesalahan tertentu.



Gambar 4.5 Residual vs *Fitted* - Jumlah Penduduk Miskin




Gambar 4.6 Residual vs *Fitted* - Persentase Kemiskinan

Kedua grafik menunjukkan sebaran titik residual yang acak di sekitar garis nol tanpa pola tertentu. Pada Gambar 4.5, residu untuk jumlah penduduk miskin tidak menunjukkan tren naik atau turun, yang menandakan bahwa asumsi linearitas terpenuhi (hubungan antara variabel benar-benar linear).


Sedangkan pada Gambar 4.6, titik-titik residu untuk persentase juga menyebar merata di sekitar garis nol, yang berarti tidak ada masalah heteroskedastisitas (perbedaan sebaran error yang tidak seragam). Kesimpulannya, model sudah cukup stabil dan kesalahannya bersifat acak, bukan karena pola tertentu yang belum tertangkap.

(c) Grafik *Scatter* Aktual vs *Fitted*

Tujuan dari grafik ini adalah untuk melihat seberapa dekat hasil model (*fitted*) terhadap nilai sebenarnya (*aktual*). Jika semua titik berada dekat dengan garis 45°, berarti hasil prediksi hampir sama dengan data aslinya.



Gambar 4.7 *Scatter* Aktual vs *Fitted* - Jumlah Penduduk Miskin



Gambar 4.8 *Scatter* Aktual vs *Fitted* - Persentase Kemiskinan

Pada Gambar 4.7 dan Gambar 4.8, semua titik terlihat berada dekat dengan garis diagonal, yang menunjukkan bahwa hasil prediksi model hampir sama dengan nilai sebenarnya. Tidak terdapat titik yang menyimpang jauh, sehingga dapat disimpulkan bahwa prediksi model akurat dan konsisten.

Hasil ini juga sejalan dengan nilai MAE dan RMSE yang rendah pada Tabel 4.6.

4.6.4 Uji Kestabilan Model

Uji kestabilan dilakukan untuk memastikan bahwa model regresi linear yang digunakan tetap memberikan hasil yang konsisten dan tidak berubah drastis walaupun dilakukan penambahan data baru. Dengan kata lain, model yang baik

seharusnya tetap stabil dan tidak terlalu sensitif terhadap data terbaru yang ditambahkan.

Dalam penelitian ini, model yang digunakan adalah regresi linear deret waktu dengan proses *retrain* sampai tahun 2024. Artinya, model dilatih ulang menggunakan seluruh data dari tahun 2013 hingga 2024, kemudian hasilnya digunakan untuk memprediksi nilai pada tahun 2025. Cara ini dipilih karena lebih menggambarkan kondisi nyata setiap kali tahun baru datang, data terbaru akan ditambahkan agar model memiliki informasi paling mutakhir.

Langkah-langkah kestabilan model dapat dijelaskan sebagai berikut:

1. **Konsistensi waktu (variabel *t*).**

Dalam model ini, variabel waktu dinyatakan dalam bentuk urutan angka yang berurutan, misalnya tahun 2013 = 1, 2014 = 2, dan seterusnya hingga 2025 = 13. Tujuannya adalah agar model mengenali pola tren secara berurutan dan konsisten. Dengan cara ini, model dapat menangkap kecenderungan naik atau turunnya kemiskinan dari waktu ke waktu secara sistematis.

2. **Pelatihan model dengan *retrain* hingga 2024.**

Seluruh data historis digunakan untuk memperbarui (*retrain*) parameter model sebelum melakukan prediksi. Hal ini berbeda dengan pendekatan lama yang hanya melatih model sampai tahun 2023 tanpa memperbarui koefisiennya. Dengan memasukkan data 2024, model memiliki gambaran paling lengkap tentang perkembangan terakhir kemiskinan di Surakarta, sehingga hasil prediksi 2025 menjadi lebih akurat dan relevan.

3. **Kestabilan hasil prediksi.**

Setelah dilatih ulang, hasil prediksi tahun 2025 menunjukkan tren penurunan yang wajar, tidak terlalu tinggi maupun rendah secara tiba-tiba. Nilai yang dihasilkan masih berada dalam kisaran historis, sehingga model dinilai stabil dan realistis. Artinya, meskipun ada sedikit perubahan data

pada tahun-tahun terakhir, hasil prediksi tidak berubah secara drastis.

Dengan demikian, proses *retrain* hingga tahun 2024 terbukti memberikan hasil yang lebih baik dan representatif dibandingkan jika model tidak diperbarui. Pendekatan ini juga lebih cocok digunakan dalam praktik nyata karena mampu menyesuaikan diri dengan perkembangan terbaru data kemiskinan setiap tahunnya.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan hasil pengolahan dan analisis data kemiskinan di Kota Surakarta dari tahun 2013 hingga 2024 menggunakan model regresi linear deret waktu (*Ordinary Least Squares / OLS*), dapat diambil beberapa kesimpulan sebagai berikut:

1. Model regresi linear mampu menggambarkan pola kemiskinan dengan baik. Berdasarkan hasil uji akurasi pada data tahun 2024, model menunjukkan nilai kesalahan yang sangat kecil, yaitu:

- MAE sebesar 0,023 untuk persentase dan 0,256 untuk jumlah penduduk miskin (ribu jiwa);
- RMSE sebesar 0,023 dan 0,256;
- MAPE di bawah 1%, menunjukkan tingkat kesalahan prediksi yang sangat rendah.

Nilai-nilai ini menandakan bahwa model memiliki akurasi tinggi dan *error* yang sangat kecil.

2. Prediksi tahun 2025 menunjukkan tren penurunan kemiskinan yang berkelanjutan. Hasil peramalan menunjukkan:

- Persentase penduduk miskin tahun 2025 sebesar 8,243%;
- Jumlah penduduk miskin tahun 2025 sekitar 43,097 ribu jiwa.

Angka ini sedikit lebih rendah dari tahun 2024 (8,31% dan 43,28 ribu jiwa), yang berarti model memproyeksikan penurunan yang wajar dan konsisten dengan tren historis sejak 2017.

3. Model yang digunakan telah memenuhi asumsi-asumsi dasar regresi. Berdasarkan hasil uji diagnostik (grafik *Residual vs Fitted* dan *Scatter Aktual vs Fitted*), sebaran residu

terlihat acak dan tidak membentuk pola tertentu. Hal ini menunjukkan bahwa hubungan antar variabel bersifat linear, tidak terdapat masalah heteroskedastisitas (variasi *error* tidak seragam), dan model tidak bias secara sistematis.

4. Model dinilai stabil dan realistis untuk peramalan jangka pendek. Dengan menggunakan pendekatan *retrain* hingga tahun 2024, model berhasil memanfaatkan data terbaru secara optimal. Hasil prediksi tetap mengikuti arah tren yang masuk akal tanpa menunjukkan lonjakan atau penurunan ekstrem. Hal ini membuktikan bahwa model stabil terhadap perubahan data terbaru dan dapat diandalkan untuk analisis tahunan.

Dari keseluruhan analisis yang telah dilakukan, dapat disimpulkan bahwa model regresi linear deret waktu mampu memberikan gambaran dan prediksi yang cukup akurat terhadap perkembangan kemiskinan di Kota Surakarta. Hasil yang diperoleh dapat menjadi bahan masukan bagi instansi atau pihak terkait dalam menyusun strategi penurunan kemiskinan secara lebih terarah dan terukur. Dengan pengelolaan data yang baik serta pembaruan model secara berkala, pendekatan seperti ini berpotensi menjadi alat analisis yang bermanfaat dalam pengambilan kebijakan sosial ekonomi di masa mendatang.

5.2 Saran

Berdasarkan hasil penelitian dan proses analisis yang telah dilakukan, beberapa saran yang dapat diberikan adalah sebagai berikut:

1. Pemutakhiran data perlu dilakukan secara rutin. Agar model prediksi tetap akurat, data kemiskinan perlu diperbarui setiap tahun. Dengan data terbaru, model dapat dilatih ulang (*retrain*) untuk menghasilkan prediksi yang lebih tepat sesuai dengan kondisi terkini.
2. Perlu mempertimbangkan faktor-faktor lain di luar waktu. Model ini hanya menggunakan faktor waktu (tahun) dan data kemiskinan itu sendiri. Ke depan, model bisa

dikembangkan dengan menambahkan variabel lain seperti tingkat pengangguran, pendidikan, inflasi, atau Produk Domestik Regional Bruto (PDRB) agar hasil prediksi lebih komprehensif.

3. Perlu dilakukan pengujian terhadap model lain untuk pembandingan. Meskipun model regresi linear memberikan hasil yang baik, penggunaan model lain seperti ARIMA, regresi polinomial, atau *machine learning* (misalnya *Random Forest* atau *LSTM*) bisa menjadi alternatif untuk melihat apakah hasilnya lebih akurat.
4. Hasil prediksi sebaiknya digunakan sebagai bahan pertimbangan, bukan keputusan akhir. Prediksi hanyalah perkiraan berdasarkan pola masa lalu. Oleh karena itu, hasil model perlu dipadukan dengan pertimbangan sosial dan ekonomi terkini agar kebijakan yang diambil benar-benar sesuai dengan kondisi masyarakat di lapangan.

DAFTAR PUSTAKA

- Airlangga, B., Santoso, R., & Putri, D. (2024). Evaluasi model regresi linear untuk data deret waktu kecil. *Jurnal Sains Data dan Analitika*, 4(1), 55–70.
- Badan Pusat Statistik. (2023). *Profil statistik indonesia 2023*. [<https://www.bps.go.id>] (<https://www.bps.go.id/>).
- BPS Kota Surakarta. (2024). *Profil kemiskinan kota surakarta maret 2024*. [<https://surakartakota.bps.go.id>] (<https://surakartakota.bps.go.id/>).
- Hyndman, R., & Athanasopoulos, G. (2023). *Forecasting: Principles and practice* (3rd ed.). OTexts.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2023). *An introduction to statistical learning* (3rd ed.). Springer.
- Putra, B., & Sari, R. (2020). Peran kerja praktik dalam penguatan kompetensi mahasiswa. *Jurnal Pendidikan Matematika Indonesia*, 11(2), 123–134.
- Rahmawati, N., & Setiawan, H. (2021). Analisis multidimensi kemiskinan di indonesia. *Jurnal Ekonomi dan Pembangunan*, 29(2), 200–214.
- Wibowo, A., et al. (2021). *Penerapan kerja praktik dalam pembelajaran berbasis proyek*. Universitas Negeri Yogyakarta Press.
- Yuliana, D., & Prasetyo, A. (2022). Peran data statistik dalam kebijakan pembangunan daerah. *Jurnal Kebijakan Publik*, 7(1), 45–59.

LAMPIRAN A

Source Code Python

```
import os
from pathlib import Path
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

from sklearn.dummy import DummyRegressor
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_absolute_error, mean_squared_error

# ----- Pengaturan output -----
OUT = Path("./output_linear_main")
OUT.mkdir(exist_ok=True, parents=True)

# Agar plotting tidak menggantung di beberapa environment
SHOW_PLOTS = True
def maybe_show():
    if SHOW_PLOTS:
        plt.show()
    else:
        plt.close()

# ----- Data -----
def load_data():
    df = pd.DataFrame({
        "Tahun": [2013, 2014, 2015, 2016, 2017, 2018, 2019, 2020, 2021, 2022, 2023, 2024],
        # JIKA INI DALAM "JIWA", GUNAKAN NAMA SEMENTARA:

        "Jumlah jiwa": [59680, 55920, 55710, 55910, 54890, 46990, 45180, 47030, 48790, 45900,
                        43890, 43280],

        "Persen": [11.74, 10.95, 10.89, 10.88, 10.65, 9.08, 8.70, 9.03, 9.40, 8.84, 8.44, 8.31]
    })
    df.sort_values("Tahun").reset_index(drop=True)

    # KONVERSI ke ribu jiwa
    df["Jumlah_ribu"] = pd.to_numeric(df["Jumlah_jiwa"], errors="coerce") /
    1000.0
    df.drop(columns=["Jumlah_jiwa"], inplace=True) # boleh dihapus agar
    tidak rancu

    # validasi
    for c in ["Jumlah_ribu", "Persen"]:
        df[c] = pd.to_numeric(df[c], errors="coerce")
    if df[["Jumlah_ribu", "Persen"]].isna().any().any():
        raise ValueError("Ada NaN di data mentah. Periksa input.")

    return df

# ----- Utils -----
def rmse(y_true, y_pred):
    y_true = np.asarray(y_true).ravel()
    y_pred = np.asarray(y_pred).ravel()
    return float(np.sqrt(mean_squared_error(y_true, y_pred)))

def mape_percent(y_true, y_pred):
    y_true = np.asarray(y_true).ravel()
    y_pred = np.asarray(y_pred).ravel()
    return float(np.mean(np.abs((y_true - y_pred) / y_true)) * 100)
```

```
def score_report(y_true, y_pred):
    return {"MAE": mean_absolute_error(y_true, y_pred),
            "RMSE": rmse(y_true, y_pred),
            "MAPE(%)": mape_percent(y_true, y_pred)}

# ----- Feature Builder -----
def build_features(df_in, target):
    """
    Fitur time-series aman (tanpa GK):
    - target_lag1, target_lag2
    - target_roll2 (rata2 dari t-1 & t-2)
    - trend t
    - cross 1 buah:
      * Target=Persen      -> Jumlah_lag1
      * Target=Jumlah_ribu -> Persen_lag1
    """
    out = df_in.copy()

    out["{target}_lag1"] = out[target].shift(1)
    out["{target}_lag2"] = out[target].shift(2)
    out["{target}_roll2"] = out[target].shift(1).rolling(2).mean()
    out["t"] = np.arange(len(out))

    if target == "Persen":
        out["Jumlah_lag1"] = out["Jumlah_ribu"].shift(1)
    elif target == "Jumlah_ribu":
        out["Persen_lag1"] = out["Persen"].shift(1)

    # drop NA di fitur saja
    drop_cols = ["Tahun", "Jumlah_ribu", "Persen", target]
    feature_cols = [c for c in out.columns if c not in drop_cols]
    out = out.dropna(subset=feature_cols).reset_index(drop=True)

    X, y, years = out[feature_cols], out[target], out["Tahun"]
    return X, y, years, feature_cols

# ----- Model: Linear -----
def fit_linear(X_np, y_np):
    lin = LinearRegression()
    lin.fit(X_np, y_np)
    return lin

# ----- Evaluasi holdout 2024 -----
def evaluate_holdout_2024(df_base, target):
    X, y, years, feats = build_features(df_base, target)
    test_mask = (years == 2024)
    if test_mask.sum() != 1:
        raise RuntimeError("Holdout 2024 tidak ditemukan.")

    X_train, y_train = X[~test_mask], y[~test_mask]
    X_test, y_test = X[test_mask], y[test_mask]

    X_train_np, y_train_np = X_train.to_numpy(), y_train.to_numpy().ravel()
    X_test_np, y_test_np = X_test.to_numpy(), y_test.to_numpy().ravel()

    # Baseline Naive: gunakan target_lag1
    lag1_col = "{target}_lag1"
    y_pred_naive = X_test[lag1_col].to_numpy()
    if np.isnan(y_pred_naive).any():
        y_pred_naive = np.nan_to_num(y_pred_naive,
                                     nan=float(np.nanmean(X_train[lag1_col].values)))
    nan=float(np.nanmean(X_train[lag1_col].values)))
```



```
dum = DummyRegressor(strategy="mean").fit(X_train_np, y_train_np)
lin = fit_linear(X_train_np, y_train_np)

rows = [
    {"Model": "Naive",          **score_report(y_test_np, y_pred_naive)},
    {"Model": "DummyMean",     **score_report(y_test_np,
dum.predict(X_test_np))},
    {"Model": "Linear",        **score_report(y_test_np,
lin.predict(X_test_np))},
]

report = pd.DataFrame(rows).reset_index(drop=True)

yhat_lin_2024 = float(lin.predict(X_test_np)[0])
return report, (int(years[test_mask].values[0]), float(y_test_np[0]),
yhat_lin_2024)

# ----- Prediksi one-step 2025 (Linear) -----
def forecast_one_step_2025(df_base, target):
    next_year = int(df_base["Tahun"].max() + 1)
    df_next = pd.concat([df_base.copy(),
pd.DataFrame({"Tahun": [next_year]}), ignore_index=True)
    for col in ["Jumlah_ribu", "Persen"]:
        if col not in df_next.columns:
            df_next[col] = np.nan

    X_full, y_full, years_full, feats_full = build_features(df_next,
target)
    row_mask = (years_full == next_year)
    row_pred = X_full[row_mask]
    fit_mask = ~row_mask
    X_fit_np = X_full[fit_mask].to_numpy()
    y_fit_np = y_full[fit_mask].to_numpy().ravel()

    lin_final = fit_linear(X_fit_np, y_fit_np)
    if row_pred.shape[0] == 0:
        raise RuntimeError("Baris fitur tahun prediksi kosong. Cek
konstruksi lag/rolling.")
    row_np = row_pred.to_numpy()
    y_hat = float(lin_final.predict(row_np)[0])

    # Koefisien: bertanda & absolut (diurutkan)
    coef_signed = pd.Series(lin_final.coef_, index=feats_full)
    coef_abs_sorted = coef_signed.abs().sort_values(ascending=False)

    return {
        "year": next_year,
        "y_hat": y_hat,
        "coef_signed": coef_signed,
        "coef_abs_sorted": coef_abs_sorted
    }

# ----- Plot helpers -----
def plot_actual_vs_pred_2024(year, y_true, y_pred, title, y_label, fname):
    plt.figure(figsize=(6,5))
    plt.bar([f"Aktual {year}", f"Prediksi {year}"], [y_true, y_pred])
    plt.title(title)
    plt.ylabel(y_label)
    for i, v in enumerate([y_true, y_pred]):
        plt.text(i, v, f"{v:.3f}", ha="center", va="bottom")
```

```

plt.tight_layout()
plt.savefig(OUT / fname, dpi=150)
maybe_show()

def plot_history_with_forecast(df_hist, fc, ycol, y_label, title, fname):
    plt.figure(figsize=(9,5))
    plt.plot(df_hist["Tahun"], df_hist[ycol], marker="o", label=f"Historis {ycol}")
    if ycol == "Persen":
        yhat = fc["Forecast_Persen"]
    else:
        yhat = fc["Forecast_Jumlah_ribu"]
    plt.plot(fc["Tahun"], yhat, marker="o", linestyle="--",
label=f"Forecast {ycol}")
    plt.title(title)
    plt.xlabel("Tahun")
    plt.ylabel(y_label)
    plt.grid(True, linestyle="--", alpha=0.4)
    plt.legend()
    plt.tight_layout()
    plt.savefig(OUT / fname, dpi=150)
    maybe_show()

# --- Tambahan: Visualisasi regresi linear (in-sample) ---
def plot_fitted_vs_actual_timeseries(df_base, target, title, y_label,
fname):
    X, y, years, _ = build_features(df_base, target)
    lin = LinearRegression().fit(X.to_numpy(), y.to_numpy().ravel())
    fitted = lin.predict(X.to_numpy())

    plt.figure(figsize=(9,5))
    plt.plot(years, y, marker="o", label="Aktual")
    plt.plot(years, fitted, marker="o", linestyle="--", label="Fitted (Linear)")
    plt.title(title)
    plt.xlabel("Tahun")
    plt.ylabel(y_label)
    plt.grid(True, linestyle="--", alpha=0.4)
    plt.legend()
    plt.tight_layout()
    plt.savefig(OUT / fname, dpi=150)
    maybe_show()

def plot_pred_vs_true_scatter(df_base, target, title, fname):
    X, y, years, _ = build_features(df_base, target)
    lin = LinearRegression().fit(X.to_numpy(), y.to_numpy().ravel())
    yhat = lin.predict(X.to_numpy())

    plt.figure(figsize=(6,6))
    plt.scatter(y, yhat)
    mn, mx = float(min(y.min(), yhat.min())), float(max(y.max(),
yhat.max()))
    plt.plot([mn, mx], [mn, mx], linestyle="--")
    plt.xlabel("Aktual")
    plt.ylabel("Fitted (Linear)")
    plt.title(title)
    plt.tight_layout()
    plt.savefig(OUT / fname, dpi=150)
    maybe_show()

def plot_residuals_vs_fitted(df_base, target, title, fname):

```

```
X, y, years, _ = build_features(df_base, target)
lin = LinearRegression().fit(X.to_numpy(), y.to_numpy().ravel())
fitted = lin.predict(X.to_numpy())
resid = y.to_numpy().ravel() - fitted

plt.figure(figsize=(8,5))
plt.scatter(fitted, resid)
plt.axhline(0, linestyle="--")
plt.title(title)
plt.xlabel("Fitted")
plt.ylabel("Residual")
plt.tight_layout()
plt.savefig(OUT / fname, dpi=150)
maybe_show()

# ----- Util: Tulis & Simpan Koefisien -----
def format_and_save_coefs(series_signed, name_prefix):
    # Buat tabel koef bertanda + absolut, diurutkan berdasarkan |koef|
    dfc = pd.DataFrame({"Koefisien": series_signed})
    dfc["|Koef|"] = dfc["Koefisien"].abs()
    dfc = dfc.sort_values("|Koef|", ascending=False)

    # Tampilkan ke console (hingga 6 desimal)
    pd.options.display.float_format = lambda x: f"{x:,.6f}"
    print(f"\n=== KOEFISIEN LINEAR - {name_prefix} (diurutkan |koef|) ===")
    print(dfc.to_string())

    # Simpan ke file
    csv_path = OUT / f"koefisien_{name_prefix.lower().replace(' ', '_')}.csv"
    xlsx_path = OUT / f"koefisien_{name_prefix.lower().replace(' ', '_')}.xlsx"
    dfc.to_csv(csv_path, index=True)
    with pd.ExcelWriter(xlsx_path) as xw:
        dfc.to_excel(xw, sheet_name="Koefisien", index=True)

# ----- Main -----
if __name__ == "__main__":
    pd.options.display.float_format = lambda x: f"{x:,.3f}"
    df = load_data()
    print(">>> ANALISIS PREDIKTIF KEMISKINAN - Linear Regression (Surakarta) <<<")

    # 1) Evaluasi holdout 2024 (Linear)
    rep_persen, avp_p = evaluate_holdout_2024(df, target="Persen")
    rep_jumlah, avp_j = evaluate_holdout_2024(df, target="Jumlah_ribu")

    print("\n=== HOLDOUT 2024 - Persentase (%) ===")
    print(rep_persen.to_string(index=False))
    print("\n=== HOLDOUT 2024 - Jumlah (ribu jiwa) ===")
    print(rep_jumlah.to_string(index=False))

    # simpan akurasi
    rep_persen.to_csv(OUT/"holdout_persen_2024_linear.csv", index=False)
    rep_jumlah.to_csv(OUT/"holdout_jumlah_2024_linear.csv", index=False)
    with pd.ExcelWriter(OUT/"holdout_all_2024_linear.xlsx") as xw:
        rep_persen.to_excel(xw, sheet_name="Persen", index=False)
        rep_jumlah.to_excel(xw, sheet_name="Jumlah_ribu", index=False)

    # 2) One-step 2025 + koefisien (HANYA 2025)
    f_p = forecast_one_step_2025(df, target="Persen")
```

```
f_j = forecast_one_step_2025(df, target="Jumlah_ribu")

print(f"\n=== ONE-STEP (2025) ===")
print(f"Persentase 2025 = {f_p['y_hat']:.3f}")
# >>> Perubahan di bawah: tampilkan 3 desimal untuk Jumlah_ribu
print(f"Jumlah_ribu 2025 = {f_j['y_hat']:.3f}")

# Tulis & simpan koefisien (tanpa grafik)
format_and_save_coefs(f_p["coef_signed"], "Persentase_2025_one_step")
format_and_save_coefs(f_j["coef_signed"], "Jumlah_ribu_2025_one_step")

# Buat dataframe forecast SATU TAHUN (2025) untuk dipakai plotting &
ekspor
fc_2025 = pd.DataFrame([
    {
        "Tahun": f_p["year"],
        "Forecast_Persen": f_p["y_hat"],
        "Forecast_Jumlah_ribu": f_j["y_hat"]
    }
])

# Simpan hasil forecast
fc_2025.to_csv(OUT/"forecast_2025_linear.csv", index=False)
fc_2025.to_excel(OUT/"forecast_2025_linear.xlsx", index=False)

# ----- Plot -----
# Aktual vs prediksi 2024
year_p, ytrue_p, yhat_p = avp_p
plot_actual_vs_pred_2024(
    year_p, ytrue_p, yhat_p,
    "Aktual vs Prediksi 2024 - Persentase Kemiskinan (Linear)",
    "Persen (%)",
    "plot_avp_2024_persen_linear.png"
)
year_j, ytrue_j, yhat_j = avp_j
plot_actual_vs_pred_2024(
    year_j, ytrue_j, yhat_j,
    "Aktual vs Prediksi 2024 - Jumlah Penduduk Miskin (Linear)",
    "Ribu jiwa",
    "plot_avp_2024_jumlah_linear.png"
)

# Historis + forecast satu titik (2025)
plot_history_with_forecast(
    df, fc_2025,
    "Persen", "Persen (%)",
    "Historis & Forecast - Persentase Kemiskinan (Linear)",
    "plot_hist_fc_persen_linear.png"
)
plot_history_with_forecast(
    df, fc_2025,
    "Jumlah_ribu", "Ribu jiwa",
    "Historis & Forecast - Jumlah Penduduk Miskin (Linear)",
    "plot_hist_fc_jumlah_linear.png"
)

print(f"\nFile hasil disimpan di folder: {OUT.resolve()}")

# --- Tambahan grafik regresi (in-sample) ---
# 2.1 Garis waktu: Aktual vs Fitted
plot_fitted_vs_actual_timeseries(
    df, "Persen",
    "Aktual vs Fitted (In-sample) - Persentase Kemiskinan (Linear)",
```

```
"Persen (%)",  
"plot_fitted_actual_persen_linear.png"  
)  
plot_fitted_vs_actual_timeseries(  
df, "Jumlah ribu",  
"Aktual vs Fitted (In-sample) - Jumlah Penduduk Miskin (Linear)",  
"Ribu jiwa",  
"plot_fitted_actual_jumlah_linear.png"  
)  
  
# 2.2 Scatter: y true vs y_pred (garis 45°)  
plot_pred_vs_true_scatter(  
df, "Persen",  
"Scatter Aktual vs Fitted - Persentase (Linear)",  
"plot_scatter_persen_linear.png"  
)  
plot_pred_vs_true_scatter(  
df, "Jumlah ribu",  
"Scatter Aktual vs Fitted - Jumlah (Linear)",  
"plot_scatter_jumlah_linear.png"  
)  
  
# 2.3 Diagnostik: Residual vs Fitted  
plot_residuals_vs_fitted(  
df, "Persen",  
"Residual vs Fitted - Persentase (Linear)",  
"plot_resid_persen_linear.png"  
)  
plot_residuals_vs_fitted(  
df, "Jumlah ribu",  
"Residual vs Fitted - Jumlah (Linear)",  
"plot_resid_jumlah_linear.png"  
)
```


LAMPIRAN B

Logbook Kegiatan



KEMENTERIAN PENDIDIKAN DAN KEBUDAYAAN
INSTITUT TEKNOLOGI SEPULUH NOPEMBER
Kampus ITS Sukolilo-Surabaya 60111
Telepon : 031-5994251-54, 5947274, 5945472
Fax : 031-5947264, 5950806
<http://www.its.ac.id>

LOG BOOK KERJA PRAKTIK

Nama Mahasiswa : Lintang Syawalani Hawa Ningrum
NRP : 5002221058
Judul Kerja Praktik : PERAMALAN TINGKAT KEMISKINAN DI KOTA SURAKARTA TAHUN
2025 MENGGUNAKAN MODEL REGRESI LINEAR DERET WAKTU
Pembimbing : Istanti, S.Si, M.Ec.Dev
Mitra Kerja Praktik : Badan Pusat Statistik Kota Surakarta
Waktu Pelaksanaan : 30 Juni 2025 – 8 Agustus 2025

NO	TANGGAL	DESKRIPSI KEGIATAN	PARAF
1	30 Juni 2025 (07.30 – 16.00 WIB)	Pengenalan instansi dan orientasi magang	
2	1 Juli 2025 (07.30 – 16.00 WIB)	Pengenalan struktur organisasi BPS dan briefing terkait bidang kerja yang akan diikuti. Membantu membuat surat yang akan dibagikan ke beberapa dinas untuk rapat keesokan harinya.	
3	2 Juli 2025 (07.30 – 16.00 WIB)	Membantu penginputan data PDRB ke dalam sistem pengolahan data, melakukan pengecekan data awal.	
4	3 Juli 2025 (07.30 – 16.00 WIB)	Membantu mencari anomali dalam data hasil kuesioner yang telah masuk untuk memastikan konsistensi.	
5	4 Juli 2025 (07.30 – 16.30 WIB)	Membantu penyusunan berkas untuk Wilkerstat, merapikan dokumen pendukung laporan statistik.	
6	5 Juli 2025	Libur	
7	6 Juli 2025	Libur	
8	7 Juli 2025 (07.30 – 16.00 WIB)	Membantu pembuatan draft awal infografis untuk publikasi statistik bulanan.	
9	8 Juli 2025 (07.30 – 16.00 WIB)	Menginput data distribusi perdagangan dan valuta asing, melakukan pengecekan data tidak valid.	
10	9 Juli 2025 (07.30 – 16.00 WIB)	Membantu menyusun draft buku indikator ekonomi, mengompilasi data dan grafik pendukung.	
11	10 Juli 2025 (07.30 – 16.00 WIB)	Membantu menyiapkan materi PowerPoint untuk presentasi rapat Kepala BPS.	
12	11 Juli 2025 (07.30 – 16.30 WIB)	Membantu tim dalam mencari ide fenomena ekonomi terbaru untuk bahan publikasi.	
13	12 Juli 2025	Libur	
14	13 Juli 2025	Libur	
15	14 Juli 2025 (07.30 – 16.00 WIB)	Menginput data PDRB lanjutan, melakukan verifikasi dengan data tahun sebelumnya.	
16	15 Juli 2025 (07.30 – 16.00 WIB)	Membantu membuat PowerPoint untuk kegiatan Statistik Daerah (Statda).	
17	16 Juli 2025 (07.30 – 16.00 WIB)	Membantu merancang draft infografis terkait data ekonomi triwulanan.	
18	17 Juli 2025 (07.30 – 16.00 WIB)	Mengidentifikasi data yang tidak wajar (anomali) pada hasil kuesioner dan memberikan catatan revisi.	



KEMENTERIAN PENDIDIKAN DAN KEBUDAYAAN
INSTITUT TEKNOLOGI SEPULUH NOPEMBER
Kampus ITS Sukohilo-Surabaya 60111
Telepon : 031-5994251-54, 5947274, 5945472
Fax : 031-5947264, 5950806
<http://www.its.ac.id>

19	18 Juli 2025 (07.30 – 16.30 WIB)	Mengumpulkan dan mengarsipkan data pendukung untuk penyusunan Wilkerstat.	
20	19 Juli 2025	Libur	
21	20 Juli 2025	Libur	
22	21 Juli 2025 (07.30 – 16.00 WIB)	Membantu menginput data distribusi valuta asing dan perdagangan luar negeri.	
23	22 Juli 2025 (07.30 – 16.00 WIB)	Mencari tema dan topik ide untuk paparan akhir magang.	
24	23 Juli 2025 (07.30 – 16.00 WIB)	Brainstorming dan memperdalam serta mempelajari lebih lanjut mengenai tema yang telah ditentukan.	
25	24 Juli 2025 (07.30 – 16.00 WIB)	Penyusunan Power Point terkait paparan akhir magang dan merevisi beberapa poin-poin yang akan dipaparkan.	
26	25 Juli 2025 (07.30 – 16.30 WIB)	Pemaparan akhir magang dilanjut dengan pengerjaan tugas magang yaitu menambahkan grafik dan tabel pada buku indikator ekonomi berdasarkan data terbaru.	
27	26 Juli 2025	Libur	
28	27 Juli 2025	Libur	
29	28 Juli 2025 (07.30 – 16.00 WIB)	Melanjutkan rancangan draft infografis dan penyusunan infografis dalam aplikasi canva.	
30	29 Juli 2025 (07.30 – 16.00 WIB)	Membantu tim dalam menyusun draft materi rapat pimpinan terkait perkembangan ekonomi regional.	
31	30 Juli 2025 (07.30 – 16.00 WIB)	Menyusun daftar catatan revisi atas data PDRB yang masih memiliki inkonsistensi.	
32	31 Juli 2025 (07.30 – 16.00 WIB)	Membantu pengolahan data distribusi perdagangan antarwilayah dan membuat recap sementara.	
33	1 Agustus 2025 (07.30 – 16.30 WIB)	Menginput laporan realisasi APBD triwulan III ke dalam sistem pengolahan data BPS.	
34	2 Agustus 2025	Libur	
35	3 Agustus 2025	Libur	
36	4 Agustus 2025 (07.30 – 16.00 WIB)	Melanjutkan penginputan laporan realisasi APBD triwulan III untuk beberapa daerah yang datanya baru diterima.	
37	5 Agustus 2025 (07.30 – 16.00 WIB)	- Membantu verifikasi data laporan realisasi APBD triwulan III dan memastikan kesesuaian dengan data yang dilaporkan oleh pemerintah daerah. - Mengidentifikasi fenomena ekonomi yang menarik untuk dijadikan topik pada laporan ringkas.	
38	6 Agustus 2025 (07.30 – 16.00 WIB)	Memasukkan pembaruan data realisasi APBD triwulan III ke dalam tabel rekapitulasi sementara.	
39	7 Agustus 2025 (07.30 – 16.00 WIB)	Memformat ulang beberapa tabel buku indikator ekonomi, termasuk menambahkan data realisasi APBD triwulan III terbaru.	
40	8 Agustus 2025 (07.30 – 16.30 WIB)	Merekap dan men-series kan data inflasi per komoditas dari bulan Januari-Juli	



KEMENTERIAN PENDIDIKAN DAN KEBUDAYAAN
INSTITUT TEKNOLOGI SEPULUH NOPEMBER
Kampus ITS Sukolilo-Surabaya 60111
Telepon : 031-5994251-54, 5947274, 5945472
Fax : 031-5947264, 5950806
<http://www.its.ac.id>

(Surakarta 8 Agustus 2025)

Pembimbing



(Istanti)

LAMPIRAN C

Dokumentasi Kegiatan



BIODATA PENULIS



Lintang Syawalani Hawa Ningrum merupakan mahasiswa program sarjana pada Departemen Matematika, Fakultas Sains dan Analitika Data, Institut Teknologi Sepuluh Nopember (ITS) Surabaya. Penulis menamatkan pendidikan menengah atas di SMA Negeri 1 Baturetno pada tahun 2022 dengan jurusan Matematika dan Ilmu Pengetahuan Alam (MIPA). Ketertarikan penulis terhadap bidang matematika mulai tumbuh sejak duduk di bangku sekolah, khususnya pada penerapan konsep-konsep matematika dalam menyelesaikan persoalan sehari-hari maupun fenomena nyata di masyarakat.

Selama menempuh studi di ITS, penulis tidak hanya aktif dalam kegiatan akademik, tetapi juga terlibat dalam berbagai kegiatan non-akademik yang mendukung pengembangan diri, baik dalam aspek kepemimpinan, organisasi, maupun keterampilan sosial. Dengan latar belakang tersebut, penulis berharap dapat terus mengembangkan kemampuan analitis dan berkontribusi dalam bidang data serta penerapan ilmu matematika di dunia kerja maupun penelitian.