

SISTEM DETEKSI EMAIL *PHISHING* BERBASIS FITUR *STYLOMETRIC* DENGAN SVM-RBF DAN SHAP

Lintang Syawalani Hawa Ningrum, Prof. Dr. techn. Drs. Mohammad Isa Irawan, MT

Departemen Matematika

Institut Teknologi Sepuluh Nopember (ITS)

Jl. Arief Rahman Hakim, Surabaya 60111 Indonesia

email: 5002221058@student.its.ac.id; mii@its.ac.id

Abstrak—Perkembangan teknologi informasi mempermudah komunikasi melalui email, namun juga meningkatkan ancaman *phishing* yang semakin sulit dideteksi menggunakan metode konvensional berbasis URL dan domain. Penelitian ini bertujuan membangun sistem deteksi email *phishing* berbasis *stylometry* dengan menganalisis karakteristik linguistik pada isi email. Sebanyak 60 fitur *stylometric* digunakan sebagai representasi data dan diklasifikasikan menggunakan algoritma *Support Vector Machine* (SVM) dengan kernel *Radial Basis Function* (RBF). Untuk meningkatkan transparansi model, penelitian ini menerapkan *Explainable Artificial Intelligence* (XAI) menggunakan SHAP untuk menjelaskan kontribusi fitur terhadap hasil prediksi. Model yang dibangun kemudian diimplementasikan dalam aplikasi berbasis web bernama *StylDetect* menggunakan *Streamlit*, dengan dua mode penggunaan yaitu input manual dan integrasi Gmail dengan hak akses *read-only*. Hasil penelitian ini menunjukkan bahwa pendekatan berbasis *stylometry* dengan SVM-RBF mampu mendeteksi email *phishing* secara efektif serta memberikan interpretasi yang transparan terhadap keputusan model.

Kata Kunci—*Phishing, Stylometry, Support Vector Machine, RBF Kernel, Explainable AI, SHAP*

I. PENDAHULUAN

Perkembangan teknologi informasi telah meningkatkan penggunaan email sebagai media komunikasi yang cepat dan efisien. Namun, peningkatan penggunaan email juga diikuti oleh meningkatnya ancaman *phishing*, yaitu serangan siber yang bertujuan memperoleh informasi sensitif pengguna melalui teknik rekayasa sosial. Laporan APWG mencatat lebih dari satu juta insiden *phishing* dalam satu kuartal pada tahun 2023, sementara laporan Zscaler menunjukkan peningkatan kasus hingga 47,2% dibandingkan tahun sebelumnya [1], [2]. Di Indonesia, jumlah laporan insiden *phishing* juga terus meningkat sehingga menunjukkan bahwa ancaman ini masih menjadi permasalahan keamanan siber yang signifikan [3], [4].

Metode deteksi *phishing* konvensional umumnya memanfaatkan indikator teknis seperti URL, reputasi domain, maupun *blacklist*. Meskipun efektif pada beberapa kasus, pendekatan tersebut memiliki keterbatasan ketika email *phishing* menggunakan konten yang menyerupai komunikasi asli atau memanfaatkan teknologi kecerdasan buatan untuk menghasilkan teks yang lebih alami [6]. Oleh karena itu, diperlukan pendekatan yang mampu menganalisis karakteristik isi email secara lebih mendalam.

Salah satu pendekatan yang dapat digunakan adalah *stylometry*, yaitu analisis karakteristik linguistik dan gaya penulisan suatu teks. Fitur-fitur *stylometric* seperti panjang kata, struktur kalimat, tingkat keterbacaan, dan keragaman kosakata dapat digunakan untuk membedakan email *phishing* dan email *legitimate*. Penelitian sebelumnya menunjukkan bahwa fitur *stylometric* memiliki potensi yang baik dalam mendukung proses deteksi *phishing* berbasis teks [6], [7].

Dalam proses klasifikasi, *Support Vector Machine* (SVM) dengan kernel *Radial Basis Function* (RBF) banyak digunakan karena mampu menangani hubungan non-linear pada data dan memberikan performa yang baik pada permasalahan klasifikasi biner [9]. Namun, model SVM-RBF termasuk kategori *black-box* sehingga alasan di balik keputusan model sulit dipahami secara langsung. Untuk meningkatkan interpretabilitas model, dapat digunakan pendekatan *Explainable Artificial Intelligence* (XAI) seperti *Shapley Additive Explanations* (SHAP), yang mampu menjelaskan kontribusi setiap fitur terhadap hasil prediksi baik secara global maupun lokal [10], [11].

Berdasarkan permasalahan tersebut, penelitian ini mengembangkan sistem deteksi email *phishing* berbasis 60 fitur *stylometric* menggunakan model SVM-RBF dan metode SHAP. Model yang dibangun diimplementasikan dalam aplikasi web bernama *StylDetect* menggunakan *Streamlit* dengan dua mode penggunaan, yaitu input manual dan integrasi Gmail *read-only*. Penelitian ini bertujuan menganalisis kemampuan fitur *stylometric* dalam membedakan email *phishing* dan *legitimate*, mengevaluasi performa model SVM-RBF, serta menjelaskan keputusan model menggunakan SHAP agar hasil prediksi lebih transparan dan mudah dipahami pengguna.

II. TINJAUAN PUSTAKA

A. Email Phishing

Phishing merupakan salah satu bentuk serangan rekayasa sosial yang bertujuan memperoleh informasi sensitif pengguna, seperti kata sandi, data pribadi, maupun informasi keuangan dengan menyamar sebagai pihak yang terpercaya. Email menjadi media yang paling sering digunakan dalam serangan *phishing* karena mudah didistribusikan dan mampu menjangkau banyak pengguna dalam waktu singkat [5].

Perkembangan teknologi menyebabkan email *phishing* semakin sulit dibedakan dari email *legitimate*. Pelaku

serangan kini mampu menghasilkan pesan yang menyerupai komunikasi resmi organisasi sehingga metode deteksi yang hanya bergantung pada indikator teknis seperti URL, reputasi domain, atau *blacklist* menjadi kurang efektif dalam beberapa kasus [6]. Oleh karena itu, diperlukan pendekatan yang mampu menganalisis isi dan karakteristik bahasa pada email.

B. Stylometry

Stylometry merupakan teknik analisis gaya penulisan yang digunakan untuk mengidentifikasi karakteristik linguistik suatu teks. Pendekatan ini memanfaatkan berbagai fitur seperti panjang kata, panjang kalimat, keragaman kosakata (*lexical diversity*), penggunaan tanda baca, serta tingkat keterbacaan untuk menggambarkan pola penulisan suatu dokumen [7].

Dalam konteks deteksi email *phishing*, fitur-fitur *stylometric* dapat digunakan untuk membedakan karakteristik bahasa yang umum ditemukan pada email *phishing* dan email *legitimate*. Penelitian sebelumnya menunjukkan bahwa pola penggunaan bahasa tertentu dapat menjadi indikator yang efektif dalam mendukung proses klasifikasi email karena email *phishing* sering memiliki karakteristik linguistik yang berbeda dibandingkan email sah [6].

C. Normalisasi Data

Normalisasi data dilakukan untuk menyamakan skala antar fitur *stylometric* sebelum digunakan pada proses pelatihan model. Tahap ini diperlukan karena fitur yang digunakan memiliki rentang nilai yang berbeda, seperti jumlah kata, frekuensi tanda baca, dan skor keterbacaan. Pada penelitian ini, normalisasi dilakukan menggunakan *StandardScaler* yang mengubah setiap fitur sehingga memiliki rata-rata mendekati 0 dan standar deviasi mendekati 1. Proses ini membantu meningkatkan performa model SVM-RBF yang sensitif terhadap perbedaan skala antar fitur [8].

$$x' = \frac{x - \mu}{\sigma} \quad (2.1)$$

di mana x' adalah nilai fitur setelah dinormalisasi, x adalah nilai fitur asli, μ adalah rata-rata fitur, dan σ adalah standar deviasi fitur.

D. Support Vector Machine dengan Kernel RBF

Support Vector Machine (SVM) merupakan algoritma *machine learning* yang banyak digunakan untuk permasalahan klasifikasi biner. SVM bekerja dengan mencari *hyperplane* optimal yang mampu memisahkan dua kelas data dengan margin maksimum sehingga menghasilkan kemampuan generalisasi yang baik [12].

Pada permasalahan yang memiliki hubungan non-linear antar fitur, SVM dapat dikombinasikan dengan fungsi kernel. Salah satu kernel yang paling banyak digunakan adalah *Radial Basis Function* (RBF), yang mampu memetakan data ke ruang fitur berdimensi lebih tinggi sehingga pola yang kompleks menjadi lebih mudah dipisahkan [13]. Fungsi kernel RBF dinyatakan sebagai:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2) \quad (2.2)$$

di mana $\mathbf{x}_i$ dan $\mathbf{x}_j$ merupakan dua data yang dibandingkan, sedangkan γ adalah parameter yang mengatur pengaruh suatu data terhadap data lainnya.

Kemampuan kernel RBF dalam menangani hubungan non-linear menjadikan SVM-RBF sesuai digunakan untuk klasifikasi email berdasarkan fitur *stylometric* yang memiliki karakteristik kompleks dan beragam.

E. Platt Scaling dan Threshold Tuning

Secara umum, SVM menghasilkan nilai fungsi keputusan yang tidak secara langsung merepresentasikan probabilitas kelas. Oleh karena itu, digunakan *Platt Scaling* untuk mengubah keluaran model menjadi probabilitas melalui fungsi sigmoid [14].

$$P(y = 1|x) = \frac{1}{1 + \exp(Af(x) + B)} \quad (2.3)$$

di mana $f(x)$ adalah nilai fungsi keputusan SVM, sedangkan A dan B merupakan parameter kalibrasi.

Probabilitas yang dihasilkan kemudian digunakan pada proses *threshold tuning* untuk menentukan batas keputusan yang memberikan keseimbangan terbaik antara *precision* dan *recall* berdasarkan nilai *F1-score*.

F. Explainable Artificial Intelligence dan SHAP

Explainable Artificial Intelligence (XAI) merupakan pendekatan yang bertujuan meningkatkan transparansi model kecerdasan buatan dengan memberikan penjelasan mengenai alasan di balik suatu prediksi. XAI menjadi penting terutama pada model yang bersifat *black-box*, di mana proses pengambilan keputusan sulit dipahami secara langsung oleh pengguna [15].

Salah satu metode XAI yang banyak digunakan adalah SHAP (*Shapley Additive Explanations*). SHAP menggunakan konsep nilai Shapley dari teori permainan kooperatif untuk menghitung kontribusi setiap fitur terhadap hasil prediksi model [10]. Nilai Shapley untuk fitur ke- i dirumuskan sebagai:

$$\phi_i = \sum_{S \subseteq F \setminus i} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f(S \cup i) - f(S)] \quad (2.4)$$

di mana ϕ_i adalah kontribusi fitur ke- i , S merupakan subset fitur yang tidak memuat fitur ke- i , dan F adalah himpunan seluruh fitur.

SHAP bekerja berdasarkan konsep *additive feature attribution*, yaitu hasil prediksi model dijelaskan sebagai penjumlahan antara nilai dasar (*base value*) dan kontribusi masing-masing fitur:

$$f(x) = \phi_0 + \sum_i 1^m \phi_i \quad (2.5)$$

di mana $f(x)$ adalah hasil prediksi model, ϕ_0 merupakan *base value*, dan ϕ_i adalah kontribusi fitur ke- i terhadap prediksi.


SHAP dapat digunakan untuk analisis global maupun lokal. Analisis global digunakan untuk mengetahui fitur yang paling berpengaruh terhadap keputusan model secara keseluruhan, sedangkan analisis lokal digunakan untuk menjelaskan alasan di balik prediksi suatu data tertentu. Dengan demikian, SHAP membantu meningkatkan interpretabilitas model klasifikasi email *phishing* yang dibangun dalam penelitian ini [16].

G. Streamlit

Streamlit merupakan *framework open-source* berbasis Python yang digunakan untuk membangun aplikasi web interaktif secara cepat dan terintegrasi dengan model *machine learning* [17]. Pada penelitian ini, *Streamlit* digunakan untuk mengimplementasikan sistem *StylDetect*, yang menyediakan fitur analisis email melalui *input* manual maupun integrasi Gmail serta menampilkan hasil klasifikasi dan interpretasi SHAP secara langsung.

III. METODOLOGI

Alur penelitian yang digunakan dalam penelitian ini ditunjukkan pada Gambar di bawah ini.



Gambar 1. Diagram Alir Penelitian

A. Dataset

Penelitian ini menggunakan *Phishing Email Dataset* yang diperoleh dari Kaggle. Dataset terdiri atas 82.486 email yang telah diberi label *phishing* dan *legitimate*. Isi email tersimpan pada atribut *text_combined*, sedangkan label kelas tersimpan pada atribut *label*. Dataset digunakan sebagai sumber data pada seluruh tahapan penelitian.

B. Preprocessing Data

Tahap *preprocessing* dilakukan untuk membersihkan teks email tanpa menghilangkan karakteristik gaya penulisannya. Proses yang dilakukan meliputi normalisasi *line break*, penghapusan *tag HTML*, penghapusan *header* email, serta normalisasi *whitespace*. Hasil dari tahap ini berupa teks email yang lebih bersih dan siap digunakan pada proses ekstraksi fitur.

C. Ekstraksi Fitur Stylometric

Setelah proses *preprocessing*, dilakukan ekstraksi 60 fitur *stylometric* yang mengacu pada penelitian Opara *et al.* Fitur yang digunakan mencakup karakteristik leksikal, sintaktik, tanda baca, keterbacaan, kategori kata, karakteristik email, kompleksitas teks, dan stilistika. Seluruh fitur direpresentasikan dalam bentuk numerik sebagai masukan bagi model klasifikasi.

D. Pembagian dan Normalisasi Data

Dataset hasil ekstraksi fitur dibagi menjadi data latih dan data uji dengan rasio 80:20 menggunakan metode *stratified split* untuk mempertahankan proporsi kelas pada kedua kelompok data. Selanjutnya dilakukan normalisasi menggunakan *StandardScaler* agar seluruh fitur berada pada skala yang sebanding sebelum digunakan pada proses pelatihan model.

E. Pelatihan Model SVM-RBF

Model klasifikasi dibangun menggunakan *Support Vector Machine* dengan kernel *Radial Basis Function* (SVM-RBF). Untuk memperoleh konfigurasi terbaik, dilakukan *hyperparameter tuning* menggunakan *GridSearchCV* dan *5-fold cross validation*. Parameter yang diuji meliputi nilai *C*, *gamma*, dan *class weight*. Setelah parameter terbaik diperoleh, model final dilatih menggunakan seluruh data latih yang telah dinormalisasi.

Selanjutnya, model dikonfigurasi menggunakan *Platt Scaling* untuk menghasilkan probabilitas prediksi. Probabilitas tersebut digunakan pada proses *threshold tuning* untuk menentukan batas keputusan yang memberikan performa terbaik berdasarkan nilai *F1-score*.

F. Evaluasi Model

Performa model dievaluasi menggunakan data uji yang tidak terlibat dalam proses pelatihan. Evaluasi dilakukan menggunakan metrik *accuracy*, *precision*, *recall*, *F1-score*, dan ROC-AUC. Selain itu, digunakan *confusion matrix* untuk menganalisis distribusi prediksi benar maupun kesalahan klasifikasi pada masing-masing kelas.

G. Implementasi Prediksi Model

Model SVM-RBF yang telah dilatih digunakan untuk menghasilkan probabilitas prediksi terhadap seluruh data email. Probabilitas yang diperoleh kemudian dikonversi menjadi label klasifikasi menggunakan nilai *threshold*

optimal yang diperoleh pada tahap sebelumnya. Hasil prediksi yang dihasilkan meliputi probabilitas kelas, label prediksi, serta kesesuaian antara prediksi dan label aktual.

Selanjutnya, hasil prediksi digunakan untuk memilih sampel yang mewakili kondisi *true positive* (TP), *true negative* (TN), *false positive* (FP), *false negative* (FN), dan *borderline*. Sampel-sampel tersebut digunakan pada tahap interpretasi model menggunakan SHAP untuk menganalisis alasan di balik keputusan model.

H. Implementasi SHAP

Untuk meningkatkan interpretabilitas model, penelitian ini menerapkan metode SHAP (*SHapley Additive Explanations*). Analisis dilakukan secara global dan lokal. Analisis global digunakan untuk mengidentifikasi fitur *stylometric* yang paling berpengaruh terhadap keputusan model secara keseluruhan, sedangkan analisis lokal digunakan untuk menjelaskan kontribusi masing-masing fitur terhadap prediksi suatu email tertentu. Analisis lokal dilakukan pada sampel yang mewakili kondisi *true positive*, *true negative*, *false positive*, *false negative*, dan *borderline*.

I. Implementasi Sistem StylDetect

Model yang telah dibangun diimplementasikan ke dalam aplikasi web bernama *StylDetect* menggunakan framework *Streamlit*. Sistem menyediakan dua mode penggunaan, yaitu *input* manual dan integrasi Gmail API dengan hak akses *read-only*. Proses analisis meliputi *preprocessing* email, ekstraksi fitur *stylometric*, normalisasi data, klasifikasi menggunakan SVM-RBF, serta interpretasi hasil menggunakan SHAP. Keluaran sistem berupa label klasifikasi, probabilitas prediksi, dan penjelasan fitur yang memengaruhi keputusan model.

IV. HASIL DAN PEMBAHASAN

A. Deskripsi Dataset

Penelitian ini menggunakan *Phishing Email Dataset* yang diperoleh dari Kaggle. Dataset terdiri atas 82.486 email yang terbagi menjadi 41.891 email *phishing* dan 39.595 email *legitimate*. Setiap data terdiri atas teks email pada kolom *text_combined* dan label kelas pada kolom *label*. Dataset ini digunakan pada seluruh tahapan penelitian, mulai dari *preprocessing*, ekstraksi fitur, pelatihan model, hingga evaluasi.

```
1 text_combined,label
2 hpl nom may 25 2001 see attached file hplno 525 xls hplno 525 xls,0
3 nom actual vols 24 th forwarded sabrae zajac hou ect 05 30 2001 12 07 pm enron capital trade
4 enron actuals march 30 april 1 201 estimated actuals march 30 2001 flow march 31 2001 flow a
5 hpl nom may 30 2001 see attached file hplno 530 xls hplno 530 xls,0
6 hpl nom june 1 2001 see attached file hplno 601 xls hplno 601 xls,0
7 hpl nom may 31 2001 see attached file hplno 531 xls hplno 531 xls,0
```

Gambar 2. Contoh Sampel Data dalam Dataset

B. Preprocessing Data

Tahap *preprocessing* dilakukan untuk membersihkan isi email sebelum ekstraksi fitur. Karena penelitian ini menggunakan pendekatan *stylometric*, *preprocessing*

dilakukan secara minimal agar karakteristik penulisan tetap terjaga. Tahapan yang dilakukan meliputi normalisasi *line break*, penghapusan tag HTML, penghapusan *header* email, dan normalisasi *whitespace*. Hasil *preprocessing* berupa teks email yang lebih bersih dan konsisten tanpa menghilangkan informasi yang diperlukan untuk analisis *stylometric*.

C. Ekstraksi Fitur Stylometric


Setelah tahap *preprocessing*, dilakukan ekstraksi fitur *stylometric* untuk mengubah teks email menjadi representasi numerik yang dapat digunakan oleh model klasifikasi. Penelitian ini menggunakan 60 fitur *stylometric* yang diadaptasi dari penelitian Opara dkk. [6]. Fitur-fitur tersebut dirancang untuk menangkap karakteristik gaya penulisan email yang berpotensi membedakan email *phishing* dan *legitimate*.

Fitur yang digunakan dikelompokkan ke dalam beberapa kategori, yaitu fitur leksikal, sintaktik, tanda baca, keterbacaan (*readability*), kategori kata, karakteristik email, kompleksitas teks, dan stilistika. Kelompok fitur tersebut mencakup berbagai karakteristik penulisan seperti jumlah kata, panjang kalimat, variasi kosakata, penggunaan tanda baca, tingkat keterbacaan, penggunaan kata ganti, kata perintah, kata yang menunjukkan urgensi, hingga pola personalisasi dalam isi email.

Hasil ekstraksi menghasilkan sebuah dataset numerik dengan 60 fitur untuk setiap email. Dataset hasil ekstraksi inilah yang selanjutnya digunakan sebagai masukan pada proses pelatihan model SVM-RBF.

D. Pembagian Data

Dataset hasil ekstraksi fitur dibagi menjadi data latih dan data uji dengan proporsi 80% dan 20% menggunakan metode *stratified split*. Metode ini digunakan untuk mempertahankan proporsi kelas *phishing* dan *legitimate* pada kedua kelompok data. Hasil pembagian menghasilkan 65.988 data latih dan 16.498 data uji.



Gambar 3. Hasil Pembagian Data

E. Normalisasi Data

Setelah proses pembagian data, dilakukan normalisasi terhadap seluruh fitur *stylometric* menggunakan metode *StandardScaler*. Tahap ini bertujuan untuk menyamakan

skala antar fitur yang memiliki rentang nilai berbeda, seperti jumlah kata, frekuensi tanda baca, dan skor keterbacaan.

Hasil normalisasi menunjukkan bahwa seluruh fitur berhasil ditransformasikan ke dalam skala yang lebih seragam dengan rata-rata mendekati 0 dan standar deviasi mendekati 1. Dengan demikian, tidak terdapat fitur tertentu yang mendominasi proses pembelajaran model akibat perbedaan rentang nilai yang terlalu besar.


Normalisasi menjadi tahap penting dalam penelitian ini karena model SVM-RBF sensitif terhadap perbedaan skala fitur. Data hasil normalisasi selanjutnya digunakan pada proses pelatihan dan optimasi model klasifikasi.

F. Pelatihan Model SVM-RBF

Data hasil normalisasi digunakan untuk membangun model klasifikasi menggunakan *Support Vector Machine* (SVM) dengan kernel *Radial Basis Function* (RBF). Pemilihan kernel RBF dilakukan karena kemampuannya dalam menangani pola data non-linear yang umum ditemukan pada fitur *stylographic*.

Sebelum pelatihan model, dilakukan *hyperparameter tuning* menggunakan *Grid Search* dengan *5-fold cross-validation*. Parameter yang diuji meliputi nilai *C*, *gamma*, dan *class weight*. Evaluasi selama proses pencarian parameter menggunakan metrik ROC-AUC.

Hasil *hyperparameter tuning* menunjukkan bahwa kombinasi parameter terbaik diperoleh pada nilai *C* = 100, *gamma* = 0.1, *kernel* = RBF, dan *class weight* = *balanced*. Parameter tersebut kemudian digunakan untuk membentuk model SVM-RBF final.



Gambar 4. Heatmap Hasil Hyperparameter Tuning

Berdasarkan Gambar di atas, kombinasi parameter terbaik menghasilkan nilai ROC-AUC sebesar 0,9517. Model yang telah dilatih selanjutnya digunakan untuk menghasilkan probabilitas prediksi pada data uji.

Setelah model menghasilkan probabilitas prediksi, dilakukan *threshold tuning* untuk menentukan batas keputusan klasifikasi yang optimal. Pengujian dilakukan pada beberapa nilai *threshold* dalam rentang 0,30 hingga 0,75 dengan interval 0,05. Pemilihan *threshold* terbaik didasarkan pada nilai *F1-score* tertinggi.

Hasil pengujian menunjukkan bahwa *threshold* sebesar 0,45 memberikan performa terbaik dengan nilai *F1-score* sebesar 0,8949. Oleh karena itu, nilai tersebut

digunakan sebagai batas keputusan pada proses klasifikasi email *phishing* dan *legitimate*.

Tabel I
Perbandingan Beberapa Nilai *Threshold*

Threshold	Accuracy	Precision	Recall	F1-Score
0.30	0.8739	0.8353	0.9436	0.8862
0.45	0.8887	0.8793	0.9111	0.8949
0.50	0.8885	0.8881	0.8987	0.8934
0.75	0.8770	0.9362	0.8193	0.8739

Berdasarkan Tabel di atas, nilai *threshold* 0,45 menghasilkan keseimbangan terbaik antara *precision* dan *recall*, sehingga dipilih sebagai *threshold* optimal pada penelitian ini.


G. Evaluasi dan Analisis Hasil

Evaluasi model dilakukan menggunakan data uji dengan *threshold* optimal sebesar 0,45. Metrik yang digunakan meliputi *accuracy*, *precision*, *recall*, *F1-score*, dan ROC-AUC.

Tabel II
Hasil Evaluasi Model SVM-RBF

Metrik	Nilai
Accuracy	0.8887
Precision	0.8793
Recall	0.9111
F1-Score	0.8949
ROC-AUC	0.9509


Berdasarkan Tabel di atas, model SVM-RBF menghasilkan performa yang baik dengan nilai *F1-score* sebesar 89,49% dan ROC-AUC sebesar 95,09%. Nilai *recall* yang mencapai 91,11% menunjukkan bahwa model mampu mendeteksi sebagian besar email *phishing*, sehingga risiko email berbahaya yang tidak terdeteksi dapat diminimalkan.



Gambar 5. Confusion Matrix Model SVM-RBF

Gambar di atas menunjukkan bahwa model mampu mengklasifikasikan sebagian besar email dengan benar, baik pada kelas *phishing* maupun *legitimate*. Meskipun masih terdapat beberapa kesalahan klasifikasi, hasil yang diperoleh

menunjukkan kemampuan model yang cukup baik dalam membedakan kedua kelas.




Gambar 6. ROC Curve Model SVM-RBF

Nilai ROC-AUC sebesar 0,9509 menunjukkan bahwa model memiliki kemampuan diskriminasi yang sangat baik dalam membedakan email *phishing* dan *legitimate*. Kurva ROC yang berada jauh di atas garis diagonal acak mengindikasikan bahwa model mampu menghasilkan performa klasifikasi yang konsisten.

H. Implementasi Prediksi Model

Model SVM-RBF yang telah melalui tahap pelatihan dan evaluasi selanjutnya digunakan untuk melakukan prediksi pada seluruh data email menggunakan *threshold* optimal sebesar 0,45. Setiap email terlebih dahulu melalui proses ekstraksi fitur *stylometric* dan normalisasi, kemudian diproses oleh model untuk menghasilkan probabilitas serta label klasifikasi akhir, yaitu *phishing* atau *legitimate*.

Hasil prediksi menunjukkan bahwa model mengklasifikasikan 44.268 email sebagai *phishing* dan 38.218 email sebagai *legitimate*. Distribusi hasil prediksi tersebut ditunjukkan pada Gambar berikut.




Gambar 7. Distribusi Hasil Prediksi Model

Selain menghasilkan label klasifikasi, tahap ini juga digunakan untuk memilih sampel yang akan dianalisis menggunakan SHAP. Sampel dipilih untuk mewakili berbagai kondisi prediksi model, yaitu *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), *False Negative* (FN), dan *borderline*. Sampel-sampel tersebut nantinya akan digunakan pada tahap interpretasi SHAP untuk menjelaskan faktor-faktor yang memengaruhi keputusan model dalam mengklasifikasikan email *phishing* dan *legitimate*.

I. Implementasi SHAP pada Model SVM-RBF

Untuk meningkatkan interpretabilitas model, penelitian ini menggunakan SHAP (*SHapley Additive*


Explanations) untuk menjelaskan kontribusi setiap fitur *stylometric* terhadap hasil prediksi model SVM-RBF. Analisis dilakukan untuk mengetahui fitur-fitur yang paling berpengaruh dalam membedakan email *phishing* dan *legitimate*.



Gambar 8. SHAP Summary Plot

Berdasarkan nilai *mean absolute SHAP*, fitur yang memiliki pengaruh terbesar terhadap keputusan model adalah *gunning_fog_index*, *coleman_liau_index*, *avg_word_length*, *trigram_count*, dan *lexical_diversity*. Hasil ini menunjukkan bahwa tingkat keterbacaan, kompleksitas teks, dan keragaman kosakata merupakan karakteristik penting dalam deteksi email *phishing*.

Selain *summary plot* berbentuk diagram batang, analisis global juga divisualisasikan menggunakan SHAP *beeswarm plot* seperti pada Gambar di bawah. Visualisasi ini menunjukkan distribusi dan arah kontribusi setiap fitur terhadap prediksi model.




Gambar 9. SHAP Beeswarm Plot

Pada *beeswarm plot*, setiap titik merepresentasikan satu data. Nilai SHAP positif menunjukkan kontribusi ke arah *phishing*, sedangkan nilai negatif mengarah ke *legitimate*. Terlihat bahwa fitur seperti *gunning_fog_index*, *coleman_liau_index*, dan *avg_word_length* memiliki pengaruh yang cukup besar terhadap keputusan model,

sehingga menjadi fitur penting dalam proses klasifikasi email.

Selain analisis global, SHAP juga digunakan untuk menjelaskan prediksi pada email tertentu melalui *waterfall plot*. Visualisasi ini menunjukkan fitur-fitur yang mendorong prediksi ke arah *phishing* maupun *legitimate*, sehingga alasan di balik keputusan model dapat dipahami dengan lebih jelas.




Gambar 10. Contoh Interpretasi Lokal Menggunakan SHAP

Hasil analisis menunjukkan bahwa model tidak hanya mampu mengklasifikasikan email dengan performa yang baik, tetapi juga memberikan penjelasan mengenai faktor-faktor yang memengaruhi proses pengambilan keputusan. Dengan demikian, penggunaan SHAP meningkatkan transparansi dan interpretabilitas sistem *StylDetect*.

J. Implementasi dan Pengujian Sistem Deteksi Email Phishing (*StylDetect*)

Model yang telah dibangun kemudian diimplementasikan ke dalam sistem deteksi email *phishing* berbasis web bernama *StylDetect* menggunakan *Streamlit*. Sistem mengintegrasikan model SVM-RBF, 60 fitur *stylometric*, serta metode SHAP untuk memberikan hasil prediksi yang lebih mudah dipahami pengguna.




Gambar 11. Halaman Utama Sistem *StylDetect*


Sistem menyediakan dua mode analisis, yaitu *input* manual dan integrasi Gmail. Pada mode *input* manual, pengguna dapat memasukkan isi email secara langsung untuk dianalisis. Sementara itu, pada mode Gmail, sistem dapat mengambil email dari akun pengguna melalui Gmail API dan melakukan analisis secara otomatis terhadap email yang dipilih.

Alur kerja sistem dimulai dari *preprocessing* teks email, ekstraksi fitur *stylometric*, normalisasi data, klasifikasi menggunakan model SVM-RBF, hingga menampilkan probabilitas *phishing* dan interpretasi SHAP. Hasil analisis disajikan dalam bentuk label klasifikasi, skor probabilitas, serta fitur-fitur yang paling berpengaruh terhadap keputusan model.

Pengujian dilakukan pada kedua mode penggunaan sistem. Pada mode *input* manual, sistem berhasil menerima email, melakukan klasifikasi, dan menampilkan interpretasi SHAP. Pada mode Gmail, sistem berhasil terhubung dengan akun pengguna, mengambil email dari *inbox*, dan melakukan analisis secara otomatis.



Gambar 12. Contoh Hasil Analisis pada Mode *Input* Manual



Gambar 13. Contoh Hasil Analisis pada Mode Integrasi Gmail

Berdasarkan hasil implementasi dan pengujian, sistem *StylDetect* berhasil mendeteksi email *phishing* baik melalui *input* manual maupun integrasi Gmail. Selain menghasilkan klasifikasi, sistem juga menyediakan interpretasi SHAP sehingga pengguna dapat memahami faktor-faktor yang memengaruhi keputusan model.

V. KESIMPULAN DAN SARAN

Berdasarkan hasil penelitian, berhasil dibangun sistem deteksi email *phishing* berbasis fitur *stylometric* menggunakan model SVM-RBF dan metode interpretasi SHAP. Model yang dihasilkan menunjukkan performa yang baik dengan nilai *accuracy* sebesar 88.87%, *F1-score* sebesar 89.49%, dan *ROC-AUC* sebesar 95.09%. Model juga berhasil diimplementasikan ke dalam sistem berbasis web *StylDetect* yang mendukung analisis email melalui *input* manual maupun integrasi Gmail serta mampu menampilkan interpretasi hasil prediksi secara transparan. Namun, hasil pengujian menunjukkan bahwa model masih memiliki keterbatasan dalam mendeteksi beberapa email *phishing* yang memiliki karakteristik penulisan menyerupai email *legitimate*, sehingga masih ditemukan kasus *false negative*.

Untuk pengembangan selanjutnya, penelitian dapat menggunakan dataset yang lebih besar dan beragam serta mengombinasikan fitur *stylometric* dengan fitur lain, seperti analisis URL, *header* email, atau fitur semantik untuk meningkatkan kemampuan deteksi. Selain itu, sistem dapat dikembangkan dengan dukungan layanan email lain serta kemampuan analisis terhadap tautan dan lampiran email.

UCAPAN TERIMA KASIH

Penulis mengucapkan terima kasih kepada Departemen Matematika, Fakultas Sains dan Analitika Data, Institut Teknologi Sepuluh Nopember atas dukungan dan fasilitas yang diberikan selama penelitian ini. Penulis juga menyampaikan apresiasi kepada seluruh pihak yang telah memberikan bantuan, dukungan, dan masukan sehingga penelitian ini dapat diselesaikan dengan baik.

VI. DAFTAR PUSTAKA

- [1] Anti-Phishing Working Group (APWG), *Phishing Activity Trends Report, 4th Quarter 2023*, 2024.
- [2] D. Desai, R. Hegde, E. Laufer, and J. Wang, "2023 Phishing Report Reveals 47.2% Surge in Phishing Attacks Last Year," Zscaler ThreatLabz, 2023.
- [3] Indonesia Anti-Phishing Data Exchange (IDADX), *Laporan Aktivitas Phishing Domain .id: Periode Q2 2023*, 2023.
- [4] Kaspersky, "Laporan Phishing Finansial di Asia Tenggara 2023," Medcom.id, 2023.
- [5] A. Alhuzali, A. Alloqmani, M. Aljabri, and F. Alharbi, "In-depth analysis of phishing email detection: Evaluating the performance of machine learning and deep learning models across multiple datasets," *Applied Sciences*, vol. 15, no. 6, p. 3396, 2025.
- [6] C. Opara, P. Modesti, and L. Golightly, "Evaluating Spam Filters and Stylometric Detection of AI-generated Phishing Emails," *Expert Systems with Applications*, vol. 276, p. 127044, 2025.
- [7] I. Chanis and A. Arampatzis, "Enhancing Phishing Email Detection with Stylometric Features and Classifier Stacking," *International Journal of Information Security*, 2025.
- [8] G. James, D. Witten, T. Hastie, and R. Tibshirani, *An Introduction to Statistical Learning: With Applications in R*. Springer, 2013.

- [9] N. Rumini, A. Mustofa, and S. Pradana, "Perbandingan Pengujian Deteksi Phishing Menggunakan Metode SVM dengan Kernel RBF dan Linear," *SISTEMASI: Jurnal Sistem Informasi*, vol. 12, no. 3, pp. 754–759, 2023.
- [10] S. M. Lundberg and S. I. Lee, "A Unified Approach to Interpreting Model Predictions," in *Proc. 31st Int. Conf. Neural Information Processing Systems (NIPS)*, 2017.
- [11] B. Lim *et al.*, "EXPLICATE: Enhancing Phishing Detection through Explainable AI and LLM-powered Interpretability," *arXiv preprint*, 2025.
- [12] C. Cortes and V. Vapnik, "Support-vector Networks," *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.
- [13] C.-W. Hsu, C.-C. Chang, and C.-J. Lin, *A Practical Guide to Support Vector Classification*. National Taiwan University, 2003.
- [14] J. C. Platt, "Probabilistic Outputs for Support Vector Machines and Comparisons to Regularized Likelihood Methods," in *Advances in Large Margin Classifiers*, MIT Press, 2000, pp. 61–74.
- [15] C. Molnar, *Interpretable Machine Learning*. Lulu.com, 2022.
- [16] S. M. Lundberg *et al.*, "From Local Explanations to Global Understanding with Explainable AI for Trees," *Nature Machine Intelligence*, vol. 2, no. 1, pp. 56–67, 2020.
- [17] S. Raghavendra, *Beginner's Guide to Streamlit with Python: Build Web-Based Data and Machine Learning Applications*. Springer, 2023.