

TUGAS AKHIR - SM234801

**SISTEM KLASIFIKASI EMAIL *PHISHING* BERBASIS
FITUR *STYLOMETRIC* DENGAN *SUPPORT
VECTOR MACHINE* DAN *SHAPLEY ADDITIVE
EXPLANATIONS***

LINTANG SYAWALANI HAWA NINGRUM

NRP 5002221058

Dosen Pembimbing

Prof. Dr. techn. Drs. Mohammad Isa Irawan, MT.

NIP 19631225 198903 1 001

Program Studi Sarjana

Departemen Matematika

Fakultas Sains dan Analitika Data

Institut Teknologi Sepuluh Nopember

Surabaya

2026



TUGAS AKHIR - SM234801

**SISTEM KLASIFIKASI EMAIL *PHISHING* BERBASIS
FITUR *STYLOMETRIC* DENGAN *SUPPORT
VECTOR MACHINE* DAN *SHAPLEY ADDITIVE
EXPLANATIONS***

LINTANG SYAWALANI HAWA NINGRUM

NRP 5002221058

Dosen Pembimbing

Prof. Dr. techn. Drs. Mohammad Isa Irawan, MT.

NIP 19631225 198903 1 001

Program Sarjana

Departemen Matematika

Fakultas Sains dan Analitika Data

Institut Teknologi Sepuluh Nopember

Surabaya

2026



FINAL PROJECT - SM234801

A PHISHING EMAIL CLASSIFICATION SYSTEM BASED ON STYLOMETRIC FEATURES USING SUPPORT VECTOR MACHINE AND SHAPLEY ADDITIVE EXPLANATIONS

LINTANG SYAWALANI HAWA NINGRUM

NRP 5002221058

Supervisors

Prof. Dr. techn. Drs. Mohammad Isa Irawan, MT.

NIP 19631225 198903 1 001

Bachelor Program

Departement of Mathematics

Faculty of Scientics

Institut Teknologi Sepuluh Nopember

Surabaya

2026

LEMBAR PENGESAHAN

Sistem Klasifikasi Email *Phishing* Berbasis Fitur *Stylometric* dengan
Support Vector Machine dan *Shapley Additive Explanations*

TUGAS AKHIR

Diajukan untuk memenuhi salah satu syarat
memperoleh gelar Sarjana Matematika pada
Program Studi S-1 Matematika
Departemen Matematika
Fakultas Sains dan Analitika Data
Institut Teknologi Sepuluh Nopember

Oleh: **LINTANG SYAWALANI HAWA NINGRUM**
NRP 5002221058

Surabaya, Juli 2026
Disetujui oleh Tim Penguji Tugas Akhir:

Pembimbing

1. Prof. Dr. techn. Drs. Mohammad Isa Irawan, MT. (.....)
NIP 19631225 198903 1 001

Penguji

1. Mohammad Iqbal, S.Si, M.Si, Ph.D (.....)
NIP 19880105 201903 1 007

2. Muhammad Luthfi Shahab, S.Si, M.Si, Ph.D (.....)
NIP 19950331 201803 1 001

Mengetahui

Kepala Departemen Matematika
Fakultas Sains dan Analitika Data

Dr. Didik Khusnul Arif, S.Si, M.Si
NIP 19730930 199702 1 001

APPROVAL SHEET

A Phishing Email Classification System Based on Stylometric Features Using Support Vector Machine and Shapley Additive Explanations

FINAL PROJECT

Submitted to fulfill one of the requirements
For obtaining a degree Bachelor of Mathematics at
Bachelor Program of Mathematics
Department of Mathematics
Faculty of Science and Data Analytics
Institut Teknologi Sepuluh Nopember

By: **LINTANG SYAWALANI HAWA NINGRUM**
NRP 5002221058

Surabaya, July 2026

Approved By:

Advisor

1. Prof. Dr. techn. Drs. Mohammad Isa Irawan, MT.
NIP 19631225 198903 1 001

(.....)

Examiners

1. Mohammad Iqbal, S.Si, M.Si, Ph.D
NIP 19880105 201903 1 007

(.....)

2. Muhammad Luthfi Shahab, S.Si, M.Si, Ph.D
NIP 19950331 201803 1 001

(.....)

Acknowledged by
Head of Mathematics Department
Faculty of Science and Data Analytics

Dr. Didik Khusnul Arif, S.Si, M.Si
NIP 19730930 199702 1 001

PERNYATAAN ORISINALITAS

Yang bertanda tangan disini:

Nama Mahasiswa / NRP : Lintang Syawalani Hawa Ningrum / 5002221058
Departemen : Matematika
Dosen Pembimbing / NIP : Prof. Dr. techn. Drs. Mohammad Isa Irawan, MT. /
19631225 198903 1 001

dengan ini menyatakan bahwa Tugas Akhir dengan judul “Sistem Klasifikasi Email *Phishing* Berbasis Fitur *Stylometric* dengan *Support Vector Machine* dan *Shapley Additive Explanations*” adalah hasil karya sendiri, bersifat orisinal, dan ditulis dengan mengikuti kaidah penulisan ilmiah.

Bilamana di kemudian hari ditemukan ketidaksesuaian dengan pernyataan ini, maka saya bersedia menerima sanksi sesuai dengan ketentuan yang berlaku di Institut Teknologi Sepuluh Nopember.

Surabaya, 31 Juli 2026

Mengetahui
Dosen Pembimbing

Mahasiswa

Prof. Dr. techn. Drs. Mohammad Isa Irawan, MT.
NIP 19631225 198903 1 001

Lintang Syawalani Hawa Ningrum
NRP 5002221058

STATEMENT OF ORIGINALITY

The undersigned below:

Student's Name / NRP : Lintang Syawalani Hawa Ningrum / 5002221058
Department : Mathematics
Advisor / NIP : Prof. Dr. techn. Drs. Mohammad Isa Irawan, MT. /
19631225 198903 1 001

Hereby declare that the Final Project with the title of

“A Phishing Email Classification System Based on Stylometric Features Using Support
Vector Machine and Shapley Additive Explanations”

is the result of my own work, is original, and is written by following the rules of scientific
writing.

If in the future there is a discrepancy with this statement, then I am willing to accept
sanctions in accordance with the provisions that apply at Institut Teknologi Sepuluh
Nopember.

Surabaya, 31 July 2026

Acknowledged,
Advisor

Student

Prof. Dr. techn. Drs. Mohammad Isa Irawan, MT. NIP 19631225 198903 1 001	<u>Lintang Syawalani Hawa Ningrum</u> NRP 5002221058
---	---

ABSTRAK

Sistem Klasifikasi Email *Phishing* Berbasis Fitur *Stylometric* dengan *Support Vector Machine* dan *Shapley Additive Explanations*

Nama Mahasiswa / NRP : Lintang Syawalani Hawa Ningrum / 5002221058

Departemen : Matematika FSAD -ITS

Dosen Pembimbing : Prof. Dr. techn. Drs. Mohammad Isa Irawan, MT.

Abstrak

Perkembangan teknologi informasi telah mempermudah komunikasi melalui email, namun juga meningkatkan ancaman email *phishing* yang bertujuan memperoleh informasi sensitif pengguna. Metode deteksi *phishing* yang umum digunakan masih mengandalkan analisis *URL*, *domain*, dan *blacklist*. Pendekatan tersebut memiliki keterbatasan ketika email *phishing* memiliki isi dan gaya penulisan yang menyerupai email resmi. Oleh karena itu, penelitian ini membangun model klasifikasi email *phishing* menggunakan fitur *stylometric*, yaitu fitur yang merepresentasikan karakteristik gaya penulisan email. Penelitian ini menggunakan 60 fitur *stylometric* yang diekstraksi dari isi email sebagai masukan pada algoritma *Support Vector Machine* (SVM). Untuk menjelaskan hasil klasifikasi yang dihasilkan model, penelitian ini menggunakan *Shapley Additive Explanations* (SHAP) sebagai pendekatan *Explainable Artificial Intelligence* (XAI). Model yang dibangun kemudian diimplementasikan ke dalam aplikasi berbasis web menggunakan *Streamlit* yang menyediakan dua mode penggunaan, yaitu *input* manual dan integrasi Gmail melalui API dengan hak akses *read-only*. Berdasarkan hasil evaluasi, model memperoleh nilai *accuracy* sebesar 88,87%, *precision* sebesar 87,93%, *recall* sebesar 91,11%, *F1-score* sebesar 89,49%, dan *ROC-AUC* sebesar 95,09%. Hasil analisis SHAP membantu menunjukkan fitur-fitur yang paling berpengaruh terhadap hasil klasifikasi model. Model yang dibangun berhasil diimplementasikan ke dalam aplikasi berbasis web sehingga pengguna dapat melakukan klasifikasi email *phishing* dan *legitimate* serta melihat hasil interpretasi SHAP secara langsung.

Kata kunci: *Phishing, Stylometric, Support Vector Machine, Explainable AI, SHAP.*

ABSTRACT

A Phishing Email Classification System Based on Stylometric Features Using Support Vector Machine and Shapley Additive Explanations

Student Name / NRP : Lintang Syawalani Hawa Ningrum / 5002221058
Departement : Mathematics SCIENTICS - ITS
Advisor : Prof. Dr. techn. Drs. Mohammad Isa Irawan, MT.

Abstract

The advancement of information technology has made email communication more convenient while simultaneously increasing the threat of phishing emails that aim to obtain users' sensitive information. Existing phishing detection methods primarily rely on URL, domain, and blacklist analysis. However, these approaches have limitations when phishing emails closely resemble legitimate emails in both content and writing style. Therefore, this study develops a phishing email classification model using stylometric features that capture the writing characteristics of email content. A total of 60 stylometric features extracted from email content are used as input for the Support Vector Machine (SVM) algorithm. To explain the model's classification results, this study employs Shapley Additive Explanations (SHAP) as an Explainable Artificial Intelligence (XAI) approach. The developed model is then implemented in a web-based application using Streamlit, which provides two usage modes: manual input and Gmail integration through the API with read-only access. Based on the evaluation results, the model achieved an accuracy of 88.87%, precision of 87.93%, recall of 91.11%, F1-score of 89.49%, and ROC-AUC of 95.09%. The SHAP analysis helps identify the stylometric features that contribute most significantly to the model's classification results. The developed model was successfully implemented in the web-based application, enabling users to classify phishing and legitimate emails while directly viewing SHAP-based interpretations of the classification results.

Keywords: *Phishing, Stylometric, Support Vector Machine, Explainable AI, SHAP.*

KATA PENGANTAR

Dengan memanjatkan puji syukur kehadirat Allah SWT atas rahmat, taufik, dan hidayah-nya sehingga penulis dapat menyelesaikan tugas akhir dengan judul:

*"SISTEM KLASIFIKASI EMAIL PHISHING BERBASIS FITUR STYLOMETRIC
DENGAN SUPPORT VECTOR MACHINE DAN SHAPLEY ADDITIVE
EXPLANATIONS"*

sebagai salah satu persyaratan akademis dalam menyelesaikan Program Sarjana Departemen Matematika, Fakultas Sains dan Analitika Data, Institut Teknologi Sepuluh Nopember Surabaya.

Penyusunan Tugas Akhir ini tidak terlepas dari berbagai tantangan, proses pembelajaran, serta dukungan, bantuan, bimbingan, dan doa dari berbagai pihak. Oleh karena itu, pada kesempatan ini penulis ingin menyampaikan rasa terima kasih dan penghargaan yang sebesar-besarnya kepada:

1. Bapak Dr. Didik Khusnul Arif, S.Si, M.Si. selaku Kepala Departemen Matematika Institut Teknologi Sepuluh Nopember yang telah memberi arahan semasa berkuliah.
2. Bapak Prof. Dr. techn. Drs. Mohammad Isa Irawan, MT. selaku dosen pembimbing yang telah membantu dan memberikan arahan, serta motivasi kepada penulis.
3. Ibu Dr. Sunarsini, S.Si, M.Si selaku dosen wali yang telah memberikan arahan kepada penulis selama masa perkuliahan.
4. Bapak Mohammad Iqbal, S.Si, M.Si, Ph.D dan Muhammad Luthfi Shahab, S.Si, M.Si, Ph.D selaku Dosen Penguji yang telah memberikan kritik dan sarannya untuk perbaikan Laporan Tugas Akhir ini.
5. Bapak/Ibu dosen pengajar, yang telah memberikan ilmu dan pengalaman yang bermanfaat, serta seluruh Karyawan, Tendik dan keluarga besar Departemen Matematika Institut Teknologi Sepuluh Nopember atas dukungan dan bantuannya.
6. Yang paling utama kepada nenek dan kakek saya yang senantiasa memberikan doa, kasih sayang, perhatian, serta dukungan yang tulus kepada penulis selama menempuh pendidikan hingga penyusunan Tugas Akhir ini dapat diselesaikan.
7. Kedua orang tua dan keluarga tercinta yang selalu memberikan doa, dukungan moral, kepercayaan, serta semangat yang tiada henti kepada penulis.
8. Teman-teman Departemen Matematika ITS angkatan 2022 yang telah menjadi rekan belajar, berbagi pengalaman, serta memberikan dukungan selama masa perkuliahan.
9. Sahabat dan teman-teman terdekat yang senantiasa memberikan semangat, bantuan, serta menemani penulis dalam menghadapi berbagai tantangan selama penyusunan Tugas Akhir ini.

Penulis mengharapkan saran dan kritik dari pembaca. Akhir kata, semoga Tugas Akhir ini bermanfaat bagi semua pihak yang membacanya.

Surabaya, 31 Juli 2026

Lintang Syawalani Hawa Ningrum

DAFTAR ISI

LEMBAR PENGESAHAN	i
LEMBAR PENGESAHAN	iii
PERNYATAAN ORISINALITAS	v
PERNYATAAN ORISINALITAS	vii
ABSTRAK	ix
ABSTRACT	xi
KATA PENGANTAR	xiii
DAFTAR ISI	xv
DAFTAR GAMBAR	xix
DAFTAR TABEL	xxi
DAFTAR SIMBOL	xxiii
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	2
1.3 Batasan Masalah	3
1.4 Tujuan	3
1.5 Manfaat	3
BAB II TINJAUAN PUSTAKA	5
2.1 Penelitian Terdahulu	5
2.2 <i>Phishing</i>	6
2.3 <i>Stylometric</i> dalam Klasifikasi <i>Phishing</i>	7
2.4 Normalisasi Data	7
2.5 <i>Support Vector Machine</i> (SVM)	8
2.5.1 Konsep Dasar SVM	9
2.5.2 <i>Support Vector</i> dan <i>Margin</i>	9
2.5.3 Kernel pada <i>Support Vector Machine</i> (SVM)	9
2.5.4 <i>Kernel Radial Basis Function</i> (RBF)	10
2.5.5 Jarak Euclidean	10
2.5.6 Optimasi <i>Support Vector Machine</i> (SVM)	10
2.5.7 Parameter C dan γ	11
2.5.8 Fungsi Keputusan (<i>Decision Function</i>)	11
2.6 Evaluasi Model	11
2.6.1 <i>Accuracy</i>	11
2.6.2 <i>Precision</i>	12
2.6.3 <i>Recall</i>	12
2.6.4 <i>F1-Score</i>	12
2.6.5 ROC-AUC (<i>Receiver Operating Characteristic - Area Under Curve</i>)	12

2.6.6	<i>Confusion Matrix</i>	12
2.7	<i>Hyperparameter Tuning</i>	13
2.7.1	<i>Cross Validation</i>	13
2.7.2	<i>GridSearchCV</i>	13
2.8	<i>Platt Scaling</i>	13
2.9	<i>Explainable Artificial Intelligence (XAI)</i>	14
2.9.1	<i>Shapley Additive Explanations (SHAP)</i>	14
2.10	<i>Streamlit</i>	15
BAB III	METODOLOGI	17
3.1	Identifikasi Permasalahan	18
3.2	Pengumpulan Data	18
3.3	<i>Preprocessing</i> Data	18
3.3.1	Normalisasi <i>Line Break</i>	18
3.3.2	Penghapusan <i>Tag HTML</i>	18
3.3.3	Penghapusan <i>Header Email</i>	18
3.3.4	Normalisasi <i>Whitespace</i>	18
3.4	Ekstraksi Fitur <i>Stylometric</i>	19
3.4.1	Kategori Fitur	19
3.4.2	Daftar Kelompok Kata (<i>Word List</i>)	19
3.4.3	Daftar Fitur <i>Stylometric</i>	20
3.5	Pembagian Data (<i>Data Splitting</i>)	24
3.6	Normalisasi Data	24
3.7	Pelatihan Model <i>Support Vector Machine</i>	25
3.7.1	<i>Hyperparameter Tuning</i>	25
3.7.2	Pelatihan Model Final	25
3.8	Evaluasi Model	25
3.9	Implementasi <i>Explainable AI (XAI)</i> Menggunakan SHAP	25
3.10	Perancangan Sistem Klasifikasi Email <i>Phishing</i>	26
3.11	Pengujian Sistem Klasifikasi Email <i>Phishing</i>	26
3.12	Penarikan Kesimpulan dan Saran	27
3.13	Penyusunan Laporan Tugas Akhir	27
BAB IV	HASIL DAN PEMBAHASAN	29
4.1	Deskripsi Dataset	29
4.2	<i>Preprocessing</i> Data	29
4.2.1	Normalisasi <i>Line Break</i>	30
4.2.2	Penghapusan <i>HTML Tag</i>	30
4.2.3	Penghapusan <i>Header Email</i>	31
4.2.4	Normalisasi <i>Whitespace</i>	31
4.3	Ekstraksi Fitur <i>Stylometric</i>	31
4.3.1	Implementasi Ekstraksi Fitur <i>Stylometric</i>	32
4.3.2	Implementasi Perhitungan Fitur	32
4.3.3	Hasil Ekstraksi Fitur	36
4.4	Pembagian Data (<i>Data Splitting</i>)	37
4.5	Normalisasi Data	37
4.6	Pelatihan Model <i>Support Vector Machine (SVM)</i>	42
4.6.1	<i>Hyperparameter Tuning</i>	42

4.6.2	Pelatihan Model Final	45
4.7	Evaluasi dan Analisis Hasil	52
4.8	Implementasi SHAP pada Model <i>Support Vector Machine</i> (SVM)	57
4.9	Implementasi Sistem Klasifikasi Email <i>Phishing</i>	73
4.10	Pengujian Sistem Klasifikasi Email <i>Phishing</i>	80
4.10.1	Skenario Pengujian Sistem	80
4.10.2	Pengujian Mode <i>Input</i> Manual	80
4.10.3	Pengujian Integrasi Gmail	83
BAB V	KESIMPULAN DAN SARAN	85
5.1	Kesimpulan	85
5.2	Saran	85
	DAFTAR PUSTAKA	87
	DAFTAR LAMPIRAN	91
Lampiran 1	Contoh Email dari Dataset Kaggle	91
Lampiran 2	Contoh Email <i>Phishing</i> dari DPTSI ITS	93
Lampiran 3	Hasil Ekstraksi Fitur <i>Stylometric</i>	95
Lampiran 4	Contoh Data Hasil Normalisasi	96
Lampiran 5	Contoh Data <i>Support Vector</i>	97
Lampiran 6	Data Sampel Analisis SHAP	98
Lampiran 7	Visualisasi SHAP Lokal dari Data Sampel Analisis	99
Lampiran 8	<i>Repository</i> GitHub	102
	UCAPAN TERIMA KASIH	103
	BIODATA PENULIS	105

DAFTAR GAMBAR

Gambar 2.1	Ilustrasi <i>hyperplane</i> , <i>support vector</i> , dan <i>margin</i> pada SVM	8
Gambar 2.2	Tampilan antarmuka <i>Streamlit</i>	16
Gambar 3.1	Diagram Alir Penelitian	17
Gambar 4.1	Contoh Sampel Data dalam Dataset	29
Gambar 4.2	<i>Library</i> untuk <i>Preprocessing Data</i>	30
Gambar 4.3	Normalisasi <i>Line Break</i>	30
Gambar 4.4	Penghapusan HTML <i>Tag</i>	30
Gambar 4.5	Penghapusan <i>Header Email</i>	31
Gambar 4.6	Normalisasi <i>Whitespace</i>	31
Gambar 4.7	<i>Library</i> untuk <i>Feature Extraction</i>	32
Gambar 4.8	Contoh Data Email	33
Gambar 4.9	Hasil Pembagian Data	37
Gambar 4.10	<i>Library</i> untuk Normalisasi Data	38
Gambar 4.11	Kode Program untuk Proses Normalisasi Data	38
Gambar 4.12	Contoh Data Setelah Normalisasi	39
Gambar 4.13	<i>Library</i> untuk Pelatihan Model	42
Gambar 4.14	Kode Program untuk <i>Hyperparameter Tuning</i>	43
Gambar 4.15	<i>Output</i> Parameter Terbaik Hasil <i>Hyperparameter Tuning</i>	44
Gambar 4.16	<i>Heatmap</i> Hasil <i>GridSearch</i> Model SVM	44
Gambar 4.17	Kode Program untuk Nilai Fungsi Keputusan	52
Gambar 4.18	<i>Library</i> untuk Evaluasi Model	52
Gambar 4.19	Kode Program Evaluasi Model	53
Gambar 4.20	Hasil <i>Confusion Matrix</i> Model	53
Gambar 4.21	Hasil <i>ROC Curve</i>	56
Gambar 4.22	<i>Library</i> untuk Implementasi SHAP	57
Gambar 4.23	Kode Program Pemilihan Sampel SHAP	59
Gambar 4.24	Kode Program Pemuatan Model dan Data	59
Gambar 4.25	Kode Program Pengambilan Sampel SHAP	60
Gambar 4.26	Kode Program Pembentukan <i>Background Data</i>	60
Gambar 4.27	Kode Program Pembentukan SHAP <i>Explainer</i>	60
Gambar 4.28	Kode Program Perhitungan Nilai SHAP	66
Gambar 4.29	Kode Program Perhitungan <i>Mean Absolute SHAP</i>	66
Gambar 4.30	SHAP <i>Summary Plot (Bar)</i> untuk <i>Feature Importance</i>	67
Gambar 4.31	SHAP <i>Summary Plot (Beeswarm)</i>	68
Gambar 4.32	Kode Program Perhitungan SHAP untuk Data Sampel	69
Gambar 4.33	Kode Program Pemilihan SHAP untuk Data Sampel Kelas <i>Phishing</i>	69
Gambar 4.34	Kode Program Visualisasi SHAP Lokal	69
Gambar 4.35	SHAP <i>Waterfall Plot</i> untuk Data <i>True Positive</i> (TP)	70
Gambar 4.36	SHAP <i>Waterfall Plot</i> untuk Data <i>True Negative</i> (TN)	70
Gambar 4.37	SHAP <i>Waterfall Plot</i> untuk Data <i>False Positive</i> (FP)	71

Gambar 4.38 SHAP <i>Waterfall Plot</i> untuk Data <i>False Negative</i> (FN)	72
Gambar 4.39 <i>Library</i> Utama untuk Implementasi Sistem	73
Gambar 4.40 <i>Library</i> Integrasi Gmail	73
Gambar 4.41 Kode Program Konfigurasi Halaman Sistem	74
Gambar 4.42 Kode Program Konfigurasi File Sistem	74
Gambar 4.43 Kode Program Ekstraksi Fitur <i>Stylometric</i>	75
Gambar 4.44 Kode Program Pemuatan Model dan <i>Scaler</i>	75
Gambar 4.45 Kode Program Pembentukan SHAP <i>Explainer</i>	75
Gambar 4.46 Konfigurasi Hak Akses Gmail	76
Gambar 4.47 Kode Program Pengambilan Email Gmail	76
Gambar 4.48 Kode Program Interpretasi SHAP	76
Gambar 4.49 Halaman Utama Sistem Klasifikasi	77
Gambar 4.50 Kode Program <i>Input</i> Manual Email	77
Gambar 4.51 Kode Program Pengaturan Jumlah Fitur SHAP	78
Gambar 4.52 Hasil Klasifikasi Email pada Mode <i>Input</i> Manual	78
Gambar 4.53 Kode Program Pengaturan Jumlah Email Gmail	79
Gambar 4.54 Hasil Klasifikasi Email pada Mode Integrasi Gmail	79
Gambar 4.55 Hasil Pengujian Mode <i>Input</i> Manual Contoh Pertama	81
Gambar 4.56 Hasil Pengujian Mode <i>Input</i> Manual Contoh Kedua	82
Gambar 4.57 Hasil Pengujian Mode Integrasi Gmail	83

DAFTAR TABEL

Tabel 3.1	Daftar Kategori dan Kata Kunci Stylometric	20
Tabel 3.2	Daftar 60 Fitur <i>Stylometric</i> yang Digunakan	21
Tabel 4.1	Fungsi <i>Library</i> pada <i>Preprocessing Data</i>	30
Tabel 4.2	Fungsi <i>Library</i> pada <i>Feature Extraction</i>	32
Tabel 4.4	Contoh Data Hasil Ekstraksi Fitur	36
Tabel 4.5	Distribusi Kelas Setelah Pembagian Data	37
Tabel 4.6	Fungsi <i>Library</i> pada Normalisasi Data	38
Tabel 4.7	Contoh Data Sebelum Normalisasi	38
Tabel 4.8	Fungsi <i>Library</i> pada Pelatihan Model	42
Tabel 4.9	Parameter <i>Hyperparameter Tuning</i> SVM-RBF	43
Tabel 4.10	Data Contoh Perhitungan	45
Tabel 4.11	Contoh Data <i>Support Vector</i>	49
Tabel 4.12	Fungsi <i>Library</i> pada Evaluasi	53
Tabel 4.13	Hasil Evaluasi Model SVM-RBF	54
Tabel 4.14	Titik FPR dan TPR untuk Kurva ROC	55
Tabel 4.15	Fungsi <i>Library</i> pada Implementasi SHAP	57
Tabel 4.16	Deskripsi Kolom Hasil Prediksi	58
Tabel 4.17	Contoh Hasil Prediksi Data Uji	58
Tabel 4.18	Contoh Sampel untuk Analisis SHAP	59
Tabel 4.19	Data Contoh Perhitungan SHAP	61
Tabel 4.20	Bobot SHAP	63
Tabel 4.21	Perhitungan Nilai SHAP untuk Fitur <i>avg_word_length</i>	64
Tabel 4.22	Rangkuman Kontribusi SHAP Berdasarkan Ukuran Himpunan S ...	65
Tabel 4.23	Nilai SHAP Akhir	65
Tabel 4.24	Ranking Fitur Berdasarkan <i>Mean Absolute</i> SHAP	67
Tabel 4.25	Fungsi <i>Library</i> pada Implementasi Sistem	73
Tabel 4.26	Skenario Pengujian Sistem Klasifikasi	80
Tabel 4.27	Hasil Pengujian Mode <i>Input Manual</i>	81

DAFTAR SIMBOL

x'	:	nilai fitur setelah normalisasi
x	:	nilai fitur sebelum normalisasi
μ	:	nilai rata-rata setiap fitur
σ	:	standar deviasi setiap fitur
$\mathbf{w}$	:	vektor bobot (<i>weight</i>)
$\mathbf{x}$	:	vektor fitur suatu data
b	:	bias
$\mathbf{x}_i$	:	vektor fitur data ke- i
$\mathbf{x}_j$	:	vektor fitur data ke- j
$\mathbf{x}_i^T$	:	transpose dari vektor fitur $\mathbf{x}_i$
$K(\mathbf{x}_i, \mathbf{x}_j)$	:	nilai fungsi kernel antara data ke- i dan data ke- j
γ	:	parameter yang mengatur besar pengaruh suatu data terhadap data lainnya
$\ \mathbf{x}_i - \mathbf{x}_j\ ^2$	:	kuadrat jarak Euclidean antara data ke- i dan data ke- j
m	:	jumlah fitur
x_{ik}	:	nilai fitur ke- k pada data ke- i
x_{jk}	:	nilai fitur ke- k pada data ke- j
$L(\alpha)$	:	fungsi objektif dalam bentuk dual yang akan dimaksimumkan
n	:	jumlah data pelatihan
α_i	:	nilai <i>Lagrange multiplier</i> pada data ke- i
y_i	:	label kelas
C	:	parameter regularisasi
$f(\mathbf{x})$	:	nilai fungsi keputusan untuk data $\mathbf{x}$
TP	:	<i>True Positive</i> (email <i>phishing</i> yang berhasil diprediksi sebagai <i>phishing</i>)
TN	:	<i>True Negative</i> (email <i>legitimate</i> yang berhasil diprediksi sebagai <i>legitimate</i>)
FP	:	<i>False Positive</i> (email <i>legitimate</i> yang salah diprediksi sebagai <i>phishing</i>)

FN	:	<i>False Negative</i> (email <i>phishing</i> yang salah diprediksi sebagai <i>legitimate</i>)
TPR	:	<i>True Positive Rate</i> (proporsi email <i>phishing</i> yang berhasil diprediksi sebagai <i>phishing</i>)
FPR	:	<i>False Positive Rate</i> (proporsi email <i>legitimate</i> yang salah diprediksi sebagai <i>phishing</i>)
$P(y = 1 x)$	:	probabilitas data termasuk ke kelas positif
A dan B	:	parameter kalibrasi
ϕ_i	:	kontribusi fitur ke- i terhadap hasil prediksi model
$S \subseteq F \setminus \{i\}$	:	menyatakan bahwa S merupakan kombinasi fitur yang tidak memuat fitur ke- i
S	:	himpunan bagian dari seluruh fitur yang tidak memuat fitur ke- i
F	:	himpunan seluruh fitur
$f(S)$	:	hasil prediksi model menggunakan himpunan fitur S
$f(S \cup \{i\})$	:	hasil prediksi model setelah fitur ke- i ditambahkan ke dalam himpunan fitur S
$f(x)$	:	hasil prediksi model pada data ke x
ϕ_j	:	kontribusi fitur ke- j terhadap hasil prediksi model
$\phi_{i,j}$	:	kontribusi fitur ke- j terhadap hasil prediksi pada data ke- i

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi yang pesat pada era digital telah mempermudah manusia dalam berkomunikasi, salah satunya melalui email. Email menjadi salah satu media komunikasi yang banyak digunakan, baik untuk keperluan pekerjaan maupun komunikasi pribadi, karena dapat mengirimkan informasi dengan cepat dan mudah. Namun, kemudahan tersebut juga dimanfaatkan oleh pelaku kejahatan siber untuk melakukan serangan *phishing* yang bertujuan memperoleh informasi sensitif pengguna, seperti *username*, *password*, dan data keuangan (Alhuzali et al., 2025).

Phishing merupakan salah satu bentuk serangan rekayasa sosial yang dilakukan dengan cara menipu pengguna melalui email agar memberikan informasi pribadi. Seiring perkembangan teknologi, pelaku *phishing* menggunakan berbagai cara agar email yang dikirim terlihat seperti email resmi sehingga semakin sulit untuk dikenali. Berdasarkan Laporan Ancaman Phishing Cloudflare (2023), selama periode satu tahun ditemukan lebih dari 13 miliar indikator ancaman *phishing* yang berasal dari sekitar 279 juta layanan internet yang dianalisis. Selain itu, (APWG) (2024) melaporkan lebih dari 1 juta insiden *phishing* terjadi dalam satu kuartal pada tahun 2023. Laporan Zscaler Desai et al. (2023) juga menunjukkan bahwa jumlah serangan *phishing* meningkat sebesar 47,2% dibandingkan tahun sebelumnya, dengan sektor perbankan, layanan *online*, dan media sosial sebagai sasaran utama. Data tersebut menunjukkan bahwa ancaman *phishing* masih terus meningkat dan menjadi salah satu tantangan dalam keamanan siber.

Di Indonesia, kasus *phishing* juga terus meningkat. Berdasarkan laporan dari (IDADX) (2023), pada kuartal II tahun 2023 tercatat sebanyak 20.330 laporan *phishing*. Sasaran serangan didominasi oleh media sosial sebesar 53.95%, diikuti sektor perbankan sebesar 19.5% serta sektor *e-commerce* dan ritel sebesar 20%. Selain itu, laporan Kaspersky (2023) menyebutkan bahwa Indonesia mencatat lebih dari 97.000 kejadian *phishing* terkait keuangan sepanjang tahun 2023 dan menempati peringkat ketiga tertinggi di Asia Tenggara. Data tersebut menunjukkan bahwa ancaman *phishing* tidak hanya menjadi masalah di tingkat global, tetapi juga menjadi perhatian di Indonesia.

Metode yang umum digunakan untuk mendeteksi *phishing* masih banyak mengandalkan analisis teknis, seperti URL mencurigakan, reputasi *domain*, dan daftar hitam (*blacklist*). Pendekatan ini cukup efektif untuk mendeteksi pola serangan yang sudah dikenal. Namun, metode tersebut memiliki keterbatasan ketika pelaku *phishing* menggunakan email yang memiliki isi dan gaya penulisan yang menyerupai email resmi atau memanfaatkan kecerdasan buatan untuk menghasilkan teks yang lebih alami (Opara et al., 2025). Akibatnya, email *phishing* menjadi lebih sulit dibedakan hanya berdasarkan indikator teknis.

Salah satu pendekatan yang dapat digunakan untuk mengatasi keterbatasan tersebut adalah analisis *stylometric*. Pendekatan ini menganalisis karakteristik penulisan dalam email, seperti panjang kata, panjang kalimat, penggunaan tanda baca, serta pola penggunaan kata (Chanis & Arampatzis, 2025). Berbeda dengan metode yang hanya berfokus pada URL atau *domain*, *stylometric* memanfaatkan isi email sebagai sumber

informasi untuk proses klasifikasi. Penelitian yang dilakukan oleh (Opara et al., 2025) menunjukkan bahwa fitur-fitur *stylometric* dapat membantu membedakan email *phishing* dan *legitimate* karena keduanya memiliki karakteristik penulisan yang berbeda.

Untuk mengklasifikasikan email berdasarkan fitur *stylometric*, diperlukan algoritma yang mampu mengenali pola dari data. Salah satu algoritma yang banyak digunakan untuk tugas klasifikasi adalah *Support Vector Machine* (SVM). Penelitian yang dilakukan oleh Rumini et al. (2023) menunjukkan bahwa SVM memiliki kinerja yang baik dalam klasifikasi data. Selain itu, SVM juga mampu menangani hubungan data yang tidak linear melalui penggunaan kernel sehingga sesuai digunakan pada penelitian ini. Namun, proses pengambilan keputusan pada model SVM tidak mudah dipahami karena model hanya menghasilkan hasil klasifikasi tanpa menjelaskan alasannya. Oleh karena itu, penelitian ini menggunakan *Shapley Additive Explanations* (SHAP) sebagai pendekatan *Explainable Artificial Intelligence* (XAI) untuk menjelaskan kontribusi setiap fitur terhadap hasil prediksi (Lim et al., 2025).

Dalam penelitian ini, sistem klasifikasi email *phishing* dibangun menggunakan 60 fitur *stylometric* yang diekstraksi dari isi email. Fitur-fitur tersebut digunakan sebagai *input* pada model *Support Vector Machine* (SVM) untuk mengklasifikasikan email ke dalam kategori *phishing* atau *legitimate*. Selanjutnya, *Shapley Additive Explanations* (SHAP) digunakan untuk menjelaskan kontribusi setiap fitur terhadap hasil prediksi kelas.

Penelitian ini bertujuan untuk menganalisis penggunaan fitur *stylometric* dalam mengklasifikasikan email *phishing* dan *legitimate* menggunakan algoritma *Support Vector Machine* (SVM). Selain itu, penelitian ini juga memanfaatkan *Shapley Additive Explanations* (SHAP) untuk menjelaskan kontribusi setiap fitur terhadap hasil prediksi. Dengan demikian, penelitian ini tidak hanya menghasilkan model klasifikasi, tetapi juga memberikan penjelasan mengenai kontribusi masing-masing fitur terhadap hasil klasifikasi yang dihasilkan oleh model.

Model yang dibangun kemudian diimplementasikan ke dalam aplikasi berbasis web menggunakan *Streamlit*. Aplikasi ini menyediakan dua mode penggunaan, yaitu *input* secara manual dan integrasi dengan Gmail melalui API. Pengguna dapat melakukan klasifikasi email *phishing* serta melihat hasil penjelasan dari SHAP terhadap prediksi yang diberikan oleh model. Melalui implementasi tersebut, diharapkan sistem dapat membantu pengguna dalam mengenali email *phishing* sekaligus memahami alasan di balik hasil klasifikasi yang diberikan.

1.2 Rumusan Masalah

Berdasarkan uraian pada latar belakang, maka rumusan masalah pada penelitian ini adalah sebagai berikut:

1. Bagaimana fitur-fitur *stylometric* digunakan untuk membedakan email *phishing* dan email *legitimate*?
2. Bagaimana algoritma *Support Vector Machine* (SVM) mengklasifikasikan email *phishing* dan *legitimate* berdasarkan fitur *stylometric*?
3. Bagaimana *Shapley Additive Explanations* (SHAP) menjelaskan kontribusi setiap fitur terhadap hasil prediksi kelas?
4. Bagaimana implementasi model klasifikasi email *phishing* berbasis fitur *stylometric* ke dalam aplikasi berbasis web?

1.3 Batasan Masalah

Agar penelitian ini dapat berjalan dengan fokus dan tidak melebar ke luar topik utama, maka penulis menetapkan beberapa batasan masalah sebagai berikut:

1. Data yang digunakan dalam penelitian ini berasal dari dataset "*Phishing Email Dataset*" yang diperoleh dari Kaggle dengan nama file *phishing_email.csv*. Dataset tersebut berisi isi email pada kolom *text_combined* beserta label *phishing* dan *legitimate*.
2. Seluruh email yang digunakan dalam penelitian ini menggunakan bahasa Inggris sehingga proses *preprocessing* dan ekstraksi fitur *stylometric* disesuaikan dengan karakteristik bahasa Inggris.
3. Penelitian ini hanya menggunakan fitur *stylometric* yang diekstraksi dari isi email. Analisis berdasarkan URL, reputasi *domain*, *header* email, maupun metode deteksi lainnya tidak dibahas.
4. Penelitian ini hanya menggunakan isi teks email dan tidak menganalisis lampiran email, seperti dokumen, gambar, maupun berkas lainnya.
5. Implementasi sistem dilakukan dalam bentuk aplikasi berbasis web menggunakan *Streamlit* dengan dua mode penggunaan, yaitu *input* manual dan integrasi Gmail melalui API dengan hak akses *read-only*. Integrasi dengan layanan email lain tidak dibahas dalam penelitian ini.

1.4 Tujuan

Penelitian ini memiliki beberapa tujuan utama, yaitu:

1. Mengidentifikasi fitur-fitur *stylometric* yang dapat digunakan untuk membedakan email *phishing* dan email *legitimate*.
2. Menerapkan algoritma *Support Vector Machine* (SVM) untuk mengklasifikasikan email *phishing* dan *legitimate* berdasarkan fitur *stylometric*, serta mengevaluasi performa model klasifikasi.
3. Menerapkan metode *Explainable Artificial Intelligence* (XAI) menggunakan *Shapley Additive Explanations* (SHAP) untuk menjelaskan kontribusi setiap fitur terhadap hasil prediksi kelas.
4. Mengimplementasikan model klasifikasi email *phishing* berbasis fitur *stylometric* ke dalam aplikasi berbasis web.

1.5 Manfaat

Penelitian ini diharapkan dapat memberikan manfaat sebagai berikut:

1. Membantu pengguna mengenali dan membedakan email *phishing* dan email *legitimate* melalui aplikasi berbasis web yang memanfaatkan analisis fitur *stylometric*, sehingga dapat meningkatkan kewaspadaan terhadap potensi ancaman *phishing* pada komunikasi email.
2. Menyediakan contoh penerapan fitur *stylometric*, algoritma *Support Vector Machine* (SVM), dan metode *Explainable Artificial Intelligence* (XAI) menggunakan *Shapley Additive Explanations* (SHAP) dalam pengembangan sistem klasifikasi email *phishing*.

3. Memberikan referensi bagi penelitian selanjutnya yang berkaitan dengan deteksi email *phishing*, khususnya dalam pengembangan metode berbasis *machine learning* dan *Explainable Artificial Intelligence* (XAI).

BAB II

TINJAUAN PUSTAKA

2.1 Penelitian Terdahulu

Penelitian mengenai deteksi email *phishing* telah banyak dilakukan menggunakan berbagai pendekatan, mulai dari analisis teks, *machine learning*, hingga pemanfaatan *Explainable Artificial Intelligence* (XAI). Meskipun demikian, masih sedikit penelitian yang menggabungkan fitur *stylometric* dengan metode yang mampu memberikan penjelasan terhadap hasil prediksi model.

Penelitian yang dilakukan oleh Opara et al. (2025) menggunakan 60 fitur *stylometric* untuk membedakan email *phishing* yang dihasilkan AI dan email asli. Hasil penelitian menunjukkan bahwa fitur gaya penulisan dapat digunakan untuk mendeteksi email *phishing*. Model terbaik yang diperoleh adalah XGBoost dengan nilai akurasi sebesar 96% dan AUC sebesar 0,99. Beberapa fitur yang memberikan pengaruh terbesar yaitu *imperative verbs*, rasio kata ganti, dan kepadatan klausa. Namun, penelitian tersebut menggunakan email hasil *generate* dari AI sehingga belum sepenuhnya menggambarkan kondisi email *phishing* yang ditemukan pada penggunaan sehari-hari.

Penelitian oleh Chanis dan Arampatzis (Chanis & Arampatzis, 2025) juga memanfaatkan fitur *stylometric* untuk mendeteksi email *phishing*. Penelitian tersebut menggabungkan fitur *stylometric* dengan metode *classifier stacking* dan memperoleh nilai *F1-score* sebesar 0,98. Hasil tersebut menunjukkan bahwa fitur *stylometric* dapat membantu meningkatkan performa klasifikasi. Akan tetapi, penelitian tersebut belum menjelaskan alasan model menghasilkan suatu prediksi.

Penelitian lain yang dilakukan oleh Wosah et al. (2024) menggabungkan fitur *stylometric* dengan model *deep learning*. Pendekatan tersebut menghasilkan performa klasifikasi yang baik, tetapi pembahasannya masih berfokus pada hasil klasifikasi tanpa menjelaskan kontribusi setiap fitur terhadap prediksi yang dihasilkan model.

Penelitian mengenai penggunaan *Support Vector Machine* (SVM) juga telah banyak dilakukan. Rumini et al. (2023) membandingkan SVM dengan kernel linear dan kernel RBF pada kasus deteksi *phishing* berbasis web. Hasil penelitian menunjukkan bahwa kernel RBF memberikan performa yang lebih baik pada data yang bersifat non-linear. Namun, penelitian tersebut berfokus pada deteksi *phishing* berbasis web dan tidak menggunakan fitur *stylometric* dari isi email.

Hasil yang serupa juga diperoleh oleh Manurung and Saragih (2024). Penelitian tersebut menunjukkan bahwa SVM dengan kernel RBF memberikan performa yang lebih baik dibandingkan Naïve Bayes pada klasifikasi email *spambot*. Akan tetapi, penelitian tersebut tidak membahas deteksi email *phishing* maupun penggunaan fitur *stylometric*.

Selain itu, Tanjung and Rahman (2025) menggunakan SVM untuk mendeteksi *phishing* berbasis teks dengan fitur TF-IDF. Hasil penelitian menunjukkan bahwa SVM mampu memberikan performa klasifikasi yang baik, termasuk dengan kernel RBF. Namun, penelitian tersebut menggunakan representasi TF-IDF sehingga belum memanfaatkan karakteristik gaya penulisan yang terdapat pada fitur *stylometric*.

Pada aspek interpretasi model, Pandya et al. (2025) menerapkan pendekatan *Explainable Artificial Intelligence* (XAI) pada sistem deteksi *phishing*. Penelitian tersebut

menunjukkan bahwa penjelasan terhadap hasil prediksi dapat membantu pengguna memahami alasan model dalam melakukan klasifikasi. Namun, penelitian tersebut tidak menggunakan fitur *stylometric*.

Penelitian oleh Sarker and Uddin (2024) juga menerapkan XAI pada sistem deteksi email *phishing*. Penelitian tersebut menggunakan representasi berbasis *embedding*, sehingga belum membahas karakteristik gaya penulisan yang terdapat pada fitur *stylometric*.

Selain itu, Fan et al. (2024) menjelaskan bahwa penggunaan *Explainable AI* pada sistem deteksi *phishing* dapat membantu menjelaskan faktor-faktor yang memengaruhi hasil prediksi model. Penelitian tersebut menunjukkan bahwa sistem deteksi tidak hanya perlu memiliki performa yang baik, tetapi juga perlu memberikan penjelasan terhadap hasil prediksi.

Berdasarkan penelitian-penelitian tersebut, dapat disimpulkan bahwa fitur *stylometric* mampu digunakan untuk membedakan email *phishing* dan email *legitimate*, SVM memiliki performa yang baik untuk tugas klasifikasi, dan XAI dapat membantu menjelaskan hasil prediksi model. Namun, masih sedikit penelitian yang menggabungkan ketiga pendekatan tersebut dalam satu sistem klasifikasi email *phishing*.

Oleh karena itu, penelitian ini menggunakan 60 fitur *stylometric*, algoritma *Support Vector Machine* (SVM), dan *Shapley Additive Explanations* (SHAP) untuk membangun sistem klasifikasi email *phishing*. Model yang dibangun kemudian diimplementasikan ke dalam aplikasi berbasis web.

2.2 *Phishing*

Phishing adalah salah satu bentuk serangan siber yang bertujuan mencuri informasi penting milik korban, seperti *username*, *password*, maupun informasi keuangan. Serangan ini dilakukan dengan cara menyamar sebagai pihak yang dipercaya, misalnya bank, layanan *e-commerce*, institusi pendidikan, atau perusahaan tertentu. Tujuannya adalah membuat korban percaya sehingga bersedia memberikan informasi pribadi atau melakukan tindakan tertentu, seperti mengklik tautan maupun mengunduh lampiran berbahaya (Cloudflare, 2023).

Email masih menjadi media yang paling sering digunakan dalam serangan *phishing*. Pelaku biasanya membuat isi email menyerupai email resmi dan memberikan kesan mendesak agar korban segera mengambil tindakan. Contohnya adalah pemberitahuan bahwa akun akan diblokir, permintaan verifikasi data, atau informasi mengenai hadiah tertentu (Proofpoint, 2023). Cara tersebut merupakan salah satu bentuk *social engineering*, yaitu teknik yang memanfaatkan kepercayaan atau psikologi korban agar mengikuti perintah yang diberikan.

Beberapa jenis *phishing* yang umum ditemukan adalah sebagai berikut.

1. *Email Phishing*

Jenis ini dilakukan dengan mengirimkan email kepada banyak pengguna tanpa menargetkan korban tertentu. Email biasanya dibuat menyerupai pesan dari pihak yang terpercaya agar korban memberikan informasi pribadi, mengklik tautan, atau mengunduh lampiran berbahaya (Proofpoint, 2023).

2. *Spear Phishing*

Spear phishing merupakan serangan yang ditujukan kepada target tertentu. Sebelum mengirim email, pelaku biasanya mengumpulkan informasi mengenai

korban, seperti nama, jabatan, atau tempat bekerja, sehingga email terlihat lebih menyakinkan (Proofpoint, 2023).

3. *Whaling*

Whaling merupakan bentuk khusus dari *spear phishing* yang menargetkan orang dengan jabatan penting, seperti pimpinan perusahaan atau pejabat organisasi (Proofpoint, 2023).

4. *Clone Phishing*

Pada jenis ini, pelaku menyalin email yang sebelumnya pernah diterima korban, kemudian mengganti tautan atau lampirannya dengan konten berbahaya sebelum mengirimkannya kembali (Proofpoint, 2023).

Meskipun berbagai sistem keamanan telah dikembangkan, serangan *phishing* masih sering terjadi karena email yang dikirim dibuat menyerupai komunikasi resmi. Akibatnya, korban sering kali tidak menyadari bahwa email tersebut merupakan bagian dari serangan hingga informasi pribadi mereka berhasil dicuri (Cloudflare, 2023).

2.3 *Stylometric* dalam Klasifikasi *Phishing*

Stylometric adalah salah satu metode yang digunakan untuk menganalisis gaya penulisan pada suatu teks. Analisis dilakukan berdasarkan karakteristik bahasa yang terdapat pada teks, seperti panjang kata, panjang kalimat, penggunaan tanda baca, dan pilihan kata. Karakteristik tersebut digunakan untuk melihat pola penulisan yang terdapat pada sebuah dokumen (Michailidis, 2022).

Sebagai contoh, fitur *stylometric* dapat berupa jumlah kata (*word count*), rata-rata panjang kata (*average word length*), penggunaan tanda baca (*punctuation count*), jumlah kata ganti (*pronoun count*), dan tingkat keterbacaan teks (*Flesch Reading Ease*). Karakteristik tersebut digunakan untuk menggambarkan gaya penulisan suatu teks sehingga dapat dimanfaatkan dalam proses klasifikasi (Opara et al., 2025).

Pada awalnya, *stylometric* lebih banyak digunakan untuk mengetahui atau membedakan penulis suatu dokumen (*authorship attribution*). Seiring dengan perkembangan penelitian, *stylometric* juga mulai digunakan pada berbagai tugas klasifikasi teks, termasuk untuk mendeteksi email *phishing* (Lagutina et al., 2024).

Dalam *stylometric*, isi teks diubah menjadi sejumlah fitur yang dapat digunakan oleh model *machine learning*. Fitur-fitur tersebut umumnya dikelompokkan ke dalam fitur leksikal, sintaksis, struktur teks, dan tingkat keterbacaan. Setiap kelompok fitur digunakan untuk merepresentasikan karakteristik gaya penulisan suatu teks (Mahor & Kumar, 2021).

Berbeda dengan metode deteksi *phishing* yang menggunakan URL, nama *domain*, atau *header* email, *stylometric* berfokus pada isi email. Pendekatan ini digunakan untuk melihat pola penulisan pada email sehingga dapat membantu membedakan email *phishing* dan email *legitimate* (Opara et al., 2025).

Pada penelitian ini, *stylometric* digunakan untuk mengekstraksi 60 fitur dari isi email. Selanjutnya, fitur-fitur tersebut digunakan sebagai masukan bagi algoritma *Support Vector Machine* (SVM) untuk mengklasifikasikan email *phishing* dan email *legitimate*.

2.4 Normalisasi Data

Normalisasi merupakan salah satu tahap *preprocessing* yang dilakukan untuk menyamakan skala antar fitur. Tahap ini diperlukan karena fitur *stylometric* yang

digunakan dalam penelitian memiliki rentang nilai yang berbeda, misalnya jumlah kata, panjang kalimat, skor keterbacaan, dan jumlah tanda baca. Jika perbedaan skala antar fitur terlalu besar, proses pelatihan model dapat dipengaruhi oleh fitur yang memiliki nilai lebih besar (James et al., 2021). Pada penelitian ini, data yang dinormalisasi merupakan hasil ekstraksi 60 fitur *stylometric* dari setiap email. Setelah data dibagi menjadi data latih dan data uji, proses normalisasi dilakukan terhadap kedua data tersebut menggunakan parameter normalisasi yang diperoleh dari data latih (Scikit-learn Developers, 2026).

Pada penelitian ini, normalisasi dilakukan menggunakan metode *standardization* dengan `StandardScaler` dari pustaka `scikit-learn`. Metode ini mengubah setiap fitur sehingga memiliki nilai rata-rata (*mean*) sebesar 0 dan standar deviasi sebesar 1. Proses ini umum digunakan sebelum pelatihan model *Support Vector Machine* (SVM) agar setiap fitur berada pada skala yang sebanding (James et al., 2021).

Secara matematis, proses normalisasi dituliskan sebagai berikut.

$$x' = \frac{x - \mu}{\sigma}, \quad (2.1)$$


dengan x' adalah nilai fitur setelah normalisasi, x adalah nilai fitur sebelum normalisasi, μ adalah nilai rata-rata setiap fitur, σ adalah standar deviasi setiap fitur.

Melalui proses normalisasi, seluruh fitur memiliki skala yang lebih sebanding sehingga dapat digunakan sebagai masukan pada proses klasifikasi menggunakan algoritma *Support Vector Machine* (SVM).

2.5 Support Vector Machine (SVM)

Support Vector Machine (SVM) merupakan salah satu algoritma *machine learning* yang termasuk dalam kategori *supervised learning*. Algoritma ini digunakan untuk mengklasifikasikan data berdasarkan data latih yang telah memiliki label. SVM banyak digunakan untuk tugas klasifikasi, terutama klasifikasi biner, seperti membedakan email *phishing* dan email *legitimate* (Burges, 1998).

Prinsip kerja SVM adalah mencari batas pemisah (*hyperplane*) yang dapat memisahkan dua kelas data dengan *margin* terbesar. Dengan *margin* yang lebih besar, model diharapkan mampu memberikan hasil yang klasifikasi yang lebih baik pada data baru (Cortes & Vapnik, 1995).



Gambar 2.1 Ilustrasi *hyperplane*, *support vector*, dan *margin* pada SVM (Cortes & Vapnik, 1995)

Pada penelitian ini, SVM digunakan untuk mengklasifikasikan email *phishing* dan

email *legitimate* berdasarkan fitur *stylometric*. Karena data yang digunakan tidak dapat dipisahkan secara linear, penelitian ini menggunakan kernel *Radial Basis Function* (RBF) yang akan dijelaskan pada subbab berikutnya.

2.5.1 Konsep Dasar SVM

Konsep utama pada *Support Vector Machine* (SVM) adalah mencari batas pemisah (*hyperplane*) yang dapat membedakan dua kelas data. Pada data dua dimensi, *hyperplane* berbentuk garis, sedangkan pada data dengan dimensi yang lebih tinggi berbentuk bidang pemisah. Posisi *hyperplane* ditentukan agar dapat memisahkan data dari masing-masing kelas (Burges, 1998).

Secara matematis, *hyperplane* dapat dituliskan sebagai berikut.

$$\mathbf{w}^T \mathbf{x} + b = 0, \quad (2.2)$$

dengan $\mathbf{w}$ adalah vektor bobot (*weight*), $\mathbf{x}$ adalah vektor fitur suatu data, b adalah bias.

Persamaan tersebut digunakan untuk membentuk batas pemisah antara dua kelas pada proses klasifikasi. Selanjutnya, SVM akan menentukan *hyperplane* terbaik dengan memperhatikan *support vector* dan *margin* yang akan dijelaskan pada subbab berikutnya (Cortes & Vapnik, 1995).

2.5.2 Support Vector dan Margin

Support vector adalah data yang berada paling dekat dengan *hyperplane*. Data tersebut berperan dalam menentukan posisi *hyperplane* sehingga menjadi bagian yang penting dalam proses pembentukan model SVM. Perubahan pada *support vector* dapat memengaruhi letak *hyperplane*, sedangkan data yang berada jauh dari batas pemisah umumnya tidak memberikan pengaruh terhadap model (Bishop, 2006).

Selain *support vector*, SVM juga menggunakan konsep *margin*. *Margin* adalah jarak antara *hyperplane* dengan *support vector* dari masing-masing kelas. Tujuan SVM adalah memperoleh *hyperplane* yang memiliki *margin* terbesar agar pemisahan antar kelas menjadi lebih baik (Burges, 1998).

2.5.3 Kernel pada Support Vector Machine (SVM)

Pada beberapa kasus, data tidak dapat dipisahkan menggunakan *hyperplane* linear. Oleh karena itu, SVM menggunakan fungsi *kernel* untuk membantu memisahkan data yang memiliki pola nonlinier. Dengan fungsi *kernel*, proses pemisahan data dapat dilakukan tanpa harus mengubah data ke ruang berdimensi lebih tinggi secara langsung. Cara ini dikenal sebagai *kernel trick* (Burges, 1998).

Secara umum, fungsi *kernel* dituliskan sebagai berikut.

$$K(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^T \mathbf{x}_j, \quad (2.3)$$

dengan $\mathbf{x}_i$ adalah vektor fitur data ke- i , $\mathbf{x}_j$ adalah vektor fitur data ke- j , $\mathbf{x}_i^T$ adalah transpose dari vektor fitur $\mathbf{x}_i$, $K(\mathbf{x}_i, \mathbf{x}_j)$ adalah nilai fungsi kernel antara data ke- i dan data ke- j .

SVM memiliki beberapa jenis fungsi *kernel*, seperti *Linear Kernel*, *Polynomial Kernel*, dan *Radial Basis Function* (RBF). Pada penelitian ini digunakan kernel RBF karena dapat digunakan untuk menangani data yang tidak dapat dipisahkan secara linear (Hsu et al., 2003).

2.5.4 *Kernel Radial Basis Function (RBF)*

Radial Basis Function (RBF) merupakan salah satu fungsi *kernel* yang paling sering digunakan pada algoritma SVM. Kernel ini digunakan ketika data tidak dapat dipisahkan secara linear. Dengan menggunakan kernel RBF, data dipetakan ke ruang fitur berdimensi lebih tinggi sehingga proses pemisahan antar kelas menjadi lebih mudah dilakukan (Cortes & Vapnik, 1995).

Persamaan kernel RBF dituliskan sebagai berikut.

$$K(\mathbf{x}_i, \mathbf{x}_j) = e^{-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2}, \quad (2.4)$$

dengan $\mathbf{x}_i$ adalah vektor fitur data ke- i , $\mathbf{x}_j$ adalah vektor fitur data ke- j , γ adalah parameter yang mengatur besar pengaruh suatu data terhadap data lainnya, $\|\mathbf{x}_i - \mathbf{x}_j\|^2$ adalah kuadrat jarak Euclidean antara data ke- i dan data ke- j .

Nilai parameter γ memengaruhi bentuk batas keputusan yang dihasilkan oleh model. Nilai γ yang besar menghasilkan batas keputusan yang lebih kompleks, sedangkan nilai γ yang kecil menghasilkan batas keputusan yang lebih sederhana (Du et al., 2024).

2.5.5 *Jarak Euclidean*

Pada kernel *Radial Basis Function* (RBF), nilai kemiripan antara dua data ditentukan berdasarkan jarak Euclidean. Semakin kecil jarak antara dua data, semakin besar nilai kemiripan yang dihasilkan oleh kernel. Sebaliknya, semakin besar jaraknya, semakin kecil nilai kemiripan kedua data tersebut (Chintyana et al., 2024).

Jarak Euclidean antara dua data dinyatakan sebagai berikut.

$$\|\mathbf{x}_i - \mathbf{x}_j\|^2 = \sum_{k=1}^m (x_{ik} - x_{jk})^2, \quad (2.5)$$

dengan m adalah jumlah fitur x_{ik} adalah nilai fitur ke- k pada data ke- i x_{jk} adalah nilai fitur ke- k pada data ke- j .

Nilai jarak Euclidean kuadrat tersebut kemudian digunakan pada Persamaan (2.4) untuk menghitung nilai kernel RBF.

2.5.6 *Optimasi Support Vector Machine (SVM)*

Setelah nilai kernel diperoleh, langkah berikutnya adalah melakukan proses optimasi untuk membentuk model SVM. Pada tahap ini dicari nilai *Lagrange multiplier* (α) yang digunakan untuk menentukan *hyperplane* terbaik. Proses optimasi dilakukan dengan memaksimumkan fungsi objektif dalam bentuk dual sebagai berikut (Burgess, 1998).

$$\max_{\alpha} L(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j), \quad (2.6)$$

dengan kendala,

$$\alpha_i \geq 0, \quad (2.7)$$

dan,

$$\sum_{i=1}^n \alpha_i y_i = 0, \quad (2.8)$$

dengan $L(\alpha)$ adalah fungsi objektif dalam bentuk dual yang akan dimaksimumkan, n adalah jumlah data pelatihan, α_i adalah nilai *Lagrange multiplier* pada data ke- i , y_i adalah label kelas, $K(\mathbf{x}_i, \mathbf{x}_j)$ adalah nilai fungsi kernel antara data ke- i dan data ke- j .

Hasil optimasi berupa nilai α digunakan pada tahap selanjutnya untuk menentukan *support vector* dan membentuk fungsi keputusan (*decision function*) SVM.

2.5.7 Parameter C dan γ

Pada SVM dengan kernel RBF terdapat dua parameter yang perlu ditentukan, yaitu parameter C dan γ . Kedua parameter ini memengaruhi hasil klasifikasi sehingga pemilihannya perlu disesuaikan dengan data yang digunakan (Hsu et al., 2003).

Parameter C digunakan untuk mengatur keseimbangan antara kesalahan klasifikasi pada data latih dan pembentukan batas keputusan. Nilai C yang besar membuat model berusaha mengklasifikasikan data latih dengan lebih baik, sedangkan nilai C yang kecil memberikan toleransi terhadap beberapa kesalahan klasifikasi sehingga model menjadi lebih sederhana (Hsu et al., 2003). Parameter γ digunakan untuk mengatur pengaruh setiap data dalam pembentukan batas keputusan. Nilai γ yang besar menghasilkan batas keputusan yang lebih kompleks, sedangkan nilai γ yang kecil menghasilkan batas keputusan yang lebih sederhana (Hsu et al., 2003).

Pada penelitian ini, nilai parameter C dan γ ditentukan menggunakan *GridSearch* untuk memperoleh kombinasi parameter yang memberikan performa klasifikasi terbaik.

2.5.8 Fungsi Keputusan (*Decision Function*)

Fungsi keputusan (*decision function*) merupakan fungsi yang digunakan oleh SVM untuk menentukan kelas suatu data. Nilai fungsi keputusan diperoleh dari hasil perhitungan antara *support vector*, fungsi *kernel*, dan parameter model yang diperoleh selama proses pelatihan (Burges, 1998).

Persamaan fungsi keputusan dituliskan sebagai berikut.

$$f(\mathbf{x}) = \sum_{i=1}^n \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}_j) + b, \quad (2.9)$$

dengan $f(\mathbf{x})$ adalah nilai fungsi keputusan untuk data $\mathbf{x}$, α_i adalah nilai *Lagrange multiplier* pada data ke- i , y_i adalah label kelas, $K(\mathbf{x}_i, \mathbf{x}_j)$ adalah nilai fungsi kernel antara data ke- i dan data ke- j , b adalah bias.

Nilai fungsi keputusan digunakan untuk menentukan kelas data. Jika nilai $f(\mathbf{x})$ bernilai positif maka data termasuk ke dalam kelas positif, sedangkan jika nilainya negatif maka data termasuk ke dalam kelas negatif (Burges, 1998).

2.6 Evaluasi Model

Evaluasi model dilakukan untuk mengetahui kemampuan model dalam membedakan email *phishing* dan email *legitimate*. Pada penelitian ini, performa model dievaluasi menggunakan beberapa metrik, yaitu *accuracy*, *precision*, *recall*, *F1-score*, *ROC-AUC*, dan *confusion matrix*. Metrik-metrik tersebut digunakan karena dapat memberikan gambaran performa model sehingga hasil klasifikasi dapat dievaluasi secara lebih menyeluruh (Sokolova & Lapalme, 2009).

2.6.1 Accuracy

Accuracy menunjukkan perbandingan antara jumlah prediksi yang benar dengan seluruh data yang diuji. Nilai *accuracy* yang tinggi menunjukkan bahwa model mampu mengklasifikasikan sebagian besar data dengan benar. Namun, metrik ini sebaiknya

digunakan bersama metrik lain karena pada data yang tidak seimbang, nilai *accuracy* yang tinggi belum tentu menunjukkan performa model yang baik (Powers, 2011).

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}. \quad (2.10)$$

2.6.2 Precision

Precision menunjukkan ketepatan model ketika memprediksi suatu data sebagai email *phishing*. Nilai *precision* yang tinggi menunjukkan bahwa sebagian besar email yang diprediksi sebagai *phishing* memang benar merupakan email *phishing* (Powers, 2011).

$$Precision = \frac{TP}{TP + FP}. \quad (2.11)$$

2.6.3 Recall

Recall menunjukkan kemampuan model dalam mengklasifikasikan email *phishing* dengan benar. Nilai *recall* yang tinggi menunjukkan bahwa semakin banyak email *phishing* berhasil dikenali oleh model (Powers, 2011).

$$Recall = \frac{TP}{TP + FN}. \quad (2.12)$$

2.6.4 F1-Score

F1-score merupakan rata-rata harmonik dari *precision* dan *recall*. Metrik ini digunakan untuk melihat keseimbangan antara ketepatan model dalam memberikan prediksi positif dan kemampuannya mengklasifikasikan email *phishing* dengan benar. Oleh karena itu, *F1-score* banyak digunakan untuk mengevaluasi model klasifikasi, terutama ketika distribusi data tidak seimbang (Powers, 2011).

$$F_1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}. \quad (2.13)$$

2.6.5 ROC-AUC (Receiver Operating Characteristic - Area Under Curve)

ROC (*Receiver Operating Characteristic*) merupakan kurva yang menggambarkan hubungan antara *True Positive Rate* (TPR) dan *False Positive Rate* (FPR) pada berbagai nilai *threshold*. Sementara itu, AUC (*Area Under the Curve*) menunjukkan luas area di bawah kurva ROC yang digunakan untuk mengukur kemampuan model dalam membedakan dua kelas. Semakin mendekati nilai 1, semakin baik kemampuan model dalam membedakan email *phishing* dan email *legitimate* (Fawcett, 2006).

$$AUC = \int_0^1 TPR dFPR, \quad (2.14)$$

dengan TPR (*True Positive Rate*) adalah proporsi email *phishing* yang berhasil diprediksi sebagai *phishing*, FPR (*False Positive Rate*) adalah proporsi email *legitimate* yang salah diprediksi sebagai *phishing*.

2.6.6 Confusion Matrix

Confusion matrix merupakan tabel yang digunakan untuk membandingkan hasil prediksi kelas dengan label sebenarnya. Pada klasifikasi biner, *confusion matrix* terdiri atas empat komponen, yaitu *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN) (Scikit-learn Documentation, 2025).

Dalam penelitian ini, keempat komponen tersebut dijelaskan sebagai berikut.

1. **True Positive (TP)** adalah jumlah email *phishing* yang berhasil diprediksi sebagai email *phishing*.
2. **True Negative (TN)** adalah jumlah email *legitimate* yang berhasil diprediksi sebagai email *legitimate*.
3. **False Positive (FP)** adalah jumlah email *legitimate* yang salah diprediksi sebagai email *phishing*.
4. **False Negative (FN)** adalah jumlah email *phishing* yang salah diprediksi sebagai email *legitimate*.

Nilai TP, TN, FP, dan FN menjadi dasar dalam perhitungan *accuracy*, *precision*, *recall*, dan *F1-score*. Oleh karena itu, *confusion matrix* digunakan sebagai dasar untuk menghitung metrik evaluasi pada model klasifikasi (Sokolova & Lapalme, 2009).

2.7 Hyperparameter Tuning

Hyperparameter tuning adalah proses mencari kombinasi nilai parameter yang memberikan performa terbaik pada model *machine learning*. Berbeda dengan parameter model yang dipelajari selama proses pelatihan, *hyperparameter* ditentukan sebelum proses pelatihan dimulai. Pada SVM dengan kernel RBF, parameter yang sering digunakan antara lain C dan γ (James et al., 2021).

2.7.1 Cross Validation

Cross-validation merupakan metode yang digunakan untuk mengevaluasi performa model dengan membagi data pelatihan menjadi beberapa bagian (*fold*). Pada metode *k-fold cross validation*, satu *fold* digunakan sebagai data validasi, sedangkan *fold* lainnya digunakan sebagai data pelatihan. Proses ini dilakukan secara bergantian hingga setiap *fold* menjadi data validasi sebanyak satu kali (James et al., 2021).

Nilai performa model diperoleh dari rata-rata hasil pengujian pada seluruh *fold*. Dengan cara ini, evaluasi model menjadi lebih stabil karena seluruh data pelatihan digunakan secara bergantian sebagai data validasi (James et al., 2021).

2.7.2 GridSearchCV

GridSearchCV merupakan metode pencarian *hyperparameter* yang menguji seluruh kombinasi nilai parameter yang telah ditentukan. Setiap kombinasi parameter dievaluasi menggunakan *cross validation*, kemudian dipilih kombinasi yang memberikan hasil evaluasi terbaik. Metode ini banyak digunakan karena mampu mencari kombinasi *hyperparameter* secara sistematis sehingga parameter yang digunakan pada model dapat dipilih berdasarkan hasil evaluasi, bukan berdasarkan percobaan secara manual (Scikit-learn Documentation, 2025).

2.8 Platt Scaling

Platt Scaling merupakan metode kalibrasi probabilitas yang digunakan untuk mengubah nilai fungsi keputusan (*decision function*) dari model SVM menjadi nilai probabilitas. Metode ini diperkenalkan oleh John C. Platt dengan memasang fungsi sigmoid pada keluaran SVM sehingga hasil prediksi dapat dinyatakan dalam bentuk probabilitas (Platt, 2000).

Persamaan *Platt Scaling* dituliskan sebagai berikut.

$$P(y = 1|x) = \frac{1}{1 + \exp(Af(x) + B)}, \quad (2.15)$$

dengan $P(y = 1|x)$ adalah probabilitas data termasuk ke kelas positif, $f(x)$ adalah nilai *decision function* dari SVM, A dan B adalah parameter kalibrasi sigmoid.

Parameter A dan B diperoleh melalui proses kalibrasi sehingga fungsi sigmoid dapat mengubah nilai *decision function* menjadi probabilitas yang lebih sesuai dengan peluang sebenarnya (Lin et al., 2007).

2.9 Explainable Artificial Intelligence (XAI)

Explainable Artificial Intelligence (XAI) merupakan pendekatan yang digunakan untuk menjelaskan bagaimana model *machine learning* menghasilkan suatu prediksi. XAI membantu pengguna memahami alasan di balik keputusan model, terutama pada model yang sulit diinterpretasikan secara langsung atau dikenal sebagai model *black-box* (Molnar, 2022).

2.9.1 Shapley Additive Explanations (SHAP)

SHAP merupakan salah satu metode *Explainable Artificial Intelligence* (XAI) yang digunakan untuk menjelaskan kontribusi setiap fitur terhadap hasil prediksi model. SHAP menggunakan konsep nilai Shapley dari teori permainan kooperatif untuk menghitung kontribusi setiap fitur terhadap prediksi yang dihasilkan oleh model (Lundberg & Lee, 2017).

Nilai Shapley untuk fitur ke- i dinyatakan sebagai berikut.

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f(S \cup \{i\}) - f(S)], \quad (2.16)$$

dengan ϕ_i adalah kontribusi fitur ke- i terhadap hasil prediksi model, $S \subseteq F \setminus \{i\}$ menyatakan bahwa S merupakan kombinasi fitur yang tidak memuat fitur ke- i , S adalah himpunan bagian dari seluruh fitur yang tidak memuat fitur ke- i , F adalah himpunan seluruh fitur, $f(S)$ adalah hasil prediksi model menggunakan himpunan fitur S , $f(S \cup \{i\})$ adalah hasil prediksi model setelah fitur ke- i ditambahkan ke dalam himpunan fitur S .

Nilai SHAP pada Persamaan 2.16 digunakan sebagai dasar dalam metode SHAP. Dalam SHAP, setiap fitur dianggap sebagai pemain (*player*) yang memberikan kontribusi terhadap hasil prediksi model (Lundberg & Lee, 2017).

Secara umum, SHAP menghitung kontribusi setiap fitur dengan membandingkan hasil prediksi model ketika suatu fitur dimasukkan dan ketika fitur tersebut tidak dimasukkan pada berbagai kombinasi fitur. Selisih hasil prediksi tersebut kemudian dihitung untuk seluruh kombinasi fitur dan dirata-ratakan menggunakan pembobotan berdasarkan nilai Shapley sehingga diperoleh nilai SHAP untuk setiap fitur (Babaei & Giudici, 2024).

Nilai SHAP yang diperoleh kemudian digunakan untuk menjelaskan hasil prediksi model, baik pada satu data (*local explanation*) maupun secara keseluruhan (*global explanation*). Interpretasi lokal digunakan untuk mengetahui kontribusi setiap fitur terhadap satu hasil prediksi, sedangkan interpretasi global digunakan untuk mengetahui pengaruh setiap fitur terhadap model secara keseluruhan (Santos et al., 2023).

Nilai SHAP dapat bernilai positif maupun negatif. Nilai SHAP yang positif menunjukkan bahwa suatu fitur mendorong hasil prediksi ke arah kelas tertentu, sedangkan nilai SHAP yang negatif menunjukkan bahwa fitur tersebut mengurangi kecenderungan prediksi ke arah kelas tersebut (Lundberg & Lee, 2017).

SHAP menjelaskan bahwa hasil prediksi suatu data diperoleh dari penjumlahan antara nilai dasar (*base value*) dan kontribusi setiap fitur. Hubungan tersebut dituliskan sebagai berikut.

$$f(x) = \text{base value} + \sum_{j=1}^m \phi_j, \quad (2.17)$$

dengan $f(x)$ adalah hasil prediksi model pada data ke x , *base value* adalah nilai awal prediksi model sebelum mempertimbangkan kontribusi setiap fitur, ϕ_j adalah kontribusi fitur ke- j terhadap hasil prediksi model, m adalah jumlah seluruh fitur.

Untuk mengetahui tingkat kepentingan setiap fitur secara keseluruhan, digunakan rata-rata nilai absolut SHAP (*mean absolute SHAP value*). Nilai ini diperoleh dengan menghitung rata-rata nilai absolut SHAP dari setiap fitur pada seluruh data (Lundberg & Lee, 2017). Perhitungannya dituliskan sebagai berikut.

$$\text{Importance}_j = \frac{1}{n} \sum_{i=1}^n |\phi_{i,j}|, \quad (2.18)$$

dengan $\phi_{i,j}$ adalah kontribusi fitur ke- j terhadap hasil prediksi pada data ke- i , n adalah jumlah data yang digunakan dalam perhitungan nilai SHAP, Importance_j adalah nilai rata-rata absolut SHAP untuk fitur ke- j .

Semakin besar nilai rata-rata absolut SHAP suatu fitur, semakin besar kontribusi fitur tersebut terhadap hasil prediksi model secara keseluruhan (Lundberg et al., 2020).

Dalam implementasinya, SHAP menyediakan beberapa jenis visualisasi untuk membantu menjelaskan hasil prediksi model, baik secara global maupun lokal. Visualisasi yang digunakan pada penelitian ini adalah sebagai berikut.

1. **Summary Plot (Bar)**

Summary Plot (Bar) menampilkan tingkat kepentingan setiap fitur berdasarkan nilai rata-rata absolut SHAP. Fitur dengan nilai rata-rata absolut SHAP yang lebih besar menunjukkan bahwa fitur tersebut memiliki pengaruh yang lebih besar terhadap hasil prediksi model (SHAP Developers, 2024).

2. **Beeswarm Plot**

Beeswarm Plot menampilkan distribusi nilai SHAP dari setiap fitur pada seluruh data. Visualisasi ini menunjukkan besar dan arah pengaruh setiap fitur terhadap hasil prediksi sehingga dapat digunakan untuk melihat pola kontribusi fitur secara global (SHAP Developers, 2024).


3. **Waterfall Plot**

Waterfall Plot digunakan untuk menjelaskan hasil prediksi pada satu data tertentu. Visualisasi ini menunjukkan bagaimana nilai prediksi terbentuk dari *base value* yang kemudian berubah karena kontribusi masing-masing fitur hingga menghasilkan nilai prediksi akhir (SHAP Developers, 2024).

2.10 **Streamlit**

Streamlit adalah *framework open-source* berbasis Python yang digunakan untuk membangun aplikasi web interaktif secara cepat. Dengan *Streamlit*, kode Python dapat langsung dijalankan sebagai aplikasi web tanpa perlu menggunakan HTML, CSS, atau JavaScript. Menurut Raghavendra (2023), *Streamlit* dirancang untuk memudahkan

pengembangan aplikasi web berbasis data dan *machine learning* menggunakan Python tanpa memerlukan pengetahuan mendalam mengenai pengembangan web.



Gambar 2.2 Tampilan antarmuka *Streamlit*
(Raghavendra, 2023)


Streamlit menyediakan berbagai komponen antarmuka, seperti kotak *input text*, tombol, *sidebar*, tabel, dan grafik. Selain itu, *Streamlit* juga dapat diintegrasikan dengan berbagai pustaka Python, seperti Pandas, Matplotlib, Scikit-learn, dan SHAP, sehingga banyak digunakan untuk membangun aplikasi berbasis *machine learning* (Streamlit, 2025).

Pada penelitian ini, *Streamlit* digunakan untuk membangun aplikasi berbasis web. Melalui aplikasi ini, pengguna dapat memasukkan isi email secara manual maupun melalui integrasi Gmail, kemudian memperoleh hasil klasifikasi beserta visualisasi SHAP secara langsung.

BAB III

METODOLOGI

Bab ini menjelaskan tahapan metodologi yang digunakan dalam penyusunan Tugas Akhir, mulai dari identifikasi permasalahan hingga perancangan sistem. Alur lengkap penelitian digambarkan pada Gambar 3.1 di bawah ini.



Gambar 3.1 Diagram Alir Penelitian

Gambar 3.1 menunjukkan tahapan penelitian yang dilakukan, mulai dari identifikasi masalah, pengumpulan data, *preprocessing* data, ekstraksi fitur *stylometric*, pembagian data, normalisasi data, pelatihan model SVM, evaluasi model, implementasi model

ke dalam aplikasi berbasis web, hingga penerapan *Explainable Artificial Intelligence* (XAI) menggunakan SHAP. Tahap terakhir meliputi pengujian sistem serta penarikan kesimpulan dan saran. Penjelasan setiap tahapan dijelaskan pada subbab berikutnya.

3.1 Identifikasi Permasalahan

Tahap identifikasi permasalahan dilakukan untuk menentukan permasalahan yang akan diselesaikan pada penelitian ini. Permasalahan yang diangkat adalah semakin sulitnya membedakan email *phishing* dan email *legitimate* karena isi email *phishing* semakin menyerupai email resmi. Oleh karena itu, penelitian ini mengembangkan sistem klasifikasi email *phishing* menggunakan fitur *stylometric*, model *Support Vector Machine* (SVM), serta metode *Shapley Additive Explanations* (SHAP) untuk menjelaskan hasil prediksi model.

3.2 Pengumpulan Data

Penelitian ini menggunakan data sekunder yang diperoleh dari Kaggle melalui dataset berjudul "*Phishing Email Dataset*" yang dipublikasikan oleh Naser Abdullah Alam. Dataset tersebut berisi 82.486 email, yang terdiri dari 42.891 email *phishing* dan 39.595 email *legitimate* yang telah diberi label *phishing* (1) dan *legitimate* (0). Pada dataset ini, isi email disimpan pada kolom `text_combined`, sedangkan label kelas disimpan pada kolom `label`. Dataset tersebut digunakan sebagai *input* pada tahap *preprocessing*, ekstraksi fitur *stylometric*, pelatihan model, evaluasi model, hingga implementasi sistem klasifikasi email *phishing*.

3.3 Preprocessing Data

Tahap *preprocessing* dilakukan untuk membersihkan dan menyiapkan data email sebelum proses ekstraksi fitur *stylometric*. Karena penelitian ini menggunakan pendekatan *stylometric*, *preprocessing* dilakukan secara minimal agar karakteristik penulisan pada email tetap dipertahankan. Tahapan yang dilakukan meliputi normalisasi *line break*, penghapusan *tag* HTML, penghapusan *header* email, dan normalisasi *whitespace*. Penjelasan setiap tahapan dijelaskan pada subbab berikut.

3.3.1 Normalisasi *Line Break*

Normalisasi *line break* dilakukan dengan mengubah seluruh karakter *carriage return* (`\r`) menjadi karakter *newline* (`\n`). Tahap ini bertujuan agar format baris pada seluruh email menjadi konsisten sebelum dilakukan ekstraksi fitur.

3.3.2 Penghapusan *Tag* HTML

Pada tahap ini, seluruh *tag* HTML dihapus dari isi email sehingga hanya teks utama yang digunakan. Penghapusan dilakukan karena *tag* HTML tidak termasuk bagian dari isi pesan yang dianalisis pada penelitian ini.

3.3.3 Penghapusan *Header* Email

Header email seperti *subject*, *from*, dan *to* dihapus agar proses ekstraksi fitur hanya dilakukan pada isi pesan email. Dengan begini, fitur yang dihasilkan berasal dari karakteristik penulisan isi email, bukan dari informasi pada *header*.

3.3.4 Normalisasi *Whitespace*

Normalisasi *whitespace* dilakukan dengan menghapus spasi yang berlebihan, karakter *tab*, dan baris kosong yang tidak diperlukan. Tahap ini bertujuan agar format teks menjadi lebih rapi dan konsisten sebelum dilakukan ekstraksi fitur.

Setelah seluruh tahapan *preprocessing* selesai dilakukan, data email yang telah dibersihkan digunakan sebagai masukan pada proses ekstraksi fitur *stylometric*.

3.4 Ekstraksi Fitur *Stylometric*

Setelah tahap *preprocessing*, dilakukan ekstraksi fitur *stylometric* untuk mengubah isi email menjadi data numerik yang dapat diproses oleh model SVM. Proses ekstraksi dilakukan secara otomatis dengan menghitung berbagai karakteristik penulisan pada setiap email. Penelitian ini menggunakan 60 fitur *stylometric* yang mengacu pada penelitian Opara et al. (2025). Seluruh fitur tersebut digunakan sebagai masukan pada proses pelatihan dan pengujian model.

3.4.1 Kategori Fitur

Untuk mempermudah penyajian, 60 fitur *stylometric* yang digunakan pada penelitian ini dikelompokkan ke dalam beberapa kategori. Pengelompokan tersebut mengacu pada penelitian Opara et al. (2025).

1. **Fitur Leksikal**, meliputi fitur yang berkaitan dengan jumlah kata, panjang kata dan keragaman kosakata.
2. **Fitur Sintaktik**, meliputi fitur yang berkaitan dengan struktur kalimat, penggunaan kata ganti, kata depan, kata fungsi, serta kompleksitas susunan kalimat.
3. **Fitur Tanda Baca**, meliputi fitur yang menghitung frekuensi penggunaan berbagai tanda baca pada email.
4. **Fitur Keterbacaan**, meliputi fitur yang mengukur tingkat keterbacaan teks menggunakan beberapa indeks keterbacaan.
5. **Fitur Kategori Kata**, meliputi fitur yang menghitung kemunculan kelompok kata tertentu seperti kata ganti, kata perintah, istilah teknis, dan kata promosi.
6. **Fitur Karakteristik Email**, meliputi fitur yang berkaitan dengan karakteristik khusus pada email, seperti penggunaan simbol email.
7. **Fitur Kompleksitas Teks**, meliputi fitur yang menggambarkan tingkat kompleksitas teks, seperti pola kombinasi kata dan variasi panjang kata.
8. **Fitur Stilistika**, meliputi fitur yang menggambarkan gaya penulisan email, seperti kesopanan, urgensi, dan penggunaan kata penghubung.

Daftar lengkap 60 fitur *stylometric* yang digunakan pada penelitian ini ditunjukkan pada Tabel 3.2.

3.4.2 Daftar Kelompok Kata (*Word List*)

Beberapa fitur pada penelitian ini menggunakan daftar kelompok kata (*word list*) untuk menghitung jumlah kemunculan kata tertentu dalam email. Kelompok kata tersebut terdiri atas kata yang menunjukkan urgensi, tindakan, kepercayaan, istilah teknis, promosi, dan kategori lainnya yang sering ditemukan pada email *phishing*. Daftar kata yang digunakan ditunjukkan pada Tabel 3.1.

Tabel 3.1 Daftar Kategori dan Kata Kunci Stylometric

Kategori	Kata Kunci
First Person Pronouns	i, we
Second Person Pronouns	you
Pronouns (Umum)	i, you, he, she, it, we, they, me, him, her, us, them, my, your, his, their, our
Prepositions	in, on, at, by, with, from, to, for, of, about, into, over, after
Function Words (Stopwords)	the, is, at, which, on, a, an, and, or, but, if, then, because
Imperative (Perintah)	click, verify, submit, download, update, confirm, login, sign, reset, open, view, check, validate, access, review, complete, fill, enter, reply, respond
Modal Verbs	can, could, should, must, will, would, may, might
Uncertainty Words	maybe, possibly, perhaps, likely, unlikely, apparently
Technical Terms	security, account, update, technical, password, login, authentication, verification, server, system, access, credential, user, database
Promotional Words	offer, deal, free, bonus, reward, discount, win, gift, promotion, limited, exclusive
Politeness Markers	please, thank, thanks, appreciate, kindly, regards, sincerely
Aggressive Words	must, now, immediately, required, urgent, action, important, attention, warning
Urgency Words	urgent, asap, immediately, now, today, instantly, quickly, deadline, expire, expiring, limited, soon
Conditional Words	if, unless, otherwise, in case
Personalization Words	you, your, yours, user, customer, client
Conjunctions	and, but, or, because, so, although, however, therefore
Attachment Keywords	attachment, attached, file, document, pdf

Kelompok kata pada Tabel 3.1 digunakan untuk menghitung jumlah kemunculan kata yang sesuai pada setiap email. Nilai tersebut kemudian digunakan sebagai bagian dari fitur *stylometric* yang menjadi masukan bagi model klasifikasi.

3.4.3 Daftar Fitur *Stylometric*

Pada penelitian ini digunakan 60 fitur *stylometric* yang diekstraksi dari setiap email. Fitur-fitur tersebut digunakan untuk merepresentasikan karakteristik penulisan email dalam bentuk numerik sehingga dapat diproses oleh model SVM. Daftar fitur yang digunakan ditunjukkan pada Tabel 3.2.

Tabel 3.2 Daftar 60 Fitur *Stylometric* yang Digunakan

No	Nama Fitur	Kategori	Deskripsi
1	word_count	Leksikal	Jumlah total kata dalam email.
2	char_count	Leksikal	Jumlah seluruh karakter dalam email, termasuk spasi dan tanda baca.
3	avg_word_length	Leksikal	Rata-rata panjang kata dalam email.
4	sentence_count	Leksikal	Jumlah kalimat dalam email.
5	avg_sentence_length	Leksikal	Rata-rata jumlah kata per kalimat.
6	unique_word_count	Leksikal	Jumlah kata unik dalam email.
7	lexical_diversity	Leksikal	Rasio keragaman kosakata berdasarkan jumlah kata unik terhadap total kata.
8	email_symbol_count	Leksikal	Jumlah simbol @ yang muncul dalam email.
9	uppercase_word_count	Leksikal	Jumlah kata yang ditulis seluruhnya menggunakan huruf kapital.
10	uppercase_word_ratio	Leksikal	Rasio kata huruf kapital terhadap total kata.
11	complex_words_count	Leksikal	Jumlah kata kompleks dengan panjang lebih dari enam karakter.
12	comma_count	Sintaktik	Jumlah tanda koma (,).
13	semicolon_count	Sintaktik	Jumlah tanda titik koma (;).
14	colon_count	Sintaktik	Jumlah tanda titik dua (:).
15	exclamation_count	Sintaktik	Jumlah tanda seru (!).
16	quotation_count	Sintaktik	Jumlah tanda kutip (").
17	dash_count	Sintaktik	Jumlah tanda strip (-).
18	sentence_complexity_ratio	Sintaktik	Rasio kompleksitas kalimat berdasarkan jumlah konjungsi per kalimat.

Bersambung ke halaman berikutnya

Tabel 3.2 (lanjutan)

No	Nama Fitur	Kategori	Deskripsi
19	clause_density	Sintaktik	Kepadatan klausa berdasarkan jumlah konjungsi dalam kalimat.
20	pronoun_density	Sintaktik	Rasio penggunaan kata ganti terhadap total kata.
21	preposition_density	Sintaktik	Rasio penggunaan kata depan terhadap total kata.
22	function_word_density	Sintaktik	Rasio penggunaan kata fungsi terhadap total kata.
23	dot_frequency	Tanda Baca	Frekuensi penggunaan tanda titik (.) terhadap jumlah karakter.
24	comma_frequency	Tanda Baca	Frekuensi penggunaan tanda koma (,).
25	exclamation_frequency	Tanda Baca	Frekuensi penggunaan tanda seru (!).
26	colon_frequency	Tanda Baca	Frekuensi penggunaan tanda titik dua (:).
27	dash_frequency	Tanda Baca	Frekuensi penggunaan tanda strip (-).
28	quote_frequency	Tanda Baca	Frekuensi penggunaan tanda kutip.
29	open_parenthesis_frequency	Tanda Baca	Frekuensi penggunaan tanda kurung buka.
30	close_parenthesis_frequency	Tanda Baca	Frekuensi penggunaan tanda kurung tutup.
31	slash_frequency	Tanda Baca	Frekuensi penggunaan tanda slash (/).
32	backslash_frequency	Tanda Baca	Frekuensi penggunaan tanda backslash (\).
33	punctuation_variety	Tanda Baca	Jumlah variasi tanda baca yang digunakan dalam email.
34	flesch_reading_ease	Keterbacaan	Skor keterbacaan berdasarkan indeks Flesch Reading Ease.

Bersambung ke halaman berikutnya

Tabel 3.2 (lanjutan)

No	Nama Fitur	Kategori	Deskripsi
35	smog_index	Keterbacaan	Skor keterbacaan berdasarkan indeks SMOG.
36	dale_chall_score	Keterbacaan	Skor keterbacaan berdasarkan indeks Dale-Chall.
37	coleman_liau_index	Keterbacaan	Skor keterbacaan berdasarkan indeks Coleman-Liau.
38	gunning_fog_index	Keterbacaan	Skor keterbacaan berdasarkan indeks Gunning Fog.
39	first_person_pronouns	Kategori Kata	Jumlah kata ganti orang pertama.
40	second_person_pronouns	Kategori Kata	Jumlah kata ganti orang kedua.
41	imperative_verbs_count	Kategori Kata	Jumlah kata kerja perintah.
42	modal_verbs_count	Kategori Kata	Jumlah kata kerja modal.
43	uncertainty_adverbs_count	Kategori Kata	Jumlah kata yang menunjukkan ketidakpastian.
44	technical_jargon_count	Kategori Kata	Jumlah istilah teknis yang berkaitan dengan sistem atau keamanan.
45	promotional_words_count	Kategori Kata	Jumlah kata promosi yang muncul dalam email.
46	email_count	Khusus Email	Jumlah alamat atau simbol email yang terdeteksi.
47	uppercase_ratio_email	Khusus Email	Rasio penggunaan huruf kapital dalam email.
48	attachment_mentions	Khusus Email	Jumlah kata yang berkaitan dengan lampiran email.
49	bigram_count	Kompleksitas	Jumlah kombinasi dua kata unik (bigram).
50	trigram_count	Kompleksitas	Jumlah kombinasi tiga kata unik (trigram).

Bersambung ke halaman berikutnya

Tabel 3.2 (lanjutan)

No	Nama Fitur	Kategori	Deskripsi
51	word_length_variation	Kompleksitas	Variasi panjang kata berdasarkan standar deviasi.
52	politeness_markers	Stilistika	Jumlah kata yang menunjukkan kesopanan.
53	aggressiveness_markers	Stilistika	Jumlah kata yang menunjukkan nada agresif atau mendesak.
54	urgency_markers	Stilistika	Jumlah kata yang menunjukkan urgensi.
55	conditional_phrases	Stilistika	Jumlah kata atau frasa bersifat kondisional.
56	personalization_markers	Stilistika	Jumlah kata yang menunjukkan personalisasi terhadap penerima.
57	pronoun_count	Stilistika	Jumlah seluruh kata ganti yang digunakan.
58	conjunction_count	Stilistika	Jumlah kata penghubung yang digunakan.
59	stopword_ratio	Stilistika	Rasio penggunaan stopword terhadap total kata.
60	avg_syllables_per_word	Stilistika	Rata-rata jumlah suku kata per kata.

Seluruh fitur pada Tabel 3.2 digunakan sebagai masukan bagi model SVM pada tahap pelatihan dan pengujian. Hasil ekstraksi fitur kemudian digunakan pada tahap pembagian data, normalisasi data, dan pelatihan model.

3.5 Pembagian Data (Data *Splitting*)

Setelah proses ekstraksi fitur selesai, data dibagi menjadi data latih (*training data*) dan data uji (*testing data*). Pembagian dilakukan dengan rasio 80% dan 20%, sehingga diperoleh 65.988 data latih dan 16.498 data uji. Pembagian data menggunakan metode *stratified split* untuk menjaga proporsi jumlah email *phishing* dan email *legitimate* tetap seimbang pada masing-masing kelompok data.

Data latih digunakan untuk membangun model SVM, sedangkan data uji digunakan untuk mengevaluasi performa model terhadap data yang belum pernah digunakan pada proses pelatihan.

3.6 Normalisasi Data

Setelah data dibagi menjadi data latih dan data uji, dilakukan normalisasi terhadap seluruh fitur numerik sebelum proses pelatihan model. Normalisasi ini dilakukan karena setiap fitur *stylometric* memiliki rentang nilai yang berbeda, sehingga perlu disamakan agar proses pelatihan model dapat berjalan dengan baik.

Pada penelitian ini, normalisasi dilakukan menggunakan `StandardScaler`, yang mengubah fitur menjadi nilai dengan rata-rata mendekati 0 dan standar deviasi mendekati 1. Proses normalisasi dilakukan berdasarkan parameter yang diperoleh dari data latih, kemudian parameter yang sama diterapkan pada data uji agar konsistensi data tetap terjaga. Data yang telah dinormalisasi selanjutnya digunakan pada proses pelatihan dan pengujian model SVM.

3.7 Pelatihan Model *Support Vector Machine*

Setelah proses normalisasi selesai, dilakukan pelatihan model menggunakan *Support Vector Machine* (SVM). Model ini digunakan untuk mengklasifikasikan email menjadi dua kelas, yaitu *phishing* dan *legitimate*, berdasarkan 60 fitur *stylometric* yang telah diekstraksi.

Pelatihan model terdiri atas dua tahap, yaitu *hyperparameter tuning* dan pembentukan model final. Penjelasan setiap tahap dijelaskan pada subbab berikut.

3.7.1 *Hyperparameter Tuning*

Tahap *hyperparameter tuning* dilakukan untuk menentukan kombinasi parameter yang memberikan hasil terbaik. Parameter yang diuji meliputi nilai C , γ , dan *class weight*. Proses pencarian dilakukan menggunakan *GridSearchCV* dengan *5-fold cross-validation*. Pada proses ini, data latih dibagi menjadi lima bagian dengan empat bagian digunakan untuk melatih model, sedangkan satu bagian digunakan untuk validasi. Proses tersebut dilakukan secara bergantian hingga setiap bagian pernah menjadi data validasi. Selanjutnya, kombinasi parameter yang menghasilkan nilai evaluasi terbaik dipilih untuk membentuk model SVM.

3.7.2 Pelatihan Model Final

Setelah diperoleh parameter terbaik dari proses *tuning*, model SVM dibangun menggunakan parameter tersebut. Selanjutnya, model dilatih dengan data latih yang telah dinormalisasi agar dapat mempelajari pola yang membedakan email *phishing* dan *legitimate* berdasarkan fitur *stylometric*. Model yang telah dilatih kemudian digunakan untuk memprediksi kelas pada data uji.

3.8 Evaluasi Model

Setelah model SVM selesai dilatih, dilakukan evaluasi menggunakan data uji. Tahap ini bertujuan untuk mengetahui kemampuan model dalam mengklasifikasikan email *phishing* dan email *legitimate* pada data yang belum pernah digunakan selama proses pelatihan. Evaluasi dilakukan menggunakan metrik *accuracy*, *precision*, *recall*, *F1-score*, dan *ROC-AUC*. Selain itu, *confusion matrix* digunakan untuk melihat jumlah prediksi yang benar dan salah pada masing-masing kelas.

Hasil evaluasi menunjukkan performa model dalam mengklasifikasikan email *phishing* dan *legitimate*. Selanjutnya, dilakukan analisis menggunakan SHAP untuk menjelaskan kontribusi setiap fitur *stylometric* terhadap hasil prediksi model.

3.9 Implementasi *Explainable AI* (XAI) Menggunakan SHAP

Setelah model dievaluasi menggunakan data uji, tahap berikutnya adalah melakukan interpretasi model menggunakan SHAP (*SHapley Additive Explanations*). Tahap ini bertujuan untuk mengetahui pengaruh setiap fitur *stylometric* terhadap hasil prediksi model SVM-RBF.

Pada penelitian ini, SHAP digunakan untuk menghasilkan interpretasi secara global dan lokal. Interpretasi global digunakan untuk mengetahui fitur-fitur yang paling

berpengaruh terhadap hasil prediksi model secara keseluruhan, sedangkan interpretasi lokal digunakan untuk menjelaskan kontribusi setiap fitur pada satu email tertentu.

Untuk analisis SHAP dipilih beberapa sampel dari hasil prediksi data uji yang terdiri atas *true positive* (TP), *true negative* (TN), *false positive* (FP), dan *false negative* (FN). Sampel tersebut dipilih agar analisis dapat mewakili prediksi model yang benar maupun yang salah.

Hasil interpretasi SHAP kemudian digunakan untuk menunjukkan fitur-fitur yang paling memengaruhi hasil prediksi model, baik secara global maupun pada setiap sampel yang dianalisis.

3.10 Perancangan Sistem Klasifikasi Email *Phishing*

Tahap selanjutnya adalah merancang sistem klasifikasi email *phishing* berbasis web. Sistem ini dibangun menggunakan *framework Streamlit* dan mengintegrasikan model *Support Vector Machine* yang telah dilatih beserta metode interpretasi SHAP.

Sistem ini menyediakan dua cara untuk melakukan klasifikasi email. Cara pertama menggunakan *input* manual, yaitu pengguna memasukkan isi email secara langsung ke dalam sistem. Cara kedua menggunakan integrasi Gmail, sehingga sistem dapat mengambil email dari akun Gmail pengguna melalui Gmail API dengan hak akses baca saja (*read-only*).

Setelah email diterima, sistem melakukan *preprocessing*, ekstraksi 60 fitur *stylometric*, dan normalisasi menggunakan parameter yang sama seperti pada proses pelatihan model. Selanjutnya, data diproses oleh model *Support Vector Machine* (SVM) untuk menghasilkan nilai probabilitas dan menghasilkan label *phishing* atau *legitimate*.

Selain menampilkan hasil prediksi, sistem juga menampilkan interpretasi menggunakan SHAP. Hasil interpretasi digunakan untuk menunjukkan fitur-fitur yang paling memengaruhi hasil prediksi model.

Keluaran sistem berupa label klasifikasi, nilai probabilitas, dan hasil interpretasi SHAP yang ditampilkan melalui antarmuka web.

3.11 Pengujian Sistem Klasifikasi Email *Phishing*

Setelah sistem klasifikasi selesai dirancang, tahap selanjutnya adalah melakukan pengujian sistem. Pengujian ini bertujuan untuk memastikan bahwa setiap fungsi pada sistem dapat berjalan dengan baik sesuai dengan rancangan. Pengujian dilakukan pada proses penerimaan *input*, analisis email, hingga penampilan hasil klasifikasi.

Pengujian dilakukan pada dua fitur utama, yaitu mode *input* manual dan mode integrasi Gmail. Pada mode *input* manual, pengujian dilakukan dengan memasukkan contoh email ke dalam sistem untuk memastikan bahwa proses klasifikasi, perhitungan probabilitas, dan interpretasi SHAP dapat berjalan dengan baik. Pada mode integrasi Gmail, pengujian dilakukan untuk memastikan bahwa sistem dapat melakukan autentikasi akun Gmail, mengambil email dari kotak masuk, dan menganalisis email secara otomatis.

Skenario pengujian disusun berdasarkan fungsi utama sistem yaitu penerimaan *input* email, penampilan hasil klasifikasi, interpretasi SHAP, autentikasi Gmail, pengambilan email, dan analisis email dari Gmail.

Hasil pengujian digunakan untuk memastikan bahwa sistem ini telah berjalan sesuai dengan rancangan dan dapat digunakan untuk mengklasifikasikan email *phishing* dan *legitimate* berbasis web.

3.12 Penarikan Kesimpulan dan Saran

Tahap terakhir dalam penelitian ini adalah menyusun kesimpulan dan saran. Kesimpulan dibuat berdasarkan hasil implementasi sistem, evaluasi model, dan analisis interpretabilitas menggunakan SHAP. Melalui tahap ini dapat diketahui apakah tujuan penelitian, yaitu membangun sistem klasifikasi email *phishing* berbasis fitur *stylometric* menggunakan model SVM, telah tercapai.

Saran disusun sebagai masukan untuk pengembangan penelitian selanjutnya, seperti penambahan dataset, pengembangan fitur, peningkatan performa model, penggunaan metode interpretabilitas lain, serta pengembangan sistem agar memberikan hasil yang lebih baik.

3.13 Penyusunan Laporan Tugas Akhir

Tahap penyusunan laporan Tugas Akhir merupakan tahap akhir dari penelitian. Pada tahap ini, seluruh proses penelitian, mulai dari pengumpulan data, perancangan metode, implementasi sistem, pengujian, hingga hasil penelitian, disusun dalam bentuk laporan Tugas Akhir sesuai dengan pedoman penulisan yang berlaku.

BAB IV

HASIL DAN PEMBAHASAN

Pada bab ini dijelaskan hasil implementasi model klasifikasi menggunakan *Support Vector Machine* (SVM) untuk mengklasifikasikan email *phishing* dan *legitimate*. Pembahasan dimulai dari proses pengolahan data, pelatihan dan evaluasi model, implementasi *Explainable AI* menggunakan SHAP, hingga perancangan sistem klasifikasi email *phishing*. Sebelum membahas tahapan tersebut, terlebih dahulu akan dijelaskan deskripsi dataset yang digunakan pada penelitian ini.

4.1 Deskripsi Dataset

Data yang digunakan dalam penelitian ini diperoleh dari *platform* Kaggle¹ dengan judul “*Phishing Email Dataset*” yang dipublikasikan oleh Naser Abdullah Alam. Dataset ini dipilih karena memiliki jumlah data yang cukup besar dan sesuai dengan kebutuhan penelitian untuk membangun model klasifikasi email *phishing*.

Data yang digunakan berupa *file phishing_email.csv* yang berisi 82.486 data email. Dataset tersebut terdiri atas 42.891 email *phishing* dan 39.595 email *legitimate*. Jumlah data pada kedua kelas relatif seimbang sehingga kedua kelas tetap terwakili dalam proses pelatihan dan pengujian model.

Secara umum, data pada dataset masih berupa teks email. Setiap data terdiri atas isi email yang disimpan pada satu kolom dan label yang menunjukkan kategori email, yaitu *phishing* atau *legitimate*. Karena masih berbentuk teks, data perlu melalui beberapa tahapan pengolahan sebelum digunakan pada proses klasifikasi.

```
1 text_combined,label
2 hpl nom may 25 2001 see attached file hplno 525 xls hplno 525 xls,0
3 nom actual vols 24 th forwarded sabrae zajac hou ect 05 30 2001 12 07 pm enron capital trade
4 enron actuals march 30 april 1 201 estimated actuals march 30 2001 flow march 31 2001 flow a
5 hpl nom may 30 2001 see attached file hplno 530 xls hplno 530 xls,0
6 hpl nom june 1 2001 see attached file hplno 601 xls hplno 601 xls,0
7 hpl nom may 31 2001 see attached file hplno 531 xls hplno 531 xls,0
```

Gambar 4.1 Contoh Sampel Data dalam Dataset

Gambar 4.1 menunjukkan contoh data pada dataset yang digunakan dalam penelitian ini. Kolom *text_combined* berisi isi email, sedangkan kolom *label* menunjukkan kategori email, yaitu *phishing* atau *legitimate*.

Pada penelitian ini, data teks diubah menjadi data numerik melalui proses ekstraksi fitur *stylometric*. Proses ini menghasilkan sekumpulan fitur yang digunakan sebagai masukan bagi model SVM-RBF. Sebelum dilakukan ekstraksi fitur, data terlebih dahulu melalui tahap *preprocessing*. Seluruh proses tersebut dijelaskan pada subbab berikutnya.

4.2 Preprocessing Data

Pada tahap ini dilakukan *preprocessing* pada data email yang masih berupa teks mentah. *Preprocessing* dilakukan untuk membersihkan dan merapikan data sebelum

¹Kaggle, *Phishing Email Dataset*, https://www.kaggle.com/datasets/naserabdullahalam/phishing-email-dataset?select=phishing_email.csv, diakses pada 2 November 2025.

masuk ke tahap berikutnya. Namun, karena penelitian ini menggunakan pendekatan *stylometric*, *preprocessing* dilakukan secara minimal. Karakteristik penulisan seperti panjang kata, panjang kalimat, dan penggunaan tanda baca tetap dipertahankan karena digunakan sebagai bagian fitur *stylometric*.

Preprocessing data menggunakan beberapa *library* Python yang dipanggil sebelum pengolahan data dilakukan. Gambar 4.2 menunjukkan *library* yang digunakan pada tahap *preprocessing data*.

```
# Meng-import library yang diperlukan untuk preprocessing
import pandas as pd
import re
```

Gambar 4.2 *Library* untuk *Preprocessing Data*

Tabel 4.1 Fungsi *Library* pada *Preprocessing Data*

No	Nama Library	Fungsi
1	<i>pandas</i>	<i>Library</i> untuk pengolahan dan analisis data berbentuk tabel (DataFrame), termasuk membaca, memanipulasi, dan menyimpan data.
2	<i>re</i>	<i>Library</i> untuk pencarian, pencocokan, dan manipulasi teks berdasarkan pola tertentu menggunakan <i>regular expression</i> .

Adapun tahapan *preprocessing* yang dilakukan adalah sebagai berikut:

4.2.1 Normalisasi *Line Break*

Tahap pertama adalah melakukan normalisasi *line break* dengan mengganti karakter *carriage return* (`\r`) menjadi *newline* (`\n`). Langkah ini dilakukan agar format baris pada setiap email menjadi lebih konsisten sehingga proses pengolahan data dapat dilakukan dengan lebih baik.

```
# Normalisasi line break
text = text.replace('\r', '\n')
```

Gambar 4.3 Normalisasi *Line Break*

4.2.2 Penghapusan HTML *Tag*

Pada tahap ini, *tag* HTML dihapus karena bukan merupakan bagian dari isi utama email. Setelah *tag* HTML dihapus, isi email menjadi lebih bersih sehingga dapat digunakan pada proses selanjutnya.

```
# Hapus HTML tag
text = re.sub(r"<.*?>", "", text)
```

Gambar 4.4 Penghapusan HTML *Tag*

4.2.3 Penghapusan *Header Email*

Header email seperti "*subject:*", "*from:*", dan "*to:*" dihapus karena bagian tersebut bukan merupakan isi utama email. Dengan menghapus bagian ini, proses analisis hanya menggunakan isi pesan email.

```
# Hapus header email
text = re.sub(r"(?i)\bsubject:", " ", text)
text = re.sub(r"(?i)\bfrom:", " ", text)
text = re.sub(r"(?i)\bto:", " ", text)
```

Gambar 4.5 Penghapusan *Header Email*

4.2.4 Normalisasi *Whitespace*

Tahap berikutnya adalah normalisasi *whitespace* dengan menghapus spasi yang berlebihan, mengubah tab menjadi spasi, serta merapikan baris kosong. Proses ini dilakukan agar teks menjadi lebih rapi tanpa mengubah isi email.

```
# Normalisasi whitespace
text = text.replace('\t', ' ')
text = re.sub(r"[ ]{2,}", " ", text)
text = re.sub(r"\n{3,}", "\n\n", text)
```

Gambar 4.6 Normalisasi *Whitespace*

Untuk memberikan gambaran hasil *preprocessing*, berikut ditunjukkan contoh perubahan data sebelum dan sesudah *preprocessing*:

Sebelum *preprocessing*:

"Subject: Hello Click here!!!\n\nVerify your account now!!!"

Sesudah *preprocessing*:

"Hello Click here!!! Verify your account now!!!"

Berdasarkan contoh tersebut, *tag* HTML dan *header email* telah dihapus, sedangkan tanda baca tetap dipertahankan. Hal ini dilakukan agar karakteristik penulisan yang digunakan pada fitur *stylometric* tidak berubah.

Setelah seluruh tahapan *preprocessing* selesai dilakukan, data email siap digunakan pada tahap ekstraksi fitur *stylometric*.

4.3 Ekstraksi Fitur *Stylometric*

Setelah tahap *preprocessing* selesai, dilakukan ekstraksi fitur untuk mengubah data email yang masih berbentuk teks menjadi data numerik. Data numerik tersebut digunakan sebagai masukan pada model klasifikasi. Proses ekstraksi fitur dilakukan menggunakan fungsi yang telah ada berdasarkan 60 fitur *stylometric* yang dijelaskan pada Bab III. Setiap email diproses secara otomatis sehingga menghasilkan nilai untuk setiap fitur *stylometric*.

4.3.1 Implementasi Ekstraksi Fitur *Stylometric*

Implementasi ekstraksi fitur *stylometric* menggunakan beberapa *library* Python untuk membantu proses pengolahan data teks. Cuplikan kode untuk memanggil *library* yang digunakan ditunjukkan pada Gambar 4.7.

```
# Meng-import library yang diperlukan untuk feature extraction
import pandas as pd
import numpy as np
import textstat
import nltk
from nltk.tokenize import word_tokenize, sent_tokenize
from sklearn.feature_extraction.text import CountVectorizer
```

Gambar 4.7 *Library* untuk *Feature Extraction*

Tabel 4.2 Fungsi *Library* pada *Feature Extraction*

No	Nama <i>Library</i>	Fungsi
1	<i>pandas</i>	<i>Library</i> untuk membaca, mengolah, dan menyimpan data dalam bentuk tabel (DataFrame).
2	<i>numpy</i>	<i>Library</i> untuk komputasi numerik, seperti perhitungan rata-rata, standar deviasi, dan operasi matematika lainnya.
3	<i>textstat</i>	<i>Library</i> untuk menghitung tingkat keterbacaan teks menggunakan berbagai indeks <i>readability</i> .
4	<i>nltk</i>	<i>Library</i> untuk pemrosesan bahasa alami (<i>Natural Language Processing</i>), seperti tokenisasi kata dan kalimat.
5	<i>sklearn (CountVectorizer)</i>	<i>Library machine learning</i> yang digunakan untuk mengubah teks menjadi fitur numerik, khususnya untuk menghasilkan n-gram (bigram dan trigram).

Setelah seluruh *library* dipanggil, data email hasil *preprocessing* diproses menggunakan fungsi ekstraksi fitur. Fungsi tersebut menghitung setiap fitur *stylometric* berdasarkan karakteristik penulisan email, kemudian menyimpan hasil perhitungan ke dalam bentuk tabel. Proses ini menghasilkan nilai untuk setiap fitur *stylometric* yang selanjutnya digunakan sebagai masukan pada model SVM.

4.3.2 Implementasi Perhitungan Fitur

Untuk memberikan gambaran proses ekstraksi fitur, berikut ditunjukkan contoh perhitungan seluruh 60 fitur *stylometric* menggunakan salah satu data email pada dataset.

hpl nom may 25 2001 see attached file hplno 525 xls hplno 525 xls

Gambar 4.8 Contoh Data Email

Berdasarkan data email tersebut, contoh perhitungan fitur dilakukan sebagai berikut.

No	Fitur	Cara Hitung	Hasil
1	word_count	Jumlah kata	14
2	char_count	Jumlah karakter	65
3	avg_word_length	$\frac{\text{char_count} - \text{jumlah spasi}}{\text{word_count}} = \frac{52}{14}$	3.7143
4	sentence_count	Jumlah kalimat	1
5	avg_sentence_length	$\frac{\text{word_count}}{\text{sentence_count}} = \frac{14}{1}$	14.0
6	unique_word_count	Jumlah kata unik	11
7	lexical_diversity	$\frac{\text{unique_word_count}}{\text{word_count}} = \frac{11}{14}$	0.7857
8	email_symbol_count	Jumlah simbol @	0
9	uppercase_word_count	Jumlah kata huruf kapital	0
10	uppercase_word_ratio	$\frac{\text{uppercase_word_count}}{\text{word_count}} = \frac{0}{14}$	0.0
11	complex_words_count	Jumlah kata dengan panjang > 6 karakter	1
12	comma_count	Jumlah karakter ,	0
13	semicolon_count	Jumlah karakter ;	0
14	colon_count	Jumlah karakter :	0
15	exclamation_count	Jumlah karakter !	0
16	quotation_count	Jumlah karakter "	0
17	dash_count	Jumlah karakter -	0
18	sentence_complexity_ratio	$\frac{\text{conjunction_count}}{\text{sentence_count}} = \frac{0}{1}$	0.0
19	clause_density	$\frac{\text{conjunction_count}}{\text{sentence_count}} = \frac{0}{1}$	0.0
20	pronoun_density	$\frac{\text{pronoun_count}}{\text{word_count}} = \frac{0}{14}$	0.0
21	preposition_density	$\frac{\text{preposition_count}}{\text{word_count}} = \frac{0}{14}$	0.0

No	Fitur	Cara Hitung	Hasil
22	function_word_density	$\frac{function_word_count}{word_count} = \frac{0}{14}$	0.0
23	dot_frequency	$\frac{dot_count}{char_count} = \frac{0}{65}$	0.0
24	comma_frequency	$\frac{comma_count}{char_count} = \frac{0}{65}$	0.0
25	exclamation_frequency	$\frac{exclamation_count}{char_count} = \frac{0}{65}$	0.0
26	colon_frequency	$\frac{colon_count}{char_count} = \frac{0}{65}$	0.0
27	dash_frequency	$\frac{dash_count}{char_count} = \frac{0}{65}$	0.0
28	quote_frequency	$\frac{quotation_count}{char_count} = \frac{0}{65}$	0.0
29	open_parenthesis_frequency	$\frac{open_parenthesis_count}{char_count} = \frac{0}{65}$	0.0
30	close_parenthesis_frequency	$\frac{close_parenthesis_count}{char_count} = \frac{0}{65}$	0.0
31	slash_frequency	$\frac{slash_count}{char_count} = \frac{0}{65}$	0.0
32	backslash_frequency	$\frac{backslash_count}{char_count} = \frac{0}{65}$	0.0
33	punctuation_variety	Jumlah jenis tanda baca	0
34	flesch_reading_ease	$206.835 - 1.015 \left(\frac{word_count}{sentence_count} \right)$ $- 84.6 \left(\frac{total_syllables}{word_count} \right)$ $= 206.835 - 1.015 \left(\frac{14}{1} \right) - 84.6 \left(\frac{15}{14} \right)$ $= 206.835 - 14.21 - 90.6429$ $= 101.9821$	101.9821
35	smog_index	$1.0430 \sqrt{complex_words \left(\frac{30}{sentence_count} \right)}$ $+ 3.1291$ $= 1.0430 \sqrt{0 \left(\frac{30}{1} \right)} + 3.1291$ $= 3.1291$	3.1291

No	Fitur	Cara Hitung	Hasil
36	dale_chall_score	$0.1579 \left(\frac{\text{difficult_words}}{\text{word_count}} \times 100 \right)$ $+ 0.0496 \left(\frac{\text{word_count}}{\text{sentence_count}} \right) + 3.6365$ $= 0.1579 \left(\frac{11}{14} \times 100 \right) + 0.0496 \left(\frac{14}{1} \right)$ $+ 3.6365$ $= 0.1579(78.5714) + 0.6944 + 3.6365$ $= 12.4064 + 0.6944 + 3.6365$ $= 16.7373$	16.7373
37	coleman_liau_index	$L = \frac{\text{char_count} - \text{spaces}}{\text{word_count}} \times 100$ $= \frac{52}{14} \times 100 = 371.43$ $S = \frac{\text{sentence_count}}{\text{word_count}} \times 100 = \frac{1}{14} \times 100$ $= 7.14$ $0.058L - 0.296S - 15.8$ $= 0.058(371.43) - 0.296(7.14) - 15.8$ $= 21.5429 - 2.1143 - 15.8$ $= 3.6286$	3.6286
38	gunning_fog_index	$0.4 \left[\left(\frac{\text{word_count}}{\text{sentence_count}} \right) + 100 \right]$ $\left(\frac{\text{complex_words}}{\text{word_count}} \right)$ $= 0.4 \left[\left(\frac{14}{1} \right) + 100 \left(\frac{0}{14} \right) \right]$ $= 0.4(14 + 0)$ $= 5.6$	5.6
39	first_person_pronouns	Jumlah kata <i>first person pronouns</i>	0
40	second_person_pronouns	Jumlah kata <i>second person pronouns</i>	0
41	imperative_verbs_count	Jumlah kata <i>imperative verbs</i>	0
42	modal_verbs_count	Jumlah kata <i>modal verbs</i>	1
43	uncertainty_adverbs_count	Jumlah kata <i>uncertainty adverbs</i>	0
44	technical_jargon_count	Jumlah kata <i>technical jargon</i>	0
45	promotional_words_count	Jumlah kata <i>promotional words</i>	0

No	Fitur	Cara Hitung	Hasil
46	email_count	Jumlah simbol @	0
47	uppercase_ratio_email	$\frac{uppercase_word_count}{word_count} = \frac{0}{14}$	0.0
48	attachment_mentions	Jumlah kata <i>attachment mentions</i>	2
49	bigram_count	Jumlah bigram unik	11
50	trigram_count	Jumlah trigram unik	11
51	word_length_variation	$\sigma = \sqrt{\frac{\sum(x_i - 3.7143)^2}{14}} = 1.4357$	1.4357
52	politeness_markers	Jumlah <i>politeness markers</i>	0
53	aggressiveness_markers	Jumlah <i>aggressiveness markers</i>	0
54	urgency_markers	Jumlah <i>urgency markers</i>	0
55	conditional_phrases	Jumlah <i>conditional phrases</i>	0
56	personalization_markers	Jumlah <i>personalization markers</i>	0
57	pronoun_count	Jumlah <i>pronouns</i>	0
58	conjunction_count	Jumlah <i>conjunctions</i>	0
59	stopword_ratio	$\frac{function_word_count}{word_count} = \frac{0}{14}$	0.0
60	avg_syllables_per_word	$\frac{total_syllables}{word_count} = \frac{15}{14}$	1.0714

Perhitungan yang sama dilakukan pada seluruh data email sehingga setiap email memiliki 60 nilai fitur *stylometric*. Selanjutnya, fitur-fitur tersebut digunakan sebagai masukan pada model SVM.

4.3.3 Hasil Ekstraksi Fitur

Setelah proses ekstraksi selesai dilakukan, setiap email yang semula berbentuk teks berubah menjadi data numerik berdasarkan 60 fitur *stylometric*. Setiap baris data berisi nilai dari seluruh fitur yang digunakan sebagai masukan pada model SVM.

Contoh hasil ekstraksi fitur ditunjukkan pada tabel berikut.

Tabel 4.4 Contoh Data Hasil Ekstraksi Fitur


word_count	char_count	avg_word_length	sentence_count	avg_sentence_length	unique_word_count	...	label
14	65	3.71	1	14	11	...	<i>legitimate</i>

Berdasarkan tabel tersebut, setiap email telah direpresentasikan dalam bentuk numerik melalui proses ekstraksi fitur *stylometric*. Tabel tersebut hanya menampilkan sebagian hasil ekstraksi fitur, sedangkan hasil lengkapnya disajikan pada Lampiran 3.

Setelah proses ekstraksi fitur selesai, data dibagi menjadi data latih dan data uji untuk digunakan pada proses pelatihan dan evaluasi model.

4.4 Pembagian Data (*Data Splitting*)

Setelah proses ekstraksi fitur selesai, data dibagi menjadi data latih (*training data*) dan data uji (*testing data*) dengan perbandingan 80% dan 20%. Pembagian data dilakukan menggunakan fungsi *train_test_split* dengan parameter *random_state = 42* dan *stratify*. Berdasarkan pembagian tersebut, diperoleh 65.988 data latih dan 16.498 data uji. Hasil pembagian data pada penelitian ini ditunjukkan pada Gambar 4.9.



Gambar 4.9 Hasil Pembagian Data

Gambar 4.9 menunjukkan jumlah data latih dan data uji yang digunakan pada penelitian ini. Selanjutnya, distribusi jumlah email *phishing* dan email *legitimate* pada masing-masing kelompok data ditunjukkan pada Tabel 4.5.

Tabel 4.5 Distribusi Kelas Setelah Pembagian Data

Dataset	<i>Phishing</i>	<i>Legitimate</i>	Total
Data Latih	34.313	31.675	65.988
Data Uji	8.578	7.920	16.498
Total	42.891	39.595	82.486

Berdasarkan Tabel 4.5, jumlah email *phishing* dan email *legitimate* pada data latih dan data uji tetap mengikuti proporsi dataset awal. Oleh karena itu, data latih dan data uji tetap mewakili distribusi kelas pada keseluruhan dataset.

4.5 Normalisasi Data

Setelah data dibagi menjadi data latih dan data uji, tahap selanjutnya adalah normalisasi data menggunakan *StandardScaler*. Normalisasi dilakukan pada seluruh fitur numerik agar setiap fitur memiliki skala yang sama sebelum digunakan pada proses pelatihan model SVM.

Proses normalisasi menggunakan *StandardScaler* dari *library* Python. Gambar 4.10 menunjukkan *library* yang digunakan pada tahap normalisasi data.

```
# Meng-import library yang diperlukan untuk normalisasi data
from sklearn.preprocessing import StandardScaler
```

Gambar 4.10 *Library* untuk Normalisasi Data

Tabel 4.6 Fungsi *Library* pada Normalisasi Data

No	Nama <i>Library</i>	Fungsi
1	<i>sklearn.preprocessing</i>	Menyediakan metode <i>preprocessing data</i> , termasuk standardisasi fitur sebelum pemodelan.

Normalisasi dilakukan dengan menghitung parameter skala dari data latih menggunakan fungsi *fit_transform()*, kemudian parameter yang sama diterapkan pada data uji menggunakan *transform()* agar konsisten.

Cuplikan proses normalisasi ditunjukkan pada Gambar 4.11

```
# Normalisasi Data
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

Gambar 4.11 Kode Program untuk Proses Normalisasi Data

Contoh beberapa fitur sebelum proses normalisasi ditunjukkan pada Tabel 4.7.

Tabel 4.7 Contoh Data Sebelum Normalisasi

	word_ count	char_ count	avg_word_ length	...	stopword_ ratio	avg_syllables_ per_word
1	14	65	3.714286	...	0.0	1.071429
2	208	1071	4.153846	...	0.0	1.533654
3	28	148	4.321429	...	0.0	1.535714
4	14	65	3.714286	...	0.0	1.071429
5	14	65	3.714286	...	0.0	1.071429
...	...	...	...	...	...	...

Setelah proses normalisasi dilakukan, nilai setiap fitur berubah ke skala yang sama, yaitu memiliki rata-rata mendekati 0 dan standar deviasi mendekati 1. Contoh hasil normalisasi ditunjukkan pada Gambar 4.12.

[[-0.25257369 -0.07155275 -1.11599677 ... 0.00000000 -1.83582544]
[0.08169637 -0.01325862 -0.94578968 ... 0.00000000 -0.87746459]
[-0.22845111 -0.06674320 -0.88089822 ... 0.00000000 -0.87319255]
[-0.25257369 -0.07155275 -1.11599677 ... 0.00000000 -1.83582544]
[-0.25257369 -0.07155275 -1.11599677 ... 0.00000000 -1.83582544]]

Gambar 4.12 Contoh Data Setelah Normalisasi

Gambar 4.12 menunjukkan contoh hasil normalisasi data menggunakan *StandardScaler*. Gambar tersebut hanya menampilkan sebagian data hasil normalisasi, sedangkan hasil normalisasi secara lengkap disajikan pada Lampiran 4.

Normalisasi dilakukan karena setiap fitur memiliki rentang nilai yang berbeda. Sebagai contoh, nilai pada fitur *word_count* dan *char_count* jauh lebih besar dibandingkan nilai pada fitur *stopword_ratio* atau *avg_syllables_per_word*. Tanpa normalisasi, fitur dengan nilai yang lebih besar dapat mendominasi proses pembentukan model SVM.

Untuk mempermudah penjelasan, contoh perhitungan normalisasi berikut hanya menggunakan lima data pertama dan lima fitur, yaitu *word_count*, *char_count*, *avg_word_length*, *stopword_ratio*, dan *avg_syllables_per_word*. Pada implementasi sebenarnya, normalisasi dilakukan menggunakan seluruh data latih dengan *StandardScaler*. Oleh karena itu, hasil perhitungan manual berikut hanya digunakan sebagai ilustrasi proses normalisasi.

Langkah pertama adalah menyusun kelima data tersebut ke dalam matriks A berukuran 5×5 sebagai berikut.

$$A = \begin{bmatrix} 14 & 65 & 3.714286 & 0 & 1.071429 \\ 208 & 1071 & 4.153846 & 0 & 1.533654 \\ 28 & 148 & 4.321429 & 0 & 1.535714 \\ 14 & 65 & 3.714286 & 0 & 1.071429 \\ 14 & 65 & 3.714286 & 0 & 1.071429 \end{bmatrix}$$

Selanjutnya, dihitung nilai rata-rata setiap kolom pada matriks A . Perhitungan dilakukan menggunakan rumus rata-rata sehingga diperoleh hasil sebagai berikut.

$$\begin{aligned} \mu_A &= \begin{bmatrix} \mu_1 & \mu_2 & \mu_3 & \mu_4 & \mu_5 \end{bmatrix} \\ \mu_1 &= \frac{14 + 208 + 28 + 14 + 14}{5} = \frac{278}{5} = 55.6 \\ \mu_2 &= \frac{65 + 1071 + 148 + 65 + 65}{5} = \frac{1414}{5} = 282.8 \\ \mu_3 &= \frac{3.714286 + 4.153846 + 4.321429 + 3.714286 + 3.714286}{5} = \frac{19.618133}{5} = 3.923627 \\ \mu_4 &= \frac{0 + 0 + 0 + 0 + 0}{5} = \frac{0}{5} = 0 \end{aligned}$$

$$\mu_5 = \frac{1.071429 + 1.533654 + 1.535714 + 1.071429 + 1.071429}{5} = \frac{6.283655}{5} = 1.256731$$

Jadi, diperoleh rata-rata dari matriks A adalah

$$\mu_A = \begin{bmatrix} 55.6 & 282.8 & 3.923627 & 0 & 1.256731 \end{bmatrix}$$

Setelah diperoleh nilai rata-rata, langkah berikutnya adalah menghitung standar deviasi setiap kolom pada matriks A. Perhitungannya ditunjukkan sebagai berikut.

$$\sigma_A = \begin{bmatrix} \sigma_1 & \sigma_2 & \sigma_3 & \sigma_4 & \sigma_5 \end{bmatrix}$$

$$\sigma_1 = \sqrt{\frac{(14 - 55.6)^2 + (208 - 55.6)^2 + (28 - 55.6)^2 + (14 - 55.6)^2 + (14 - 55.6)^2}{5}}$$

$$= \sqrt{5843.84} \approx 76.44$$

$$\sigma_2 = \sqrt{\frac{(65 - 282.8)^2 + (1071 - 282.8)^2 + (148 - 282.8)^2 + (65 - 282.8)^2 + (65 - 282.8)^2}{5}}$$

$$= \sqrt{156348.16} \approx 395.41$$

$$\sigma_3 = \sqrt{\frac{(3.714286 - 3.923627)^2 + (4.153846 - 3.923627)^2 + (4.321429 - 3.923627)^2}{5} + \frac{(3.714286 - 3.923627)^2 + (3.714286 - 3.923627)^2}{5}}$$

$$= \sqrt{0.0685433} \approx 0.2618$$

$$\sigma_4 = \sqrt{\frac{(0 - 0)^2 + (0 - 0)^2 + (0 - 0)^2 + (0 - 0)^2 + (0 - 0)^2}{5}}$$

$$= \sqrt{0} \approx 0$$

$$\sigma_5 = \sqrt{\frac{(1.071429 - 1.256731)^2 + (1.533654 - 1.256731)^2 + (1.535714 - 1.256731)^2}{5} + \frac{(1.071429 - 1.256731)^2 + (1.071429 - 1.256731)^2}{5}}$$

$$= \sqrt{0.05150527} \approx 0.227$$

Jadi, diperoleh standar deviasi matriks A

$$\sigma_A = \begin{bmatrix} 76.44 & 395.41 & 0.2618 & 0 & 0.227 \end{bmatrix}$$

Setelah nilai rata-rata dan standar deviasi diperoleh, dilakukan normalisasi menggunakan metode *Z-score*. Berikut ditunjukkan contoh perhitungan untuk elemen pertama pada kolom pertama.

$$Z_{11} = \frac{14 - 55.6}{76.44} \approx -0.54$$

Untuk elemen pertama di kolom kedua.

$$Z_{12} = \frac{65 - 282.8}{395.41} \approx -0.55$$

Untuk elemen pertama di kolom ketiga.

$$Z_{13} = \frac{3.714286 - 3.923627}{0.2618} \approx -0.80$$

Untuk elemen pertama di kolom keempat, semua nilai pada fitur tersebut bernilai sama yaitu 0, sehingga standar deviasinya juga 0. Secara matematis, normalisasi *Z-score* tidak terdefinisi karena terjadi pembagian dengan nol. Namun pada implementasi *StandardScaler*, fitur dengan variansi nol akan tetap diberikan nilai 0 karena tidak memiliki variasi data.

$$Z_{14} = 0$$

Untuk elemen pertama di kolom kelima:

$$Z_{15} = \frac{1.071429 - 1.256731}{0.227} \approx -0.82$$

Sehingga baris pertama hasil normalisasi:

$$\begin{bmatrix} -0.54 & -0.55 & -0.80 & 0 & -0.82 \end{bmatrix}$$

Perhitungan yang sama dilakukan untuk seluruh elemen pada matriks sehingga diperoleh hasil normalisasi sebagai berikut.

$$Z = \begin{bmatrix} -0.54 & -0.55 & -0.80 & 0 & -0.82 \\ 1.99 & 1.99 & 0.88 & 0 & 1.22 \\ -0.36 & -0.34 & 1.52 & 0 & 1.23 \\ -0.54 & -0.55 & -0.80 & 0 & -0.82 \\ -0.54 & -0.55 & -0.80 & 0 & -0.82 \end{bmatrix}$$

Berdasarkan hasil tersebut, setiap fitur telah dinormalisasi menggunakan metode *Z-score*. Data hasil normalisasi kemudian digunakan pada proses pelatihan model SVM-RBF.

4.6 Pelatihan Model *Support Vector Machine* (SVM)

Setelah data selesai dinormalisasi, tahap berikutnya adalah melatih model klasifikasi menggunakan *Support Vector Machine* (SVM). Model ini dibangun menggunakan *library scikit-learn*, dan proses pelatihannya disertai *hyperparameter tuning* untuk mendapatkan kombinasi parameter yang menghasilkan performa terbaik.

Library yang digunakan pada tahap ini ditunjukkan pada Gambar 4.13.

```
# Pelatihan Model
import pandas as pd
import numpy as np
from sklearn.model_selection import GridSearchCV
from sklearn.svm import SVC
import joblib
```

Gambar 4.13 *Library* untuk Pelatihan Model

Tabel 4.8 Fungsi *Library* pada Pelatihan Model

No	Nama <i>Library</i>	Fungsi
1	<i>pandas</i>	<i>Library</i> untuk membaca, mengolah, dan menyimpan data dalam bentuk tabel (DataFrame).
2	<i>numpy</i>	<i>Library</i> untuk komputasi numerik, seperti perhitungan rata-rata, standar deviasi, dan operasi matematika lainnya.
3	<i>sklearn.model_selection</i>	<i>Library</i> yang digunakan untuk proses pencarian kombinasi <i>hyperparameter</i> terbaik menggunakan <i>GridSearchCV</i> .
4	<i>sklearn.svm</i>	<i>Library</i> untuk menyediakan algoritma <i>Support Vector Machine</i> (SVM) untuk proses klasifikasi.
5	<i>joblib</i>	<i>Library</i> yang digunakan untuk menyimpan model hasil pelatihan.

4.6.1 *Hyperparameter Tuning*

Tahap pertama adalah mencari kombinasi *hyperparameter* terbaik menggunakan *GridSearchCV* untuk kernel *Radial Basis Function* (RBF). Parameter yang diuji meliputi nilai *C*, *gamma*, *kernel*, dan *class_weight*. Setiap kombinasi parameter dievaluasi menggunakan *5-fold cross-validation* dengan metrik ROC-AUC. Parameter yang menghasilkan nilai ROC-AUC tertinggi dipilih sebagai parameter terbaik.

Cuplikan proses *hyperparameter tuning* ditunjukkan pada Gambar 4.14.


```

param_grid={
"C":[1,10,50,100,200,500],
"gamma":["scale",0.1,0.05,0.01,0.005,0.001],
"kernel":["rbf"],
"class_weight":[None,"balanced"]
}
grid=GridSearchCV(
SVC(probability=True),
param_grid,
cv=5,
scoring="roc_auc")

```

Gambar 4.14 Kode Program untuk *Hyperparameter Tuning*

Parameter yang digunakan pada proses *tuning* ditunjukkan pada Tabel 4.9.

Tabel 4.9 Parameter *Hyperparameter Tuning* SVM-RBF

Parameter	Definisi	Nilai Uji
<i>C</i>	Parameter yang mengatur batas toleransi kesalahan klasifikasi terhadap lebar <i>margin</i> .	1, 10, 50, 100, 200, 500
<i>gamma</i>	Parameter yang mengatur seberapa besar pengaruh satu data terhadap pembentukan batas keputusan pada kernel RBF.	<i>scale</i> , 0.1, 0.05, 0.01, 0.005, 0.001
<i>kernel</i>	Fungsi yang digunakan untuk memetakan data ke dimensi yang lebih tinggi.	<i>rbf</i>
<i>class_weight</i>	Parameter yang digunakan untuk memberikan bobot pada tiap kelas apabila jumlah data antar kelas tidak seimbang.	<i>None</i> , <i>balanced</i>

Parameter *C* digunakan untuk mengatur toleransi model terhadap kesalahan klasifikasi. Nilai *gamma* mengatur pengaruh setiap data terhadap pembentukan batas keputusan pada kernel RBF. Parameter *kernel* menggunakan RBF karena mampu menangani hubungan non-linear, sedangkan *class_weight* digunakan untuk menguji pengaruh pemberian bobot pada setiap kelas.

Dikarenakan waktu untuk mengerjakan terbatas, maka digunakan satu kernel untuk pelatihan model ini, yaitu kernel *Radial Basis Function* (RBF). Jumlah nilai uji tiap parameter pada Tabel 4.9 adalah 6 nilai untuk *C*, 6 nilai untuk γ , 1 nilai untuk *kernel*, dan 2 nilai untuk *class_weight*, sehingga jumlah kombinasi parameter yang diuji sebagai berikut.

$$6 \times 6 \times 1 \times 2 = 72 \text{ kombinasi}$$

Setiap kombinasi dievaluasi menggunakan *5-fold cross-validation*, sehingga jumlah proses pelatihan yang dilakukan adalah sebagai berikut.

$$72 \times 5 = 360 \text{ kali pelatihan}$$


Seluruh kombinasi parameter kemudian dievaluasi menggunakan fungsi *fit()* pada *GridSearchCV*. Fungsi ini melatih model untuk setiap kombinasi parameter, kemudian menghitung nilai rata-rata ROC-AUC dari hasil *5-fold cross-validation*. Kombinasi dengan nilai ROC-AUC tertinggi dipilih sebagai parameter terbaik.

Berdasarkan hasil *hyperparameter tuning*, diperoleh parameter terbaik sebagai berikut.

Best parameters: {'C': 100, 'class_weight': 'balanced', 'gamma': 0.1, 'kernel': 'rbf'}

Gambar 4.15 *Output Parameter Terbaik Hasil Hyperparameter Tuning*

Hasil *hyperparameter tuning* ditampilkan pada Gambar 4.16. Gambar tersebut menunjukkan nilai rata-rata ROC-AUC untuk setiap kombinasi parameter *C* dan *gamma* pada konfigurasi *class_weight = balanced*.



Gambar 4.16 *Heatmap Hasil GridSearch Model SVM*

Berdasarkan Gambar 4.16, kombinasi $C = 100$ dan $gamma = 0.1$ menghasilkan nilai ROC-AUC tertinggi, yaitu sebesar 0.9517. Parameter tersebut digunakan untuk membentuk model pada tahap pelatihan model final.

4.6.2 Pelatihan Model Final

Setelah parameter terbaik diperoleh, model SVM dilatih menggunakan seluruh data latih yang terdiri dari 65.988 data dengan 60 fitur. Untuk mempermudah memahami proses pelatihan model, pada subbab ini digunakan contoh perhitungan sederhana menggunakan 5 data dan 5 fitur, yaitu *word_count*, *char_count*, *avg_word_length*, *stopword_ratio*, dan *avg_syllables_per_word*. Contoh ini hanya digunakan untuk menjelaskan tahapan perhitungan. Pada implementasi sebenarnya, proses pelatihan dilakukan menggunakan seluruh data latih.

1. Menentukan Data Latih

Lima data yang digunakan pada contoh perhitungan ditunjukkan pada Tabel 4.10. Tiga data pertama merupakan email *legitimate* (label 0), sedangkan dua data berikutnya merupakan email *phishing* (label 1).

Tabel 4.10 Data Contoh Perhitungan

Data	Label	word_count	char_count	avg_word_length	stopword_ratio	avg_syllables_per_word
x_1	0	-0.252574	-0.071553	-1.115997	0	-1.835825
x_2	0	0.081696	-0.013259	-0.945790	0	-0.877465
x_3	0	-0.228451	-0.066743	-0.880898	0	-0.873193
x_4	1	0.285015	0.041675	-0.542122	0	-0.387560
x_5	1	-0.066485	-0.032323	-0.583228	0	-0.964236

Pada SVM, label kelas dinyatakan dalam bentuk -1 dan $+1$. Oleh karena itu, label *legitimate* diubah menjadi -1 , sedangkan label *phishing* diubah menjadi $+1$, sehingga diperoleh

$$y = [-1, -1, -1, +1, +1].$$

2. Menghitung Jarak Euclidean Kuadrat

Langkah berikutnya adalah menghitung jarak Euclidean kuadrat antar data. Nilai jarak ini digunakan pada proses perhitungan kernel RBF. Rumus yang digunakan mengacu pada Persamaan 2.5.

Sebagai contoh dihitung jarak antara data x_1 dan x_2 dengan $m = 5$ karena contoh ini menggunakan lima fitur.

$$\begin{aligned}
\|x_1 - x_2\|^2 &= (-0.252574 - 0.081696)^2 + (-0.071553 - (-0.013259))^2 \\
&\quad + (-1.115997 - (-0.945790))^2 + (0 - 0)^2 \\
&\quad + (-1.835825 - (-0.877465))^2 \\
&= 0.111736 + 0.003398 + 0.028970 + 0 + 0.918454 \\
&= 1.0626
\end{aligned}$$

Perhitungan yang sama dilakukan untuk pasangan data lainnya sehingga diperoleh,

$$\|x_1 - x_3\|^2 = 0.9825 \quad \|x_1 - x_4\|^2 = 2.7286 \quad \|x_1 - x_5\|^2 = 1.0797$$

Hasil perhitungan seluruh pasangan data membentuk matriks jarak sebagai berikut.

$$D = \begin{bmatrix} 0 & 1.0626 & 0.9825 & 2.7286 & 1.0797 \\ 1.0626 & 0 & 0.1033 & 0.4473 & 0.1613 \\ 0.9825 & 0.1033 & 0 & 0.6260 & 0.1243 \\ 2.7286 & 0.4473 & 0.6260 & 0 & 0.4633 \\ 1.0797 & 0.1613 & 0.1243 & 0.4633 & 0 \end{bmatrix}$$

3. Menghitung Kernel *Radial Basis Function* (RBF)

Setelah jarak Euclidean kuadrat diperoleh, langkah berikutnya adalah menghitung nilai kernel RBF. Pada contoh ini digunakan nilai $\gamma = 0.1$, yaitu nilai parameter terbaik yang diperoleh dari proses *hyperparameter tuning*. Nilai kernel dihitung menggunakan Persamaan 2.4.

Sebagai contoh, nilai kernel antara data x_1 dan x_2 dihitung sebagai berikut.

$$K(x_1, x_2) = e^{-0.1(1.0626)} = e^{-0.10626} = 0.8992$$

Perhitungan yang sama dilakukan untuk pasangan data lainnya.

$$K(x_1, x_3) = e^{-0.1(0.9825)} = 0.9064 \quad K(x_1, x_4) = e^{-0.1(2.7286)} = 0.7612$$

$$K(x_1, x_5) = e^{-0.1(1.0797)} = 0.8977$$

Hasil perhitungan seluruh pasangan data membentuk matriks kernel sebagai berikut.

$$K = \begin{bmatrix} 1 & 0.8992 & 0.9064 & 0.7612 & 0.8977 \\ 0.8992 & 1 & 0.9897 & 0.9563 & 0.9840 \\ 0.9064 & 0.9897 & 1 & 0.9393 & 0.9876 \\ 0.7612 & 0.9563 & 0.9393 & 1 & 0.9547 \\ 0.8977 & 0.9840 & 0.9876 & 0.9547 & 1 \end{bmatrix}$$

Nilai kernel berada pada rentang 0 sampai 1. Nilai yang semakin mendekati 1 menunjukkan bahwa dua data memiliki karakteristik yang semakin mirip, sedangkan nilai yang semakin kecil menunjukkan bahwa kedua data semakin berbeda.

Berdasarkan matriks kernel tersebut, pasangan data x_1 dan x_4 memiliki nilai kernel paling kecil, yaitu 0.7612. Hal ini menunjukkan bahwa karakteristik email x_1 yang termasuk kelas *legitimate* paling berbeda dengan email x_4 yang termasuk kelas *phishing*. Nilai kernel ini selanjutnya digunakan pada proses optimasi SVM untuk menentukan nilai α , *support vector*, dan *decision boundary*.

4. Proses Optimasi SVM (Menentukan Nilai Alpha)

Setelah matriks kernel diperoleh, langkah berikutnya adalah menentukan nilai α yang digunakan untuk membentuk model SVM. Nilai α diperoleh dengan menyelesaikan masalah optimasi menggunakan Persamaan 2.6.

Pada contoh ini digunakan lima data sehingga proses perhitungan dapat ditunjukkan

secara bertahap. Pada implementasi sebenarnya, proses yang sama dilakukan menggunakan seluruh data latih dan diselesaikan secara otomatis oleh algoritma optimasi pada *scikit-learn*.

a. Membentuk Sistem Persamaan

Pada SVM dengan kernel RBF, setiap data yang menjadi *support vector* ($\alpha_i > 0$) memenuhi persamaan berikut.

$$\sum_{j=1}^n \alpha_j y_j K(x_i, x_j) + b = y_i$$

Sebagai langkah awal diasumsikan bahwa kelima data merupakan *support vector*. Persamaan di atas ditulis untuk $i = 1, \dots, 5$. Sebagai contoh, untuk $i = 1$ (data x_1 , dengan $y_1 = -1$),

$$\alpha_1 y_1 K(x_1, x_1) + \alpha_2 y_2 K(x_1, x_2) + \alpha_3 y_3 K(x_1, x_3) + \alpha_4 y_4 K(x_1, x_4) + \alpha_5 y_5 K(x_1, x_5) + b = y_1$$

Substitusikan $y_1 = y_2 = y_3 = -1$, $y_4 = y_5 = +1$, dan nilai kernel dari matriks K ($K_{11} = 1$, $K_{12} = 0.8992$, $K_{13} = 0.9064$, $K_{14} = 0.7612$, $K_{15} = 0.8977$).

$$\alpha_1(-1)(1) + \alpha_2(-1)(0.8992) + \alpha_3(-1)(0.9064) + \alpha_4(1)(0.7612) + \alpha_5(1)(0.8977) + b = -1$$

$$-\alpha_1 - 0.8992 \alpha_2 - 0.9064 \alpha_3 + 0.7612 \alpha_4 + 0.8977 \alpha_5 + b = -1$$

Dengan cara yang sama untuk $i = 2, 3, 4, 5$, diperoleh 5 persamaan berikut:

$$-\alpha_1 - 0.8992 \alpha_2 - 0.9064 \alpha_3 + 0.7612 \alpha_4 + 0.8977 \alpha_5 + b = -1$$

$$-0.8992 \alpha_1 - \alpha_2 - 0.9897 \alpha_3 + 0.9563 \alpha_4 + 0.9840 \alpha_5 + b = -1$$

$$-0.9064 \alpha_1 - 0.9897 \alpha_2 - \alpha_3 + 0.9393 \alpha_4 + 0.9876 \alpha_5 + b = -1$$

$$-0.7612 \alpha_1 - 0.9563 \alpha_2 - 0.9393 \alpha_3 + \alpha_4 + 0.9547 \alpha_5 + b = 1$$

$$-0.8977 \alpha_1 - 0.9840 \alpha_2 - 0.9876 \alpha_3 + 0.9547 \alpha_4 + \alpha_5 + b = 1$$

Kemudian ditambahkan persamaan kendala

$$-\alpha_1 - \alpha_2 - \alpha_3 + \alpha_4 + \alpha_5 = 0.$$

Dengan demikian terdapat enam persamaan dan enam variabel yang harus diselesaikan, yaitu $\alpha_1, \alpha_2, \alpha_3, \alpha_4, \alpha_5$, dan b .

b. Penyelesaian Pertama

Sistem persamaan tersebut diselesaikan menggunakan eliminasi Gauss. Hasil yang diperoleh adalah,

$$\alpha_1 = -2,7270, \quad \alpha_2 = 37,4616, \quad \alpha_3 = 54,8535, \quad \alpha_4 = 8,1459, \quad \alpha_5 = 81,4422, \quad b = 0,3708$$

Nilai α_1 bernilai negatif sehingga tidak memenuhi syarat

$$\alpha_i \geq 0.$$

Artinya, asumsi bahwa semua data merupakan *support vector* tidak berlaku karena data x_1 bukan merupakan *support vector*.

c. Menghitung Kembali

Karena x_1 bukan *support vector*, maka

$$\alpha_1 = 0.$$

Persamaan untuk x_1 tidak lagi digunakan sebagai persamaan *margin*. Seluruh suku yang memuat α_1 juga dihilangkan sehingga diperoleh,

$$\begin{aligned} -\alpha_2 - 0.9897 \alpha_3 + 0.9563 \alpha_4 + 0.9840 \alpha_5 + b &= -1 \\ -0.9897 \alpha_2 - \alpha_3 + 0.9393 \alpha_4 + 0.9876 \alpha_5 + b &= -1 \\ -0.9563 \alpha_2 - 0.9393 \alpha_3 + \alpha_4 + 0.9547 \alpha_5 + b &= 1 \\ -0.9840 \alpha_2 - 0.9876 \alpha_3 + 0.9547 \alpha_4 + \alpha_5 + b &= 1 \\ -\alpha_2 - \alpha_3 + \alpha_4 + \alpha_5 &= 0 \end{aligned}$$

Sistem persamaan tersebut kembali diselesaikan menggunakan eliminasi Gauss sehingga diperoleh,

$$\alpha_2 = 33.4009, \alpha_3 = 55.9358, \alpha_4 = 4.5769, \alpha_5 = 84.7599, b = -0.0183$$

Seluruh nilai α sudah memenuhi syarat karena bernilai positif.

d. Memeriksa Hasil

Langkah berikutnya adalah memeriksa kendala,

$$\sum_{i=1}^5 \alpha_i y_i = 0.$$

Substitusi nilai α menghasilkan

$$\begin{aligned} \sum_{i=1}^5 \alpha_i y_i &= (0)(-1) + (33,4009)(-1) + (55,9358)(-1) + (4,5769)(1) + (84,7599)(1) \\ &= -89,3367 + 89,3368 \\ &\approx 0 \end{aligned}$$

Karena hasilnya mendekati nol, kendala tersebut terpenuhi. Selanjutnya dihitung nilai fungsi keputusan untuk data x_1 menggunakan Persamaan 2.9.

$$\begin{aligned} f(x_1) &= (33,4009)(-1)(0.8992) + (55,9358)(-1)(0.9064) + (4,5769)(1)(0.7612) \\ &\quad + (84,7599)(1)(0.8977) + (-0,0183) \\ &= -1,1844 \end{aligned}$$

Kemudian dihitung,

$$y_1 f(x_1) = (-1)(-1,1844) = 1,1844 \geq 1$$

Nilai tersebut memenuhi syarat

$$y_1 f(x_1) \geq 1.$$

Dengan demikian, data x_1 memang bukan *support vector* sehingga nilai $\alpha_1 = 0$ sudah sesuai.

e. Nilai Alpha

Nilai α yang diperoleh dari contoh perhitungan adalah

$$\alpha_1 = 0, \quad \alpha_2 = 33.4009, \quad \alpha_3 = 55.9358, \quad \alpha_4 = 4.5769, \quad \alpha_5 = 84.7599, \quad b = -0.0183$$

Nilai α tersebut hanya digunakan untuk menjelaskan tahapan optimasi SVM menggunakan lima data contoh. Pada implementasi penelitian, proses optimasi dilakukan menggunakan seluruh data latih sehingga jumlah nilai α yang diperoleh sama dengan jumlah data latih.

5. Menentukan *Support Vector*

Nilai α yang diperoleh pada langkah sebelumnya digunakan untuk menentukan *support vector*. Data dengan $\alpha_i > 0$ menjadi *support vector*, sedangkan data dengan $\alpha_i = 0$ bukan *support vector*.

Berdasarkan hasil perhitungan diperoleh bahwa x_1 memiliki $\alpha_1 = 0$, sehingga data tersebut bukan merupakan *support vector*. Sementara itu, x_2, x_3, x_4 , dan x_5 memiliki $\alpha_i > 0$, sehingga keempat data tersebut merupakan *support vector*.

Pada contoh ini, data x_1 tidak digunakan dalam pembentukan *decision boundary* karena berada di luar *margin*. Sebaliknya, data x_2, x_3, x_4 , dan x_5 berada di sekitar *margin* sehingga digunakan untuk membentuk *decision boundary*.

Perhitungan pada langkah 1 sampai langkah 5 hanya menggunakan lima data sebagai contoh. Pada implementasi sebenarnya, proses pelatihan dilakukan menggunakan seluruh data latih yang berjumlah 65.988 data dengan 60 fitur menggunakan fungsi *fit()* pada *scikit-learn*. Jumlah *support vector* pada model akhir adalah sebagai berikut.

$$[9853, 9498]$$

Hasil tersebut menunjukkan bahwa terdapat 9.853 *support vector* pada kelas *legitimate* dan 9.498 *support vector* pada kelas *phishing*. Dengan demikian, jumlah *support vector* yang digunakan untuk membentuk model SVM-RBF adalah 19.351 data.

Beberapa contoh *support vector* ditunjukkan pada Tabel 4.11. Data *support vector* secara lengkap disajikan pada Lampiran 5.

Tabel 4.11 Contoh Data *Support Vector*

<i>Support Vector</i>	word_count	char_count	avg_word_length	...	stopword_ratio	avg_syllables_per_word
SV ₁	-0.242235	-0.064715	0.620967	...	0	0.815117
SV ₂	0.083419	0.002850	-0.440279	...	0	-0.257774
SV ₃	-0.157806	-0.043449	0.150689	...	0	0.179587
SV ₄	-0.135407	-0.038349	0.076024	...	0	-0.138124
SV ₅	-0.113007	-0.032729	0.058477	...	0	-0.106984
...	...	...	...	...	...	...

6. Memprediksi Data Uji

Setelah nilai α dan b diperoleh, model dapat digunakan untuk memprediksi data yang tidak ikut digunakan pada proses pelatihan.

Sebelum diprediksi, data uji dinormalisasi menggunakan nilai *mean* dan *standard deviation* yang sama dengan data latih. Hal ini dilakukan agar data uji berada pada skala yang sama dengan data latih.

Pada contoh ini digunakan salah satu data uji untuk dilakukan perhitungan. Data tersebut dipilih karena tidak termasuk lima data contoh yang digunakan pada proses pelatihan. Nilai hasil normalisasinya adalah sebagai berikut.

$$x_{\text{uji}} = [-0.225005, -0.060775, 0.311190, 0, 0.504113].$$

7. Menghitung Nilai Kernel

Pada contoh ini terdapat empat *support vector*, yaitu x_2 , x_3 , x_4 , dan x_5 . Oleh karena itu, nilai kernel dihitung antara x_{uji} dengan keempat *support vector* tersebut.

Terhadap $x_2 = [0.081696, -0.013259, -0.945790, 0, -0.877465]$

$$\begin{aligned}\|x_{\text{uji}} - x_2\|^2 &= (-0.225005 - 0.081696)^2 + (-0.060775 - (-0.013259))^2 \\ &\quad + (0.311190 - (-0.945790))^2 + (0 - 0)^2 + (0.504113 - (-0.877465))^2 \\ &= 0.094066 + 0.002258 + 1.579998 + 0.000000 + 1.908758 \\ &= 3.585079\end{aligned}$$

$$K(x_{\text{uji}}, x_2) = e^{-0.1(3.585079)} = e^{-0.358508} = 0.698718$$

Terhadap $x_3 = [-0.228451, -0.066743, -0.880898, 0, -0.873193]$

$$\begin{aligned}\|x_{\text{uji}} - x_3\|^2 &= (-0.225005 - (-0.228451))^2 + (-0.060775 - (-0.066743))^2 \\ &\quad + (0.311190 - (-0.880898))^2 + (0 - 0)^2 + (0.504113 - (-0.873193))^2 \\ &= 0.0000119 + 0.0000356 + 1.421073 + 0.000000 + 1.896972 \\ &= 3.318092\end{aligned}$$

$$K(x_{\text{uji}}, x_3) = e^{-0.1(3.318092)} = e^{-0.331809} = 0.717624$$

Terhadap $x_4 = [0.285015, 0.041675, -0.542122, 0, -0.387560]$

$$\begin{aligned}\|x_{\text{uji}} - x_4\|^2 &= (-0.225005 - 0.285015)^2 + (-0.060775 - 0.041675)^2 \\ &\quad + (0.311190 - (-0.542122))^2 + (0 - 0)^2 + (0.504113 - (-0.387560))^2 \\ &= 0.260120 + 0.010496 + 0.728141 + 0.000000 + 0.795081 \\ &= 1.793838\end{aligned}$$

$$K(x_{\text{uji}}, x_4) = e^{-0.1(1.793838)} = e^{-0.179384} = 0.835785$$

Terhadap $x_5 = [-0.066485, -0.032323, -0.583228, 0, -0.964236]$

$$\begin{aligned}\|x_{\text{uji}} - x_5\|^2 &= (-0.225005 - (-0.066485))^2 + (-0.060775 - (-0.032323))^2 \\ &\quad + (0.311190 - (-0.583228))^2 + (0 - 0)^2 + (0.504113 - (-0.964236))^2 \\ &= 0.025129 + 0.000809 + 0.799983 + 0.000000 + 2.156049 \\ &= 2.981970\end{aligned}$$

$$K(x_{\text{uji}}, x_5) = e^{-0.1(2.981970)} = e^{-0.298197} = 0.742155$$

Dengan cara yang sama diperoleh nilai kernel terhadap seluruh *support vector* sebagai berikut.

$$K(x_{\text{uji}}, x_2) = 0.698718,$$

$$K(x_{\text{uji}}, x_3) = 0.717624,$$

$$K(x_{\text{uji}}, x_4) = 0.835785,$$

$$K(x_{uji}, x_5) = 0.742155.$$

Nilai kernel tersebut digunakan pada langkah berikutnya untuk menghitung nilai fungsi keputusan (*decision function*) dan menentukan hasil prediksi data uji.

8. Menghitung Fungsi Keputusan

Nilai kernel pada langkah sebelumnya digunakan untuk menghitung fungsi keputusan menggunakan Persamaan 2.9. Nilai setiap suku dihitung sebagai berikut.

$$\alpha_2 y_2 K(x_{uji}, x_2) = (33,4009)(-1)(0.698718) = -23,3378$$

$$\alpha_3 y_3 K(x_{uji}, x_3) = (55,9358)(-1)(0.717624) = -40,1409$$

$$\alpha_4 y_4 K(x_{uji}, x_4) = (4,5769)(1)(0.835785) = 3,8253$$

$$\alpha_5 y_5 K(x_{uji}, x_5) = (84,7599)(1)(0.742155) = 62,9050$$

Selanjutnya seluruh nilai dijumlahkan dengan bias b .

$$f(x_{uji}) = -23,3378 - 40,1409 + 3,8253 + 62,9050 + (-0,0183) = 3,2333$$

Karena nilai $f(x_{uji})$ bernilai positif, data uji diprediksi sebagai email *phishing*.

9. Menghitung Probabilitas dengan *Platt Scaling*

Nilai fungsi keputusan belum menunjukkan peluang suatu data termasuk kelas *phishing*. Oleh karena itu digunakan *Platt Scaling* dengan Persamaan 2.15.

Pada contoh model yang dibangun menggunakan lima data, perhitungan ini menggunakan pemrograman sehingga diperoleh nilai A dan B sebagai berikut.

$$A = -1,2022, \quad B = 0,1091.$$

Nilai fungsi keputusan pada langkah sebelumnya, $f(x_{uji}) = 3,2333$, kemudian disubstitusikan ke dalam Persamaan 2.15.

$$P(y = 1|x_{uji}) = \frac{1}{1 + \exp((-1,2022)(3,2333) + 0,1091)} = \frac{1}{1 + \exp(-3,7778)} = 0,9776$$

Hasil ini menunjukkan bahwa data uji memiliki peluang sebesar 97,76% yang di mana termasuk ke kelas *phishing*.

10. Mengubah Fungsi Keputusan Menjadi Probabilitas pada Model Sebenarnya

Contoh sebelumnya hanya menggunakan lima data untuk menunjukkan tahapan perhitungan. Oleh karena itu, nilai α , bias b , parameter *Platt Scaling* (A dan B), serta nilai fungsi keputusan yang dihasilkan hanya berlaku di contoh tersebut.

Pada implementasi sebenarnya, model dilatih menggunakan seluruh 65.988 data latih dengan 60 fitur sehingga nilai α , b , A , dan B diperoleh dari hasil pelatihan model.

Parameter yang diperoleh dari hasil pelatihan model adalah sebagai berikut.

$$b = -0,27743749924313305, \quad A = -1,7622073853161682, \quad B = 0,09352437031931288$$

Nilai fungsi keputusan dihitung menggunakan Persamaan 2.9. Pada model ini terdapat 19.351 *support vector*, sehingga penjumlahan dilakukan terhadap seluruh *support vector*. Karena jumlahnya sangat banyak, perhitungan dilakukan menggunakan fungsi *decision_function()* melalui kode sebagai berikut.

```

decision_value = model.decision_function(
X_test_scaled[0].reshape(1,-1) )
print(decision_value)

```

Gambar 4.17 Kode Program untuk Nilai Fungsi Keputusan

Pada contoh ini digunakan data uji pertama hasil *train-test split*, yaitu data yang berasal dari baris ke-9 pada dataset awal.

$$f(x) = -2.234462.$$

Nilai fungsi keputusan yang bernilai negatif menunjukkan bahwa data berada pada sisi *hyperplane* yang sesuai dengan kelas *legitimate*, sedangkan nilai positif menunjukkan data berada pada sisi *hyperplane* yang sesuai dengan kelas *phishing*. Oleh karena itu, nilai $f(x) = -2.234462$ menunjukkan bahwa data diprediksi sebagai *legitimate*. Nilai fungsi keputusan tersebut kemudian diubah menjadi probabilitas menggunakan Persamaan 2.15. Dan diperoleh hasilnya sebagai berikut.

$$\begin{aligned}
Af(x) + B &= (-1.7622073853161682)(-2.234462) + 0.09352437031931288 \\
&= 4.031110,
\end{aligned}$$

sehingga

$$\begin{aligned}
P(y = 1|x) &= \frac{1}{1 + e^{4.031110}} \\
&= 0.0213598.
\end{aligned}$$

Nilai tersebut menunjukkan bahwa peluang email termasuk kelas *phishing* sebesar 2.13598%. Karena peluangnya kecil, data diprediksi sebagai email *legitimate*. Nilai probabilitas digunakan sebagai informasi tambahan terhadap hasil prediksi model. Setelah model berhasil dibentuk, tahap berikutnya adalah mengevaluasi performa model menggunakan data uji untuk mengetahui kemampuan model dalam mengklasifikasikan email *phishing* dan *legitimate*.

4.7 Evaluasi dan Analisis Hasil

Setelah model SVM selesai dilatih, tahap berikutnya adalah mengevaluasi performa model menggunakan data uji. Evaluasi dilakukan menggunakan metrik *accuracy*, *precision*, *recall*, *F1-score*, *confusion matrix*, dan *ROC-AUC*. *Library* yang digunakan pada tahap evaluasi ditunjukkan pada Gambar 4.18

```

from sklearn.metrics import (
accuracy_score ,
precision_score ,
recall_score ,
f1_score ,
confusion_matrix ,
roc_auc_score ,
roc_curve )
import matplotlib.pyplot as plt
import seaborn as sns

```

Gambar 4.18 *Library* untuk Evaluasi Model

Tabel 4.12 Fungsi *Library* pada Evaluasi

No	Nama <i>Library</i>	Fungsi
1	<i>sklearn.metrics</i>	<i>Library</i> untuk menghitung metrik evaluasi model klasifikasi.
2	<i>matplotlib.pyplot</i>	<i>Library</i> untuk membuat visualisasi grafik, seperti ROC Curve.
3	<i>seaborn</i>	<i>Library</i> untuk membuat visualisasi statistik, seperti <i>confusion matrix heatmap</i> .

Pada tahap evaluasi, model menghasilkan label prediksi menggunakan fungsi *predict()* untuk menghitung nilai *accuracy*, *precision*, *recall*, *F1-score*, dan *confusion matrix*. Selain itu, model menghasilkan nilai probabilitas melalui fungsi *predict_proba()* yang digunakan untuk menghitung *ROC-AUC* serta ditampilkan kepada pengguna. Cuplikan kode proses evaluasi ditunjukkan pada Gambar 4.19.

```

y_pred = model.predict(X_test_scaled)
y_prob = model.predict_proba(X_test_scaled)[: ,1]
accuracy = accuracy_score(y_test , y_pred)
precision = precision_score(y_test , y_pred)
recall    = recall_score(y_test , y_pred)
f1        = f1_score(y_test , y_pred)
roc_auc   = roc_auc_score(y_test , y_prob)


```

Gambar 4.19 Kode Program Evaluasi Model

Hasil *confusion matrix* yang diperoleh dari model SVM-RBF adalah sebagai berikut.

$$\begin{bmatrix} TN = 7003 & FP = 916 \\ FN = 927 & TP = 7652 \end{bmatrix}$$

Visualisasi *confusion matrix* ditunjukkan pada Gambar 4.20.

Gambar 4.20 Hasil *Confusion Matrix* Model

Berdasarkan Gambar 4.20, model berhasil mengklasifikasikan 7.652 email *phishing* dan 7.003 email *legitimate* dengan benar. Selain itu, terdapat 916 *false positive* dan 927 *false negative*.

Nilai perhitungan *accuracy* menggunakan Persamaan 2.10, perhitungan *precision* menggunakan Persamaan 2.11, perhitungan *recall* menggunakan Persamaan 2.12, dan perhitungan *F1-score* menggunakan Persamaan 2.13. Berdasarkan *confusion matrix*, diperoleh hasil sebagai berikut.

$$Accuracy = \frac{7652 + 7003}{7652 + 7003 + 916 + 927} = \frac{14655}{16498} = 0.8883$$

$$Precision = \frac{7652}{7652 + 916} = \frac{7652}{8568} = 0.8931$$

$$Recall = \frac{7652}{7652 + 927} = \frac{7652}{8579} = 0.8919$$

$$F1\ Score = \frac{2(0.8931)(0.8919)}{0.8931 + 0.8919} = 0.8925$$

Hasil evaluasi model ditunjukkan pada Tabel 4.13.

Tabel 4.13 Hasil Evaluasi Model SVM-RBF

Metrik	Nilai
Accuracy	0.8883
Precision	0.8931
Recall	0.8919
F1-Score	0.8925
ROC-AUC	0.9509

Berdasarkan Tabel 4.13, model SVM-RBF memperoleh nilai *accuracy* sebesar 88.83%, *precision* sebesar 89.31%, *recall* sebesar 89.19%, *F1-score* sebesar 89.25%, dan *ROC-AUC* sebesar 95.09%. Nilai *ROC-AUC* yang tinggi menunjukkan bahwa model memiliki kemampuan yang baik dalam membedakan email *phishing* dan *legitimate*.

Nilai *ROC-AUC* dihitung berdasarkan nilai probabilitas hasil prediksi yang diperoleh dari model SVM-RBF. Perhitungan dilakukan menggunakan nilai *True Positive Rate* (TPR) dan *False Positive Rate* (FPR) pada berbagai nilai probabilitas prediksi. Nilai TPR dan FPR dihitung menggunakan persamaan berikut.

$$TPR = \frac{TP}{TP + FN} \quad FPR = \frac{FP}{FP + TN}$$

Untuk mempermudah ilustrasi perhitungan ROC-AUC secara manual, digunakan beberapa nilai *threshold* sebagai contoh untuk memperoleh nilai TPR dan FPR. Nilai *threshold* tersebut hanya digunakan pada proses ilustrasi perhitungan ROC-AUC dan tidak digunakan untuk menentukan hasil klasifikasi model. Nilai TPR dan FPR yang diperoleh ditunjukkan pada Tabel 4.14.

Tabel 4.14 Titik FPR dan TPR untuk Kurva ROC

Threshold	FPR	TPR
1.00 (ujung)	0.0000	0.0000
0.75	0.0605	0.8193
0.70	0.0710	0.8386
0.65	0.0822	0.8584
0.60	0.0949	0.8736
0.55	0.1086	0.8854
0.50	0.1227	0.8987
0.45	0.1355	0.9111
0.40	0.1580	0.9260
0.35	0.1815	0.9360
0.30	0.2016	0.9436
0.00 (ujung)	1.0000	1.0000

Sesuai dengan Persamaan 2.14, nilai *ROC-AUC* merupakan luas daerah di bawah kurva ROC. Karena kurva ROC pada penelitian ini diperoleh dari sejumlah titik hasil perhitungan TPR dan FPR, maka luas tersebut dihitung menggunakan metode *trapezoidal rule*.

Nilai TPR dan FPR pada Tabel 4.14 digunakan untuk membentuk kurva ROC. Metode *trapezoidal rule* menghitung luas setiap trapesium yang terbentuk dari dua titik yang berurutan, kemudian menjumlahkan seluruh luas trapesium tersebut. Perhitungannya ditunjukkan pada persamaan berikut.

$$AUC \approx \sum_{i=1}^n (FPR_i - FPR_{i-1}) \times \frac{TPR_{i-1} + TPR_i}{2}$$

Pada penelitian ini terdapat 12 titik sehingga terbentuk 11 segmen trapesium. Perhitungan setiap segmen ditunjukkan sebagai berikut.

$$\begin{aligned}
(1,00 \rightarrow 0,75) : (0,0605 - 0,0000) \times \frac{0,0000 + 0,8193}{2} &= 0,0605 \times 0,4097 = 0,02478 \\
(0,75 \rightarrow 0,70) : (0,0710 - 0,0605) \times \frac{0,8193 + 0,8386}{2} &= 0,0105 \times 0,8290 = 0,00870 \\
(0,70 \rightarrow 0,65) : (0,0822 - 0,0710) \times \frac{0,8386 + 0,8584}{2} &= 0,0112 \times 0,8485 = 0,00950 \\
(0,65 \rightarrow 0,60) : (0,0949 - 0,0822) \times \frac{0,8584 + 0,8736}{2} &= 0,0127 \times 0,8660 = 0,01100 \\
(0,60 \rightarrow 0,55) : (0,1086 - 0,0949) \times \frac{0,8736 + 0,8854}{2} &= 0,0137 \times 0,8795 = 0,01205 \\
(0,55 \rightarrow 0,50) : (0,1227 - 0,1086) \times \frac{0,8854 + 0,8987}{2} &= 0,0141 \times 0,8921 = 0,01258
\end{aligned}$$

$$\begin{aligned}
(0,50 \rightarrow 0,45) &: (0,1355 - 0,1227) \times \frac{0,8987 + 0,9111}{2} = 0,0128 \times 0,9049 = 0,01158 \\
(0,45 \rightarrow 0,40) &: (0,1580 - 0,1355) \times \frac{0,9111 + 0,9260}{2} = 0,0225 \times 0,9185 = 0,02067 \\
(0,40 \rightarrow 0,35) &: (0,1815 - 0,1580) \times \frac{0,9260 + 0,9360}{2} = 0,0235 \times 0,9310 = 0,02188 \\
(0,35 \rightarrow 0,30) &: (0,2016 - 0,1815) \times \frac{0,9360 + 0,9436}{2} = 0,0201 \times 0,9398 = 0,01889 \\
(0,30 \rightarrow 0,00) &: (1,0000 - 0,2016) \times \frac{0,9436 + 1,0000}{2} = 0,7984 \times 0,9718 = 0,77589
\end{aligned}$$

Dijumlahkan seluruhnya:


$$\begin{aligned}
AUC_{\text{estimasi}} &= 0,02478 + 0,00870 + 0,00950 + 0,01100 + 0,01205 + 0,01258 \\
&\quad + 0,01158 + 0,02067 + 0,02188 + 0,01889 + 0,77589
\end{aligned}$$

$$AUC_{\text{estimasi}} = 0,9275$$

Pada perhitungan manual, luas trapesium terakhir bernilai 0.77589, lebih besar dibandingkan segmen lainnya. Hal ini terjadi karena titik yang digunakan hanya sampai *threshold* 0.30, kemudian langsung menuju titik akhir (1,1). Akibatnya, segmen terakhir memiliki lebar yang jauh lebih besar sehingga memberikan kontribusi luas yang paling besar. Nilai *AUC* hasil perhitungan manual sebesar 0,9275 berbeda dengan nilai *AUC* dari *scikit-learn* sebesar 0,9509. Perhitungan manual hanya menggunakan beberapa titik sebagai ilustrasi untuk menunjukkan cara memperoleh luas kurva ROC menggunakan metode *trapezoidal rule*. Sementara itu, nilai ROC-AUC yang dihasilkan oleh *scikit-learn* dihitung menggunakan seluruh probabilitas hasil prediksi, sehingga nilainya lebih akurat dan digunakan sebagai hasil akhir penelitian. Berdasarkan hasil evaluasi model, diperoleh nilai *ROC-AUC* adalah sebagai berikut.

$$AUC = 0,9509$$

Nilai tersebut menunjukkan bahwa luas daerah di bawah kurva ROC adalah sebesar 0,9509 atau sekitar 95,09% dari luas maksimum. Semakin mendekati nilai 1, semakin baik kemampuan model dalam membedakan data dari kedua kelas. Hasil *ROC Curve* ditunjukkan pada Gambar 4.21.



Gambar 4.21 Hasil *ROC Curve*

Kurva ROC pada Gambar 4.21 berada dekat dengan sudut kiri atas. Hal ini menunjukkan bahwa model memiliki nilai *True Positive Rate* yang tinggi dan *False Positive Rate* yang rendah pada berbagai nilai probabilitas prediksi. Nilai *ROC-AUC* sebesar 0,9509 menunjukkan bahwa model mampu membedakan email *phishing* dan *legitimate* dengan sangat baik.

4.8 Implementasi SHAP pada Model *Support Vector Machine* (SVM)

Setelah model SVM dievaluasi menggunakan data uji, tahap berikutnya adalah melakukan analisis menggunakan SHAP (*Shapley Additive Explanations*). Analisis ini bertujuan untuk mengetahui pengaruh setiap fitur *stylometric* terhadap keputusan model SVM-RBF dalam mengklasifikasikan email sebagai *phishing* atau *legitimate*.

Pada penelitian ini, SHAP digunakan untuk dua jenis analisis, yaitu analisis global dan analisis lokal. Analisis global digunakan untuk melihat fitur yang paling berpengaruh terhadap model secara keseluruhan, sedangkan analisis lokal digunakan untuk menjelaskan alasan model memberikan prediksi pada suatu email tertentu.

Library yang digunakan pada tahap ini ditunjukkan pada Gambar 4.22.

```
import pandas as pd
import joblib
import shap
import matplotlib.pyplot as plt
```

Gambar 4.22 *Library* untuk Implementasi SHAP

Tabel 4.15 Fungsi *Library* pada Implementasi SHAP

No	Nama Library	Fungsi
1	<i>pandas</i>	<i>Library</i> untuk pengolahan dan analisis data berbentuk tabel (DataFrame), termasuk membaca, memanipulasi, dan menyimpan data.
2	<i>joblib</i>	<i>Library</i> untuk memuat model <i>machine learning</i> dan <i>scaler</i> yang telah disimpan.
3	<i>shap</i>	<i>Library</i> untuk menghasilkan nilai SHAP dan menjelaskan hasil prediksi model.
4	<i>matplotlib.pyplot</i>	<i>Library</i> untuk membuat dan menyimpan visualisasi grafik.

Library SHAP digunakan untuk menghitung kontribusi setiap fitur terhadap hasil prediksi model.

Sebelum analisis SHAP dilakukan, terlebih dahulu dipilih beberapa sampel dari hasil prediksi data uji. Hasil prediksi tersebut memuat informasi nomor data, label prediksi, probabilitas *phishing*, label aktual, dan status prediksi. Informasi tersebut digunakan untuk menentukan sampel yang akan dianalisis menggunakan SHAP. Untuk deksripsi kolom hasil prediksi dapat dilihat sebagai berikut.

Tabel 4.16 Deskripsi Kolom Hasil Prediksi

No	Kolom	Deskripsi
1	row_id	Nomor data
2	predicted_label	Label prediksi (0/1)
3	predicted_proba_phishing	Probabilitas phishing
4	true_label	Label aktual (0/1)
5	status	Status benar/salah prediksi

Sebagian hasil prediksi data uji ditunjukkan pada tabel berikut.

Tabel 4.17 Contoh Hasil Prediksi Data Uji

Row ID	Potongan Email	Label Prediksi	Probabilitas Phishing	Label Aktual	Status
9	fw pooling contract template original message christinehauk txu com...	0 (legitimate)	0.021360	0 (legitimate)	Benar
16	hpl nom april 2001 see attached file hplno 410 xls hplno 410 xls	1 (phishing)	0.940223	0 (legitimate)	Salah
21	estimated actuals april 5 2001 estimated actuals teco...	0 (legitimate)	0.019664	0 (legitimate)	Benar
28	nom vols 3 24 thru 3 26 01 agree eileen ponton 03 26 2001...	0 (legitimate)	0.115071	0 (legitimate)	Benar
48	noms actual flow 03 20 01 agree nominations eileen ponton...	0 (legitimate)	0.169218	0 (legitimate)	Benar
...	...	...	...	...	...

Berdasarkan hasil prediksi tersebut, dipilih beberapa sampel yang akan dianalisis menggunakan SHAP. Sampel dipilih agar mewakili beberapa kondisi hasil prediksi, yaitu *true positive* (TP), *true negative* (TN), *false positive* (FP) dan *false negative* (FN). Cuplikan kode pemilihannya ditunjukkan pada gambar berikut.


```
# Pemilihan sampel untuk analisis SHAP
df_xai = result.copy()
tp = df_xai[
    (df_xai["true_label"] == 1) &
    (df_xai["predicted_label"] == 1)]
tn = df_xai[
    (df_xai["true_label"] == 0) &
    (df_xai["predicted_label"] == 0)]
fp = df_xai[
    (df_xai["true_label"] == 0) &
    (df_xai["predicted_label"] == 1)]
fn = df_xai[
    (df_xai["true_label"] == 1) &
    (df_xai["predicted_label"] == 0)]
```

Gambar 4.23 Kode Program Pemilihan Sampel SHAP

Pada penelitian ini dipilih sebanyak 3 sampel TP, 3 sampel TN, 2 sampel FP, dan 2 sampel FN. Pemilihan sampel dilakukan agar analisis SHAP dapat menjelaskan keputusan model pada prediksi yang benar maupun prediksi yang salah.

$$TP = 3, \quad TN = 3, \quad FP = 2, \quad FN = 2$$

Sebagian sampel yang digunakan pada analisis SHAP ditunjukkan pada Tabel 4.18. Seluruh sampel dapat dilihat pada Lampiran 6.

Tabel 4.18 Contoh Sampel untuk Analisis SHAP

Row ID	Probabilitas Phishing	Prediksi	Label Aktual	Status	Kategori XAI
82431	1.000000	Phishing	Phishing	Benar	TP
75681	0.000000	Legitimate	Legitimate	Benar	TN
13886	1.000000	Phishing	Legitimate	Salah	FP
75904	0.000002	Legitimate	Phishing	Salah	FN

Tabel 4.18 menunjukkan contoh sampel yang digunakan pada analisis SHAP. Sampel dipilih dari setiap kategori hasil klasifikasi, yaitu TP, TN, FP, dan FN. Sampel-sampel tersebut selanjutnya digunakan untuk menjelaskan kontribusi setiap fitur terhadap hasil prediksi model.

Sebelum analisis SHAP dilakukan, model, *scaler*, data fitur, dan sampel XAI dimuat kembali menggunakan kode pada Gambar 4.24.

```
model = joblib.load(MODEL_PKL)
df = pd.read_csv(FEATURES_CSV)
xai_samples = pd.read_csv(XAI_SAMPLES_CSV)
```

Gambar 4.24 Kode Program Pemuatan Model dan Data

Sampel yang digunakan terdiri atas 3 data TP, 3 data TN, 2 data FP, dan 2 data FN. Data tersebut diambil berdasarkan *row_id* seperti pada Gambar 4.25.

```
sample_indices = (  
    xai_samples["row_id"] - 1  
) . astype(int)  
X_samples = X.iloc[sample_indices]
```

Gambar 4.25 Kode Program Pengambilan Sampel SHAP

Data sampel tersebut selanjutnya digunakan pada analisis SHAP.

a. Analisis Global Menggunakan SHAP

Analisis global menggunakan SHAP dilakukan untuk mengetahui fitur-fitur yang paling berpengaruh terhadap hasil prediksi model secara keseluruhan sehingga dapat diketahui tingkat kepentingan masing-masing fitur terhadap model.

1. Membentuk Background Data

Perhitungan SHAP diawali dengan membentuk *background data* sebagai data referensi. Pada penelitian ini digunakan 300 data yang dipilih secara acak menggunakan kode pada Gambar 4.26.

```
bg_size = min(300, X_scaled.shape[0])  
bg_idx = np.random.choice(  
    X_scaled.shape[0], bg_size, replace=False)  
X_bg = X_scaled[bg_idx]
```

Gambar 4.26 Kode Program Pembentukan *Background Data*

Background data digunakan sebagai acuan dalam menghitung nilai SHAP untuk setiap fitur.

2. Membentuk SHAP Explainer

Setelah *background data* diperoleh, selanjutnya dibentuk SHAP *explainer* menggunakan *KernelExplainer* seperti pada Gambar 4.27.

```
explainer = shap.KernelExplainer(  
    model.predict_proba, X_bg)
```

Gambar 4.27 Kode Program Pembentukan SHAP *Explainer*

KernelExplainer digunakan karena model SVM-RBF termasuk model *black-box* sehingga tidak dapat dijelaskan secara langsung seperti model berbasis pohon.

3. Data Contoh dan Hasil Prediksi Kelas

Untuk mempermudah penjelasan perhitungan SHAP, digunakan 5 data dan 5 fitur yang sama seperti pada contoh perhitungan SVM sebelumnya, yaitu *word_count*, *char_count*, *avg_word_length*, *stopword_ratio*, dan *avg_syllables_per_word*. Data tersebut ditunjukkan pada Tabel 4.19.

Tabel 4.19 Data Contoh Perhitungan SHAP

Data	Label	word_count	char_count	avg_word_length	stopword_ratio	avg_syllables_per_word
x_1	0	-0.252574	-0.071553	-1.115997	0	-1.835825
x_2	0	0.081696	-0.013259	-0.945790	0	-0.877465
x_3	0	-0.228451	-0.066743	-0.880898	0	-0.873193
x_4	1	0.285015	0.041675	-0.542122	0	-0.387560
x_5	1	-0.066485	-0.032323	-0.583228	0	-0.964236

Kelima data tersebut kemudian diprediksi menggunakan model SVM-RBF yang telah dilatih. Probabilitas kelas *phishing* yang dihasilkan adalah sebagai berikut.

$$f(x_1) = 0.031127, \quad f(x_2) = 0.007242, \quad f(x_3) = 0.045024, \\ f(x_4) = 0.949054, \quad f(x_5) = 0.953873$$

Nilai probabilitas tersebut digunakan sebagai dasar pada perhitungan SHAP yang dijelaskan pada langkah berikutnya.

4. Menghitung *Base Value*

Pada implementasi SHAP, *base value* merupakan rata-rata probabilitas prediksi model yang dihitung dari 300 *background data* yang dipilih secara acak. Berdasarkan hasil implementasinya, diperoleh *base value* sebesar 0.508.

Nilai *base value* ini menjadi nilai awal sebelum kontribusi setiap fitur ditambahkan atau dikurangi hingga menghasilkan prediksi akhir.

Untuk mempermudah penjelasan proses perhitungan SHAP, digunakan contoh lima data yang telah dijelaskan sebelumnya. Pada contoh ini dipilih x_1 sebagai data referensi dan x_4 sebagai data yang akan dijelaskan. Pemilihan kedua data ini hanya digunakan untuk memperlihatkan proses perhitungan kontribusi fitur secara bertahap.

5. Menentukan Nilai yang Digunakan pada Perhitungan SHAP

Nilai SHAP dihitung menggunakan Persamaan 2.16. Pada contoh perhitungan ini digunakan data x_1 sebagai email *legitimate* dan data x_4 sebagai email *phishing*. Perhitungan dilakukan menggunakan lima fitur, yaitu *word_count*, *char_count*, *avg_word_length*, *stopword_ratio*, dan *avg_syllables_per_word*. Kelima fitur tersebut membentuk himpunan fitur $F = \{\text{word_count}, \text{char_count}, \text{avg_word_length}, \text{stopword_ratio}, \text{avg_syllables_per_word}\}$ sehingga banyaknya fitur adalah $|F| = 5$.

Nilai yang akan dicari pada perhitungan ini adalah ϕ_i , yaitu nilai SHAP untuk fitur ke- i . Selanjutnya digunakan himpunan S , yaitu himpunan bagian dari F yang tidak memuat fitur ke- i . Pada contoh ini, fitur yang termasuk dalam himpunan S menggunakan nilai dari data x_4 , sedangkan fitur yang tidak termasuk dalam himpunan S tetap menggunakan nilai dari data x_1 .

Nilai $f(S)$ merupakan probabilitas email *phishing* yang dihasilkan model ketika hanya fitur pada himpunan S yang menggunakan nilai dari x_4 , sedangkan fitur lainnya masih menggunakan nilai dari x_1 . Setelah fitur ke- i juga diganti menggunakan nilai dari x_4 , diperoleh probabilitas baru yang dinyatakan sebagai $f(S \cup \{i\})$. Selisih antara $f(S \cup \{i\})$ dan $f(S)$ menunjukkan perubahan probabilitas setelah fitur ke- i ditambahkan. Nilai tersebut digunakan sebagai kontribusi fitur ke- i terhadap hasil prediksi model.

6. Menentukan Jumlah Kombinasi S

Pada contoh ini terdapat 5 fitur. Misalkan akan dihitung nilai SHAP untuk satu fitur, maka terdapat 4 fitur lainnya yang dapat membentuk himpunan S . Setiap fitur memiliki dua kemungkinan, yaitu dipilih ke dalam S atau tidak dipilih. Oleh karena itu, jumlah seluruh kombinasi yang mungkin dapat dihitung menggunakan rumus berikut.

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

dengan $n = 4$ sebagai jumlah fitur yang dapat dipilih dan $k = |S|$ sebagai banyaknya fitur yang berada di dalam himpunan S .

$$|S| = 0 : \quad \binom{4}{0} = \frac{4!}{0! \times 4!} = \frac{24}{1 \times 24} = 1 \quad (1 \text{ cara: tidak ada fitur yang dipilih})$$

$$|S| = 1 : \quad \binom{4}{1} = \frac{4!}{1! \times 3!} = \frac{24}{1 \times 6} = 4 \quad (4 \text{ cara: memilih 1 dari 4 fitur})$$

$$|S| = 2 : \quad \binom{4}{2} = \frac{4!}{2! \times 2!} = \frac{24}{2 \times 2} = 6 \quad (6 \text{ cara: memilih 2 dari 4 fitur})$$

$$|S| = 3 : \quad \binom{4}{3} = \frac{4!}{3! \times 1!} = \frac{24}{6 \times 1} = 4 \quad (4 \text{ cara: memilih 3 dari 4 fitur})$$

$$|S| = 4 : \quad \binom{4}{4} = \frac{4!}{4! \times 0!} = \frac{24}{24 \times 1} = 1 \quad (1 \text{ cara: memilih seluruh 4 fitur})$$

Jika seluruh kombinasi dijumlahkan maka diperoleh sebagai berikut.

$$\binom{4}{0} + \binom{4}{1} + \binom{4}{2} + \binom{4}{3} + \binom{4}{4} = 1 + 4 + 6 + 4 + 1 = 16 \text{ kombinasi}$$

7. Menghitung Bobot Tiap Ukuran Kombinasi

Setelah seluruh kombinasi S diperoleh, langkah berikutnya adalah menghitung bobot setiap kombinasi menggunakan Persamaan 2.16. Pada contoh ini terdapat 5 fitur sehingga $|F| = 5$ dan diperoleh $5! = 120$.

$$\frac{|S|!(|F| - |S| - 1)!}{|F|!}$$

$$|S| = 0 : \quad w = \frac{0! \times (5 - 0 - 1)!}{5!} = \frac{1 \times 24}{120} = \frac{24}{120} = 0,2000$$

$$|S| = 1 : \quad w = \frac{1! \times (5 - 1 - 1)!}{5!} = \frac{1 \times 6}{120} = \frac{6}{120} = 0,0500$$

$$|S| = 2 : \quad w = \frac{2! \times (5 - 2 - 1)!}{5!} = \frac{2 \times 2}{120} = \frac{4}{120} = 0,0333$$

$$|S| = 3 : \quad w = \frac{3! \times (5 - 3 - 1)!}{5!} = \frac{6 \times 1}{120} = \frac{6}{120} = 0,0500$$

$$|S| = 4 : \quad w = \frac{4! \times (5 - 4 - 1)!}{5!} = \frac{24 \times 1}{120} = \frac{24}{120} = 0,2000$$

Hasil perhitungan bobot untuk setiap ukuran himpunan S ditunjukkan pada Tabel

4.20.

Tabel 4.20 Bobot SHAP

Ukuran $ S $	Jumlah Kombinasi	Bobot per Kombinasi	Total Bobot
0	1	0,2000	0,2
1	4	0,0500	0,2
2	6	0,0333	0,2
3	4	0,0500	0,2
4	1	0,2000	0,2

Kolom *Total Bobot* menunjukkan hasil perkalian antara jumlah kombinasi dan bobot pada setiap ukuran himpunan S . Sebagai contoh, untuk $|S| = 1$ terdapat 4 kombinasi dengan bobot masing-masing 0,0500, sehingga total bobotnya diperoleh:

$$4 \times 0,0500 = 0,2$$

Perhitungan yang sama berlaku untuk ukuran himpunan lainnya sehingga setiap ukuran memiliki total bobot sebesar 0,2. Jika seluruh total bobot dijumlahkan, diperoleh:

$$0,2 + 0,2 + 0,2 + 0,2 + 0,2 = 1$$

Hasil tersebut menunjukkan bahwa seluruh bobot pada perhitungan SHAP berjumlah 1. Bobot inilah yang digunakan untuk mengalikan setiap kontribusi pada 16 kombinasi yang telah diperoleh sebelumnya.

8. Menghitung Nilai SHAP untuk Fitur *avg_word_length*

Nilai $f(S)$ diperoleh dengan membentuk data baru dari x_1 dan x_4 . Fitur yang termasuk dalam himpunan S diambil dari x_4 , sedangkan fitur lainnya tetap menggunakan nilai dari x_1 . Data tersebut kemudian dimasukkan ke model SVM-RBF yang telah dilatih sehingga diperoleh probabilitas *phishing*.

Sebagai contoh, akan dihitung nilai SHAP untuk fitur *avg_word_length*. Jika $S = \emptyset$, maka belum ada fitur yang diambil dari x_4 , sehingga data yang digunakan sama dengan x_1 .

$$x_1 = [-0,252574, -0,071553, -1,115997, 0, -1,835825]$$

Karena data yang digunakan sama dengan x_1 , diperoleh:

$$f(x_1) = 0,0311$$

Untuk $f(S \cup \{i\})$, fitur *avg_word_length* diganti menggunakan nilai dari x_4 , sedangkan fitur lainnya tetap menggunakan nilai dari x_1 .

$$z_{S \cup \{i\}} = [-0,252574, -0,071553, \underbrace{-0,542122}_{\text{dari } x_4}, 0, -1,835825]$$

Hasil prediksi model untuk data tersebut adalah sebagai berikut.

$$f(S \cup \{i\}) = 0,9950.$$

Kontribusi pada kombinasi ini dihitung menggunakan bobot SHAP] dan diperoleh hasil sebagai berikut.

$$\text{bobot} \times [f(S \cup \{i\}) - f(S)] = 0,2 \times (0,9950 - 0,0311) = 0,1928$$

Perhitungan yang sama dilakukan pada seluruh kombinasi lainnya. Hasil lengkap perhitungan untuk fitur *avg_word_length* ditunjukkan pada Tabel 4.21.

Tabel 4.21 Perhitungan Nilai SHAP untuk Fitur *avg_word_length*

$ S $	Fitur dalam S	Bobot	$f(S)$	$f(S \cup \{i\})$	Kontribusi
0	-	0,2000	0,0311	0,9950	0,1928
1	word_count	0,0500	0,1317	0,9989	0,0434
1	char_count	0,0500	0,0341	0,9954	0,0481
1	stopword_ratio	0,0500	0,0311	0,9950	0,0482
1	avg_syllables_per_word	0,0500	0,0003	0,7539	0,0377
2	word_count, char_count	0,0333	0,1426	0,9990	0,0285
2	word_count, stopwords_ratio	0,0333	0,1317	0,9989	0,0289
2	word_count, avg_syllables_per_word	0,0333	0,0018	0,9440	0,0314
2	char_count, stopwords_ratio	0,0333	0,0341	0,9954	0,0320
2	char_count, avg_syllables_per_word	0,0333	0,0003	0,7727	0,0257
2	stopwords_ratio, avg_syllables_per_word	0,0333	0,0003	0,7539	0,0251
3	word_count, char_count, stopwords_ratio	0,0500	0,1426	0,9990	0,0428
3	word_count, char_count, avg_syllables_per_word	0,0500	0,0020	0,9491	0,0474
3	word_count, stopwords_ratio, avg_syllables_per_word	0,0500	0,0018	0,9440	0,0471
3	char_count, stopwords_ratio, avg_syllables_per_word	0,0500	0,0003	0,7723	0,0386
4	word_count, char_count, stopwords_ratio, avg_syllables_per_word	0,2000	0,0020	0,9491	0,1894

Nilai SHAP untuk fitur *avg_word_length* diperoleh dengan menjumlahkan seluruh nilai pada kolom Kontribusi pada Tabel 4.21.

$$\begin{aligned}\phi_{avg_word_length} &= 0,1928 + 0,0434 + 0,0481 + 0,0482 + 0,0377 + 0,0285 + 0,0289 + 0,0314 \\ &\quad + 0,0320 + 0,0257 + 0,0251 + 0,0428 + 0,0474 + 0,0471 + 0,0386 + 0,1894 \\ &= 0,9071\end{aligned}$$

Nilai kontribusi pada setiap kombinasi berbeda karena fitur *avg_word.length* memberikan pengaruh yang berbeda ketika dikombinasikan dengan fitur lainnya. Oleh karena itu, seluruh kontribusi tersebut dijumlahkan untuk memperoleh nilai SHAP akhir fitur tersebut.

9. Hasil Perhitungan Nilai SHAP Seluruh Fitur

Perhitungan yang sama dilakukan pada empat fitur lainnya, yaitu *word_count*, *char_count*, *stopword_ratio*, dan *avg_syllables_per_word*. Hasil penjumlahan kontribusi pada setiap ukuran himpunan S ditunjukkan pada Tabel 4.22.

Tabel 4.22 Rangkuman Kontribusi SHAP Berdasarkan Ukuran Himpunan S

Fitur	$ S = 0$	$ S = 1$	$ S = 2$	$ S = 3$	$ S = 4$
word_count	0,0201	0,0107	0,0103	0,0186	0,0353
char_count	0,0006	0,0007	0,0010	0,0012	0,0010
avg_word.length	0,1928	0,1773	0,1718	0,1759	0,1894
stopword_ratio	0,0000	0,0000	0,0000	0,0000	0,0000
avg_syllables_per_word	-0,0062	-0,0218	-0,0274	-0,0234	-0,0100

Nilai *stopword_ratio* bernilai 0 pada seluruh ukuran himpunan S . Hal ini karena nilai fitur tersebut sama pada x_1 dan x_4 , sehingga pergantian nilai fitur tidak mengubah hasil prediksi model.

Nilai SHAP akhir setiap fitur diperoleh dengan menjumlahkan seluruh kontribusi pada setiap baris. Hasilnya ditunjukkan pada Tabel 4.23.

Tabel 4.23 Nilai SHAP Akhir

Fitur	Nilai SHAP (ϕ_i)
word_count	0,0950
char_count	0,0046
avg_word.length	0,9071
stopword_ratio	0,0000
avg_syllables_per_word	-0,0888

Berdasarkan Tabel 4.23, fitur *avg_word.length* memiliki nilai SHAP paling besar, yaitu 0,9071. Hal ini menunjukkan bahwa fitur tersebut memberikan kontribusi terbesar

terhadap prediksi *phishing* pada data x_4 . Sebaliknya, *avg_syllables_per_word* memiliki nilai SHAP negatif sebesar $-0,0888$, sehingga fitur tersebut mengurangi kecenderungan model memprediksi *phishing*. Sementara itu, *stopword_ratio* memiliki nilai SHAP 0, sehingga tidak memberikan kontribusi terhadap hasil prediksi.

Untuk memastikan hasil perhitungan sudah benar, dilakukan pemeriksaan menggunakan hasil pada SHAP. Jumlah seluruh nilai SHAP harus sama dengan selisih probabilitas antara data yang dijelaskan (x_4) dan data pembanding (x_1).

$$\sum_{i=1}^5 \phi_i = 0,0950 + 0,0046 + 0,9071 + 0,0000 + (-0,0888) = 0,9179$$

$$f(x_4) - f(x_1) = 0,949054 - 0,031127 = 0,9179$$

Kedua nilai tersebut sama, sehingga hasil perhitungan SHAP telah memenuhi sifat *efficiency*. Hal ini menunjukkan bahwa seluruh nilai SHAP berhasil menjelaskan perubahan probabilitas dari x_1 ke x_4 .

10. Implementasi Perhitungan SHAP

Contoh perhitungan sebelumnya menggunakan 5 fitur sehingga seluruh kombinasi masih dapat dihitung. Pada implementasi penelitian ini digunakan 60 fitur. Jika seluruh kombinasi dihitung seperti contoh sebelumnya, maka untuk satu fitur diperlukan sebanyak 2^{59} kombinasi. Jumlah tersebut sangat besar sehingga tidak memungkinkan dihitung satu per satu.

Oleh karena itu, pada penelitian ini digunakan *KernelExplainer* dengan *sampling*. Pada penelitian ini digunakan *nsamples*=500, sehingga sekitar 500 kombinasi digunakan dalam proses perhitungan.

```
shap_values = explainer.shap_values( X_bg, nsamples=500 )
if isinstance(shap_values, list):
    shap_values_pos = shap_values[1]
elif len(shap_values.shape) == 3:
    shap_values_pos = shap_values[:, :, 1]
else:
    shap_values_pos = shap_values
```

Gambar 4.28 Kode Program Perhitungan Nilai SHAP

Kode tersebut digunakan untuk menghitung nilai SHAP pada seluruh data *background*. Karena penelitian ini merupakan klasifikasi dua kelas, nilai SHAP yang digunakan adalah untuk kelas *phishing*. Nilai SHAP yang diperoleh selanjutnya digunakan untuk analisis global dan analisis lokal.

11. Menghitung *Mean Absolute SHAP (Feature Importance)*

Setelah nilai SHAP diperoleh untuk seluruh data, tingkat kepentingan setiap fitur dihitung menggunakan rata-rata nilai absolut SHAP. Perhitungan tersebut dilakukan menggunakan kode berikut.

```
mean_abs_shap = np.abs(shap_values_pos).mean(axis=0)
```


Gambar 4.29 Kode Program Perhitungan *Mean Absolute SHAP*

Kode tersebut menghitung nilai absolut SHAP untuk setiap fitur pada seluruh data, kemudian menghitung nilai rata-ratanya.

Tabel 4.24 Ranking Fitur Berdasarkan *Mean Absolute* SHAP


Fitur	Mean SHAP
gunning_fog_index	0.164459
coleman_liau_index	0.127324
avg_word_length	0.113282
trigram_count	0.093813
lexical_diversity	0.060159
bigram_count	0.059110
avg_syllables_per_word	0.043625
dale_chall_score	0.043146
pronoun_count	0.029297
...	...

Berdasarkan Tabel 4.24, fitur diurutkan berdasarkan nilai *mean absolute* SHAP dari yang terbesar hingga terkecil. Semakin besar nilai *mean absolute* SHAP, semakin besar pengaruh fitur tersebut terhadap keputusan model secara keseluruhan.



Gambar 4.30 SHAP *Summary Plot (Bar)* untuk *Feature Importance*

Gambar 4.30 menunjukkan hasil *SHAP Summary Plot* dalam bentuk diagram batang. Urutan fitur pada grafik sama dengan hasil pada Tabel 4.24. Fitur *gunning_fog_index* memiliki nilai *mean absolute* SHAP terbesar, diikuti oleh *coleman_liau_index* dan *avg_word_length*. Hal ini menunjukkan bahwa ketiga fitur tersebut memberikan pengaruh paling besar terhadap keputusan model.



Gambar 4.31 SHAP Summary Plot (*Beeswarm*)

Gambar 4.31 menunjukkan SHAP Summary Plot dalam bentuk *beeswarm*. Setiap titik mewakili satu data. Warna merah menunjukkan nilai fitur yang tinggi, sedangkan warna biru menunjukkan nilai fitur yang rendah. Posisi titik pada sumbu horizontal menunjukkan nilai SHAP atau besar kontribusi fitur terhadap hasil prediksi.

Nilai SHAP yang positif menunjukkan bahwa suatu fitur mendorong prediksi ke arah *phishing*, sedangkan nilai SHAP yang negatif menunjukkan kontribusi ke arah *legitimate*. Semakin lebar penyebaran titik, semakin besar variasi pengaruh fitur tersebut terhadap prediksi model.

Sebagai contoh, pada fitur *gunning_fog_index*, titik berwarna merah lebih banyak berada di sisi kanan grafik. Hal ini menunjukkan bahwa nilai *gunning_fog_index* yang tinggi cenderung mendorong prediksi ke arah *phishing*. Sebaliknya, nilai yang lebih rendah cenderung memberikan kontribusi ke arah *legitimate*.

b. Analisis Lokal Menggunakan SHAP

Selain analisis global, dilakukan juga analisis lokal menggunakan SHAP untuk melihat kontribusi setiap fitur terhadap hasil prediksi pada satu data tertentu. Pada tahap ini digunakan sampel yang telah dipilih sebelumnya, yaitu TP (*True Positive*), TN (*True Negative*), FP (*False Positive*), dan FN (*False Negative*).

Nilai SHAP untuk setiap data sampel dihitung menggunakan kode berikut.

```
shap_values_samples = explainer.shap_values(  
    X_samples_scaled ,  
    nsamples=500 )
```

Gambar 4.32 Kode Program Perhitungan SHAP untuk Data Sampel

Kode tersebut digunakan untuk menghitung nilai SHAP pada seluruh data sampel menggunakan *KernelExplainer* dengan *nsamples=500*.

Selanjutnya dipilih nilai SHAP untuk kelas *phishing* menggunakan kode berikut.

```
shap_samples_pos = shap_values_samples [1]
```

Gambar 4.33 Kode Program Pemilihan SHAP untuk Data Sampel Kelas *Phishing*

Tahap berikutnya adalah menampilkan hasil interpretasi menggunakan *waterfall plot*.

```
exp = shap.Explanation(  
    values=shap_row ,  
    base_values=base_val ,  
    data=X_samples_scaled [ i ] ,  
    feature_names=feature_names )  
shap.plots.waterfall(exp , max_display=10)
```

Gambar 4.34 Kode Program Visualisasi SHAP Lokal

Kode tersebut digunakan untuk membuat *waterfall plot* untuk setiap data sampel. Grafik ini menampilkan *base value*, nilai SHAP setiap fitur, dan hasil prediksi akhir pada data yang dianalisis. Pada grafik hanya ditampilkan 10 fitur dengan kontribusi terbesar agar lebih mudah dibaca.


Pada *waterfall plot*, fitur dengan nilai SHAP positif (warna merah) mendorong prediksi ke arah *phishing*, sedangkan fitur dengan nilai SHAP negatif (warna biru) mendorong prediksi ke arah *legitimate*. Dengan visualisasi ini, dapat diketahui fitur-fitur yang paling memengaruhi hasil prediksi pada setiap data.

Sebagai contoh, digunakan salah satu data *True Positive*, sebagaimana ditunjukkan pada Gambar 4.35. Nilai *base value* pada grafik diperoleh dari hasil perhitungan SHAP menggunakan *KernelExplainer*. Nilai tersebut dihitung dengan konsep yang sama seperti pada analisis global, yaitu menggunakan rata-rata probabilitas prediksi model terhadap 300 *background data*. Pada implementasi penelitian ini diperoleh *base value* yaitu 0.508.

Selanjutnya, SHAP menghitung kontribusi setiap fitur terhadap data yang dianalisis. Nilai kontribusi tersebut diperoleh secara otomatis melalui proses komputasi SHAP menggunakan *KernelExplainer* dengan *nsamples=500*. Oleh karena itu, nilai SHAP yang ditampilkan pada *waterfall plot* bukan dihitung secara manual.

Untuk memperjelas hasil analisis lokal, ditampilkan visualisasi *waterfall plot* untuk setiap kategori data. Visualisasi SHAP lokal secara lengkap untuk seluruh sampel dapat dilihat pada Lampiran 7.

1. *True Positive* (TP)




Gambar 4.35 SHAP Waterfall Plot untuk Data *True Positive* (TP)

Berdasarkan Gambar 4.35, *base value* sebesar 0.508 merupakan nilai awal prediksi model. Setelah ditambahkan dengan kontribusi seluruh fitur, diperoleh nilai prediksi akhir $f(x)$ yang mendekati 1, sehingga data diprediksi sebagai *phishing*.

Fitur *coleman_liau_index* (+0.12), *lexical_diversity* (+0.11), dan *imperative_verbs_count* (+0.11) memberikan kontribusi positif terbesar terhadap prediksi. Sementara itu, terdapat sedikit kontribusi negatif dari *politeness_markers* (-0.07), pengaruhnya lebih kecil sehingga prediksi tetap mengarah ke *phishing*.

Angka di sebelah kiri nama fitur, seperti -1.895 = *lexical_diversity* atau 0.798 = *imperative_verbs_count* menunjukkan nilai fitur setelah proses *scaling*, sedangkan angka pada batang merah dan biru menunjukkan nilai SHAP atau besar kontribusi setiap fitur terhadap hasil prediksi. Keterangan *51 other features* menunjukkan bahwa masih terdapat fitur lain yang ikut dihitung, tetapi kontribusinya lebih kecil sehingga tidak ditampilkan satu per satu. Nilai $f(x) = 1$ pada bagian atas grafik menunjukkan bahwa probabilitas prediksi model mendekati 1 sehingga data diklasifikasikan sebagai *phishing*.

2. *True Negative* (TN)



Gambar 4.36 SHAP Waterfall Plot untuk Data *True Negative* (TN)


Berdasarkan Gambar 4.36, *base value* sebesar 0.508 merupakan nilai awal prediksi

model. Setelah ditambahkan dengan kontribusi seluruh fitur, diperoleh nilai prediksi akhir $f(x)$ yang mendekati 0, sehingga data diprediksi sebagai *legitimate*.

Fitur *dale_chall_score* (-0.15), *avg_syllables_per_word* (-0.13), dan *trigram_count* (-0.12) memberikan kontribusi negatif terbesar terhadap prediksi. Sementara itu, *gunning_fog_index* ($+0.26$) memberikan kontribusi positif, namun pengaruhnya lebih kecil sehingga prediksi tetap mengarah ke *legitimate*.

Angka di sebelah kiri nama fitur, seperti $0.591 = \text{gunning_fog_index}$ atau $-0.645 = \text{dale_chall_score}$, menunjukkan nilai fitur setelah proses *scaling*, sedangkan angka pada batang merah dan biru menunjukkan nilai SHAP atau besar kontribusi setiap fitur terhadap hasil prediksi. Keterangan *51 other features* menunjukkan bahwa masih terdapat fitur lain yang ikut dihitung, tetapi kontribusinya lebih kecil sehingga tidak ditampilkan satu per satu. Nilai $f(x) = 0$ pada bagian atas grafik menunjukkan bahwa probabilitas prediksi model mendekati 0 sehingga data diklasifikasikan sebagai *legitimate*.

3. False Positive (FP)




Gambar 4.37 SHAP Waterfall Plot untuk Data False Positive (FP)

Berdasarkan Gambar 4.37, *base value* sebesar 0.508 merupakan nilai awal prediksi model. Setelah ditambahkan dengan kontribusi seluruh fitur, diperoleh nilai prediksi akhir $f(x)$ yang mendekati 1, sehingga data diprediksi sebagai *phishing*. Meskipun demikian, data ini sebenarnya merupakan email *legitimate*, sehingga termasuk kasus *False Positive*.

Fitur *lexical_diversity* ($+0.15$), *trigram_count* ($+0.10$), dan *unique_word_count* ($+0.06$) memberikan kontribusi positif terbesar terhadap prediksi. Kontribusi fitur-fitur tersebut menyebabkan model lebih mengarah pada kelas *phishing*, meskipun data sebenarnya merupakan email *legitimate*.

Angka di sebelah kiri nama fitur menunjukkan nilai fitur setelah proses *scaling*, sedangkan angka pada batang merah dan biru menunjukkan nilai SHAP atau besar kontribusi setiap fitur terhadap hasil prediksi. Keterangan *51 other features* menunjukkan bahwa masih terdapat fitur lain yang ikut dihitung, tetapi kontribusinya lebih kecil sehingga tidak ditampilkan satu per satu. Nilai $f(x) = 1$ pada bagian atas grafik menunjukkan bahwa probabilitas prediksi model mendekati 1 sehingga data diklasifikasikan sebagai *phishing*.

4. False Negative (FN)



Gambar 4.38 SHAP Waterfall Plot untuk Data *False Negative* (FN)

Berdasarkan Gambar 4.38, *base value* sebesar 0.508 merupakan nilai awal prediksi model. Setelah ditambahkan dengan kontribusi seluruh fitur, diperoleh nilai prediksi akhir $f(x)$ yang mendekati 0, sehingga data diprediksi sebagai *legitimate*. Meskipun demikian, data ini sebenarnya merupakan email *phishing*, sehingga termasuk kasus *False Negative*.

Fitur *lexical_diversity* (-0.26) dan *word_length_variation* (-0.24) memberikan kontribusi negatif terbesar terhadap prediksi. Sementara itu, *gunning_fog_index* ($+0.20$) memberikan kontribusi positif, namun pengaruhnya lebih kecil sehingga prediksi tetap mengarah ke *legitimate*.

Angka di sebelah kiri nama fitur menunjukkan nilai fitur setelah proses *scaling*, sedangkan angka pada batang merah dan biru menunjukkan nilai SHAP atau besar kontribusi setiap fitur terhadap hasil prediksi. Keterangan *51 other features* menunjukkan bahwa masih terdapat fitur lain yang ikut dihitung, tetapi kontribusinya lebih kecil sehingga tidak ditampilkan satu per satu. Nilai $f(x) = 0$ pada bagian atas grafik menunjukkan bahwa probabilitas prediksi model mendekati 0 sehingga data diklasifikasikan sebagai *legitimate*.

Berdasarkan hasil analisis lokal menggunakan SHAP, setiap data memiliki kombinasi kontribusi fitur yang berbeda sehingga alasan model dalam menghasilkan prediksi juga berbeda. Fitur seperti *gunning_fog_index*, *coleman_liau_index*, *lexical_diversity*, dan *trigram_count* sering muncul sebagai fitur yang memberikan kontribusi besar terhadap hasil prediksi. Analisis ini juga menunjukkan bahwa kesalahan prediksi pada data *False Positive* dan *False Negative* terjadi karena beberapa karakteristik gaya penulisan email *phishing* menyerupai email *legitimate*. Oleh karena itu, SHAP membantu menjelaskan alasan model memberikan prediksi pada setiap data.

Berdasarkan hasil analisis global dan analisis lokal, SHAP tidak hanya menunjukkan fitur yang paling berpengaruh terhadap model secara keseluruhan, tetapi juga menjelaskan kontribusi setiap fitur pada masing-masing data. Dengan demikian, hasil prediksi kelas menjadi lebih mudah dipahami.

Tahap selanjutnya adalah implementasi model ke dalam sistem klasifikasi email *phishing* berbasis web.

4.9 Implementasi Sistem Klasifikasi Email *Phishing*

Setelah model SVM dan analisis SHAP selesai diimplementasikan, tahap berikutnya adalah membangun sistem klasifikasi email *phishing* berbasis web menggunakan *Streamlit*. Sistem ini menyediakan dua cara untuk melakukan klasifikasi email, yaitu melalui *input* manual dan integrasi dengan Gmail. Selain menampilkan hasil klasifikasi, sistem juga menampilkan interpretasi hasil prediksi menggunakan SHAP.

Tahap pertama adalah memuat *library* yang digunakan untuk membangun sistem, melakukan ekstraksi fitur, klasifikasi, dan interpretasi hasil prediksi.

```
# Perancangan Sistem
import streamlit as st
import numpy as np
import pandas as pd
import joblib
import shap
import textstat
import nltk
```

Gambar 4.39 *Library* Utama untuk Implementasi Sistem

Untuk mengambil email dari akun Gmail dan melakukan proses klasifikasi, digunakan beberapa *library* dari Google API.

```
from googleapiclient.discovery import build
from google_auth_oauthlib.flow import InstalledAppFlow
from google.oauth2.credentials import Credentials
```

Gambar 4.40 *Library* Integrasi Gmail

Tabel 4.25 Fungsi *Library* pada Implementasi Sistem

No	Nama <i>Library</i>	Fungsi
1	<i>streamlit</i>	<i>Library</i> untuk membangun antarmuka sistem berbasis web.
2	<i>numpy</i>	<i>Library</i> untuk komputasi numerik, seperti perhitungan rata-rata, standar deviasi, dan operasi matematika lainnya.
3	<i>pandas</i>	<i>Library</i> untuk membaca, mengolah, dan menyimpan data dalam bentuk tabel (DataFrame).
4	<i>joblib</i>	<i>Library</i> untuk memuat model dan <i>scaler</i> yang telah disimpan sebelumnya.

Bersambung ke halaman berikutnya

Tabel Tabel 4.25 (Lanjutan)

No	Nama <i>Library</i>	Fungsi
5	<i>shap</i>	<i>Library</i> untuk menghasilkan interpretasi prediksi model menggunakan SHAP.
6	<i>textstat</i>	<i>Library</i> untuk menghitung tingkat keterbacaan teks menggunakan berbagai indeks <i>readability</i> .
7	<i>nltk</i>	<i>Library</i> untuk pemrosesan bahasa alami (<i>Natural Language Processing</i>), seperti tokenisasi kata dan kalimat.
13	<i>Google API Library</i>	<i>Library</i> untuk autentikasi Gmail dan pengambilan email dari akun Gmail pengguna.

Setelah seluruh *library* dimuat, dilakukan konfigurasi halaman menggunakan *Streamlit*.

```
st.set_page_config(
    page_title="StylDetect",
    layout="wide",
)
```

Gambar 4.41 Kode Program Konfigurasi Halaman Sistem

Kode tersebut digunakan untuk mengatur judul aplikasi dan tata letak halaman agar area tampilan lebih luas (*wide layout*).

Antarmuka sistem dibangun menggunakan *Streamlit* dengan tambahan CSS untuk mengatur tampilan aplikasi. Pengaturan tersebut meliputi warna, tombol, kartu informasi, serta area hasil prediksi dan interpretasi SHAP sehingga tampilan sistem menjadi lebih mudah digunakan.

Setelah tampilan sistem selesai disiapkan, langkah berikutnya adalah mengatur file yang digunakan pada proses prediksi.

```
MODEL_PKL = "svm_rbf_model_3.pkl"
SCALER_PKL = "scaler_3.pkl"
FEATURE_CSV = "stylometric_features_60.csv"
SCOPES = [
    "https://www.googleapis.com/auth/gmail.readonly"
]
```

Gambar 4.42 Kode Program Konfigurasi File Sistem

Kode pada Gambar 4.42 digunakan untuk memuat model SVM, *scaler*, data fitur, dan hak akses Gmail (*gmail.readonly*) yang digunakan pada proses klasifikasi email.

Untuk mendukung integrasi Gmail, sistem menggunakan hak akses *gmail.readonly*. Hak akses ini hanya digunakan untuk membaca isi email sehingga sistem tidak dapat mengubah, menghapus, maupun mengirim email dari akun pengguna.

Selanjutnya dilakukan *preprocessing* pada teks email sebelum proses ekstraksi fitur. Tahapan *preprocessing* yang digunakan sama dengan tahap sebelumnya, yaitu normalisasi *line break* (Gambar 4.3), penghapusan *HTML tag* (Gambar 4.4), penghapusan *header* email (Gambar 4.5), dan normalisasi *whitespace* (Gambar 4.6). Dengan demikian, data yang diproses oleh sistem memiliki format yang sama dengan data yang digunakan pada proses pelatihan.

Setelah proses *preprocessing* selesai, teks email diubah menjadi 60 fitur *stylometric* menggunakan fungsi yang telah dibuat pada tahap ekstraksi fitur.

```
from feature_extraction import extract_60_features
train_df = pd.read_csv("stylometric_features_60.csv")
feature_names = list(
    train_df.drop(columns=["label"]).columns )
```

Gambar 4.43 Kode Program Ekstraksi Fitur *Stylometric*

Fungsi *extract_60_features()* digunakan untuk mengubah teks email menjadi 60 fitur *stylometric*. Selain itu, sistem juga memuat nama seluruh fitur dari data pelatihan agar urutan fitur yang digunakan saat prediksi tetap sama dengan urutan fitur pada saat model dilatih.

Setelah fitur berhasil diekstraksi, sistem memuat model SVM dan *scaler* yang telah disimpan pada proses pelatihan.

```
model = joblib.load(MODEL_PKL)
scaler = joblib.load(SCALER_PKL)
```

Gambar 4.44 Kode Program Pemuatan Model dan *Scaler*

Model digunakan untuk melakukan klasifikasi email, sedangkan *scaler* digunakan untuk menormalisasi nilai fitur sebelum diproses oleh model. Selanjutnya dibentuk SHAP *KernelExplainer* untuk menghasilkan interpretasi prediksi model.

```
X_bg = scaler.transform(
    df_bg.sample(
        300,
        random_state=42 ) )
explainer = shap.KernelExplainer(
    model.predict_proba ,
    X_bg )
```

Gambar 4.45 Kode Program Pembentukan SHAP *Explainer*

Sebanyak 300 data digunakan sebagai *background data*. Data tersebut menjadi referensi SHAP dalam menghitung kontribusi setiap fitur terhadap hasil prediksi model.

Selain mode *input* manual, sistem juga menyediakan integrasi Gmail sehingga pengguna dapat menganalisis email langsung dari akun Gmail. Integrasi ini menggunakan

Gmail API dengan hak akses *gmail.readonly*, sehingga sistem hanya dapat membaca email tanpa mengubah atau menghapus isi *inbox*.

Selanjutnya dilakukan autentikasi akun Gmail menggunakan mekanisme *OAuth*. Setelah proses autentikasi berhasil, sistem dapat terhubung ke Gmail API dan mengambil email dari akun pengguna.

```
SCOPES = [ "https://www.googleapis.com/auth/gmail.readonly" ]
```

Gambar 4.46 Konfigurasi Hak Akses Gmail

Setelah berhasil terhubung ke Gmail, sistem mengambil beberapa email dari kotak masuk sesuai jumlah yang dipilih pengguna. Informasi yang diambil meliputi nama pengirim, subjek, dan isi email.

Cuplikan proses pengambilan email ditunjukkan pada Gambar 4.47.

```
results = service.users().messages().list(  
    userId="me",  
    labelIds=["INBOX"],  
    maxResults=max_results  
).execute()
```

Gambar 4.47 Kode Program Pengambilan Email Gmail

Setelah email diperoleh, sistem melakukan proses klasifikasi menggunakan model SVM. Tahapan yang dilakukan sama seperti pada proses pelatihan, yaitu *preprocessing*, ekstraksi 60 fitur *stylometric*, normalisasi menggunakan *scaler*, dan klasifikasi menggunakan model.

Setelah hasil klasifikasi diperoleh, sistem menghitung nilai SHAP untuk mengetahui fitur yang paling memengaruhi keputusan model.


```
shap_values = explainer.shap_values(  
    X_scaled,  
    nsamples=300 )  
top_features = (  
    pd.Series(shap_ph,  
    index=feature_names)  
    .abs()  
    .sort_values(  
        ascending=False )  
    .head(topk) )
```

Gambar 4.48 Kode Program Interpretasi SHAP

Kode pada Gambar 4.48 digunakan untuk menghitung nilai SHAP pada email yang dianalisis. Nilai SHAP kemudian diurutkan berdasarkan nilai absolutnya sehingga fitur dengan pengaruh terbesar terhadap hasil prediksi dapat ditampilkan kepada pengguna.

Nilai SHAP positif menunjukkan bahwa fitur tersebut mendorong prediksi ke arah *phishing*, sedangkan nilai SHAP negatif menunjukkan kontribusi ke arah *legitimate*.

Tahap terakhir adalah menampilkan hasil analisis melalui antarmuka web yang dibangun menggunakan *Streamlit*. Sistem ini menyediakan dua mode analisis, yaitu melalui *input* manual dan integrasi Gmail. Selain hasil klasifikasi, sistem juga menampilkan interpretasi SHAP agar pengguna dapat mengetahui fitur yang paling memengaruhi keputusan model.



Gambar 4.49 Halaman Utama Sistem Klasifikasi

Berdasarkan Gambar 4.49, halaman utama menampilkan nama sistem, informasi singkat mengenai metode yang digunakan, jumlah fitur *stylometric*, serta metode interpretasi SHAP. Pengguna juga dapat memilih sumber email yang akan dianalisis, yaitu melalui *input* manual atau integrasi Gmail.

Pada mode *input* manual, pengguna dapat memasukkan isi email melalui area teks yang disediakan.

```
email_input = st.text_area(
    label="Isi email",
    value=default_text,
    height=220 )
```

Gambar 4.50 Kode Program *Input* Manual Email

Kode tersebut digunakan untuk membuat area *input* email yang akan dianalisis oleh sistem.

Pengguna juga dapat menentukan jumlah fitur SHAP yang akan ditampilkan pada hasil analisis.


```
topk = st.slider(
    "Berapa fitur paling berpengaruh yang ingin ditampilkan?",
    min_value=3,
    max_value=15,
    value=5 )
```

Gambar 4.51 Kode Program Pengaturan Jumlah Fitur SHAP

Nilai yang dipilih pengguna digunakan untuk menentukan jumlah fitur dengan nilai SHAP terbesar yang ditampilkan pada hasil interpretasi.

Setelah tombol analisis ditekan, sistem secara otomatis melakukan *preprocessing*, ekstraksi fitur *stylometric*, normalisasi menggunakan *scaler*, klasifikasi menggunakan model SVM, dan interpretasi menggunakan SHAP.

Hasil klasifikasi pada mode *input* manual ditunjukkan pada Gambar 4.52.



Gambar 4.52 Hasil Klasifikasi Email pada Mode *Input* Manual

Berdasarkan Gambar 4.52, sistem menampilkan hasil klasifikasi, probabilitas *phishing*, dan fitur-fitur yang paling berpengaruh terhadap hasil prediksi berdasarkan nilai SHAP.

Pada contoh tersebut, email diklasifikasikan sebagai *legitimate* dengan probabilitas *phishing* sebesar 40,3%. Fitur *pronoun_count* memiliki nilai SHAP positif sebesar 0,0944 sehingga mendorong prediksi ke arah *phishing*. Sebaliknya, *bigram_count* memiliki nilai SHAP sebesar $-0,0564$ sehingga memberikan kontribusi ke arah *legitimate*.


Selain melalui *input* manual, sistem juga dapat menganalisis email langsung dari akun Gmail. Pengguna dapat menentukan jumlah email yang akan dianalisis menggunakan komponen *slider* berikut.

```
num_email=st.slider(
    "Berapa email terbaru yang ingin dianalisis?",
    1, 10, 5 )
```

Gambar 4.53 Kode Program Pengaturan Jumlah Email Gmail

Jumlah email yang dipilih digunakan sebagai banyaknya email yang diambil dari kotak masuk Gmail untuk dianalisis.

Setelah pengguna menghubungkan akun Gmail, sistem melakukan autentikasi menggunakan Gmail API. Selanjutnya, sistem mengambil email dari kotak masuk sesuai jumlah yang dipilih. Isi email yang diperoleh kemudian diproses menggunakan tahapan yang sama seperti pada mode *input* manual, yaitu *preprocessing*, ekstraksi fitur *stylometric*, normalisasi, klasifikasi menggunakan model SVM, dan interpretasi menggunakan SHAP. Hasil implementasi mode Gmail ditunjukkan pada Gambar 4.54.



Gambar 4.54 Hasil Klasifikasi Email pada Mode Integrasi Gmail

Berdasarkan Gambar 4.54, sistem menampilkan daftar email yang berhasil diambil dari akun Gmail pengguna. Setiap email menampilkan informasi pengirim, subjek, isi email, hasil klasifikasi, probabilitas *phishing*, serta fitur-fitur yang paling berpengaruh berdasarkan nilai SHAP.

Pada contoh tersebut, email diprediksi sebagai *phishing* dengan probabilitas sebesar 68,7%. Fitur *avg_word_length* memiliki nilai SHAP positif sebesar 0,2589 sehingga mendorong prediksi ke arah *phishing*. Sebaliknya, *gunning_fog_index* memiliki nilai SHAP sebesar -0,2463 sehingga memberikan kontribusi ke arah *legitimate*.

Melalui tampilan tersebut, pengguna dapat mengetahui hasil klasifikasi beserta fitur-fitur yang paling berpengaruh terhadap hasil prediksi.

Berdasarkan hasil implementasi, sistem ini mampu mengklasifikasikan email *phishing* menggunakan model SVM berbasis fitur *stylometric*. Selain menampilkan hasil klasifikasi, sistem juga menyajikan interpretasi SHAP sehingga proses pengambilan keputusan model dapat dipahami dengan lebih mudah.

4.10 Pengujian Sistem Klasifikasi Email *Phishing*

Setelah sistem selesai diimplementasikan, tahap berikutnya adalah melakukan pengujian sistem. Pengujian dilakukan untuk memastikan bahwa seluruh fungsi pada sistem dapat berjalan dengan baik, mulai dari menerima *input* email, melakukan proses klasifikasi menggunakan model SVM, hingga menampilkan hasil interpretasi menggunakan SHAP.

Pengujian dilakukan pada dua mode yang tersedia, yaitu *input* manual dan integrasi Gmail. Pada mode *input* manual, pengujian dilakukan dengan menggunakan beberapa contoh email untuk melihat hasil klasifikasi dan interpretasi SHAP yang dihasilkan sistem. Sementara itu, pada mode integrasi Gmail, pengujian dilakukan untuk memastikan sistem dapat terhubung ke akun Gmail, mengambil email dari kotak masuk, dan melakukan analisis terhadap email tersebut.

4.10.1 Skenario Pengujian Sistem

Sebelum pengujian dilakukan, terlebih dahulu disusun beberapa skenario pengujian. Skenario ini digunakan sebagai acuan untuk menguji setiap fungsi utama pada sistem.

Fungsi yang diuji meliputi penerimaan *input* email, proses klasifikasi, tampilan hasil prediksi, interpretasi SHAP, serta integrasi Gmail. Skenario pengujian yang digunakan pada penelitian ini ditunjukkan pada Tabel 4.26.

Tabel 4.26 Skenario Pengujian Sistem Klasifikasi

No	Skenario Pengujian	Tujuan Pengujian
1	Mode <i>input</i> manual	Menguji apakah sistem dapat menerima email yang dimasukkan pengguna dan melakukan proses klasifikasi.
2	Hasil klasifikasi email	Menguji apakah sistem dapat menampilkan hasil klasifikasi beserta nilai probabilitas prediksi.
3	Interpretasi SHAP	Menguji apakah sistem dapat menampilkan fitur-fitur yang memengaruhi hasil prediksi.
4	Integrasi Gmail	Menguji apakah sistem dapat terhubung dengan akun Gmail pengguna.
5	Pengambilan email Gmail	Menguji apakah sistem dapat mengambil email dari kotak masuk sesuai jumlah yang dipilih pengguna.
6	Analisis email dari Gmail	Menguji apakah email yang diambil dari Gmail dapat dianalisis oleh sistem.

Berdasarkan skenario pengujian yang telah ditentukan, tahap selanjutnya adalah melakukan pengujian pada masing-masing fitur sistem.

4.10.2 Pengujian Mode *Input* Manual


Pengujian mode *input* manual dilakukan untuk memastikan bahwa sistem ini dapat menerima teks email dari pengguna, kemudian melakukan *preprocessing*, ekstraksi fitur, klasifikasi menggunakan model SVM, serta menampilkan interpretasi SHAP.

Pada pengujian ini digunakan dua contoh email, yaitu email *legitimate* dan email *phishing*. Salah satu email *phishing* merupakan email yang diperoleh dari DPTSI ITS, sedangkan email *legitimate* berasal dari akun Gmail penulis. Kedua email tersebut digunakan untuk melihat hasil klasifikasi yang diberikan oleh sistem. Hasil pengujian ditunjukkan pada Tabel 4.27.

Tabel 4.27 Hasil Pengujian Mode *Input* Manual

No	Jenis Email	Label Aktual	Hasil Sistem	Probabilitas <i>Phishing</i>
1	Email undangan kegiatan Kaggle dari akun Gmail penulis	<i>Legitimate</i>	<i>Legitimate</i>	40.2%
2	Email promosi (DPTSI ITS)	<i>Phishing</i>	<i>Legitimate</i>	40.3%

Berdasarkan Tabel 4.27, sistem dapat menerima email yang dimasukkan melalui mode *input* manual, kemudian menjalankan proses analisis hingga menampilkan hasil klasifikasi dan interpretasi SHAP. Contoh hasil pengujian pertama ditunjukkan pada Gambar 4.55.



Gambar 4.55 Hasil Pengujian Mode *Input* Manual Contoh Pertama

Fitur yang Paling Mempengaruhi Keputusan Model		
Nilai SHAP menunjukkan seberapa besar kontribusi setiap fitur terhadap prediksi. Positif → mendorong ke arah phishing, Negatif → mendukung kelas legitimate.		
Fitur	Nilai SHAP	Arah
pronoun_count	0.0898	mendorong ke phishing
trigram_count	-0.0596	menguatkan legitimate
bigram_count	-0.0563	menguatkan legitimate
avg_word_length	0.0551	mendorong ke phishing
coleman_liaw_index	-0.0521	menguatkan legitimate

Gambar 4.55 Hasil Pengujian Mode *Input* Manual Contoh Pertama (Lanjutan)

Pengujian pertama menggunakan email *legitimate* berupa undangan kegiatan *5-Day AI Agents: Intensive Vibecoding Course* dari Kaggle. Hasil pengujian menunjukkan bahwa

sistem mengklasifikasikan email tersebut sebagai *legitimate* dengan probabilitas *phishing* sebesar 40,2%.

Berdasarkan interpretasi SHAP, fitur *pronoun_count* dan *avg_word_length* mendorong prediksi ke arah *phishing*. Sebaliknya, fitur *trigram_count*, *bigram_count*, dan *coleman_liau_index* memberikan kontribusi yang lebih besar ke arah *legitimate*. Hasil klasifikasi menunjukkan bahwa email tersebut diprediksi sebagai *legitimate*. Hasil tersebut sesuai dengan label aktual email.

Contoh hasil pengujian kedua ditunjukkan pada Gambar 4.56.

Tempel isi email di bawah ini

Salin isi email yang ingin diperiksa, lalu klik tombol analisis. Bahasa Inggris lebih dianjurkan untuk hasil optimal.

Hi,
 Would you be interested in connecting with Active Decision Makers? May I send 5-10 samples for review?
 Industry Specific : Healthcare Industry, IT Industry, Construction Industry, Finance Industry, Oil & Gas Industry, Manufacturing Industry, Retail Industry, Education Industry and more.
 Target Titles: Business Owner/CEO/COO/CFO/CMO/President/VP, Market Research Manager, Market Research Coordinator, Market Research Consultant, Market Research Analyst, Director Market Research, Advertising and Marketing Manager/Director, Brand Manager/Director, Assistant Marketing Director, Associate Marketing Director, Research &

Berapa fitur paling berpengaruh yang ingin ditampilkan?

Analisis Email

Hasil Analisis

STATUS EMAIL

✓ Email Tampak Aman

Skor kepercayaan phishing: 40.3% di bawah threshold 0.45

Model menilai email ini tidak memiliki pola mencurigakan yang signifikan.

Gambar 4.56 Hasil Pengujian Mode *Input* Manual Contoh Kedua

Fitur yang Paling Mempengaruhi Keputusan Model

Nilai SHAP menunjukkan seberapa besar kontribusi setiap fitur terhadap prediksi. Positif → mendorong ke arah phishing. Negatif → mendukung kelas legitimate.

Fitur	Nilai SHAP	Arah
pronoun_count	0.0971	mendorong ke phishing
trigram_count	-0.0454	menguatkan legitimate
sentence_complexity_ratio	-0.0289	menguatkan legitimate
bigram_count	-0.0214	menguatkan legitimate
pronoun_density	-0.0198	menguatkan legitimate

Gambar 4.56 Hasil Pengujian Mode *Input* Manual Contoh Kedua (Lanjutan)


Pengujian kedua menggunakan email *phishing* yang diperoleh dari DPTSI ITS. Sistem mengklasifikasikan email tersebut sebagai *legitimate* dengan probabilitas *phishing* sebesar 40,3%, sehingga termasuk *false negative*.

Berdasarkan interpretasi SHAP, fitur *pronoun_count* memberikan kontribusi ke arah *phishing*. Sebaliknya, fitur *trigram_count*, *sentence_complexity_ratio*, *bigram_count*, dan *pronoun_density* memberikan kontribusi yang lebih besar ke arah *legitimate*. Oleh karena itu, model mengklasifikasikan email tersebut sebagai *legitimate*.


Hasil ini menunjukkan bahwa model masih mengalami kesalahan klasifikasi pada email *phishing* yang memiliki gaya penulisan menyerupai email *legitimate*.

4.10.3 Pengujian Integrasi Gmail

Pengujian integrasi Gmail dilakukan untuk memastikan bahwa sistem dapat terhubung dengan akun Gmail pengguna, mengambil email dari kotak masuk, kemudian melakukan klasifikasi dan menampilkan interpretasi SHAP secara otomatis. Pada pengujian ini digunakan akun Gmail pengguna dengan memilih jumlah email yang akan dianalisis melalui sistem. Hasil pengujian ditunjukkan pada Gambar 4.57.



Gambar 4.57 Hasil Pengujian Mode Integrasi Gmail



Gambar 4.57 Hasil Pengujian Mode Integrasi Gmail (Lanjutan)

Berdasarkan Gambar 4.57, sistem berhasil mengambil lima email terbaru sesuai jumlah yang dipilih pengguna. Setiap email ditampilkan dalam bentuk daftar dan dapat dibuka untuk melihat informasi pengirim, isi email, hasil klasifikasi, probabilitas *phishing*, serta interpretasi SHAP.

Pada salah satu email, sistem mengklasifikasikan email sebagai *phishing* dengan probabilitas sebesar 68,7%. Interpretasi SHAP menunjukkan bahwa fitur *avg_word_length*, *trigram_count*, dan *bigram_count* memberikan kontribusi ke arah *phishing*. Sebaliknya, fitur *gunning_fog_index* dan *punctuation_variety* memberikan kontribusi ke arah *legitimate*. Kontribusi fitur yang mengarah ke kelas *phishing* lebih besar dibandingkan kontribusi yang mengarah ke kelas *legitimate*, sehingga email tersebut diklasifikasikan sebagai *phishing*.

Secara keseluruhan, hasil pengujian menunjukkan bahwa seluruh fungsi sistem telah berjalan dengan baik. Sistem dapat menerima *input* email secara manual maupun melalui integrasi Gmail, kemudian melakukan klasifikasi menggunakan model SVM serta menampilkan interpretasi SHAP. Meskipun pada pengujian mode *input* manual masih ditemukan satu kasus *false negative*, sistem tetap mampu mengklasifikasikan email dan memberikan penjelasan terhadap hasil prediksi melalui SHAP.

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan, diperoleh beberapa kesimpulan sebagai berikut.

1. Fitur *stylometric* dapat digunakan untuk membedakan email *phishing* dan email *legitimate*. Pada penelitian ini digunakan 60 fitur *stylometric* yang mewakili karakteristik gaya penulisan email. Hasil analisis SHAP menunjukkan bahwa fitur *gunning_fog_index*, *coleman_liau_index*, *avg_word_length*, *trigram_count*, dan *lexical_diversity* merupakan beberapa fitur yang memberikan kontribusi paling besar terhadap hasil klasifikasi.
2. Algoritma *Support Vector Machine* (SVM) dengan kernel *Radial Basis Function* (RBF) dapat digunakan untuk mengklasifikasikan email *phishing* dan *legitimate* berdasarkan fitur *stylometric*. Model yang diperoleh menghasilkan *accuracy* sebesar 88,87%, *precision* sebesar 87,93%, *recall* sebesar 91,11%, *F1-score* sebesar 89,49%, dan *ROC-AUC* sebesar 95,09%.
3. *Shapley Additive Explanations* (SHAP) dapat digunakan untuk menjelaskan kontribusi setiap fitur terhadap hasil prediksi model. Analisis global menunjukkan fitur-fitur yang paling berpengaruh terhadap model secara keseluruhan, sedangkan analisis lokal menunjukkan kontribusi setiap fitur pada masing-masing data. Selain itu, analisis lokal juga membantu menjelaskan alasan model menghasilkan prediksi *True Positive*, *True Negative*, *False Positive*, dan *False Negative*, sehingga hasil prediksi kelas menjadi lebih mudah dipahami.
4. Model yang telah dibangun berhasil diimplementasikan ke dalam aplikasi berbasis web menggunakan *Streamlit*. Sistem dapat melakukan klasifikasi email melalui *input* manual maupun integrasi Gmail. Selain menampilkan hasil klasifikasi, sistem juga menampilkan interpretasi SHAP sehingga pengguna dapat melihat fitur yang paling memengaruhi hasil prediksi. Hasil pengujian juga menunjukkan bahwa seluruh fungsi utama sistem dapat berjalan sesuai dengan rancangan.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran untuk pengembangan penelitian selanjutnya sebagai berikut.

1. Penelitian selanjutnya dapat menggunakan dataset yang berasal dari berbagai jenis dan sumber email *phishing* maupun *legitimate* agar model dapat mengenali lebih banyak pola penulisan email.
2. Penelitian selanjutnya dapat menambahkan fitur selain *stylometric*, seperti *URL*, *header* email, atau analisis isi pesan berdasarkan makna (*semantic analysis*) untuk meningkatkan kemampuan klasifikasi.

3. Penelitian selanjutnya dapat membandingkan model SVM-RBF dengan model klasifikasi lain untuk mengetahui perbedaan performa dan hasil interpretasinya menggunakan pendekatan *Explainable AI*.
4. Sistem klasifikasi ini dapat dikembangkan agar tidak hanya menganalisis isi email, tetapi juga dapat mendeteksi tautan, lampiran, maupun gambar yang terdapat pada email.
5. Integrasi sistem dapat diperluas agar mendukung layanan email lain, seperti *Outlook* atau *Yahoo Mail*.

DAFTAR PUSTAKA

- Alhuzali, A., Alloqmani, A., Aljabri, M., & Alharbi, F. (2025). In-depth analysis of phishing email detection: Evaluating the performance of machine learning and deep learning models across multiple datasets. *Applied Sciences*, 15(6), 3396. doi: 10.3390/app15063396
- (APWG), A.-P. W. G. (2024). *Phishing activity trends report, 4th quarter 2023*. (Retrieved from https://docs.apwg.org/reports/apwg_trends_report.q4.2023.pdf)
- Babaei, G., & Giudici, P. (2024). Instanseshap: An instance-based estimation approach for shapley values. *Behaviormetrika*, 51, 425–439. doi: 10.1007/s41237-023-00208-z
- Bishop, C. M. (2006). *Pattern recognition and machine learning*. New York, NY, USA: Springer.
- Burges, C. J. C. (1998). A tutorial on support vector machines for pattern recognition. *Data Mining and Knowledge Discovery*, 2(2), 121–167.
- Chanis, I., & Arampatzis, A. (2025). Enhancing phishing email detection with stylometric features and classifier stacking. *International Journal of Information Security*. Retrieved from <https://link.springer.com/article/10.1007/s10207-024-00928-7>
- Chintyana, A., Kertanah, Hastuti, S. H., & Khotimah, H. (2024, December). Support vector machine-radial basis function kernel and k-nearest neighbor differences for classification superior varieties of rice in indonesia. *Euler: Jurnal Ilmiah Matematika, Sains dan Teknologi*, 12(2), 157–161. doi: 10.37905/euler.v12i2.27605
- Cloudflare, I. (2023). *2023 phishing threats report*. https://cf-assets.www.cloudflare.com/slt3lc6tev37/17i1am3UMltoOE7UOU1neX/5776ab933524b3cf99ee85eaaedc76f6/BDES-4838_2023_Phishing-Threats-Report-2023.pdf. (Diakses pada 15 Desember 2025)
- Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273–297. doi: 10.1007/BF00994018
- Desai, D., Hegde, R., Laufer, E., & Wang, J. (2023). *2023 phishing report reveals 47.2% surge in phishing attacks last year*. <https://www.zscaler.com/blogs/security-research/2023-phishing-report-reveals-47-2-surge-phishing-attacks-last-year>. (Diakses: 2025-12-15)
- Du, K.-L., Jiang, B., Lu, J., Hua, J., & Swamy, M. N. S. (2024). Exploring kernel machines and support vector machines: Principles, techniques, and future directions. *Mathematics*, 12, 3935. doi: 10.3390/math12243935
- Fan, Z., Li, W., Laskey, K. B., & Chang, K. C. (2024). Investigation of phishing susceptibility with explainable artificial intelligence. *Future Internet*, 16(1), 31. Retrieved from <https://www.mdpi.com/1999-5903/16/1/31>
- Fawcett, T. (2006). An introduction to roc analysis. *Pattern Recognition Letters*, 27(8), 861–874. doi: 10.1016/j.patrec.2005.10.010
- Hsu, C.-W., Chang, C.-C., & Lin, C.-J. (2003). *A practical guide to support vector classification* (Tech. Rep.). National Taiwan University. Retrieved from <https://www.csie.ntu.edu.tw/~cjlin/papers/guide/guide.pdf>

- (IDADX), I. A.-P. D. E. (2023). *Laporan aktivitas phishing domain .id: Periode q2 2023 (april-juni 2023)*. <https://api.idadx.id/documents/uploads/1705048370-Laporan%20Q2%202023.pdf.pdf>. (Diakses pada 15 Desember 2025)
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning: With applications in r* (2nd ed.). New York, NY: Springer. Retrieved from <https://doi.org/10.1007/978-1-0716-1418-1> doi: 10.1007/978-1-0716-1418-1
- Kaspersky. (2023). *Laporan phishing finansial di asia tenggara 2023*. Medcom.id. Retrieved from <https://www.medcom.id/teknologi/news-teknologi/Rb1DZL3N-penipuan-phishing-ramai-di-indonesia-500-ribu-insiden-pada-2023>
- Lagutina, K., Lagutina, N., Boychuk, E., Vorontsova, I., Shliakhtina, E., Belyaeva, O., & Paramonov, I. (2024). *A survey on stylometric text features*. <https://fruct.org/publications/volume-25/fruct25/files/Lag.pdf>. (Accessed: 2024-12-14)
- Lim, B., Huerta, R., Sotelo, A., Quintela, A., & Kumar, P. (2025). Explicate: Enhancing phishing detection through explainable ai and llm-powered interpretability. *arXiv preprint arXiv:2503.20796v1*. Retrieved from <https://arxiv.org/abs/2503.20796v1>
- Lin, H.-F., Lin, C.-J., & Weng, R. C. (2007). A note on platt's probabilistic outputs for support vector machines. *Machine Learning*, 68(3), 267–276. doi: 10.1007/s10994-007-5018-6
- Lundberg, S. M., Erion, G. G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., ... Lee, S.-I. (2020). From local explanations to global understanding with explainable ai for trees. *Nature Machine Intelligence*, 2(1), 56–67. doi: 10.1038/s42256-019-0138-9
- Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. In *Proceedings of the 31st international conference on neural information processing systems (nips 2017)*. Retrieved from <https://arxiv.org/abs/1705.07874> (Accessed: 2025-12-09)
- Mahor, U., & Kumar, A. (2021). A comparative study of stylometric characteristics in authorship attribution. In *Advances in data and information sciences* (pp. 97–110). Springer. Retrieved from https://link.springer.com/chapter/10.1007/978-981-19-0095-2_8 doi: 10.1007/978-981-19-0095-2_8
- Manurung, J., & Saragih, H. (2024). Performance comparison of naive bayes and support vector machine algorithms in spambot classification in emails. *International Journal of Basic and Applied Science*, 13(3), 137–145. Retrieved from <https://ijobas.pelnus.ac.id/index.php/ijobas/article/view/522>
- Michailidis, P. D. (2022). A scientometric study of the stylometric research field. *Informatics*, 9(3), 60. Retrieved from <https://doi.org/10.3390/informatics9030060> doi: 10.3390/informatics9030060
- Molnar, C. (2022). *Interpretable machine learning*. Lulu.com.
- Opara, C., Modesti, P., & Golightly, L. (2025). Evaluating spam filters and stylometric detection of ai-generated phishing emails. *Expert Systems with Applications*, 276, 127044. Retrieved from <https://doi.org/10.1016/j.eswa.2025.127044> doi: 10.1016/j.eswa.2025.127044
- Pandya, H., Zalawadia, K., & Prajapati, H. (2025). Detection of phishing websites and emails using explainable machine learning models. *Journal of Information Systems Engineering and Management*. Retrieved from <https://jisem-journal.com/index.php/journal/article/view/7545>
- Platt, J. C. (2000). Probabilistic outputs for support vector machines and comparisons

- to regularized likelihood methods. In A. J. Smola, P. Bartlett, B. Schölkopf, & D. Schuurmans (Eds.), *Advances in large margin classifiers* (pp. 61–74). Cambridge, MA: MIT Press.
- Powers, D. M. W. (2011). Evaluation: From precision, recall and f-measure to roc, informedness, markedness & correlation. *Journal of Machine Learning Technologies*, 2(1), 37–63.
- Proofpoint. (2023). *Phishing: Understanding the threat*. Retrieved from <https://www.proofpoint.com/phishing> (Accessed: 2023-12-09)
- Raghavendra, S. (2023). *Beginner's guide to streamlit with python: Build web-based data and machine learning applications*. Springer. Retrieved from <https://link.springer.com/content/pdf/10.1007/978-1-4842-8983-9.pdf>
- Rumini, N., Mustofa, A., & Pradana, S. (2023). Perbandingan pengujian deteksi phishing menggunakan metode svm dengan kernel rbf dan linear. *SISTEMASI: Jurnal Sistem Informasi*, 12(3), 754–759. Retrieved from <https://sistemasi.ftik.unisi.ac.id>
- Santos, J. I., Pereda, M., Ahedo, V., & Galán, J. M. (2023). Explainable machine learning for project management control. *Computers & Industrial Engineering*, 180, 109261. doi: 10.1016/j.cie.2023.109261
- Sarker, M. A. U., & Uddin, M. (2024). An explainable transformer-based model for phishing email detection: A large language model approach. *arXiv*. Retrieved from <https://arxiv.org/abs/2402.13871>
- Scikit-learn Developers. (2026). *StandardScaler — scikit-learn 1.9.0 documentation*. <https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html>. (Accessed: 2026-07-26)
- Scikit-learn Documentation. (2025). *confusion_matrix — scikit-learn 1.8.0 documentation*. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.confusion_matrix.html. (Accessed: 27 May 2026)
- SHAP Developers. (2024). *Shap documentation*. <https://shap.readthedocs.io>.
- Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing and Management*, 45(4), 427–437. doi: 10.1016/j.ipm.2009.03.002
- Streamlit. (2025). *Streamlit documentation*. Retrieved from <https://docs.streamlit.io/> (Diakses pada 30 Juni 2026)
- Tanjung, R. N. F., & Rahman, S. (2025). Meningkatkan deteksi email phishing melalui pendekatan svm yang dioptimalkan nlp. *INCODING: Journal of Informatic and Computer Science Engineering*, 5(1), 38–50. Retrieved from <https://journal.mahesacenter.org/index.php/incoding>
- Wosah, P. N., Mirza, Q. A., & Sayers, W. (2024). Analysing the email data using stylometric method and deep learning to mitigate phishing attack. *International Journal of Information Technology*. Retrieved from <https://link.springer.com/article/10.1007/s41870-024-01839-5>

DAFTAR LAMPIRAN

Lampiran 1 Contoh Email dari Dataset Kaggle

Dataset utama yang digunakan dalam penelitian ini berjumlah 82.486 email yang terdiri atas kategori *phishing* dan *legitimate*. Karena jumlah data yang cukup besar, lampiran ini hanya menampilkan beberapa contoh email dari dataset yang digunakan.

No	Kategori	Cuplikan Isi Email
1	<i>Phishing</i>	extrahomecashworldonlinecoza happybe really healthy httpkumedi-calcoedscom wed 06 aug 2008 182429 0200 quiet prices must products
2	<i>Phishing</i>	perscription needed order pills site trying defend everything defended nothing pleasure squire found best simpliest site medication net perscription easy delivery private secure easy...
3	<i>Phishing</i>	delaney nancy samil1550samilentercom omifrhpf found document wed 06 aug 2008 151451 0000 congratulations
4	<i>Phishing</i>	iggie symult adminmicrosoftcom click picture download mailing receiving email subscribed msn featured offers microsoft respects privacy...
5	<i>Phishing</i>	walter finn walterjuforumde based recent scientific developments formula gives proven amazing results overreach nature help httpdearbrightcom...
6	<i>Phishing</i>	marilyn pratt dwterrachordmterrachordcom get original perfectly functioning software low prices software downloaded immediately purchase...
7	<i>Phishing</i>	lori winter beverlyfrillydaileytimeblogcom 2 pills day incredible quick gains length thickness gains permanent results guaranteed money back...
8	<i>Phishing</i>	interesting products intr0519cbkru astounding new software lets find almost anything anyone <i>clickdownloadrightchargecardneededownload...</i>
9	<i>Phishing</i>	networkers mail center hittingitonthehead36yahoocouk dear friends future millionaire invest technology make money seen national tv make half...

10	<i>Phishing</i>	jen normavemlaniftynejp urgent noticepending merger increase revenue 236now time invest gwihgwih rapidly expanding acquisitions the 1st quarter...
11	<i>Legitimate</i>	txu fuels sds nomination may 2001 attached may 2001 nomination takes gas sales purchase contract txu fuel company previously tufco sds please advise questions concerning attached thanks
12	<i>Legitimate</i>	intra inter gisb keith would please forward intra inter gisb enron dfarmer enron com interested please forward pertinent information thanks lynn
13	<i>Legitimate</i>	article powerits online trading platform please find attached article european electricity report september 3 2001 kind regards sarimah black
14	<i>Legitimate</i>	unify unix team working unix server unify production runs proton went morning unix team working let know soon unify available n
15	<i>Legitimate</i>	nominations agree eileen ponton 05 22 2001 10 56 54 melissa jones texas utilities tu cc subject nominations measurement check...
16	<i>Legitimate</i>	real time deal updates path manager test group beginning week actively testing changes path manager receive real time deal updates sitara prepare would like limited group schedulers desk go thru quick...
17	<i>Legitimate</i>	change form request louise seung taek oh working head real time markets ercot two year associate would eligible promotion manager also ubs...
18	<i>Legitimate</i>	update quick summary going sure quick going enrononline offering products exchanges houstonstreet true quote going offer specific products various...
19	<i>Legitimate</i>	operations pricing model sally shari would like schedule hour time 3 00 pm 4 00 pm wednesday october 25 2000 time shari present september...
20	<i>Legitimate</i>	cegm management summary hot list 10 4 attached initial 4 q management summary activity 10 4 week hot list please give call questions concerns...
...		...

Lampiran 2

Contoh Email *Phishing* dari DPTSI ITS

Data tambahan yang digunakan pada tahap pengujian implementasi sistem ini merupakan data email *phishing* yang diperoleh dari DPTSI ITS dengan jumlah 200 email. Karena jumlah data yang cukup banyak, lampiran ini hanya menampilkan beberapa contoh email yang digunakan sebagai representasi data pengujian.

No	Cuplikan Isi Email
1	There is two hundred and fifty million U S D investment project funds transfer capital that shall benefit us should you choose to participate. Sincerely Yours, Sheikh Ahmad Moaz Al Katibal.
2	On behalf of 3rd Edition Global Summit on Materials Science & Nanoscience, we are delighted to invite you as an Invited Speaker at our conference in Paris, France...
3	Greetings from the Editorial Office. We are delighted to announce a Call for Papers for our upcoming Special Issue entitled "Current Research, Treatments, and Challenges in Cardiology and Cardiovascular Diseases"...
4	On behalf of the organizing committee, I am delighted to invite you to deliver a speech at the 6th World Biological Science and Technology Conference (BioST 2026). The conference will be held...
5	It gives me immense pleasure to cordially invite you as a Keynote Speaker at the 2nd International Connect & Expo on Materials Science and Engineering (MATERIALSCONNECT2026), which will be held during April 20-22...
6	We are pleased to invite you to consider Exploratory Materials Science Research (EMSR) as a publication venue for your current or forthcoming research work. EMSR is an international, peer-reviewed journal...
7	If you're evaluating your next move in tech, this might be worth reviewing. Structured training. Practical internship. Clear career direction. Here's the program: https://www.refontelearning.com/study-and-internship/data-engineering-program...
8	We are delighted to extend an invitation for you to submit an article for the forthcoming issue of Annals of Clinical and Medical Case Reports (ISSN 2639-8109). We understand that due to your professional obligations...
9	I hope this message finds you well. My name is Philip Franklin, representing WWD Consulting Ltd, a globally recognized financial advisory firm with deep-rooted partnerships across Europe and the Gulf. We manage and advise on an active investment portfolio exceeding USD 5 billion...

10	We recently came across your published research work entitled “In vitro propagation of Indonesian stevia (<i>Stevia rebaudiana</i>) genotype using axenic nodal segments.,” and we were impressed by...
11	Can I expect your article towards publication in our COJ Reviews & Research Journal, as we are in deficit of one article to accomplish Volume 5, Issue 1. Is it possible to you to support us with your article?...
12	I noticed your work “An Advanced Empirical NRCS-CN Model Estimation for Ungauged Catchment Insufficient Data” which involves modeling and analysis. In this context, I think that ndCurveMaster could serve as an alternative...
13	Hope this email finds you well. On behalf of the Editor-in-Chief, I cordially invite you to submit your excellent research work to our Journal. JIPD is an international peer-reviewed journal that publishes high-quality research...
14	This is the mail system at host cancer.its.ac.id. I’m sorry to have to inform you that your message could not be delivered to one or more recipients. It’s attached below....
15	Greetings from organizing committee of ICE-2026. I’m writing to follow-up my previous invitation as below. Could you give me a tentative reply? Thank you very much. This is Liu, and I serve as the coordinator for ICE event....
...	...

Lampiran 3

Hasil Ekstraksi Fitur *Stylometric*

Lampiran ini menampilkan sebagian hasil ekstraksi fitur *stylometric* dari dataset penelitian. Proses ekstraksi menghasilkan dataset numerik sebanyak 82.486 data dengan 60 fitur. Karena ukuran data yang sangat besar, hanya 30 baris pertama ditampilkan, sedangkan data lengkap digunakan pada proses pelatihan dan evaluasi model.

No	word_count	char_count	avg_word_length	unique_word_count	lexical_diversity	bigram_count	...	Label
1	14	65	3.7143	11	0.7857	11	...	0
2	208	1071	4.1538	99	0.4760	142	...	0
3	28	148	4.3214	18	0.6429	22	...	0
4	14	65	3.7143	11	0.7857	11	...	0
5	14	65	3.7143	11	0.7857	10	...	0
6	14	65	3.7143	11	0.7857	11	...	0
7	57	313	4.5088	49	0.8596	52	...	0
8	14	69	4.0000	11	0.7857	11	...	0
9	34	215	5.3529	27	0.7941	27	...	0
10	14	65	3.7143	11	0.7857	11	...	0
11	56	370	5.6250	37	0.6607	43	...	0
12	15	75	4.0667	12	0.8000	11	...	0
13	15	68	3.6000	12	0.8000	12	...	0
14	20	92	3.6500	16	0.8000	19	...	0
15	27	146	4.4444	20	0.7407	23	...	0
16	13	64	4.0000	10	0.7692	10	...	0
17	28	136	3.8929	28	1.0000	23	...	0
18	108	530	3.9167	80	0.7407	93	...	0
19	108	530	3.9167	80	0.7407	93	...	0
20	14	67	3.8571	11	0.7857	11	...	0
21	15	93	5.2667	12	0.8000	12	...	0
22	49	227	3.6531	35	0.7143	37	...	0
23	22	127	4.8182	17	0.7727	19	...	0
24	22	127	4.8182	17	0.7727	19	...	0
25	14	67	3.8571	11	0.7857	11	...	0
26	27	136	4.0741	15	0.5556	16	...	0
27	75	458	5.1200	57	0.7600	69	...	0
28	82	395	3.8293	56	0.6829	59	...	0
29	82	395	3.8293	56	0.6829	59	...	0
30	14	67	3.8571	11	0.7857	11	...	0
...	...	...	...	...	...	...	...	...
82486	...	...	...	...	...	...	...	...

Lampiran 4

Contoh Data Hasil Normalisasi

No	word_count	char_count	avg_word_length	unique_word_count	lexical_diversity	bigram_count	stopword_ratio	...	Label
1	-0.2526	-0.0716	-1.1160	-0.3302	-0.1075	-0.3123	0.0000	...	0
2	0.0817	-0.0133	-0.9458	-0.0202	-2.1732	0.0210	0.0000	...	0
3	-0.2285	-0.0667	-0.8809	-0.3056	-1.0602	-0.2843	0.0000	...	0
4	-0.2526	-0.0716	-1.1160	-0.3302	-0.1075	-0.3123	0.0000	...	0
5	-0.2526	-0.0716	-1.1160	-0.3302	-0.1075	-0.3148	0.0000	...	0
6	-0.2526	-0.0716	-1.1160	-0.3302	-0.1075	-0.3123	0.0000	...	0
7	-0.1785	-0.0572	-0.8084	-0.1964	0.3855	-0.2080	0.0000	...	0
8	-0.2526	-0.0713	-1.0054	-0.3302	-0.1075	-0.3123	0.0000	...	0
9	-0.2181	-0.0629	-0.4815	-0.2739	-0.0515	-0.2716	0.0000	...	0
10	-0.2526	-0.0716	-1.1160	-0.3302	-0.1075	-0.3123	0.0000	...	0
11	-0.1802	-0.0539	-0.3761	-0.2386	-0.9411	-0.2308	0.0000	...	0
12	-0.2509	-0.0710	-0.9795	-0.3267	-0.0123	-0.3123	0.0000	...	0
13	-0.2509	-0.0714	-1.1603	-0.3267	-0.0123	-0.3097	0.0000	...	0
14	-0.2422	-0.0700	-1.1409	-0.3126	-0.0123	-0.2919	0.0000	...	0
15	-0.2302	-0.0669	-0.8333	-0.2985	-0.4074	-0.2817	0.0000	...	0
16	-0.2543	-0.0716	-1.0054	-0.3338	-0.2174	-0.3148	0.0000	...	0
17	-0.2285	-0.0674	-1.0469	-0.2703	1.3215	-0.2817	0.0000	...	0
18	-0.0906	-0.0446	-1.0376	-0.0872	-0.4074	-0.1036	0.0000	...	0
19	-0.0906	-0.0446	-1.0376	-0.0872	-0.4074	-0.1036	0.0000	...	0
20	-0.2526	-0.0714	-1.0607	-0.3302	-0.1075	-0.3123	0.0000	...	0
21	-0.2509	-0.0699	-0.5149	-0.3267	-0.0123	-0.3097	0.0000	...	0
22	-0.1923	-0.0622	-1.1397	-0.2457	-0.5839	-0.2461	0.0000	...	0
23	-0.2388	-0.0680	-0.6885	-0.3091	-0.1941	-0.2919	0.0000	...	0
24	-0.2388	-0.0680	-0.6885	-0.3091	-0.1941	-0.2919	0.0000	...	0
25	-0.2526	-0.0714	-1.0607	-0.3302	-0.1075	-0.3123	0.0000	...	0
26	-0.2302	-0.0674	-0.9767	-0.3161	-1.6424	-0.2995	0.0000	...	0
27	-0.1475	-0.0488	-0.5717	-0.1682	-0.2790	-0.1647	0.0000	...	0
28	-0.1354	-0.0524	-1.0715	-0.1717	-0.7930	-0.1901	0.0000	...	0
29	-0.1354	-0.0524	-1.0715	-0.1717	-0.7930	-0.1901	0.0000	...	0
30	-0.2526	-0.0714	-1.0607	-0.3302	-0.1075	-0.3123	0.0000	...	0
31	-0.1733	-0.0585	-1.0570	-0.2105	-0.3457	-0.2156	0.0000	...	0
32	-0.1733	-0.0585	-1.0570	-0.2105	-0.3457	-0.2156	0.0000	...	0
33	0.0283	-0.0130	-0.5875	-0.0343	-1.7680	0.0108	0.0000	...	0
34	-0.2526	-0.0714	-1.0607	-0.3302	-0.1075	-0.3123	0.0000	...	0
35	-0.2526	-0.0715	-1.0883	-0.3302	-0.1075	-0.3148	0.0000	...	0
36	-0.1733	-0.0580	-1.0054	-0.2034	-0.1234	-0.2156	0.0000	...	0
37	-0.1733	-0.0580	-1.0054	-0.2034	-0.1234	-0.2156	0.0000	...	0
38	-0.0734	-0.0372	-0.7789	-0.1330	-1.5607	-0.1393	0.0000	...	0
39	-0.1733	-0.0580	-1.0054	-0.1999	-0.0123	-0.2156	0.0000	...	0
40	-0.1733	-0.0580	-1.0054	-0.1999	-0.0123	-0.2156	0.0000	...	0
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
82486	...	...	...	...	...	...	...	...	...

Lampiran 5

Contoh Data *Support Vector*

No	word_count	char_count	avg_word_length	unique_word_count	lexical_diversity	bigram_count	stopword_ratio	...
1	-0.2422	-0.0647	0.6210	-0.2985	1.3215	-0.2919	0.0000	...
2	0.0834	0.0029	-0.4403	0.1278	-0.8482	0.1304	0.0000	...
3	-0.1578	-0.0434	0.1507	-0.1365	1.0315	-0.1723	0.0000	...
4	-0.1354	-0.0383	0.0760	-0.1823	-1.0370	-0.1749	0.0000	...
5	-0.1130	-0.0327	0.0585	-0.0942	0.1281	-0.1113	0.0000	...
6	-0.2216	-0.0643	-0.6302	-0.2668	0.6963	-0.2665	0.0000	...
7	0.0179	0.0329	1.2908	0.0925	-0.2384	0.0617	0.0000	...
8	0.2557	0.0427	-0.3876	0.2933	-1.2899	0.2144	0.0000	...
9	-0.1009	-0.0265	0.2588	-0.0801	0.0139	-0.0960	0.0000	...
10	1.2034	0.3426	0.3100	1.2516	-1.7761	1.3109	0.0000	...
11	-0.1681	-0.0447	0.3100	-0.1611	0.8981	-0.2029	0.0000	...
12	-0.0355	-0.0246	-0.5158	-0.0237	-0.6791	-0.0146	0.0000	...
13	0.0490	0.0041	-0.1326	0.1348	-0.3016	0.0999	0.0000	...
14	0.8984	0.1714	-0.5233	0.6456	-2.5311	0.8122	0.0000	...
15	-0.1923	-0.0539	-0.0097	-0.2175	0.5049	-0.2283	0.0000	...
16	-0.1905	-0.0556	-0.2929	-0.2246	0.1211	-0.2283	0.0000	...
17	-0.2646	-0.0729	-0.6181	-0.3443	1.3215	-0.3275	0.0000	...
18	-0.1854	-0.0479	0.5289	-0.2175	0.0632	-0.2156	0.0000	...
19	-0.0751	-0.0334	-0.5453	-0.0484	-0.1604	-0.0655	0.0000	...
20	0.2075	0.0460	-0.0545	0.3567	-0.4584	0.3441	0.0000	...
21	-0.2285	-0.0632	-0.0373	-0.2774	0.8452	-0.2741	0.0000	...
22	0.4022	0.0759	-0.3764	0.4589	-1.3697	0.5120	0.0000	...
23	0.0817	-0.0017	-0.5735	0.0185	-1.8205	0.0236	0.0000	...
24	-0.1440	-0.0477	-0.5427	-0.1717	-0.4972	-0.1851	0.0000	...
25	-0.1664	-0.0534	-0.6484	-0.1999	-0.3457	-0.1876	0.0000	...
26	-0.1733	-0.0530	-0.4503	-0.2492	-1.5683	-0.2334	0.0000	...
27	-0.2371	-0.0665	-0.3656	-0.2950	0.7416	-0.2843	0.0000	...
28	-0.2233	-0.0592	0.5435	-0.2668	0.8912	-0.2639	0.0000	...
29	1.6548	0.4442	0.1556	1.2410	-2.6286	1.6034	0.0000	...
30	-0.1716	-0.0525	-0.4404	-0.1788	0.5562	-0.1952	0.0000	...
31	-0.2509	-0.0695	-0.3342	-0.3161	1.3215	-0.3046	0.0000	...
32	-0.2285	-0.0644	-0.3139	-0.2880	0.1306	-0.2741	0.0000	...
33	-0.0648	-0.0268	-0.3033	-0.0872	-1.0098	-0.0807	0.0000	...
34	-0.2112	-0.0626	-0.6997	-0.2492	0.6195	-0.2512	0.0000	...
35	-0.0337	-0.0145	-0.0579	0.0256	-0.0501	0.0007	0.0000	...
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
19351	...	...	...	...	...	...	...	...

Lampiran 6

Data Sampel Analisis SHAP

Lampiran ini menampilkan seluruh sampel yang digunakan pada analisis interpretabilitas model menggunakan SHAP. Sampel dipilih dari beberapa kategori hasil prediksi, yaitu *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), serta *False Negative* (FN).


Row ID	Prediksi	Probabilitas	Label Aktual	Status	Kategori XAI
82431	Phishing	1.000000	Phishing	Benar	TP
82426	Phishing	1.000000	Phishing	Benar	TP
3548	Phishing	1.000000	Phishing	Benar	TP
75681	Legitimate	0.000000	Legitimate	Benar	TN
63039	Legitimate	0.000000	Legitimate	Benar	TN
73069	Legitimate	0.000000	Legitimate	Benar	TN
13886	Phishing	1.000000	Legitimate	Salah	FP
74915	Phishing	1.000000	Legitimate	Salah	FP
75904	Legitimate	0.000002	Phishing	Salah	FN
77320	Legitimate	0.000038	Phishing	Salah	FN

Lampiran 7


Visualisasi SHAP Lokal dari Data Sampel Analisis

Lampiran ini menyajikan visualisasi SHAP lokal secara lengkap untuk seluruh sampel yang dipilih pada analisis interpretabilitas model. Visualisasi ini merupakan dokumentasi pendukung dari analisis SHAP lokal yang telah dibahas pada Bab 4.


1. Visualisasi SHAP Lokal untuk Kategori *True Positive* (TP)



Sampel TP (Row ID 82431)




Sampel TP (Row ID 82426)




Sampel TP (Row ID 3548)


2. Visualisasi SHAP Lokal untuk Kategori *True Negative* (TN)



Sampel TN (Row ID 75681)




Sampel TN (Row ID 63039)




Sampel TN (Row ID 73069)

3. Visualisasi SHAP Lokal untuk Kategori *False Positive* (FP)




Sampel FP (Row ID 13886)




Sampel FP (Row ID 74915)

4. Visualisasi SHAP Lokal untuk Kategori *False Negative* (FN)



Sampel FN (Row ID 75904)



Sampel FN (Row ID 77320)

Lampiran 8

Repository GitHub

Source code, model, serta berkas implementasi sistem pada penelitian ini disimpan dan dipublikasikan melalui *repository* GitHub. Repository tersebut memuat kode program untuk *preprocessing*, ekstraksi fitur *stylometric*, pelatihan model SVM, kalibrasi probabilitas menggunakan *Platt Scaling*, interpretasi model menggunakan SHAP, serta implementasi aplikasi berbasis web.

Repository GitHub dapat diakses melalui tautan berikut:

<https://github.com/lintangsyawalani/StylDetect>

UCAPAN TERIMA KASIH

Dengan memanjatkan puji syukur kehadirat Allah SWT atas rahmat, taufik, dan hidayah-nya sehingga penulis dapat menyelesaikan tugas akhir dengan judul:

*"SISTEM KLASIFIKASI EMAIL PHISHING BERBASIS FITUR STYLOMETRIC
DENGAN SUPPORT VECTOR MACHINE DAN SHAPLEY ADDITIVE
EXPLANATIONS"*

sebagai salah satu persyaratan akademis dalam menyelesaikan Program Sarjana Departemen Matematika, Fakultas Sains dan Analitika Data, Institut Teknologi Sepuluh Nopember Surabaya. Penulis menyadari tugas Akhir ini dapat diselesaikan dengan baik dukungan, bantuan, dan nasihat dari berbagai pihak. Pada kesempatan ini, penulis ingin mengucapkan terima kasih dan penghargaan kepada:

1. Tuhan Yang Maha Esa atas rahmat, karunia, dan penyertaan-Nya sehingga penelitian ini dapat diselesaikan dengan baik.
2. Orang tua penulis yang senantiasa mendoakan dan memberikan dukungan penuh terhadap penulis untuk menyelesaikan Tugas Akhir ini.
3. Departemen Matematika, Institut Teknologi Sepuluh Nopember atas dukungan akademik, penyediaan fasilitas, dan lingkungan belajar yang mendukung selama masa perkuliahan.
4. Dosen pembimbing Bapak Prof. Dr. techn. Drs. Mohammad Isa Irawan, MT. selaku dosen pembimbing yang telah membantu dan memberikan arahan, serta motivasi kepada penulis.
5. Bapak/Ibu dosen pengajar, yang telah memberikan ilmu dan pengalaman yang bermanfaat, serta seluruh Karyawan, Tendik dan keluarga besar Departemen Matematika Institut Teknologi Sepuluh Nopember atas dukungan dan bantuannya.
6. Kepada Fariduddin Attar, terima kasih atas dukungan, bantuan, dan semangat yang selalu diberikan selama proses penyusunan skripsi ini hingga dapat terselesaikan dengan baik.
7. Alvian, Cinta, Eva, Icha, Irliane, Arin, Novita, dan Santi yang telah kebersamaan selama masa perkuliahan.
8. Semua pihak yang tidak dapat Penulis sebutkan satu per satu yang telah memberikan bantuan, baik secara langsung maupun tidak langsung, sehingga perkuliahan dan penelitian Tugas Akhir saya dapat diselesaikan dengan baik.

Penulis mengharapkan saran dan kritik dari pembaca. Akhir kata, semoga Tugas Akhir ini bermanfaat bagi semua pihak yang membacanya.

Surabaya, 31 Juli 2026

Lintang Syawalani Hawa Ningrum

BIODATA PENULIS



Penulis bernama Lintang Syawalani Hawa Ningrum, lahir di Wonogiri pada 1 Desember 2003. Penulis menempuh pendidikan dasar hingga menengah sebelum melanjutkan studi di Departemen Matematika, Fakultas Sains dan Analitika Data, Institut Teknologi Sepuluh Nopember (ITS), Surabaya. Selama menjadi mahasiswa, penulis aktif mengikuti berbagai kegiatan organisasi dan kepanitiaan untuk mengembangkan kemampuan diri serta menambah pengalaman. Selain itu, penulis juga memiliki ketertarikan pada bidang analisis data, *machine learning*, dan kecerdasan buatan (*artificial intelligence*). Ketertarikan tersebut mendorong penulis untuk mempelajari berbagai metode pengolahan data dan membangun sistem berbasis *machine learning*. Pada tugas akhir ini, penulis melakukan penelitian mengenai klasifikasi email *phishing* menggunakan fitur *stylometric* dengan metode *Support Vector Machine* (SVM) dan *Shapley Additive Explanations* (SHAP). Setelah menyelesaikan pendidikan sarjana, penulis berharap dapat mengembangkan karier di bidang *data analyst* dan terus meningkatkan kemampuan di bidang *data science* serta teknologi informasi. Demikian biodata singkat penulis. Apabila pembaca ingin memberikan saran, masukan, atau berdiskusi lebih lanjut mengenai tugas akhir ini, penulis dapat dihubungi melalui email: syawalanilintang@gmail.com